

TÍCH HỢP DỮ LIỆU PHÂN CẤP VÀO MÔ HÌNH HỌC MÁY

Trình bày: Nguyễn Thế Thành
Nam

Mục lục

- Tổng quan về đề tài
- Dữ liệu sử dụng
- Phân cấp thể loại (Hierarchical Genres)
- Tiền xử lý cho Machine Learning
- Kịch bản thực nghiệm
- Kết quả thực nghiệm
- Nhận xét & phân tích
- Kết luận
- Hướng phát triển
- Hỏi đáp

Tổng quan về đề tài

Mục tiêu tổng quát:

- Xây dựng và đánh giá một phương pháp tích hợp thông tin phân cấp thể loại phim (hierarchical genres) vào các mô hình học máy truyền thống (machine learning) nhằm cải thiện chất lượng dự đoán gợi ý trên bộ dữ liệu MovieLens 20M.

Mục tiêu cụ thể:

- Phân tích và chuẩn hóa dữ liệu
- Xây dựng các dạng phân cấp để so sánh
- Huấn luyện và đánh giá mô hình Machine Learning
- Phân tích kết quả & xác định mức phân cấp tối ưu

Dữ liệu sử dụng

Giới thiệu về MovieLens 20M

- “MovieLens 20M gồm:
- **20 triệu lượt rating** của người dùng,
- hơn **138.000 người dùng**,
- và khoảng **27.000 bộ phim**.
- Dữ liệu được thu thập từ hệ thống đề xuất phim của MovieLens.”

Dữ liệu sử dụng

Trường dữ liệu	Ý nghĩa	Ghi chú
userId	Mã hóa người dùng	Dùng để nhận diện từng user duy nhất
movieId	Mã hóa phim	Dùng để ghép thông tin phim và rating
rating	Điểm đánh giá từ 0.5 → 5.0	Được chuyển thành dạng nhị phân ($\geq 3.5 \rightarrow 1$)
genres	Chuỗi thể loại của phim	Có thể gồm nhiều cấp, ví dụ: Action Sci-Fi Adventure

Dữ liệu được tiền xử lý qua một số bước:

- **Chuẩn hóa rating**: chuyển thành nhị phân, điểm ≥ 3.5 được xem là thích (1), còn lại là không thích (0).
- **Label Encoding** cho userId, movieId và các mức thể loại để đưa vào mô hình ML.
- **Gộp bảng ratings và movies** để tạo dataset hoàn chỉnh dùng cho huấn luyện.”

Phân cấp thể loại (Hierarchical Genres)

Cấu trúc thể loại gốc:

- Trường genres trong MovieLens là một chuỗi gồm nhiều thể loại
 - ví dụ: Action | Sci-Fi | SpaceAdventure | ComedyDrama | Romance
 - Điều này cho thấy các phim thường có nhiều thể loại và các thể loại có quan hệ phân cấp rõ ràng.”

Tách thành các cấp phân cấp:

- main_genre → thể loại cha
- sub_genre → thể loại con thứ nhất
- child_0, child_1, child_2... → các thể loại con sâu hơn

Việc tách nhiều cấp giúp mô hình hiểu rõ hơn nội dung phim.”

Phân cấp thể loại (Hierarchical Genres)

Xây dựng 3 dạng phân cấp để so sánh:

- **Flat**
 - Không sử dụng phân cấp
 - Chỉ dùng user và movie
 - Đây là baseline để so sánh
- **1 cha + 1 con**
 - Sử dụng main_genre và sub_genre
 - Thể hiện mức phân cấp đơn giản
- **cha + nhiều con**
 - Sử dụng main_genre và toàn bộ child_n
 - Đây là mức phân cấp đầy đủ nhất

TIỀN XỬ LÝ CHO MACHINE LEARNING

- Chuẩn hóa nhãn (Label Transformation)
 - Rating ≥ 3.5 được xem là thích (1)
 - Rating < 3.5 được xem là không thích (0)
- Mã hóa danh mục (Label Encoding)
 - userId
 - movieId
 - main_genre
 - child_genres
- Tách phân cấp thể loại thành nhiều biến
 - main_genre – thể loại cha
 - sub_genre – thể loại con cấp 1
 - child_0, child_1, child_2... – các cấp con sâu hơn

TIỀN XỬ LÝ CHO MACHINE LEARNING

- Sinh biến đặc trưng (Feature Engineering)
 - Ghép bảng ratings và movies
 - Loại bỏ các trường không cần thiết
 - Tạo dataset dạng hàng (user, movie, các cấp thể loại, nhãn)”
- Chia tập train–test
 - 80% train
 - 20% test,

Kịch bản thực nghiệm

- **Flat (Không phân cấp)**

Mô hình chỉ dựa trên các đặc trưng đơn giản như:

- user_idx
- movie_idx

Đây là setting được dùng làm baseline để so sánh.

- **1 Cha + 1 Con (Two-Level Hierarchy)**

- Đưa vào mô hình main_genre và sub_genre

Chỉ sử dụng hai tầng phân cấp đầu tiên, nhằm kiểm tra mức phân cấp đơn giản có mang lại cải thiện hay không.

- **1 Cha + Nhiều Con (Full Hierarchy)**

- Sử dụng tất cả các thể loại con, bao gồm child_0, child_1, child_2,...

Đây là mức phân cấp đầy đủ nhất, thể hiện toàn bộ thông tin hierarchy trong trường genres.

Kết quả thực nghiệm

- Flat (Không phân cấp)

Mô hình	Accuracy	F1-score
Logistic Regression	0.5141	0.5894
XGBoost	0.6384	0.6292
LightGBM	0.6486	0.6388

Kết quả thực nghiệm

- 1 Cha + 1 Con

Mô hình	Accuracy	F1-score
Logistic Regression	0.5393	0.5228
XGBoost	0.6636	0.6629
LightGBM	0.6637	0.6617

Kết quả thực nghiệm


- 1 Cha + Nhiều Con

Mô hình	Accuracy	F1-score
Logistic Regression	0.5589	0.5543
XGBoost	0.6642	0.6642
LightGBM	0.6646	0.6641


Mô hình	Flat	1 Cha + 1 Con	1 Cha + Nhiều Con
Logistic Regression (F1)	0.5894	0.5228	0.5543
XGBoost (F1)	0.6292	0.6629	0.6642
LightGBM (F1)	0.6388	0.6617	0.6641

Kết quả thực nghiệm

So sánh F1: Flat vs Hier 1 con vs Hier nhiều con



Kết quả thực nghiệm



Nhận xét & phân tích

So sánh giữa Flat và dữ liệu phân cấp

- “Thứ nhất, kết quả cho thấy **cả XGBoost và LightGBM đều cải thiện hiệu suất** khi thêm thông tin phân cấp của genres.
- Ở setting Flat, F1-score của LightGBM chỉ khoảng **0.6388**
- Nhưng khi thêm phân cấp, F1-score tăng lên **0.6617** và **0.6641**
- Điều này chứng minh rằng **thể loại phân cấp cung cấp thêm ngữ nghĩa nội dung phim mà mô hình có thể khai thác**, từ đó cải thiện khả năng dự đoán.

Nhận xét & phân tích

So sánh: 1 Cha + 1 Con vs 1 Cha + Nhiều Con

- “Giữa hai mức phân cấp:
- **1 cha + 1 con:** $F1 \sim 0.6617$
- **1 cha + nhiều con:** $F1 \sim 0.6641$
- Sự cải thiện tuy không lớn nhưng **ổn định và nhất quán trên cả XGBoost và LightGBM.**
- Điều này cho thấy rằng **mức độ phân cấp sâu hơn giúp mô hình học được nhiều đặc điểm chi tiết hơn của từng bộ phim.**

Nhận xét & phân tích

So sánh giữa các mô hình ML

Xét giữa các mô hình:

- **Logistic Regression** luôn cho kết quả thấp nhất → vì đây là mô hình tuyến tính, không phù hợp với dữ liệu phức tạp.
- **XGBoost** và **LightGBM** đều khai thác tốt dữ liệu phân cấp.
- **LightGBM** nhanh hơn một chút và là mô hình có kết quả **cao nhất** trong tất cả các setting.
- Do đó, **LightGBM** là mô hình phù hợp nhất cho đề tài này.

Nhận xét & phân tích

Tóm lại:

- Thêm phân cấp genres luôn giúp mô hình dự đoán tốt hơn.
- Càng nhiều cấp phân loại → mô hình càng hiệu quả.
- LightGBM + Setting 1 cha nhiều con cho hiệu suất tốt nhất, đạt F1 gần 0.664.
- Điều này chứng minh rằng việc tích hợp dữ liệu phân cấp thực sự giúp nâng cao chất lượng hệ gợi ý ngay cả khi chỉ dùng các mô hình học máy đơn giản.

Kết luận

- Phân cấp thể loại giúp tăng hiệu quả mô hình
 - Việc tách genres thành nhiều cấp (cha – con – nhiều con) giúp mô hình học được nhiều thông tin hơn về nội dung phim.
 - Kết quả thực nghiệm cho thấy cả Accuracy và F1-score đều tăng so với setting Flat.
- Mức phân cấp sâu mang lại kết quả tốt nhất
 - Flat
 - 1 cha + 1 con
 - 1 cha + nhiều con

Thì setting 1 cha + nhiều con cho hiệu suất cao nhất, đạt F1 khoảng 0.664 với LightGBM.

- Mô hình tree-based phù hợp nhất
 - LightGBM có kết quả cao nhất, chứng tỏ mô hình tree-based là lựa chọn phù hợp cho dạng dữ liệu này

HƯỚNG PHÁT TRIỂN

- Áp dụng thêm mô hình khác: CatBoost
 - CatBoost xử lý dữ liệu phân loại rất tốt và có thể mang lại hiệu suất cao hơn LightGBM trong dữ liệu phân cấp
- Sử dụng mô hình Deep Learning

Có thể mở rộng sang:

- VAE (Variational Autoencoder)
- Neural Collaborative Filtering

Hoặc các mô hình embedding học sâu để học representation của user và movie tốt hơn

HƯỚNG PHÁT TRIỂN

- Tối ưu tham số nâng cao

Áp dụng:

- Bayesian Optimization
- Optuna
- Grid/Random Search để tìm bộ tham số tối ưu cho LightGBM và XGBoost
- Mở rộng sang dữ liệu E-commerce thực tế
 - Áp dụng phương pháp phân cấp này cho các hệ thống gợi ý sản phẩm (Shopee, Tiki), nơi taxonomy thường có nhiều cấp cha – con – cháu và rất phù hợp với hướng tiếp cận của đề tài