

Ứng dụng Topic modeling để tạo phân loại chủ đề cho gợi ý

Hoang Van Tai



Mục lục

1. Giới thiệu
2. Mục đích
3. Nội dung
4. Kết quả




Giới thiệu về Topic Modeling

Là một kỹ thuật trong xử lý ngôn ngữ tự nhiên (NLP), dùng để tự động phát hiện các chủ đề ẩn (topics) có trong một tập hợp văn bản lớn mà không cần gán nhãn trước.

- Nhóm các văn bản giống nhau vào một chủ đề
- Tự động tìm ra những từ khóa quan trọng đại diện cho từng chủ đề
- Cho biết mỗi văn bản thuộc chủ đề nào



MỤC ĐÍCH



Đầu vào: Collection of Text Documents: Đây là dữ liệu thô bạn đưa vào: hàng nghìn, hàng chục nghìn bài báo, đánh giá khách hàng, tweet, comment...

Topic Modelling: Thuật toán (LDA, BERTopic, NMF...) sẽ “đọc” toàn bộ dữ liệu và tự động tìm ra các chủ đề ẩn mà không cần con người chỉ bảo

Cluster of Word by Topic (Nhóm các từ theo chủ đề):

-> Kết quả: Máy tự nhóm các từ hay xuất hiện cùng nhau thành một chủ đề.

Cluster of Document by Topic (Nhóm các tài liệu theo chủ đề)

- Mỗi thanh ngang = 1 tài liệu (một bài báo, một đánh giá...).
- Mỗi màu = một chủ đề khác nhau.
- Độ dài của màu trong thanh = tỷ lệ % chủ đề đó trong tài liệu.




Nội Dung

LDA (Latent Dirichlet Allocation):

Model LDA là lớp mô hình sinh (generative model) cho phép xác định một tập hợp các chủ đề tưởng tượng (imaginary topics) mà mỗi topic sẽ được biểu diễn bởi tập hợp các từ.

Mục tiêu của LDA là mapping toàn bộ các văn bản sang các topics tương ứng sao cho các từ trong mỗi một văn bản sẽ thể hiện những topic tưởng tượng ấy.



LDA đã tự học từ dữ liệu và nhóm các từ hay xuất hiện cùng nhau thành các chủ đề. Ví dụ, nếu thấy "gene, dna, genetic" thường đi chung → máy coi đó là một topic.


Máy không chỉ đọc toàn bộ bài, mà còn phân tích từng từ và gán chúng vào chủ đề phù hợp. Bài báo này chủ yếu nói về di truyền và sinh học, nên hầu hết từ được nối với topic "gene/dna" và "life/evolution".



Nội Dung

LDA giảm thiểu khối lượng tính toán

Giả định rằng chúng ta có 1000 từ có tần suất xuất hiện nhiều nhất trong văn bản và chúng ta có 1000 văn bản. mỗi văn bản có 500 từ xuất hiện bên trong chúng



Thông qua việc thống kê tần suất xuất hiện của các từ quan trọng trong một văn bản ta nhận thấy rằng có một số văn bản sẽ có một tập hợp các từ gần như nhau.

Do đó chúng sẽ liên quan với nhau về một chủ đề nào đó. Nhưng để làm như vậy chúng ta cần có $\text{num_words} * \text{num_documents} = 500 * 1000 = 500000$ threads cho nó. Số lượng này tạo ra một chi phí tính toán rất lớn.




Nội Dung

Làm thế nào để giảm chiều dữ liệu

Chúng ta có thể giải quyết vấn đề này bằng cách thêm một layer nhân tố ẩn có số units tương ứng với số lượng các topics mà chúng ta xác định sẽ có trong mô hình

Giả định chúng ta biết 10 topics có thể xuất hiện trong toàn bộ các văn bản.

Nhưng vậy mỗi văn bản sẽ có khoảng 10 topics và mỗi topic sẽ có 500 từ. Số lượng threads lúc này sẽ là 20000 threads bao gồm 10000 threads kết nối giữa 1000 văn bản đến 10 topics và 10000 threads kết nối 10 topics đến 1000 từ vựng.




- Trong đó chúng ta giả định có 3 topics ẩn là (“Animals”, “Sports”, “Tech”).
- Trên thực tế chúng ta sẽ không có 3 topics này mà thay vào đó một phân phối của các từ chẳng hạn ($0.3 \cdot \text{Cats}$, $0.4 \cdot \text{Dogs}$, $0.2 \cdot \text{Loyal}$, $0.1 \cdot \text{Evil}$) sẽ biểu diễn cho topic “Animals”.
- Mỗi topics sẽ là một biểu diễn phân phối của các từ mà nó thuộc về.



Nội Dung

Quy trình sinh dữ liệu (generative process) của mô hình Latent Dirichlet Allocation (LDA)



α : Siêu tham số (hyperparameter) cho phân phối Dirichlet prior của θ .

θ_m : Phân bố chủ đề cho tài liệu m (document-topic distribution).

$z_{m,n}$: Chủ đề ẩn (topic assignment) cho từ thứ n trong tài liệu m .

$w_{m,n}$: Từ quan sát được (observed word) thứ n trong tài liệu m .

ϕ_k : Phân bố từ cho chủ đề k (topic-word distribution).


β : Siêu tham số cho Dirichlet prior của



Nội Dung

BERTopic

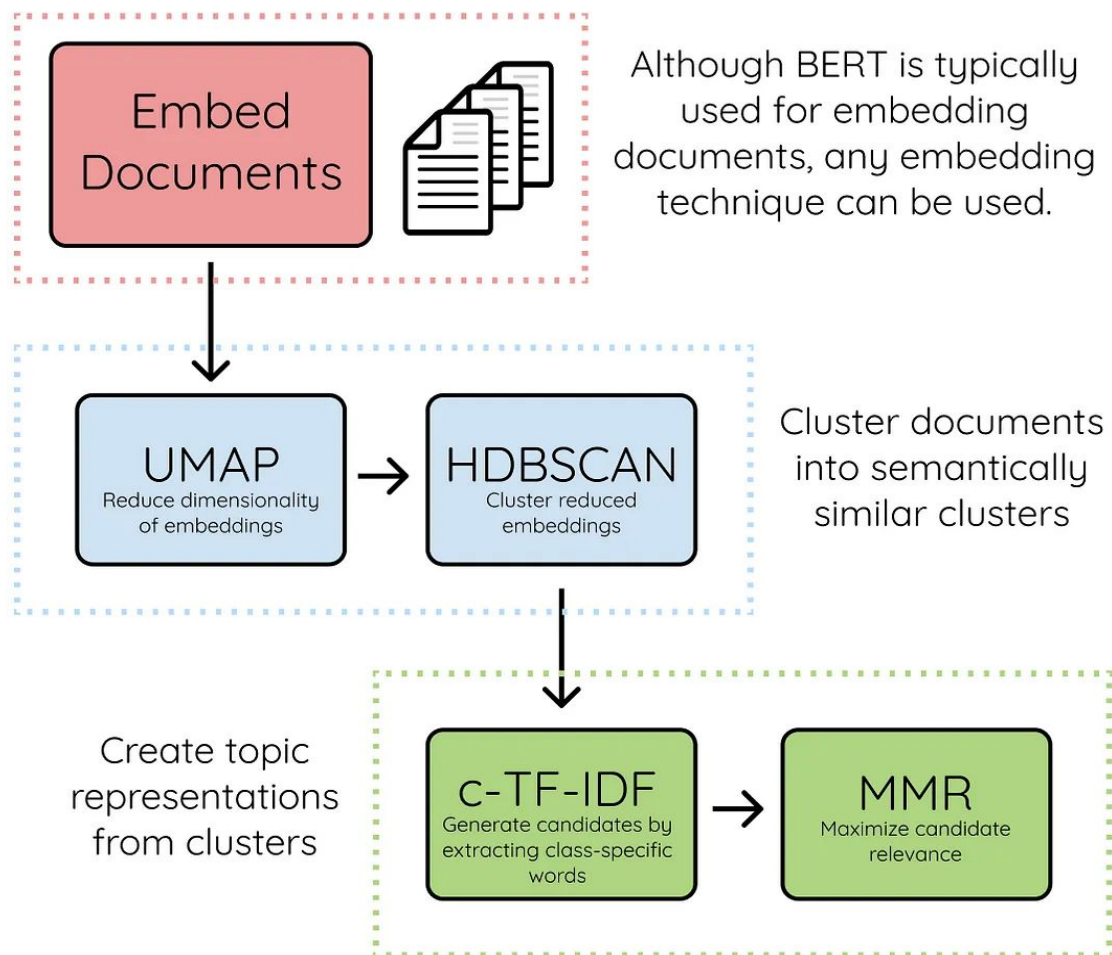
BERTopic là một mô hình hóa chủ đề dựa trên phân cụm sử dụng nhúng ngữ cảnh (BERT) để tạo ra các chủ đề bằng cách nhóm các tài liệu có ý nghĩa tương tự lại với nhau





Nội Dung

BERTopic



Bước đầu là chuyển đổi văn bản thành một định dạng số mà mô hình có thể xử lý, đồng thời nắm bắt được ý nghĩa của nó.

Bước 2 nhằm sắp xếp các vector nhúng thành các nhóm dựa trên sự tương đồng về ý nghĩa, biến các vector phức tạp thành các chủ đề dễ nhận dạng:

- **UMAP (Uniform Manifold Approximation and Projection):** Giảm số chiều của các vector nhúng.
- **HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise):** Phân cụm các nhúng đã được giảm chiều thành các cụm ngữ nghĩa tương tự.

Sau khi tài liệu được phân cụm, bước cuối cùng là gán các từ khóa mô tả rõ ràng cho từng cụm (chủ đề):

- **C-TF-IDF (Class-based Term Frequency-Inverse Document Frequency):** Trích xuất các từ khóa ứng viên đặc trưng cho từng chủ đề.
- **MMR (Maximal Marginal Relevance):** Tối đa hóa sự phù hợp (relevance) và đa dạng (diversity) của các từ khóa được chọn.



Kết Quả



Thank You !
Question?