



VISION AND LEARNING LAB

Customer Segmentation and Recommend Systems

Speaker: Tuan-Hung Giang



**HUNG YEN UNIVERSITY OF
TECHNOLOGY AND EDUCATION**

Date: 12/2025

Content

- Dataset and data preprocessing
- KMeans Clustering (Segmentation)
- Recommendation Strategy
- Personalized Recommendation System
- Content-based Recommendation System
- Conclusion

1. Dataset

- Source: Kaggle[\[1\]](https://www.kaggle.com/datasets/carrie1/ecommerce-data)
- Volume: 541909 records
- Features: InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country

[\[1\] https://www.kaggle.com/datasets/carrie1/ecommerce-data](https://www.kaggle.com/datasets/carrie1/ecommerce-data)

Dataset & Data preprocessing

1. Dataset

InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6	12/1/2010 8:26	2.55	17850.0	United Kingdom
536365	71053	WHITE METAL LANTERN	6	12/1/2010 8:26	3.39	17850.0	United Kingdom
536365	84406B	CREAM CUPID HEARTS COAT HANGER	8	12/1/2010 8:26	2.75	17850.0	United Kingdom
536365	84029G	KNITTED UNION FLAG HOT WATER BOTTLE	6	12/1/2010 8:26	3.39	17850.0	United Kingdom

2. Data preprocessing

- Remove rows which have missing values, duplicates (5225)
- Remove records cancelled transactions (2.21%)
- Remove records anomalous stock codes: POST, D, C2, M, BANK CHARGES, PADS, DOT, CRUK (0.48%)
- Remove records which have unit price of zero




399573 records

[1] <https://www.kaggle.com/datasets/carrie1/ecommerce-data>

Customer Segmentation

Customer Segmentation

- Cluster 0: VIP Customers
- Cluster 1: Potential Customers
- Cluster 2: Churnable Customers



Recommendation System

- Take 10 products of best seller in cluster
- Ignore products bought by customer
- Recommend 3 most seller products for user

[1] <https://www.kaggle.com/datasets/carrie1/ecommerce-data>

Feature Engineering

- From start, **each customer** have many records of different transactions
- To segment customers (PCA + Kmeans) into behavior-cluster more accuracy,
Transform raw transaction data into behavioral features, allowing the model to understand customers.

Feature Engineering

- 1. Days_Since_Last_Purchase

Date of latest transaction of dataset:

$$D_{\max} = \max(\text{InvoiceDay})$$

Date of latest transaction of each customer:

$$D_{\text{last}}(i) = \max(\text{InvoiceDay}_i)$$

Days since last purchase:

$$\text{Days_Since_Last_Purchase}_i = D_{\max} - D_{\text{last}}(i)$$

Feature Engineering

- 2. Total_Transactions

$$\text{Total_Transactions}_i = |\{\text{unique InvoiceNo of customer } i\}|$$

- 3. Total_Products_Purchased

$$\text{Total_Products_Purchased}_i = \sum_{t \in i} \text{Quantity}_t$$

- 4. Total_Spend

Each transaction:

$$\text{Total_Spend}_t = \text{UnitPrice}_t \times \text{Quantity}_t$$

Total spend:

$$\text{Total_Spend}_i = \sum_{t \in i} \text{Total_Spend}_t$$

Feature Engineering

- 5. Average_Transaction_Value

$$\text{Average_Transaction_Value}_i = \frac{\text{Total_Spend}_i}{\text{Total_Transactions}_i}$$

- 6. Unique_Products_Purchased

$$\text{Unique_Products_Purchased}_i = |\{\text{unique StockCode of customer } i\}|$$

- 7. Average_Days_Between_Purchases

List date of transaction: $D_1, D_2, \dots, D_n$

The interval between consecutive purchases: $\Delta_k = D_k - D_{k-1}, \quad k = 2..n$

Average: $\frac{1}{n-1} \sum_{k=2}^n \Delta_k$

▪ 8. Day_of_Week

$$\text{Favorite_Day}_i = \arg \max_d |\{t : \text{Day_Of_Week}_t = d\}|$$

▪ 9. Hour

$$\text{Favorite_Hour}_i = \arg \max_h |\{t : \text{Hour}_t = h\}|$$

▪ 10. Is_UK

$$\text{Is_UK}_i = \begin{cases} 1, & \text{if Country} = \text{United Kingdom} \\ 0, & \text{otherwise} \end{cases}$$

- 11. Cancellation Frequency

$$\text{Cancellation_Frequency}_i = |\{\text{unique InvoiceNo of customer } i \text{ with status} = \text{Cancelled}\}|$$

- 9. Cancellation Rate

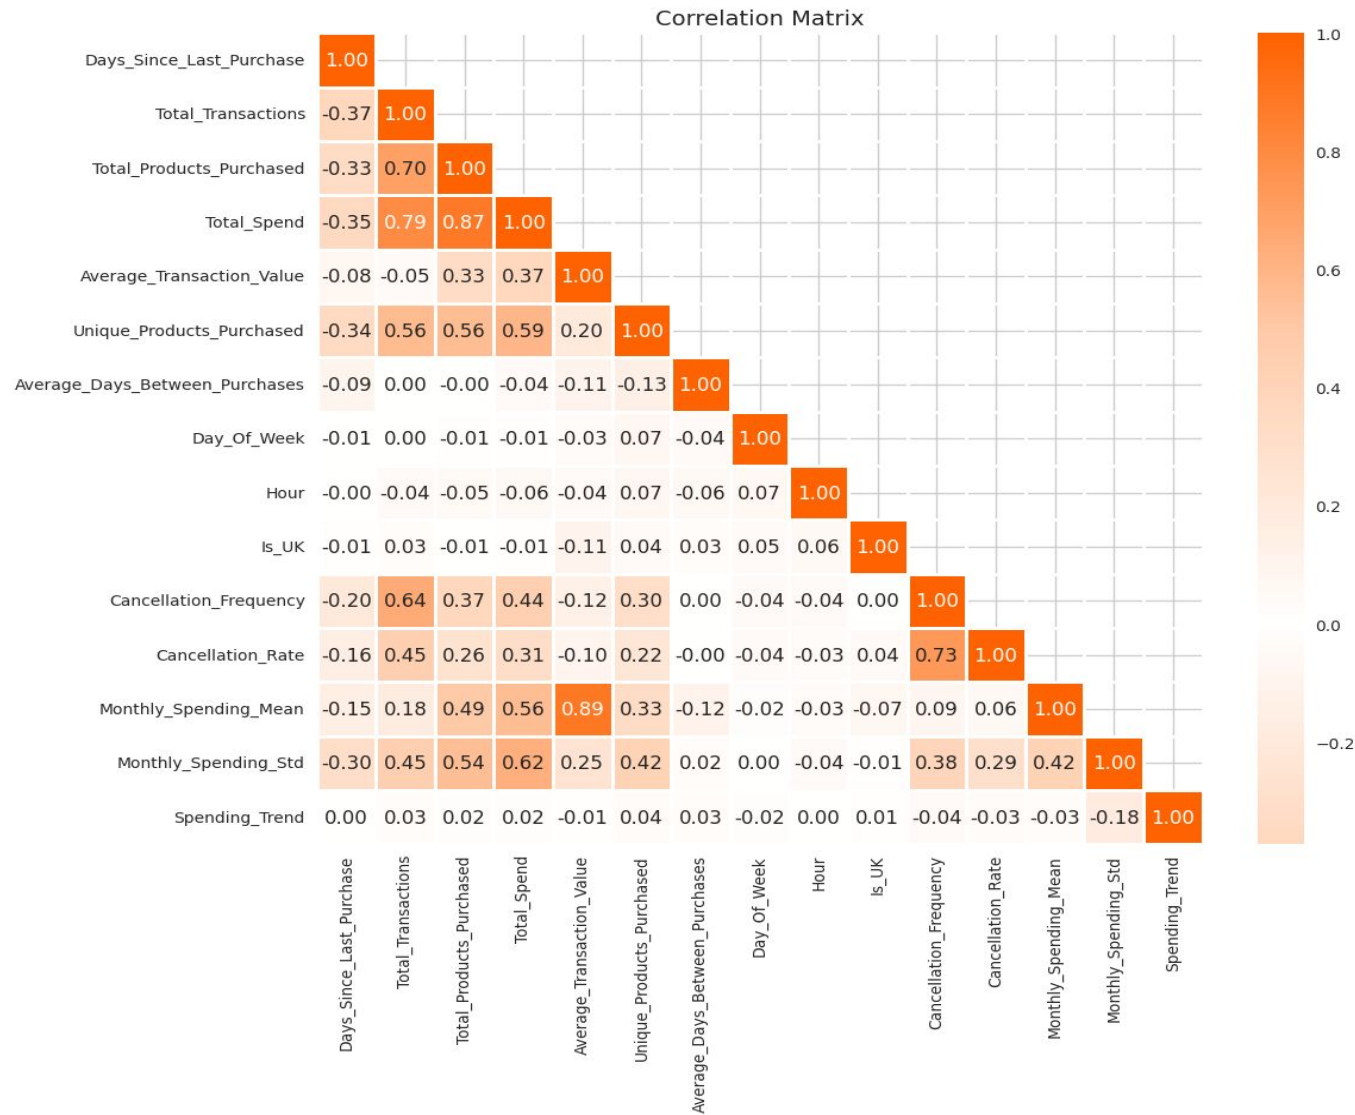
$$\text{Favorite_Hour}_i = \arg \max_h |\{t : \text{Hour}_t = h\}|$$

- 10. Monthly_Spending_Mean


- 11. Monthly_Spending_Std

- 12. Spending_Trend

Feature Engineering



Principal Component Analysis (PCA) is a dimensionality-reduction technique that transforms many correlated features into a smaller set of new features called **principal components**.



K-Means Clustering


K-Means is an unsupervised clustering algorithm that partitions data into **K groups**

- Requires Predefining K: **Elbow Method** or **Silhouette Score**
- Distances become less meaningful in high-dimensional spaces (Applied PCA).

K-Means Clustering

K-Means is an unsupervised clustering algorithm that partitions data into **K** groups

- Requires Predefining K: **Elbow Method**




K=3

K-Means Clustering

Assign cluster label for each customer

1. VIP Customer
2. Potential customer
3. Churnable customer



Mô hình LightGCN (Light Graph Convolutional Network)

LightGCN (Light Graph Convolutional Network) là một mô hình mạng nơ-ron tích chập đồ thị (GCN) được đơn giản hóa, chuyên dùng cho các hệ thống gợi ý dựa trên **Lọc cộng tác (Collaborative Filtering)**

Công thức cho việc cập nhật nhúng của người dùng u từ lớp k lên lớp $k + 1$:

$$\mathbf{e}_u^{(k+1)} = \sum_{i \in N_u} \frac{1}{\sqrt{|N_u|} \sqrt{|N_i|}} \mathbf{e}_i^{(k)}$$

Công thức cho việc cập nhật nhúng của mục i từ lớp k lên lớp $k + 1$:

$$\mathbf{e}_i^{(k+1)} = \sum_{u \in N_i} \frac{1}{\sqrt{|N_i|} \sqrt{|N_u|}} \mathbf{e}_u^{(k)}$$

Mô hình LightGCN (Light Graph Convolutional Network)

LightGCN (Light Graph Convolutional Network) là một mô hình mạng nơ-ron tích chập đồ thị (GCN) được đơn giản hóa, chuyên dùng cho các hệ thống gợi ý dựa trên **Lọc cộng tác (Collaborative Filtering)**

Công thức cho việc cập nhật nhúng của người dùng u từ lớp k lên lớp $k + 1$:

$$\mathbf{e}_u^{(k+1)} = \sum_{i \in N_u} \frac{1}{\sqrt{|N_u|} \sqrt{|N_i|}} \mathbf{e}_i^{(k)}$$

Công thức cho việc cập nhật nhúng của mục i từ lớp k lên lớp $k + 1$:

$$\mathbf{e}_i^{(k+1)} = \sum_{u \in N_i} \frac{1}{\sqrt{|N_i|} \sqrt{|N_u|}} \mathbf{e}_u^{(k)}$$

Content-Based Recommendation

Phương pháp này tập trung vào các **thuộc tính (nội dung)** của sản phẩm để tìm ra những đề xuất phù hợp với sở thích của người dùng. Quá trình này diễn ra qua hai bước chính:

1. **Chuyển đổi Sản phẩm thành Vector:** Đầu tiên, chúng ta sử dụng kỹ thuật **TF-IDF (Term Frequency-Inverse Document Frequency)** để biến đổi mô tả của mỗi sản phẩm (như tiêu đề hoặc mô tả) thành một **vector số học**
2. **Xây dựng và So sánh Hồ sơ Người dùng:** Sau đó, chúng ta tạo ra một **Hồ sơ Sở thích Người dùng (User Profile)** bằng cách lấy **trung bình cộng** các vector của tất cả sản phẩm mà người dùng đã mua hoặc thích. Vector sở thích này đại diện cho "gu" sản phẩm chung của họ. Cuối cùng, hệ thống sẽ sử dụng **Độ tương đồng Cosine (Cosine Similarity)** để so sánh vector sở thích của người dùng với vector của tất cả các sản phẩm chưa mua. Sản phẩm nào có độ tương đồng cao nhất về mặt nội dung (tức là có các từ khóa mô tả giống với sở thích của người dùng) sẽ được ưu tiên gợi ý

Methods	Precision	Recall
LightGCN	0.131	0.126
Content-Based Recommendation	0.110	0.129

References

[1] <https://arxiv.org/pdf/2002.02126>

[2] <https://www.kaggle.com/code/farzadnekouei/customer-segmentation-recommendation-system#Step-12-%7C-Recommendation-System>

Thank You !

Question?