


# Building a Personalized Movie Recommendation System

by Van-Truong Nguyen



# MỤC LỤC

**01**

Giới thiệu về dataset  
**Movielens 20M**

**03**

Đề xuất mô hình

**02**

Xử lý cold start với CBF

**04**

Kết luận

# Giới thiệu về dataset Movielens 20M

## Bao gồm

**20.000.263** ratings

**465.564** tag applications

**27.278** movies

**138.493** users

→ Phù hợp cho mô hình  
explicit feedback

Liên kết với IMDb thông qua  
links.csv, có thể lấy các thông tin  
về **Title, Genres, Directors,**  
**Actors, Plot, Country,...**

→ Thích hợp để nghiên  
cứu content-based

# Xử lý cold start

Dữ liệu metadata của phim có dạng:

```
{
  "Title": "Young Aphrodites",
  "Year": "1963",
  "Rated": "N/A",
  "Released": "01 Dec 1966",
  "Runtime": "88 min",
  "Genre": "Drama, History, Romance",
  "Director": "Nikos Koundouros",
  "Writer": "Longus, Kostas Sfikas, Theokritos",
  "Actors": "Eleni Prokopiou, Takis Emmanuel, Kleopatra Rota",
  "Plot": "200 BC. During a merciless drought, the brute nature of man and the delicate essence of woman become inextricably intertwined, as the omnipotence of the carnal instinct demands the total surrender of the flesh.",
  "Language": "Greek",
  "Country": "Greece"
}
```

Các phương pháp **Item Content-based Filtering**:

Sử dụng TF-IDF

Sử dụng TF-IDF  
kết hợp SBERT

# Xử lý cold start

## Sử dụng TF-IDF

### Bước 1: Chuẩn hóa dữ liệu

"Tom Hanks" → "tom\_hanks"

"Sci-Fi" → "sci-fi"

### Bước 2: Đánh dấu tiền tố

| Thuộc tính | Tiền tố | Ví dụ               |
|------------|---------|---------------------|
| genre      | g_      | g_action            |
| actor      | a_      | a_tom_hanks         |
| director   | d_      | d_steven_spielberg  |
| writer     | w_      | w_christopher_nolan |
| country    | c_      | c_usa               |
| year       | year_   | year_1998           |

### Bước 3: Ghép full text

# Xử lý cold start

## Sử dụng TF-IDF

```
{
  "movieId": 84557,
  "imdbId": "tt0893412",
  "title": "From Prada to Nada",
  "year": 2011,
  "genres": "Action, Comedy, Drama",
  "actors": "Camilla Belle, Alexa PenaVega,
Kuno Becker",
  "directors": "Angel Gracia",
  "writers": "Fina Torres, Luis Alfaro, Craig
Fernandez",
  "country": "Mexico, United States",
  "plot": "A Latina spin on Jane Austen's
Sense and Sensibility: two spoiled sisters who
have been left penniless after their father's
sudden death are forced to move in with their
estranged aunt in East Los Angeles."
}
```

```
from prada to nada

g_action g_comedy g_drama

a_camilla_belle a_alexa_penavega a_kuno_becker

d_angel_gracia

w_fina_torres w_luis_alfaro w_craig_fernandez

c_mexico c_united_states

year_2011

a latina spin on jane austen's sense and
sensibility: two spoiled sisters who have been
left penniless after their father's sudden
death are forced to move in with their
estranged aunt in east los angeles.
```

## Setup cấu hình TF-IDF

| Tham số      | Giá trị |
|--------------|---------|
| max_features | 50,000  |
| ngram_range  | (1,2)   |

# Xử lý cold start

## Sử dụng TF-IDF kết hợp SBERT

### Đổi mới:

- Chỉ dùng TF-IDF + SVD với metadata
- Dùng SBERT cho title và plot

**SBERT (Sentence-BERT)** là mô hình BERT được tinh chỉnh để tạo **sentence embedding** – tức là chuyển câu/văn bản thành vector có ý nghĩa ngữ nghĩa, có thể so sánh bằng cosine similarity.

### Đây là một trong những mô hình SBERT mạnh nhất hiện nay vì:

- Dựa trên MPNet, mô hình ngôn ngữ tối ưu hơn BERT truyền thống
- Tạo embedding kích thước 768 chiều
- Hiểu ngữ nghĩa văn bản rất tốt
- Được huấn luyện trên hàng trăm triệu cặp câu để tối ưu similarity search

# Xử lý cold start

## Cách đánh giá CBF

### Nguyên tắc tách tập dữ liệu

- Ưu tiên dùng Timestamp Split
- Trường hợp dataset nhỏ cần filter theo user
- Dùng LOO (Leave One Out) đánh giá trên HitRate@K, Precision@K, NDCG@K

| Metric      | Ý nghĩa                    | Mục đích          |
|-------------|----------------------------|-------------------|
| HitRate@K   | Số lần đoán đúng           | Độ bao phủ        |
| Precision@K | Số dự đoán đúng            | Độ chính xác      |
| NDCG@K      | Đánh giá cao xếp hạng đúng | Khả năng xếp hạng |



# Xử lý cold start

## So sánh kết quả CBF

| Mô hình                 | HitRate@10    | Precision@10  | NDCG@10       |
|-------------------------|---------------|---------------|---------------|
| TF-IDF thuần            | 0.0497        | 0.0050        | 0.0322        |
| Fusion (SBERT + TF-IDF) | <b>0.0626</b> | <b>0.0063</b> | <b>0.0377</b> |

| Mô hình                 | HitRate@20    | Precision@20  | NDCG@20       |
|-------------------------|---------------|---------------|---------------|
| TF-IDF thuần            | 0.0637        | 0.0032        | 0.0357        |
| Fusion (SBERT + TF-IDF) | <b>0.0807</b> | <b>0.0055</b> | <b>0.0422</b> |

**Nhận xét: Fusion SBERT + TF-IDF vượt trội TF-IDF thuần ở tất cả các metric**

- HitRate tăng khoảng **25-27%**
- Precision tăng **26-71%**
- NDCG cũng tăng khoảng **18%** → mô hình xếp đúng item lên vị trí cao hơn

# Đề xuất mô hình

## SVD (Singular Value Decomposition)

**SVD** trong hệ gợi ý thực chất là một dạng *Matrix Factorization* được tối ưu hóa trực tiếp trên các rating quan sát được. Mục tiêu là xấp xỉ ma trận đánh giá  $R$  bằng tích của hai ma trận người dùng và sản phẩm trong không gian các nhân tố tiềm ẩn:

$$\hat{r}_{ui} = \mu + b_u + b_i + p_u^\top q_i$$

Trong đó:

- $\mu$ : giá trị rating trung bình toàn hệ.
- $b_u, b_i$ : bias của người dùng và phim.
- $p_u \in \mathbb{R}^k$ : vector đặc trưng (latent vector) của người dùng  $u$ .
- $q_i \in \mathbb{R}^k$ : vector đặc trưng của phim  $i$ .

**Mục tiêu huấn luyện là giảm thiểu sai số bình phương có điều chuẩn:**

$$\min_{p_*, q_*, b_*} \sum_{(u,i) \in K} (r_{ui} - \hat{r}_{ui})^2 + \lambda (\|p_u\|^2 + \|q_i\|^2 + b_u^2 + b_i^2)$$

Với  $K$  là tập các cặp đánh giá quan sát được. Tối ưu thường dùng **Stochastic Gradient Descent (SGD)** hoặc **ALS**.

# Đề xuất mô hình

## SVD (Singular Value Decomposition)

### Sử dụng Lib Surprise

| Tham số      | Giá trị mặc định | Ý nghĩa                                             |
|--------------|------------------|-----------------------------------------------------|
| n_factors    | 100              | Số latent factors (kích thước embedding user/movie) |
| n_epochs     | 20               | Số vòng lặp SGD                                     |
| lr_all       | 0.005            | Learning rate cho tất cả parameters                 |
| reg_all      | 0.02             | Regularization để tránh overfitting                 |
| biased       | True             | Mô hình có dùng bias (global + user + item bias)    |
| init_mean    | 0                | Mean khi khởi tạo tham số                           |
| init_std_dev | 0.1              | Độ lệch chuẩn khi khởi tạo tham số                  |
| random_state | None             | Không cố định random seed                           |

# Đề xuất mô hình

## ► SVD (Singular Value Decomposition)

### Kết quả trên

'n\_factors': 100

'n\_epochs': 30

'lr\_all': 0.005

'reg\_all': 0.05

**RMSE: 0.7864**

**MAE: 0.5981**

x x  
x x  
x x  
x x  
x x  
x x

# Đề xuất mô hình

## SVD++

SVD++ bổ sung thêm một thành phần dựa trên tập các phim người dùng đã tương tác  $N(u)$ :

$$\hat{r}_{ui} = \mu + b_u + b_i + q_i^T \left( p_u + \frac{1}{\sqrt{|N(u)|}} \sum_{j \in N(u)} y_j \right)$$

Trong đó:

- $p_u$ : vector biểu diễn người dùng từ đánh giá tương minh.
- $y_j$ : vector đóng góp từ implicit feedback của item  $j$ .
- $N(u)$ : tập các phim mà người dùng  $u$  đã xem hoặc tương tác.

Hàm mất mát:

$$\min \sum_{(u,i) \in K} (r_{ui} - \hat{r}_{ui})^2 + \lambda (\|p_u\|^2 + \|q_i\|^2 + \sum_{j \in N(u)} \|y_j\|^2 + b_u^2 + b_i^2)$$

Ý nghĩa:

- Thành phần  $\frac{1}{\sqrt{|N(u)|}} \sum y_j$  giúp mô hình nhận biết sở thích từ các phim người dùng từng xem, kể cả không đánh giá.
- SVD++ đặc biệt hiệu quả trong dữ liệu thưa – ví dụ, MovieLens có rất nhiều người dùng đánh giá rất ít phim.

## Đề xuất mô hình

### So sánh SVD và SVD++

Scale lại trên cùng bộ 5M rating

Mô hình

RMSE

MAE

SVD

0.8687

0.6673

SVD++

0.8451

0.6444

→ SVD++ cải thiện dần khi lượng dữ liệu tăng lên

## Kết luận

- Tăng cường chất lượng embedding bằng các phương pháp hiện đại giúp cải thiện kết quả
- Yếu tố implicit giúp tăng cường khả năng học cho RS

## Định hướng phát triển

**Nghiên cứu theo hướng Genres-based Filtering bằng việc:**

- **Phân cụm dữ liệu item**
- **Gợi ý item theo cụm gần nhất và cụm lân cận**

→ Kỳ vọng tăng khả năng bao phủ



**Thanks for  
your  
attention!**

