

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HƯNG YÊN



ĐỒ ÁN 3

BUILDING A MOVIE RECOMMENDATION SYSTEM

NGÀNH: KHOA HỌC MÁY TÍNH
CHUYÊN NGÀNH: TRÍ TUỆ NHÂN TẠO VÀ KHOA HỌC DỮ LIỆU

SINH VIÊN: **ĐÀO VĂN THUẬN**
MÃ SINH VIÊN: **12422015**
MÃ LỚP: **12422TNKS**
HƯỚNG DẪN: **PGS. TS. NGUYỄN VĂN HẬU**

HƯNG YÊN – 2025

NHẬN XÉT

Nhận xét của giảng viên hướng dẫn:

[illegible]

GIẢNG VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

LỜI CAM ĐOAN

Em xin cam đoan đồ án “Building a movie recommendation system” là kết quả thực hiện của bản thân em dưới sự hướng dẫn của PGS.TS Nguyễn Văn Hậu

Những phần sử dụng tài liệu tham khảo trong đồ án đã được nêu rõ trong phần tài liệu tham khảo. Các kết quả trình bày trong đồ án và chương trình xây dựng được hoàn toàn là kết quả do bản thân em thực hiện.

Nếu vi phạm lời cam đoan này, em xin chịu hoàn toàn trách nhiệm trước khoa và nhà trường.

Hưng Yên, ngày

... tháng ... năm.....

Sinh viên

Thuận

Đào Văn Thuận

LỜI CẢM ƠN

Để có thể hoàn thành đồ án này, lời đầu tiên em xin phép gửi lời cảm ơn tới bộ môn Công nghệ phần mềm, Khoa Công nghệ thông tin – Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã tạo điều kiện thuận lợi cho em thực hiện đồ án môn học này.

Đặc biệt em xin chân thành cảm ơn PGS.TS Nguyễn Văn Hậu đã rất tận tình hướng dẫn, chỉ bảo em trong suốt thời gian thực hiện đồ án vừa qua.

Em cũng xin chân thành cảm ơn tất cả các Thầy, các Cô trong Trường đã tận tình giảng dạy, trang bị cho em những kiến thức cần thiết, quý báu để giúp em thực hiện được đồ án này.

Mặc dù em đã có cố gắng, nhưng với trình độ còn hạn chế, trong quá trình thực hiện đề tài không tránh khỏi những thiếu sót. Em hi vọng sẽ nhận được những ý kiến nhận xét, góp ý của các Thầy giáo, Cô giáo về những kết quả triển khai trong đồ án.

Em xin trân trọng cảm ơn!

MỤC LỤC

MỤC LỤC.....	5
DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ.....	6
CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI.....	7
1.1. Mở đầu.....	7
1.2. Ý nghĩa và tầm quan trọng của bài toán gợi ý.....	7
1.3. Lịch sử ngắn gọn và một số mốc quan trọng.....	7
1.4. Phân loại các phương pháp chính.....	8
1.4.1. Content-Based Recommendation.....	8
1.4.2. Collaborative Filtering (CF).....	8
1.4.3. Hybrid Methods.....	8
1.4.4. Deep Learning & Representation Learning.....	8
1.4.5. Knowledge-Based & Context-Aware.....	8
1.5. Một số thuật toán tiêu biểu.....	8
1.6. Đánh giá hệ gợi ý phim.....	9
1.7. Dữ liệu và nguồn tham khảo thực tế.....	9
1.8. Các thách thức chính trong gợi ý phim.....	9
1.9. AI đang làm và kết quả thực tế.....	9
1.10. Liên hệ bài toán đồ án “Building movie recommendation system”.....	10
1.11. Kết luận.....	10
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	11
2.1. Giới thiệu về hệ thống gợi ý (Recommender System).....	11
2.2. Mô hình Collaborative Filtering.....	11
2.2.1. Khái niệm.....	11
2.2.2. Phân rã ma trận (Matrix Factorization).....	11
2.2.3. Huấn luyện mô hình.....	12
2.2.4. Đánh giá mô hình.....	12
2.2.5. Ưu và nhược điểm.....	13
2.3. Mô hình Content-Based Filtering.....	13
2.3.1. Khái niệm.....	13
2.3.2. Biểu diễn đặc trưng phim bằng TF-IDF.....	13

Đồ án 3: Building a Movie Recommendation System

2.3.3. Tính độ tương đồng bằng Cosine Similarity.....	13
2.3.4. Quy trình gợi ý.....	14
2.3.5 Ưu và nhược điểm.....	14
2.4. Mô hình Hybrid Recommendation.....	14
2.4.1. Khái niệm.....	14
2.4.2. Cơ chế hoạt động.....	14
2.4.3 Ưu và nhược điểm.....	15
2.5. So sánh tổng quan các mô hình.....	15
CHƯƠNG 3: ÁP DỤNG MÔ HÌNH.....	16
3.1.Thu thập dữ liệu.....	16
3.1.1. Trình bày dữ liệu bài toán.....	16
3.1.2. Tiền xử lý dữ liệu.....	16
3.2.Trực quan hóa dữ liệu.....	18
3.3.Áp dụng mô hình.....	20
3.3.1. Mô hình Collaborative Filtering.....	20
3.3.2. Mô hình Content-Based Filtering.....	22
3.3.3. Mô hình Hybrid Recommendation.....	23
3.4 So sánh ba mô hình gợi ý.....	24
CHƯƠNG 4: XÂY DỰNG WEBSITE.....	25
4.1 Triển khai các chức năng nghiệp vụ.....	25
4.2 Kiểm thử đơn vị và kiểm tra hệ thống.....	26
4.3 Kết chương.....	26
KẾT LUẬN.....	28
TÀI LIỆU THAM KHẢO.....	30

DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ

Hình 3. 1 Dữ liệu bộ Movie2025	18
Hình 3. 2 Dữ liệu bộ rating	18
Hình 3. 3 Kiểm tra dữ liệu	19
Hình 3. 4 Bộ dữ liệu sau khi gộp	19
Hình 3. 5 Biểu đồ phân phối xếp hạng phim	20
Hình 3. 6 Biểu đồ phân phối số lượng xếp hạng cho mỗi phim	20
Hình 3. 7 Biểu đồ số lượng đánh giá trên mỗi người dùng	21
Hình 3. 8 Biểu đồ thể loại phim phổ biến nhất	22
Hình 3. 9 Ví dụ dự đoán với mô hình Collaborative Filtering	23
Hình 3. 10 xử lý dữ liệu genres và overview	24
Hình 3. 11 Ma trận thể hiện độ đo cosine similarity	25
Hình 3. 12 Ví dụ dự đoán mô hình content-based filtering	25
Hình 3. 13 Ví dụ dự đoán của mô hình hybrid Recommendations	26
Hình 4. 1 Website demo gợi ý phim	28
Hình 4. 2 Giao diện xử lý frontend	29

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI

1.1. Mở đầu

Hệ gợi ý (Recommendation System — RS) là một nhánh quan trọng trong khai phá dữ liệu và trí tuệ nhân tạo, với mục tiêu hỗ trợ người dùng lựa chọn từ một tập mục lớn (sản phẩm, phim, bài hát, bài viết, v.v.) bằng cách đưa ra gợi ý cá nhân hóa. Trong lĩnh vực giải trí số, đặc biệt là phim ảnh, hệ gợi ý đóng vai trò trung tâm giúp cải thiện trải nghiệm người xem, giữ chân khách hàng và nâng cao doanh thu cho các nền tảng streaming.

Trong chương này, chúng ta sẽ trình bày tổng quan khái niệm, lịch sử, phân loại phương pháp, thách thức, dữ liệu thường dùng và tình hình nghiên cứu/sản phẩm hiện có — đồng thời lồng ghép bài toán cụ thể của đề án: "Movie Recommendation System with Deep Learning". Mục tiêu là giúp người đọc có một nền tảng vững chắc trước khi đi sâu vào các chi tiết kỹ thuật.

1.2. Ý nghĩa và tầm quan trọng của bài toán gợi ý

- Tăng trải nghiệm người dùng: giúp người xem nhanh chóng tìm ra phim phù hợp với sở thích.
- Giữ chân người dùng & tăng doanh thu: tăng tỷ lệ click, watch-time, và subscription.
- Giảm quá tải thông tin: thư viện phim thường rất lớn, gợi ý giúp cá nhân hóa lựa chọn.
- Tối ưu hóa quảng cáo và hiển thị nội dung: hiển thị phim có khả năng thu hút cao hơn.

1.3. Lịch sử ngắn gọn và một số mốc quan trọng

- Collaborative Filtering (CF): xuất hiện sớm, dựa trên hành vi người dùng.
- Content-Based (CB): dựa trên đặc trưng phim (thể loại, diễn viên, từ khóa).
- Netflix Prize (2006–2009): cột mốc quan trọng, thúc đẩy Matrix Factorization và ensemble.

Đồ án 3: Building a Movie Recommendation System

- 2010 đến nay: deep learning, embedding (user–movie), sequential models (SASRec), và graph-based recommenders.

1.4. Phân loại các phương pháp chính

1.4.1. Content-Based Recommendation

- Ý tưởng: gợi ý phim có đặc điểm tương tự (thể loại, đạo diễn, tag).
- Ưu điểm: hoạt động tốt khi ít dữ liệu hành vi.
- Nhược điểm: hạn chế khả năng khám phá phim mới.

1.4.2. Collaborative Filtering (CF)

- Memory-based: User-User, Item-Item KNN.
- Model-based: Matrix Factorization (SVD, ALS, BPR).
- Ưu điểm: phát hiện sở thích tiềm ẩn.
- Nhược điểm: cold-start user/item, sparsity.

1.4.3. Hybrid Methods

- Kết hợp CF và CB (ví dụ: MF + metadata phim).

1.4.4. Deep Learning & Representation Learning

- Two-Tower Models: user tower (lịch sử xem), item tower (poster, tag, metadata).
- Neural Collaborative Filtering (NCF): dùng MLP thay dot-product.
- Sequence Models (GRU, Transformer/SASRec): học sở thích theo thời gian xem phim.
- Autoencoders/VAE: học latent factors.

1.4.5. Knowledge-Based & Context-Aware

- Knowledge-based: dựa trên ontology phim (IMDB categories, taxonomy).
- Context-aware: thêm yếu tố thời gian, thiết bị, hoặc ngữ cảnh xem.

1.5. Một số thuật toán tiêu biểu

- User-based / Item-based KNN.
- Matrix Factorization (SVD, ALS).
- BPR (Bayesian Personalized Ranking).

- Neural CF, Two-Tower, DSSM.
- Sequence Models (SASRec, GRU4Rec).

1.6. Đánh giá hệ gợi ý phim

- **Metrics:**
 - RMSE/MAE: dự đoán rating (số sao).
 - Precision@K, Recall@K, NDCG@K: cho ranking.
 - MRR, HitRate, MAP.
- **Protocol:**
 - Holdout / time-based split (chia theo thời gian xem phim).
 - Cross-validation.

Lưu ý: khi so sánh mô hình, phải dùng cùng protocol và cùng metric, đặt biệt với data implicit(view/click), thường dùng ranking metrics thay vì RMSE.

1.7. Dữ liệu và nguồn tham khảo thực tế

- MovieLens (GroupLens): dataset chuẩn cho nghiên cứu gợi ý phim.
- Netflix Prize dataset: nền tảng cho nhiều nghiên cứu MF.
- IMDB datasets: metadata phim (thể loại, diễn viên, đạo diễn).
- Amazon Prime / Kaggle movie datasets: nhiều bộ dữ liệu mở.

1.8. Các thách thức chính trong gợi ý phim

- Cold-start: người dùng mới hoặc phim mới chưa có đánh giá.
- Data sparsity: ma trận user-movie rất thưa.
- Scalability: số lượng phim & người xem lớn.
- Diversity vs Relevance: tránh gợi ý toàn phim giống nhau.
- Serendipity & Novelty: gợi ý phim bất ngờ nhưng phù hợp gu.
- Bias & Fairness: tránh thiên vị theo xu hướng/hãng phim.
- Explainability: giải thích vì sao gợi ý phim (“bạn thích phim cùng thể loại”).

1.9. AI đang làm và kết quả thực tế

- Học thuật: RecSys, KDD, WWW, SIGIR, NeurIPS. Các paper nổi bật: BPR, MF, NCF, SASRec.
- Công ty lớn: Netflix, YouTube, Amazon Prime, Disney+ sử dụng recommender systems tiên tiến.
- Kết quả: cải thiện CTR, watch-time, giữ chân user.

1.10. Liên hệ bài toán đồ án “Building movie recommendation system”

- Ý nghĩa: phim là dạng nội dung giàu metadata (thể loại, diễn viên, poster), nên deep learning (embedding + sequence models) rất phù hợp.
- Phương pháp: Hybrid multi-modal recommender (metadata + hành vi + embedding).
- Vấn đề cần chú ý: xử lý dữ liệu lớn, chuẩn hóa rating, cold-start phim mới, tối ưu latency khi deploy.

1.11. Kết luận

Chương 1 đã tổng quan hệ gợi ý phim: khái niệm, phân loại, thuật toán tiêu biểu, dữ liệu, đánh giá, thách thức và ứng dụng thực tế. Đề tài thuộc loại deep learning-based recommendation, tập trung kết hợp hành vi xem phim và metadata để cá nhân hóa trải nghiệm. Phần tiếp theo (Chương 2) sẽ trình bày kiến trúc mô hình chi tiết, pipeline xử lý dữ liệu và hàm đánh giá được sử dụng.

Đồ án 3: Building a Movie Recommendation System

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Giới thiệu về hệ thống gợi ý (Recommender System)

Hệ thống gợi ý (Recommender System) là một nhánh của trí tuệ nhân tạo, có nhiệm vụ dự đoán sở thích hoặc hành vi tương lai của người dùng dựa trên dữ liệu lịch sử. Các hệ thống này được ứng dụng rộng rãi trong các nền tảng thương mại điện tử, nghe nhạc, xem phim, mua sắm,... nhằm giúp người dùng tìm kiếm nhanh hơn những sản phẩm phù hợp với nhu cầu.

Có ba nhóm phương pháp phổ biến:

1. Lọc cộng tác (Collaborative Filtering)
2. Lọc theo nội dung (Content-Based Filtering)
3. Phương pháp lai (Hybrid Recommendation)

2.2. Mô hình Collaborative Filtering

2.2.1. Khái niệm

Collaborative Filtering (CF) là phương pháp dựa vào hành vi và đánh giá của tập người dùng. Giả định cơ bản của CF là:

“Những người dùng có hành vi giống nhau trong quá khứ sẽ có xu hướng đánh giá giống nhau trong tương lai.”

Thay vì phân tích nội dung phim, CF học mối quan hệ giữa người dùng và sản phẩm (phim) thông qua ma trận đánh giá.

2.2.2. Phân rã ma trận (Matrix Factorization)

Trong mô hình này, ta có một **ma trận đánh giá** R gồm:

- Các hàng là người dùng u
- Các cột là phim i
- Phần tử $r_{u,i}$ là điểm đánh giá mà người dùng u cho phim i

Do ma trận này thường rất lớn và thưa (sparse), ta thực hiện **phân rã ma trận** như sau:

$$R \approx P \times Q^T$$

Trong đó:

- $P \in R^{m \times k}$: ma trận đặc trưng người dùng
- $Q \in R^{n \times k}$: ma trận đặc trưng phim
- k : số chiều tiềm ẩn (latent factors)

Dự đoán điểm đánh giá được tính theo công thức:

$$\hat{r}_{u,i} = \mu + b_u + b_i + q_i^T p_u$$

Trong đó:

- μ : trung bình toàn bộ đánh giá
- b_u, b_i : độ lệch (bias) của người dùng và phim
- q_i, p_u : vector đặc trưng ẩn của phim và người dùng

2.2.3. Huấn luyện mô hình

Việc huấn luyện được thực hiện bằng cách tối thiểu hóa sai số bình phương trung bình (RMSE) giữa giá trị thực và giá trị dự đoán:

$$\min_{P, Q, b_u, b_i} \sum_{(u,i) \in K} (r_{u,i} - \hat{r}_{u,i})^2 + \lambda(\|P\|^2 + \|Q\|^2)$$

Trong đó K là tập hợp các đánh giá có sẵn, và λ là hệ số điều chuẩn (regularization).

Trong mã nguồn, mô hình SVD được huấn luyện bằng thư viện Surprise.

2.2.4. Đánh giá mô hình

Các chỉ số đánh giá phổ biến:

RMSE (Root Mean Square Error):

$$RMSE = \sqrt{\frac{1}{N} \sum_{(u,i)} (\hat{r}_{u,i} - r_{u,i})^2}$$

MAE (Mean Absolute Error):

$$MAE = \frac{1}{N} \sum_{(u,i)} |\hat{r}_{u,i} - r_{u,i}|$$

2.2.5. Ưu và nhược điểm

Ưu điểm

Học được sở thích tiềm ẩn của người dùng

Không cần biết nội dung phim

Độ chính xác cao khi dữ liệu đủ

Nhược điểm

Không hoạt động tốt với người dùng mới (cold-start)

Cần dữ liệu đánh giá lớn và đầy đủ

Không giải thích được lý do gợi ý

2.3. Mô hình Content-Based Filtering

2.3.1. Khái niệm

Content-Based Filtering (CBF) là phương pháp gợi ý dựa vào nội dung mô tả của sản phẩm hoặc phim, chẳng hạn như thể loại, diễn viên, đạo diễn, tóm tắt nội dung,...

Giả định cơ bản:

“Nếu người dùng thích một phim A, họ sẽ thích những phim khác có đặc điểm tương tự A.”

2.3.2. Biểu diễn đặc trưng phim bằng TF-IDF

Để biểu diễn nội dung phim, ta dùng **TF-IDF (Term Frequency - Inverse Document Frequency)**.

Công thức:

$$TFIDF(t, d) = TF(t, d) \times IDF(t)$$

Trong đó:

- $TF(t, d)$: tần suất xuất hiện của từ (thể loại) t trong phim d
- $IDF(t) = \log(\frac{N}{n_t})$: N là tổng số phim, n_t là số phim chứa thể loại t

2.3.3. Tính độ tương đồng bằng Cosine Similarity

Sau khi biểu diễn phim dưới dạng vector TF-IDF, ta đo độ tương đồng giữa hai phim A và B :

$$\text{similarity}(A, B) = \frac{A \cdot B}{\|A\| \times \|B\|}$$

Giá trị nằm trong $[0, 1]$; càng gần 1 thì hai phim càng giống nhau.

2.3.4. Quy trình gợi ý

1. Chuẩn hóa dữ liệu (genres, keywords, ...).
2. Dùng TfidfVectorizer để biến dữ liệu thành ma trận đặc trưng.
3. Tính ma trận tương đồng cosine_similarity.
4. Với một phim được chọn, lấy Top-N phim có độ tương đồng cao nhất.

2.3.5 Ưu và nhược điểm

Ưu điểm

- Không cần dữ liệu người dùng khác
- Giải thích dễ hiểu, dựa vào thể loại
- Dễ triển khai và trực quan

Nhược điểm

- Không gợi ý được nếu phim mới không có mô tả
- Dễ bị hạn chế trong phạm vi sở thích hiện tại
- Không học được sở thích ngầm của người dùng

2.4. Mô hình Hybrid Recommendation

2.4.1. Khái niệm

Hybrid Recommendation System là mô hình kết hợp giữa Collaborative Filtering và Content-Based Filtering nhằm tận dụng ưu điểm và hạn chế nhược điểm của từng phương pháp riêng lẻ.

2.4.2. Cơ chế hoạt động

Quy trình kết hợp trong hệ thống của bạn:

Đồ án 3: Building a Movie Recommendation System

1. Từ Content-Based:

Lấy danh sách các phim tương tự (ví dụ: top-30 phim giống "The Dark Knight").

2. Từ Collaborative (SVD):

Dự đoán điểm mà người dùng có thể cho từng phim trong danh sách này.

3. Xếp hạng lại (re-ranking):

Sắp xếp các phim theo điểm dự đoán cao nhất và chọn Top-N để gợi ý.

2.4.3 Ưu và nhược điểm

Ưu điểm

- Cải thiện độ chính xác và cá nhân hóa
- Giảm cold-start và tăng độ đa dạng
- Phù hợp với ứng dụng thực tế

Nhược điểm

- Cấu trúc phức tạp hơn
- Cần nhiều dữ liệu (nội dung + hành vi)
- Tốn thời gian tính toán hơn

2.5. So sánh tổng quan các mô hình

Tiêu chí	Collaborative Filtering (SVD)	Content-Based Filtering	Hybrid Recommendation
Dữ liệu đầu vào	userId, movieId, rating	genres, description	Cả hai
Loại học	Học từ hành vi người dùng	Học từ nội dung phim	Kết hợp
Khả năng cá nhân hóa	Cao	Trung bình	Rất cao
Xử lý cold-start	Kém	Tốt hơn	Tốt
Khả năng giải thích	Thấp	Cao	Trung bình

Đồ án 3: Building a Movie Recommendation System

Độ chính xác tổng thể	Cao khi dữ liệu lớn	Trung bình	Cao nhất
-----------------------	---------------------	------------	----------

CHƯƠNG 3: ỨNG DỤNG MÔ HÌNH

3.1. Thu thập dữ liệu

3.1.1. Trình bày dữ liệu bài toán

- Dữ liệu bài toán được lấy từ website <https://www.themoviedb.org/movie> bằng API gồm có 2 file Movie và Rating, sau đó được upload lên Kaggle với tên:

[Movie2025](#) và [Rating](#)

	movieId	title	genres	overview	poster_path	year
0	1	Zootopia 2	Animation Family Comedy Adventure Mystery	After cracking the biggest case in Zootopia's ...	/oJ7g2CifqStmoYQyaLQgEU32qO.jpg	2025
1	2	The Shadow's Edge	Action Crime Thriller	Macau Police brings the tracking expert police...	/e0RU6KpdnrqFxDKI3NOqN8nHL6.jpg	2025
2	3	Bureau 749	Action Adventure Science Fiction	A traumatized young man with physical abnormal...	/flykCMw22y6yv8vKnBjmsW3pneo.jpg	2024
3	4	Altered	Science Fiction Action	In an alternate present, genetically enhanced ...	/6QIAcGRaUrgHcZ4WTBh5IsPnzKx.jpg	2025
4	5	Wildcat	Action Thriller Crime	An ex-black ops team reunite to pull off a des...	/h893ImjM6Fsv5DFhKJdlZFZIJno.jpg	2025

Hình 3. 1 Dữ liệu bộ Movie2025

	userId	movieId	rating	timestamp
0	1	1234	5.0	944053948
1	1	2232	3.0	943228696
2	1	908	5.0	944250228
3	1	1178	4.0	943231162
4	1	1944	2.0	943231120

Hình 3. 2 Dữ liệu bộ rating

- Dữ liệu của bài toán là 2 file csv gồm:
 - o file movie2025: 9892 rows x 6 columns
 - o file rating: 15998927 rows x 4 columns

3.1.2. Tiền xử lý dữ liệu

a) kiểm tra dữ liệu khuyết thiếu

```
print(df.info())  
  
print(df.describe())  
  
print(df.dtypes)
```

Hình 3. 3 Kiểm tra dữ liệu

Trong quá trình tiền xử lý dữ liệu, nhận thấy bộ dữ liệu đã được chuẩn hóa và làm sạch rất tốt từ trước. Các giá trị bị thiếu, trùng lặp hoặc ngoại lệ hầu như không xuất hiện, đồng thời các thuộc tính cũng đã được định dạng đúng kiểu dữ liệu. Vì vậy, tôi không cần thực hiện thêm các bước xử lý như loại bỏ nhiễu, chuẩn hoá dữ liệu hay mã hoá lại biến. Điều này giúp rút ngắn thời gian tiền xử lý và cho phép tập trung trực tiếp vào các bước phân tích và xây dựng mô hình.

b) Gộp dữ liệu

Để phục vụ cho quá trình phân tích và xây dựng mô hình, tôi tiến hành gộp hai bảng dữ liệu ratings và movies lại với nhau dựa trên khóa chung *movieId*. Việc gộp dữ liệu được thực hiện bằng lệnh `pd.merge()` với phương thức `left join`, đảm bảo toàn bộ dữ liệu từ bảng ratings được giữ lại, đồng thời bổ sung thêm thông tin phim tương ứng.


Đồ án 3: Building a Movie Recommendation System

	userId	movieId	rating	timestamp	title	genres	overview	poster_path
0	1	1234	5.0	944053948	Contraband	Thriller Action Drama Crime	When his brother-in-law runs afoul of a drug l...	/dNNjyZQ0zVtmPa74nJE63Kn0xEx.jpg
1	1	2232	3.0	943228696	Belle Époque	Comedy Drama Romance	In 1931, a young soldier deserts from the army...	/2pb7i9pl6wMH5dlyjbVTXdfSKun.jpg
2	1	908	5.0	944250228	Saltburn	Drama Comedy Thriller	Struggling to find his place at Oxford Univers...	/zGTfMwG112BC66mpaveVxoWPOaB.jpg
3	1	1178	4.0	943231162	Halo: Nightfall	Science Fiction Action Adventure	Set between the events of Halo 4 and Halo 5: G...	/iILQ8EFzHN06eFZ9KQMDK6cmGaK.jpg
4	1	1944	2.0	943231120	The Californians	Drama Comedy	When real estate mogul Gavin Ransom announces ...	/94w3CM4V8AG9OEgtPQSwDfD6Vw.jpg

Hình 3. 4 Bộ dữ liệu sau khi gộp

3.2.Trực quan hóa dữ liệu

a) Biểu đồ phân phối xếp hạng phim




Hình 3. 5 Biểu đồ phân phối xếp hạng phim

- Biểu đồ cho thấy rõ ràng người dùng đánh giá tích cực nhiều hơn tiêu cực. Mức đánh giá phổ biến nhất là 4.0, tiếp theo là 3.0. Các mức đánh giá thấp hơn như 1.0 và 0.5 ít phổ biến hơn nhiều. Chúng ta cũng có thể thấy rằng

Đồ án 3: Building a Movie Recommendation System

người dùng thích đánh giá toàn sao (ví dụ: 4.0, 3.0) hơn là nửa sao (ví dụ: 3.5, 2.5).

b) Biểu đồ phân phối số lượng xếp hạng cho mỗi phim




Hình 3. 6 Biểu đồ phân phối số lượng xếp hạng cho mỗi phim


- Biểu đồ histogram xác nhận giả thuyết. Phân phối bị lệch rất nhiều sang phải. Trực y được biểu diễn theo thang logarit để dễ dàng quan sát mô hình; nếu không có nó, các thanh biểu diễn của những bộ phim ít phổ biến hơn sẽ quá nhỏ để nhìn thấy. Biểu đồ này cho thấy một lượng lớn phim có ít hơn 100 lượt đánh giá, trong khi một nhóm phim rất nhỏ, tinh hoa, đã được đánh giá hàng chục nghìn lần. Đây là một phân phối đuôi dài kinh điển và là một đặc điểm chính của các tập dữ liệu hệ thống đề xuất.

c) Biểu đồ phân phối số lượng đánh giá trên mỗi người dùng

Đồ án 3: Building a Movie Recommendation System



Đồ án 3: Building a Movie Recommendation System



Hình 3. 8 Biểu đồ thể loại phim phổ biến nhất

- Biểu đồ thanh cho thấy Thể loại Drama và Comedy là hai thể loại phổ biến nhất trong tập dữ liệu. Tiếp theo là Phim kinh dị, giật gân và Hành động. Danh mục "(không có thể loại nào được liệt kê)" thể hiện một số lượng nhỏ phim thiếu thông tin thể loại, đây là điều cần lưu ý đối với mô hình dựa trên nội dung của chúng tôi. Phân tích này cung cấp cho chúng tôi cái nhìn tổng quan tốt về nội dung chúng tôi đang xử lý.

3.3. Áp dụng mô hình

3.3.1. Mô hình Collaborative Filtering

Sau khi tiến hành gộp dữ liệu và chuẩn hóa các trường thông tin cần thiết, mô hình Collaborative Filtering được huấn luyện dựa trên thuật toán Singular Value Decomposition (SVD) từ thư viện Surprise. Quy trình bao gồm các bước: tạo đối tượng Reader, chuyển dữ liệu thành dataset chuẩn của Surprise, chia dữ liệu thành tập huấn luyện – kiểm thử (80% – 20%) và tiến hành huấn luyện mô hình.

RMSE	0.8096
MAE	0.6113

Đồ án 3: Building a Movie Recommendation System

- Giá trị RMSE ≈ 0.81 cho thấy mức độ sai lệch giữa giá trị dự đoán và thực tế là tương đối thấp, mô hình dự đoán khá ổn định.
- Giá trị MAE ≈ 0.61 chứng tỏ sai số trung bình giữa các dự đoán và đánh giá thực tế chỉ khoảng 0.6 điểm trên thang 5 điểm, đây là mức sai số chấp nhận được đối với mô hình gợi ý dựa trên thông tin người dùng thật.
- Việc mô hình đạt độ chính xác ở mức tốt phản ánh rằng thuật toán SVD đã học được khá hiệu quả mối quan hệ giữa người dùng và các bộ phim trong dữ liệu.

Mô hình sau đó được sử dụng để tạo danh sách phim đề xuất cho một người dùng cụ thể. Quá trình này bao gồm:

- Xác định các bộ phim mà người dùng chưa xem.
- Dự đoán điểm đánh giá tiềm năng bằng `model.predict`.
- Sắp xếp theo thứ tự giảm dần và chọn ra **Top-N** phim có điểm dự đoán cao nhất.

Top 10 phim được đề xuất hàng đầu cho người dùng: 2025

	movieId	title	genres	predicted_rating
857	858	High Rollers	Action Crime Thriller	5.000000
317	318	Oppenheimer	Drama History	4.961483
1234	1235	El Camino: A Breaking Bad Movie	Crime Drama Thriller	4.937652
1220	1221	Blood Out	Action Thriller	4.912123
1703	1704	Freedom Force	Animation Adventure Family	4.905148
49	50	xXx	Action Adventure Thriller Crime Drama	4.896234
2857	2858	8-Ball	Drama Crime	4.850215
1243	1244	Blind Fury	Action Thriller	4.849750
4641	4642	Lone Wolf	Drama	4.838407
2328	2329	Futureworld	Action Adventure Science Fiction Thriller	4.832777

Hình 3. 9 Ví dụ dự đoán với mô hình Collaborative Filtering

Kết quả trả về danh sách 10 bộ phim được đề xuất hàng đầu cho người dùng 2025, kèm theo điểm đánh giá dự đoán (`predicted_rating`). Điều này cho thấy mô hình hoạt động hiệu quả trong việc cá nhân hóa gợi ý.

3.3.2. Mô hình Content-Based Filtering

Trong mô hình Content-Based Filtering, hệ thống sử dụng chính thông tin mô tả của từng bộ phim để tìm ra những bộ phim có nội dung tương đồng. Hai nguồn dữ liệu quan trọng được khai thác gồm: thể loại phim (genres) và tóm tắt nội dung (overview).

Trước tiên, dữ liệu được chuẩn hóa lại để phù hợp cho việc phân tích:

- Các thể loại phim được tách và đưa về dạng văn bản liên tục để mô hình hiểu đúng ngữ nghĩa.
- Những trường nội dung bị thiếu được thay thế bằng chuỗi rỗng nhằm đảm bảo dữ liệu đầy đủ và không gây lỗi khi xử lý văn bản.

```
Genres TF-IDF: (9892, 21)
Overview TF-IDF: (9892, 5000)
Combined TF-IDF matrix shape: (9892, 5021)
```

Hình 3. 10 xử lý dữ liệu genres và overview

Sau khi làm sạch, toàn bộ văn bản được chuyển thành dạng số thông qua kỹ thuật TF-IDF.

Kỹ thuật này giúp mô hình hiểu mức độ quan trọng của từng từ trong từng bộ phim mà không bị ảnh hưởng bởi các từ xuất hiện quá phổ biến.

Hai TF-IDF độc lập được tạo:

- Một cho thể loại phim
- Một cho mô tả phim

Sau đó, hai phần này được gộp lại để tạo thành một vector đặc trưng hoàn chỉnh cho mỗi bộ phim.

Từ vector đặc trưng, hệ thống tính toán mức độ giống nhau giữa từng cặp phim bằng độ đo cosine similarity.

Đồ án 3: Building a Movie Recommendation System

Kết quả là một ma trận cho biết mỗi bộ phim giống các phim khác bao nhiêu (giá trị từ 0 đến 1).

Shape of the cosine similarity matrix: (9892, 9892)

A slice of the similarity matrix (first 5x5 movies):

	0	1	2	3	4
0	1.000000	0.000000	0.104609	0.000000	0.000000
1	0.000000	1.000000	0.116488	0.134546	0.500000
2	0.104609	0.116488	1.000000	0.432891	0.125559
3	0.000000	0.134546	0.432891	1.000000	0.134546
4	0.000000	0.500000	0.125559	0.134546	1.000000

Hình 3. 11 Ma trận thể hiện độ đo cosine similarity

Khi người dùng chọn một bộ phim, hệ thống:

1. Tìm bộ phim đó trong dữ liệu
2. Lấy mức độ tương đồng của nó với toàn bộ phim khác
3. Sắp xếp theo độ tương đồng giảm dần
4. Chọn ra 10 bộ phim giống nhất để gợi ý

Danh sách gợi ý gồm tên phim, thể loại và phần mô tả của từng phim tương đồng.

Recommendations for viewers who liked 'Zootopia 2':

	title	genres	overview
20	Zootopia	Animation Adventure Family Comedy	Determined to prove herself, Officer Judy Hopp...
4496	Wallace & Gromit: The Curse of the Were-Rabbit	Adventure Animation Comedy Family	Cheese-loving eccentric Wallace and his cunnin...
5924	A Matter of Loaf and Death	Family Animation Comedy Mystery	Wallace and Gromit open a bakery, accidentally...
2984	PAW Patrol: The Movie	Family Comedy Adventure Animation	Ryder and the pups are called to Adventure Cit...
5899	Smurfs: The Lost Village	Family Comedy Adventure Animation	In this fully animated, all-new take on the Sm...
4828	The SpongeBob Movie: Sponge on the Run	Family Comedy Adventure Animation	When his best friend Gary is suddenly snatched...
732	Cars 3	Animation Adventure Comedy Family	Blindsided by a new generation of blazing-fast...
2222	Madagascar 3: Europe's Most Wanted	Animation Family Comedy Adventure	Animal pals Alex, Marty, Melman, and Gloria ar...
322	Madagascar	Family Animation Adventure Comedy	Four animal friends get a taste of the wild li...
924	Cars	Animation Adventure Comedy Family	Lightning McQueen, a hotshot rookie race car d...

Hình 3. 12 Ví dụ dự đoán mô hình content-based filtering

3.3.3. Mô hình Hybrid Recommendation

Mô hình gợi ý lai được xây dựng nhằm kết hợp ưu điểm của hai phương pháp chính: Content-Based Filtering và Collaborative Filtering (SVD). Điều này giúp hệ thống tạo ra các đề xuất chính xác và cá nhân hóa hơn so với từng mô hình đơn lẻ.

Hệ thống bắt đầu bằng cách tìm ra những bộ phim có nội dung tương tự với bộ phim mà người dùng chọn. Dựa trên ma trận cosine similarity, hệ thống xác định mức độ giống nhau giữa phim đầu vào và các phim khác, sau đó chọn ra khoảng 30 phim tương tự nhất làm danh sách ứng viên ban đầu. Việc này đảm bảo rằng danh sách gợi ý chỉ gồm những bộ phim có nội dung liên quan trực tiếp đến sở thích của người dùng. Sau khi có danh sách các phim ứng viên từ bước 1, hệ thống tiếp tục dùng mô hình SVD (đã huấn luyện trước đó từ dữ liệu đánh giá của người dùng) để dự đoán mức độ mà người dùng sẽ yêu thích mỗi bộ phim. Mỗi phim trong danh sách được gán một điểm đánh giá dự đoán, phản ánh mức độ phù hợp của bộ phim đối với người dùng dựa trên hành vi và sở thích giống nhau từ cộng đồng người dùng.

Cuối cùng, hệ thống sắp xếp tất cả các ứng viên theo điểm dự đoán từ cao đến thấp và lựa chọn Top 10 bộ phim có điểm cao nhất để đưa ra gợi ý.

Nhờ cơ chế này:

Content-Based đảm bảo các đề xuất có chủ đề phù hợp với phim ban đầu.

Collaborative Filtering đảm bảo rằng các đề xuất phù hợp với sở thích cá nhân của từng người dùng.

Hybrid Recommendations for User 1024 (based on 'Candyman'):

	movielid	title	genres	predicted_rating
0	389	The Book	Horror Thriller	4.386813
5	4291	Shrew's Nest	Horror Thriller Drama	4.114525
3	9427	Somewhere Quiet	Drama Thriller Horror	3.996067
1	3413	Aurora 15	Thriller Horror	3.970040
4	7723	Special Effects	Drama Horror Thriller	3.426896
2	6827	The Eye	Drama Horror Thriller	2.558003

Hình 3. 13 Ví dụ dự đoán của mô hình hybrid Recommendations


3.4 So sánh ba mô hình gợi ý

Đồ án 3: Building a Movie Recommendation System

- Ba mô hình được triển khai gồm Content-Based Filtering, Collaborative Filtering (SVD) và Hybrid. Kết quả cho thấy mô hình SVD có độ chính xác dự đoán tốt với $RMSE \approx 0.81$ và $MAE \approx 0.61$. Tuy nhiên, SVD không khai thác được thông tin nội dung phim và gặp hạn chế với phim mới chưa có đánh giá.
- Mô hình Content-Based Filtering hoạt động tốt trong việc tìm phim có nội dung tương đồng và xử lý hiệu quả bài toán cold-start đối với item, nhưng khả năng cá nhân hóa còn hạn chế.
- Mô hình Hybrid kết hợp ưu điểm của cả hai phương pháp: sử dụng Content-Based để lọc danh sách phim liên quan, sau đó dùng SVD để xếp hạng theo mức độ phù hợp với từng người dùng. Nhờ đó, Hybrid cho chất lượng gợi ý toàn diện nhất, vừa đảm bảo tính cá nhân hóa vừa duy trì sự tương đồng về nội dung.

CHƯƠNG 4: XÂY DỰNG WEBSITE

4.1 Triển khai các chức năng nghiệp vụ



Hình 4. 1 Website demo gợi ý phim

- Hệ thống gợi ý phim được xây dựng với mục tiêu cung cấp trải nghiệm tìm kiếm và đề xuất nội dung cá nhân hóa cho người dùng dựa trên dữ liệu đánh giá phim và thông tin mô tả phim. Các chức năng nghiệp vụ chính bao gồm:
 - o Chức năng gợi ý theo collaborative Filtering (CF)
 - o Chức năng gợi ý dựa trên nội dung (CBF)
 - o Chức năng gợi ý hybrid (Kết hợp CF + Content-Based)
 - o Chức năng trending (phim thịnh hành)
- Về giao diện người dùng
 - o Giao diện web được xây dựng bằng:
 - HTML + TailwindCSS
 - JavaScript thuần
 - API giao tiếp bằng JSON
 - o Các tab:
 - Trending
 - Collaborative Filtering (CF)
 - Content-Based Filtering
 - Hybrid
 - o Mỗi tab hiển thị lưới poster phim với:
 - Tên phim

Đồ án 3: Building a Movie Recommendation System

- Năm phát hành
- Thể loại
- Điểm CF (nếu có)
- Độ tương đồng nội dung

4.2 Kiểm thử đơn vị và kiểm tra hệ thống

Backend được tiến hành kiểm thử các phần sau:

- Tiền xử lý đầu vào: kiểm tra dữ liệu có được chuẩn hóa đúng định dạng không
- Các API phải nhận được và trả về dữ liệu cho frontend

```
* Serving Flask app 'app'
* Debug mode: on
WARNING: This is a development server. Do not use it in a production deployment. Use a production WSGI server instead.
* Running on http://127.0.0.1:5000
Press CTRL+C to quit
* Restarting with stat
* Debugger is active!
* Debugger PIN: 120-318-716
127.0.0.1 - - [14/Jun/2025 09:39:41] "OPTIONS /predict HTTP/1.1" 200 -
C:\Users\DAO VAN THUAN\period 1 year 3\Machine Learning\WEB BTL\app.py:130: PerformanceWarning: DataFrame is highly fragmented. This is usually the result of calling 'frame.insert'
many times, which has poor performance. Consider joining all columns at once using pd.concat(axis=1) instead. To get a de-fragmented frame, use 'newframe = frame.copy()'
new_df[col] = 0
C:\Users\DAO VAN THUAN\period 1 year 3\Machine Learning\WEB BTL\app.py:130: PerformanceWarning: DataFrame is highly fragmented. This is usually the result of calling 'frame.insert'
many times, which has poor performance. Consider joining all columns at once using pd.concat(axis=1) instead. To get a de-fragmented frame, use 'newframe = frame.copy()'
new_df[col] = 0
C:\Users\DAO VAN THUAN\period 1 year 3\Machine Learning\WEB BTL\app.py:130: PerformanceWarning: DataFrame is highly fragmented. This is usually the result of calling 'frame.insert'
many times, which has poor performance. Consider joining all columns at once using pd.concat(axis=1) instead. To get a de-fragmented frame, use 'newframe = frame.copy()'
new_df[col] = 0
```

Hình 4. 2 Giao diện xử lý frontend

Sau khi tích hợp đầy đủ cả backend và frontend, tiến hành kiểm tra toàn bộ hệ thống với quy trình:

- Người dùng nhập dữ liệu đầu vào ở giao diện HTML, sau đó gửi tới server Flask
- Server nhận, xử lý và gọi mô hình để dự đoán và trả kết quả về frontend
- Frontend hiển thị kết quả chính xác, không bị lỗi kiểu dữ liệu

4.3 Kết chương

Trong chương này, hệ thống gợi ý phim đã được triển khai hoàn chỉnh với các chức năng cốt lõi gồm: gợi ý theo người dùng (Collaborative Filtering), gợi ý theo nội dung (Content-Based), gợi ý kết hợp (Hybrid) và hiển thị phim thịnh hành (Trending). Các module xử lý dữ liệu, mô hình máy học và API đều được xây dựng khoa học, tách biệt và dễ mở rộng.

Thông qua quá trình kiểm thử đơn vị và kiểm thử hệ thống, các chức năng hoạt động chính xác, giao diện thân thiện, tốc độ phản hồi nhanh và đảm bảo tính ổn định. Hệ thống chứng minh được khả năng ứng dụng thực tế trong các nền tảng xem phim hoặc đề xuất nội dung số.

Đồ án 3: Building a Movie Recommendation System

Những kết quả đạt được ở chương này tạo tiền đề để mở rộng thêm các thuật toán nâng cao như:

- Sử dụng BERT/Sentence-BERT cho embedding mô tả phim
- Tối ưu collaborative filtering bằng mô hình latent factor nâng cao
- Tích hợp gợi ý đa tiêu chí (mood-based, thời gian xem, lịch sử tìm kiếm)
- Tối ưu giao diện người dùng và trải nghiệm sử dụng

Hệ thống hiện tại đã đáp ứng đầy đủ yêu cầu đề tài và sẵn sàng cho bước triển khai thực tế hoặc phát triển tiếp trong đồ án tốt nghiệp.

KẾT LUẬN

Kết quả đạt được

Sau quá trình nghiên cứu và triển khai, đề tài “Xây dựng hệ thống gợi ý phim sử dụng Collaborative Filtering, Content-Based và Hybrid” đã đạt được các kết quả nổi bật sau:

- Xử lý và chuẩn hóa dữ liệu phim:
Thu thập và làm sạch dữ liệu MovieLens, TMDB. Các thuộc tính như genres, overview, rating, poster_path, year được xử lý và chuẩn hóa nhằm phục vụ cho các mô hình gợi ý.
- Áp dụng đa dạng kỹ thuật học máy trong gợi ý:
Triển khai và so sánh ba kỹ thuật chính:
 - Collaborative Filtering (SVD – Surprise) dự đoán điểm phim dựa trên hành vi người dùng.
 - Content-Based Filtering (TF-IDF + Cosine Similarity) dựa trên thể loại và nội dung phim.
 - Hybrid Model kết hợp cả CF và Content-Based để tăng độ chính xác và tính cá nhân hóa.
- Tối ưu hoá mô hình Content-Based:
Ghép vector TF-IDF của genres và TF-IDF của overview, tạo ra ma trận đặc trưng lớn, giúp mô hình hiểu sâu hơn nội dung phim → tăng độ tương đồng chính xác.
- Xây dựng API và hệ thống web hoàn chỉnh:
Backend sử dụng Flask để cung cấp các API:
 - /recommend/user/me (CF)
 - /recommend/similar (Content-Based)
 - /recommend/hybrid (kết hợp CF + Content-Based)
 - /recommend/trending (TMDB)

Frontend xây dựng bằng HTML, TailwindCSS, JavaScript, giúp người dùng dễ dàng:

- Nhập user ID để xem gợi ý cá nhân
- Nhập tên phim để xem phim tương tự
- Nhận gợi ý kết hợp chính xác và phù hợp hơn
- Khả năng ứng dụng thực tế cao:
Hệ thống có thể tích hợp vào:
 - nền tảng xem phim trực tuyến,

Đồ án 3: Building a Movie Recommendation System

- hệ thống phân tích hành vi người dùng,
- công cụ gợi ý nội dung cá nhân hoá phục vụ marketing hoặc OTT.

Hạn chế

Mặc dù hệ thống hoạt động tốt, vẫn còn tồn tại một số hạn chế:

- Phụ thuộc vào dữ liệu MovieLens:
Dữ liệu chủ yếu là dữ liệu mẫu, chưa đại diện hoàn toàn cho hành vi người dùng Việt Nam.
- Overview chưa sử dụng mô hình NLP mạnh:
TF-IDF chỉ mô tả mức độ xuất hiện từ, chưa hiểu sâu ngữ nghĩa như BERT hoặc Sentence-BERT.
- Mô hình CF chưa xử lý cold-start người dùng mới hoàn toàn:
Nếu `user_id` chưa có lịch sử, CF chưa hoạt động tối ưu và phải fallback sang Content-Based.
- Không có cập nhật dữ liệu thời gian thực:
Việc cập nhật đánh giá người dùng hoặc thay đổi nội dung phim vẫn chưa tự động.

Hướng phát triển

Trong tương lai, hệ thống có thể mở rộng với các hướng cải tiến sau:

- Mở rộng nguồn dữ liệu:
Thu thập thêm dữ liệu đánh giá phim từ nhiều nguồn hơn (TMDB, IMDb, Netflix dataset), cập nhật theo thời gian thực.
- Ứng dụng mô hình NLP hiện đại cho Content-Based:
Sử dụng BERT, Sentence-BERT, DistilBERT để vector hóa phân mô tả phim, giúp hiểu nội dung đa chiều và chính xác hơn.
- Phát triển mô hình gợi ý theo ngữ cảnh (Context-aware Recommender):
Tính đến thời gian xem, ngày trong tuần, thiết bị, tâm trạng,...
- Xây dựng hệ thống người dùng hoàn chỉnh:
Thêm tính năng:
 - đăng ký / đăng nhập,
 - lưu danh sách phim yêu thích,
 - lịch sử xem phim,
 - dashboard phân tích hành vi.
- Triển khai bản đồ phim theo thể loại và phân cụm người dùng:
Cho phép người dùng khám phá phim theo cluster hoặc embedding trực quan.

Đồ án 3: Building a Movie Recommendation System

- Tối ưu UI/UX và đưa lên server thực tế:
Deploy lên Render, Railway, AWS để chạy liên tục như một sản phẩm hoàn chỉnh

TÀI LIỆU THAM KHẢO

- [1] F. Ricci, L. Rokach & B. Shapira, *Recommender Systems Handbook*, Springer, 2015.
- [2] C. C. Aggarwal, *Recommender Systems: The Textbook*, Springer, 2016.
- [3] Y. Koren et al., “Matrix Factorization Techniques for Recommender Systems,” IEEE Computer, 2009.
- [4] R. Salakhutdinov & A. Mnih, “Probabilistic Matrix Factorization,” NIPS, 2007.
- [5] [Scikit-learn Documentation](#).
- [6] [Surprise Library Documentation](#).
- [7] [Flask Documentation](#).
- [8] [GroupLens – MovieLens Dataset](#).
- [9] [TMDB API Documentation](#).