

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HÙNG YÊN



ĐỒ ÁN 3
XÂY DỰNG HỆ THỐNG CÁ NHÂN HÓA
TRONG ĐỀ XUẤT PHIM

NGÀNH: KHOA HỌC MÁY TÍNH

KHOA: CÔNG NGHỆ THÔNG TIN

SINH VIÊN: **NGUYỄN VĂN TRƯỜNG**

MÃ SINH VIÊN: **10122381**

MÃ LỚP: **12422TN**

HƯỚNG DẪN: **PGS. TS. NGUYỄN VĂN HẬU**

HÙNG YÊN - 2025

NHẬN XÉT

Nhận xét của giáo viên hướng dẫn:

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

GIÁO VIÊN HƯỚNG DẪN

LỜI CAM ĐOAN

Tôi xin cam đoan đồ án “Xây dựng hệ thống cá nhân hóa trong đề xuất phim” là kết quả thực hiện của bản thân tôi dưới sự hướng dẫn của thầy Nguyễn Văn Hậu.

Những phần sử dụng tài liệu tham khảo trong đồ án đã được nêu rõ trong phần tài liệu tham khảo. Các kết quả trình bày trong đồ án và chương trình xây dựng được hoàn toàn là kết quả do bản thân tôi thực hiện.

Nếu vi phạm lời cam đoan này, Tôi xin chịu hoàn toàn trách nhiệm trước khoa và nhà trường.

Hưng Yên, ngày ... tháng ... năm 2025

Nguyễn Văn Trường

LỜI CẢM ƠN

Để có thể hoàn thành đồ án này, lời đầu tiên tôi xin phép gửi lời cảm ơn tới bộ môn Khoa học máy tính, Khoa Công nghệ thông tin – Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã tạo điều kiện thuận lợi cho Tôi thực hiện đồ án môn học này.

Đặc biệt Tôi xin chân thành cảm ơn thầy Nguyễn Văn Hậu đã rất tận tình hướng dẫn, chỉ bảo Tôi trong suốt thời gian thực hiện đồ án vừa qua.

Tôi cũng xin chân thành cảm ơn tất cả các Thầy, các Cô trong Trường đã tận tình giảng dạy, trang bị cho Tôi những kiến thức cần thiết, quý báu để giúp Tôi thực hiện được đồ án này.

Mặc dù Tôi đã có cố gắng, nhưng với trình độ còn hạn chế, trong quá trình thực hiện đề tài không tránh khỏi những thiếu sót. Tôi hy vọng sẽ nhận được những ý kiến nhận xét, góp ý của các Thầy cô về những kết quả triển khai trong đồ án.

Tôi xin trân trọng cảm ơn!

MỤC LỤC

LỜI CAM ĐOAN	3
LỜI CẢM ƠN	4
MỤC LỤC	5
DANH MỤC BẢNG BIỂU	7
DANH MỤC HÌNH ẢNH	8
CHƯƠNG 1: TỔNG QUAN VỀ BÀI TOÁN	9
1.1. Lý do chọn đề tài	9
1.2. Mục tiêu của đề tài	10
1.2.1. Mục tiêu tổng quát.....	10
1.2.2. Mục tiêu cụ thể.....	10
1.3. Giới hạn và phạm vi của đề tài	11
1.3.1. Giới hạn nghiên cứu.....	11
1.3.2. Phạm vi nghiên cứu.....	12
1.4. Nội dung thực hiện	13
1.5. Phương pháp tiếp cận	13
1.6. Các nghiên cứu liên quan	14
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT	15
2.1. Hệ thống gợi ý	15
2.2. Khái niệm Matrix Factorization	16
2.3. Các mô hình kinh điển	18
2.4. Vấn đề cold start	21
2.5. Các metric đánh giá	22
CHƯƠNG 3: GIẢI PHÁP	24

3.1. Giới thiệu dataset	24
3.2. Cách xử lý cold start	29
3.3. Mô hình đề xuất	36
KẾT LUẬN	39
TÀI LIỆU THAM KHẢO	40

DANH MỤC BẢNG BIỂU

Bảng 3.1: Cấu hình TF-IDF	33
Bảng 3.2: So sánh mô hình và kết quả huấn luyện	38
Bảng 3.3: Kết quả huấn luyện và đánh giá trên cùng 1 tập 5M rating	38

DANH MỤC HÌNH ẢNH

Hình 2.1: Minh họa hệ thống gợi ý	15
Hình 2.2: Phương pháp Collaborative Filtering và Content-Based Filtering	19
Hình 3.1: Biểu đồ phân bố điểm đánh giá của người xem	25
Hình 3.2: Biểu đồ phân bố lượt đánh giá theo phim	26
Hình 3.3: Biểu đồ phân bố lượt đánh giá theo người xem	27
Hình 3.4: Biểu đồ 15 thể loại phim phổ biến nhất	28
Hình 3.5: Mối tương quan giữa số lượng đánh giá và điểm đánh giá trung bình	29
Hình 3.6: Mã nguồn mã hóa nội dung với TF-IDF	31

CHƯƠNG 1: **TỔNG QUAN VỀ BÀI TOÁN**

1.1. **Lý do chọn đề tài**

Trong bối cảnh công nghệ thông tin phát triển mạnh mẽ, nhu cầu giải trí của con người ngày càng tăng cao, trong đó xem phim là một trong những hình thức được ưa chuộng nhất. Với sự bùng nổ của các nền tảng phát trực tuyến như Netflix, Amazon Prime, YouTube và các ứng dụng xem phim khác, người dùng phải đối mặt với một khối lượng nội dung khổng lồ. Việc tìm kiếm một bộ phim phù hợp với sở thích, tâm trạng và thói quen cá nhân trở thành một thách thức lớn. Hệ thống gợi ý phim cá nhân hóa ra đời như một giải pháp hiệu quả, giúp người dùng tiết kiệm thời gian, nâng cao trải nghiệm giải trí và mang lại sự tiện lợi tối đa.

Đề tài "Xây dựng hệ thống cá nhân hóa trong gợi ý phim" được lựa chọn vì đây là một bài toán hấp dẫn trong lĩnh vực trí tuệ nhân tạo và học máy, kết hợp cả tính ứng dụng thực tiễn và giá trị khoa học. Việc phát triển một hệ thống gợi ý đòi hỏi sự tích hợp của nhiều kỹ thuật tiên tiến như xử lý dữ liệu lớn, phân tích hành vi người dùng, và các thuật toán học máy hiện đại. Điều này không chỉ mang lại cơ hội nghiên cứu sâu rộng mà còn cho phép khám phá những giải pháp sáng tạo để tối ưu hóa hiệu suất của hệ thống.

Hệ thống gợi ý phim cá nhân hóa có tiềm năng ứng dụng cao trong thực tế. Nó có thể được tích hợp vào các nền tảng phát trực tuyến, ứng dụng di động hoặc các dịch vụ giải trí trực tuyến khác, giúp đề xuất những bộ phim phù hợp với từng cá nhân dựa trên lịch sử xem phim, đánh giá, sở thích và bối cảnh sử dụng. Điều này không chỉ mang lại trải nghiệm người dùng tốt hơn mà còn giúp các nhà cung cấp dịch vụ tối ưu hóa nội dung, tăng mức độ tương tác và giữ chân người dùng lâu dài.

Bên cạnh đó, đề tài này mở ra cơ hội khám phá và ứng dụng các công nghệ tiên tiến như học sâu (deep learning), xử lý ngôn ngữ tự nhiên (natural language processing) và học tăng cường (reinforcement learning). Những công nghệ này không chỉ giới hạn trong việc gợi ý phim mà còn có thể được mở rộng sang các lĩnh vực khác như gợi ý sản phẩm, nội dung tin tức, hoặc thậm chí là các dịch vụ cá nhân hóa trong y tế và giáo dục. Việc nghiên cứu và phát triển hệ thống này sẽ giúp người thực hiện đề

tài tích lũy kiến thức chuyên sâu và kỹ năng thực tiễn trong các lĩnh vực công nghệ mới.

Cuối cùng, việc xây dựng một hệ thống gợi ý phim hiệu quả không chỉ mang lại lợi ích trực tiếp cho người dùng mà còn đóng góp giá trị cho cộng đồng và ngành công nghiệp giải trí. Hệ thống này hỗ trợ các nhà cung cấp dịch vụ trong việc phân tích dữ liệu người dùng, dự đoán xu hướng và tối ưu hóa chiến lược kinh doanh. Đồng thời, nó góp phần nâng cao chất lượng trải nghiệm giải trí, giúp người dùng dễ dàng khám phá những nội dung phù hợp và ý nghĩa. Với những lý do trên, đề tài "Building a Personalized Movie Recommendation System" không chỉ mang tính thực tiễn cao mà còn là một cơ hội để đóng góp vào sự phát triển của công nghệ trí tuệ nhân tạo và cải thiện đời sống giải trí của cộng đồng.

1.2. Mục tiêu của đề tài

1.2.1. Mục tiêu tổng quát

Đề tài nhằm mục đích nghiên cứu và phát triển một hệ thống gợi ý phim cá nhân hóa, giúp người dùng khám phá các bộ phim phù hợp với sở thích và thói quen cá nhân. Đề tài tập trung vào việc áp dụng các thuật toán trí tuệ nhân tạo và học máy để xây dựng một hệ thống thông minh, nhằm nâng cao trải nghiệm giải trí và cung cấp cơ hội học tập chuyên sâu về các kỹ thuật xử lý dữ liệu.

Đề tài hướng đến việc tìm hiểu, phân tích và triển khai các phương pháp học máy tiên tiến như học sâu và xử lý dữ liệu người dùng, qua đó nâng cao hiểu biết về cách xây dựng các hệ thống gợi ý hiệu quả. Mục tiêu chính là tạo ra một môi trường nghiên cứu thực tiễn, giúp người thực hiện nắm vững các công nghệ hiện đại và phát triển kỹ năng giải quyết các bài toán phức tạp trong lĩnh vực trí tuệ nhân tạo.

1.2.2. Mục tiêu cụ thể

Để đạt được mục tiêu tổng quát của đề tài "Building a Personalized Movie Recommendation System", các mục tiêu cụ thể được xác định như sau:

Tìm hiểu và thu thập dữ liệu: Nghiên cứu và thu thập dữ liệu từ các tập dữ liệu phim, ví dụ như MovieLens hoặc IMDb, bao gồm thông tin về phim (thể loại, đạo

diễn, diễn viên, năm phát hành), đánh giá của người dùng, lịch sử xem phim và các yếu tố phụ trợ như thời gian xem hoặc thiết bị sử dụng.

Tiền xử lý và phân tích dữ liệu: Làm sạch dữ liệu, xử lý các giá trị thiếu, dữ liệu không hợp lệ và chuẩn hóa định dạng. Thực hiện phân tích dữ liệu khám phá (EDA) để tìm hiểu mối quan hệ giữa các phim, thể loại, và hành vi người dùng, từ đó xác định các mẫu sở thích phổ biến.

Nghiên cứu và áp dụng thuật toán gợi ý: Tìm hiểu các thuật toán học máy như Collaborative Filtering, Content-Based Filtering hoặc Hybrid Filtering để xây dựng mô hình gợi ý phim. Sử dụng các kỹ thuật như Matrix Factorization hoặc học sâu để khai thác mối quan hệ giữa người dùng và phim.

Xây dựng hệ thống gợi ý phim cá nhân hóa: Dựa trên các thuật toán đã nghiên cứu, phát triển một hệ thống gợi ý phim có khả năng đề xuất các bộ phim phù hợp với sở thích và hành vi của từng người dùng, đảm bảo tính chính xác và đa dạng trong gợi ý.

Đánh giá hiệu quả hệ thống gợi ý: Đánh giá mô hình thông qua các chỉ số như Precision@K, Recall@K, và Mean Average Precision (MAP). So sánh hiệu quả của hệ thống với các phương pháp gợi ý cơ bản bằng cách sử dụng tập kiểm tra hoặc phương pháp A/B testing.

Trực quan hóa và tối ưu hóa: Triển khai hệ thống gợi ý, trực quan hóa kết quả gợi ý thông qua giao diện người dùng đơn giản. Đề xuất các cải tiến để nâng cao hiệu suất hệ thống, chẳng hạn như tích hợp thêm yếu tố ngữ cảnh (thời gian, tâm trạng) hoặc tối ưu hóa thuật toán để giảm thời gian xử lý.

1.3. Giới hạn và phạm vi của đề tài

1.3.1. Giới hạn nghiên cứu

Dữ liệu sử dụng: Sử dụng bộ dữ liệu MovieLens, bao gồm thông tin về phim (thể loại, năm phát hành), đánh giá của người dùng và lịch sử xem phim. Không bao gồm các yếu tố hành vi người dùng ngoài dữ liệu này, như hành vi duyệt web, cảm xúc hoặc bối cảnh xem phim (ví dụ: thời gian, thiết bị).

Dữ liệu theo danh mục phim: Dữ liệu được phân nhóm theo thể loại phim, nhưng phân loại thể loại có thể chưa hoàn toàn chính xác hoặc đầy đủ do sự đa dạng và chồng chéo của các thể loại.

Hệ thống gợi ý: Chỉ sử dụng các thuật toán học máy như Collaborative Filtering hoặc Content-Based Filtering để xây dựng hệ thống gợi ý, không kết hợp với các phương pháp khác như khai phá luật kết hợp (Association Rule Mining) hoặc các kỹ thuật dựa trên ngữ cảnh.

Đánh giá hệ thống: Hiệu quả của hệ thống gợi ý được đánh giá dựa trên các chỉ số như Precision@K, Recall@K và Mean Average Precision (MAP), không bao gồm phản hồi trực tiếp từ người dùng thực tế hoặc khảo sát trải nghiệm người dùng.

Không bao gồm yếu tố bên ngoài: Không xem xét các yếu tố bên ngoài dữ liệu MovieLens, như xu hướng thị trường giải trí, chiến lược quảng bá phim hoặc các yếu tố xã hội ảnh hưởng đến sở thích xem phim.

Phạm vi ứng dụng: Hệ thống gợi ý chỉ tập trung vào việc đề xuất phim cá nhân hóa cho người dùng trên các nền tảng phát trực tuyến, không mở rộng sang các ứng dụng khác như phân tích xu hướng phim, quản lý nội dung hoặc tối ưu hóa chiến lược kinh doanh của các nền tảng.

1.3.2. Phạm vi nghiên cứu

Đề tài tập trung vào việc nghiên cứu và xây dựng hệ thống gợi ý phim cá nhân hóa dựa trên bộ dữ liệu MovieLens. Dữ liệu bao gồm thông tin về phim (thể loại, năm phát hành, đạo diễn, diễn viên), đánh giá của người dùng, lịch sử xem phim và các yếu tố phụ trợ như thời gian đánh giá hoặc thông tin người dùng (độ tuổi, giới tính).

Phạm vi nghiên cứu giới hạn ở việc phân tích mối quan hệ giữa các phim và sở thích người dùng trong cùng một thể loại hoặc dựa trên lịch sử xem phim, từ đó xây dựng hệ thống gợi ý phim cá nhân hóa. Các yếu tố ngoài dữ liệu MovieLens như hành vi duyệt web, phản hồi trực tiếp từ người dùng, hoặc các yếu tố bên ngoài như xu hướng thị trường giải trí và chiến lược quảng bá phim không được xem xét trong nghiên cứu này.

1.4. Nội dung thực hiện

Đề tài gồm 3 chương:

Chương 1: Tổng quan về đề tài

Chương 2: Cơ sở lý thuyết

Chương 3: Giải pháp

1.5. Phương pháp tiếp cận

Thu thập và tiền xử lý dữ liệu: Thu thập dữ liệu từ bộ dữ liệu MovieLens, bao gồm thông tin về phim (thể loại, năm phát hành, đạo diễn, diễn viên), đánh giá người dùng và lịch sử xem phim. Dữ liệu sẽ được làm sạch bằng cách xử lý giá trị thiếu, chuẩn hóa định dạng và loại bỏ dữ liệu ngoại lai để đảm bảo chất lượng phân tích.

Phân tích dữ liệu khám phá (EDA): Tiến hành phân tích dữ liệu để xác định các mẫu sở thích của người dùng, mối quan hệ giữa các thể loại phim và hành vi đánh giá. Các công cụ như thống kê mô tả, biểu đồ phân tán hoặc ma trận tương quan sẽ được sử dụng để khám phá đặc điểm dữ liệu.

Nghiên cứu và lựa chọn thuật toán: Tìm hiểu và so sánh các thuật toán gợi ý như Collaborative Filtering (dựa trên người dùng và dựa trên mục), Content-Based Filtering, và các phương pháp lai (Hybrid Filtering). Các thuật toán như Matrix Factorization hoặc mô hình học sâu sẽ được ưu tiên để cải thiện hiệu quả gợi ý.

Xây dựng mô hình gợi ý: Phát triển hệ thống gợi ý phim dựa trên các thuật toán đã chọn. Mô hình sẽ được huấn luyện trên tập dữ liệu MovieLens, tối ưu hóa để đề xuất các bộ phim phù hợp với sở thích cá nhân của người dùng.

Đánh giá mô hình: Đánh giá hiệu quả của hệ thống gợi ý bằng các chỉ số như Precision@K, Recall@K và Mean Average Precision (MAP). Phương pháp kiểm tra chéo (cross-validation) hoặc A/B testing sẽ được sử dụng để đảm bảo tính chính xác và khả năng tổng quát hóa của mô hình.

Thực quan hóa và cải tiến: Xây dựng giao diện đơn giản để hiển thị kết quả gợi ý phim. Dựa trên kết quả đánh giá, thực hiện các cải tiến như điều chỉnh tham số mô hình hoặc tích hợp thêm yếu tố ngữ cảnh (nếu cần) để nâng cao hiệu suất hệ thống.

1.6. Các nghiên cứu liên quan

Nhiều nghiên cứu trước đây đã đặt nền móng cho việc phát triển hệ thống gợi ý phim cá nhân hóa, đặc biệt trong lĩnh vực trí tuệ nhân tạo và học máy. Dưới đây là một số nghiên cứu tiêu biểu và kết quả đạt được:

Koren et al. (2009) trong bài báo "Matrix Factorization Techniques for Recommender Systems" đã đề xuất các kỹ thuật phân rã ma trận (Matrix Factorization) để xây dựng hệ thống gợi ý dựa trên Collaborative Filtering. Nghiên cứu này, được áp dụng trên bộ dữ liệu Netflix Prize, đạt được cải thiện đáng kể về độ chính xác với RMSE (Root Mean Squared Error) giảm xuống còn khoảng 0.8567 khi kết hợp các mô hình như SVD++ [1].


Ricci et al. (2011) trong cuốn sách "Recommender Systems Handbook" đã tổng hợp các phương pháp gợi ý, bao gồm Content-Based Filtering và Collaborative Filtering. Các tác giả chỉ ra rằng Content-Based Filtering đạt hiệu quả cao khi thông tin về nội dung (như thể loại phim, diễn viên) được khai thác tốt, với tỷ lệ Precision@K trung bình đạt khoảng 0.7 trong các hệ thống gợi ý phim [2].

He et al. (2017) trong bài báo "Neural Collaborative Filtering" đã giới thiệu mô hình học sâu Neural Collaborative Filtering (NCF), kết hợp mạng nơ-ron với Collaborative Filtering. Kết quả trên bộ dữ liệu MovieLens cho thấy mô hình NCF cải thiện hiệu suất so với các phương pháp truyền thống, đạt Precision@10 khoảng 0.73 và Recall@10 khoảng 0.65 [3].

Covington et al. (2016) trong bài báo "Deep Neural Networks for YouTube Recommendations" đã mô tả cách YouTube sử dụng mạng nơ-ron sâu để gợi ý video. Mô hình của họ đạt được cải thiện đáng kể về tỷ lệ nhấp chuột (CTR) và thời gian xem, với độ chính xác gợi ý tăng khoảng 15% so với các phương pháp dựa trên luật [4].

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Hệ thống gợi ý



Hình 2.1: Minh họa hệ thống gợi ý

Hệ thống gợi ý, hay còn gọi là recommender system, là một công cụ quan trọng trong lĩnh vực trí tuệ nhân tạo và khai phá dữ liệu, nhằm dự đoán và đề xuất các sản phẩm, dịch vụ hoặc nội dung phù hợp với sở thích cá nhân của người dùng. Trong bối cảnh đề xuất phim, hệ thống này phân tích hành vi người dùng như lịch sử xem phim, đánh giá và tương tác để tạo ra các gợi ý cá nhân hóa, giúp tăng cường trải nghiệm người dùng và thúc đẩy doanh thu cho các nền tảng như Netflix hay YouTube. Có hai loại chính: hệ thống dựa trên nội dung (content-based), tập trung vào đặc trưng của phim như thể loại, đạo diễn hoặc diễn viên để tìm kiếm sự tương đồng; và hệ thống lọc cộng tác (collaborative filtering), dựa trên hành vi của cộng đồng người dùng để dự đoán sở thích dựa trên sự tương đồng giữa người dùng hoặc giữa các item. Ngoài ra, còn có hệ thống lai (hybrid), kết hợp cả hai để khắc phục hạn chế của từng loại, chẳng hạn như thiếu dữ liệu ban đầu hoặc sự đa dạng trong gợi ý. Việc xây dựng hệ thống gợi ý đòi hỏi xử lý dữ liệu lớn và áp dụng các thuật toán học máy để đảm bảo độ chính xác và tốc độ phản hồi.

2.2. Khái niệm Matrix Factorization

Matrix Factorization (MF) là một trong những kỹ thuật cốt lõi và kinh điển trong hệ thống gợi ý, đặc biệt trong các bài toán dự đoán mức độ ưa thích của người dùng đối với các mục (items). Ý tưởng trung tâm của MF là phân rã ma trận tương tác người dùng – sản phẩm (ví dụ: ma trận đánh giá phim) thành hai ma trận tiềm ẩn có kích thước nhỏ hơn, qua đó mô hình hóa sở thích ngầm của người dùng và đặc trưng ngầm của sản phẩm.

a) Bối cảnh hình thành

Trong hệ thống gợi ý dựa trên cộng tác (Collaborative Filtering), dữ liệu thường được biểu diễn dưới dạng ma trận $R \in \mathbb{R}^{m \times n}$, trong đó:

- m : số lượng người dùng
- n : số lượng phim
- R_{ui} : điểm đánh giá của người dùng u dành cho phim i .

Tuy nhiên, ma trận này thường **thưa** (sparse) do mỗi người dùng chỉ đánh giá một phần rất nhỏ các phim. Điều này gây khó khăn cho các thuật toán truyền thống như k-NN. Matrix Factorization giải quyết vấn đề này bằng cách học ra các *latent factors* — những đặc trưng ẩn mô tả hành vi và xu hướng của người dùng, cũng như thuộc tính trừu tượng của phim.

b) Nguyên lý phân rã

Matrix Factorization tìm hai ma trận hạng thấp:

- Ma trận người dùng $P \in \mathbb{R}^{m \times k}$
- Ma trận phim $Q \in \mathbb{R}^{n \times k}$

Trong đó k là số chiều của không gian đặc trưng ẩn (latent space). Khi đó, điểm đánh giá dự đoán được ước lượng bởi:

$$\hat{R}_{ui} = P_u^\top Q_i$$

Ý nghĩa:

- P_u : vector đặc trưng ẩn mô tả sở thích của người dùng u
- Q_i : vector đặc trưng ẩn mô tả “tính cách” hoặc “nội dung tiềm ẩn” của phim i

Ví dụ:

Một latent factor có thể biểu diễn “mức độ hành động”, một factor khác biểu diễn “độ lãng mạn”, “tính hài hước”,... Người dùng có vector P_u thể hiện mức độ họ thích các đặc tính này.

c) Bài toán tối ưu

Mục tiêu là tìm P và Q sao cho sai số giữa đánh giá thật và đánh giá dự đoán là nhỏ nhất. Hàm mất mát phổ biến:

$$L = \sum_{(u,i) \in K} (R_{ui} - P_u^\top Q_i)^2 + \lambda(\|P_u\|^2 + \|Q_i\|^2)$$

Trong đó:

- K : tập các cặp (người dùng, phim) có đánh giá thật
- λ : hệ số regularization giúp tránh overfitting.

Giải thuật thường dùng:

- Gradient Descent / Stochastic Gradient Descent (SGD)
- Alternating Least Squares (ALS)

d) Biến thể của Matrix Factorization

MF có nhiều biến thể tăng cường hiệu năng:

- Biased Matrix Factorization

Thêm vào bias của người dùng và bias của phim:

$$\hat{R}_{ui} = \mu + b_u + b_i + P_u^\top Q_i$$

Trong đó:

- μ : trung bình toàn cục
- b_u : xu hướng của người dùng (thích chấm cao/thấp)
- b_i : mức độ hấp dẫn chung của phim

Biến thể này là nền tảng mô hình thắng giải Netflix Prize.

- Non-negative Matrix Factorization (NMF)

Ràng buộc $P, Q \geq 0$, phù hợp khi muốn các latent factor mang ý nghĩa dễ diễn giải.

- Factorization Machines (FM)


Mở rộng MF sang các dữ liệu có đặc trưng đa dạng (không chỉ ma trận đánh giá), thích hợp cho bài toán cold start.

e) Ưu điểm của Matrix Factorization

- Xử lý tốt dữ liệu sparse
- Khả năng khái quát cao nhờ biểu diễn latent
- Dự đoán chính xác hơn mô hình truyền thống dựa trên lân cận
- Mở rộng được cho nhiều loại dữ liệu và ngữ cảnh

2.3. Các mô hình kinh điển

Các mô hình gợi ý truyền thống thường được phân thành hai lĩnh vực chính: phương pháp dựa trên nội dung (Content-Based) và phương pháp dựa trên cộng tác (Collaborative Filtering). Mỗi lĩnh vực chứa nhiều mô hình kinh điển đã định hình cách các hệ thống gợi ý hoạt động trong suốt hai thập kỷ qua. Việc hiểu rõ các mô hình này không chỉ giúp nắm được nền tảng lý thuyết mà còn cho phép đánh giá những điểm mạnh, điểm yếu để từ đó lựa chọn giải pháp phù hợp cho hệ thống cá nhân hoá trong đề xuất phim.



Hình 2.2: Phương pháp Collaborative Filtering và Content-Based Filtering

a) Lĩnh vực gợi ý dựa trên nội dung (Content-Based Recommendation)

Trong lĩnh vực này, các mô hình tập trung vào đặc trưng nội dung của từng bộ phim để tạo ra gợi ý có tính cá nhân hoá. Một trong những mô hình kinh điển nhất là Content-Based Filtering (CBF). Phương pháp này biểu diễn mỗi bộ phim dưới dạng một vector đặc trưng được xây dựng từ thể loại, diễn viên, đạo diễn hoặc nội dung tóm tắt. Các đặc trưng dạng văn bản thường được xử lý bằng TF-IDF hoặc các kỹ thuật nhúng (embedding). Hồ sơ của người dùng được tổng hợp dựa trên những bộ phim họ đã đánh giá tích cực. Từ đó, hệ thống đo độ tương đồng giữa hồ sơ này và các phim chưa xem để đưa ra dự đoán.

CBF nổi bật nhờ khả năng hoạt động ngay cả khi dữ liệu đánh giá của người dùng còn ít, đồng thời dễ giải thích vì dựa vào đặc trưng rõ ràng của phim. Tuy vậy, cách tiếp cận này mang đặc tính “không khám phá được nội dung mới”, do mô hình chỉ ưu tiên các phim tương tự với những gì người dùng đã từng thích. Một hạn chế khác là sự phụ thuộc mạnh vào chất lượng metadata — nếu mô tả phim sơ sài, hệ thống khó hoạt động hiệu quả.

Trong cùng lĩnh vực dựa trên nội dung, các mô hình luật kết hợp (Association Rule Mining) như Apriori hay FP-Growth cũng từng được sử dụng để khai thác mối quan hệ giữa các phim dựa trên hành vi đồng xuất hiện trong lịch sử xem. Chẳng hạn,

nếu một tỷ lệ lớn người dùng xem phim A và sau đó xem phim B, hệ thống có thể gợi ý B cho những người vừa xem A. Các mô hình này không dự đoán điểm đánh giá nhưng lại hữu ích trong việc đề xuất những nội dung có xu hướng được xem liên kế nhau, phù hợp với gợi ý theo phiên hoặc theo hành vi thị trường.

Nhìn chung, lĩnh vực gợi ý dựa trên nội dung cung cấp những mô hình đơn giản nhưng mạnh mẽ trong việc học sở thích trực tiếp từ thuộc tính của phim, và thường đóng vai trò quan trọng trong việc xử lý người dùng mới hoặc hệ thống không có đủ dữ liệu cộng tác.

b) Lĩnh vực gợi ý dựa trên cộng tác (Collaborative Filtering)

Trái với hướng tiếp cận dựa vào nội dung, lĩnh vực Collaborative Filtering (CF) tập trung vào mô hình hóa hành vi đánh giá của cộng đồng người dùng, thay vì mô tả nội dung của phim. Những mô hình kinh điển trong lĩnh vực này có thể chia thành hai nhóm lớn: dựa trên bộ nhớ (memory-based) và dựa trên mô hình (model-based).

Trong nhóm dựa trên bộ nhớ, User-Based Collaborative Filtering là mô hình nền tảng nhất. Mô hình giả định rằng những người dùng có hành vi đánh giá tương tự sẽ thích những phim giống nhau. Bằng cách tính toán độ tương đồng giữa người dùng mục tiêu và các người dùng khác, hệ thống dự đoán điểm đánh giá dựa trên ý kiến của “hàng xóm gần nhất”. Mặc dù trực quan, phương pháp này khó mở rộng khi số người dùng lớn và dễ bị ảnh hưởng bởi dữ liệu nhiễu. Một mô hình kinh điển khác thuộc nhóm này là Item-Based Collaborative Filtering, vốn tập trung vào mối quan hệ giữa các bộ phim thay vì giữa người dùng. Nhờ sự ổn định hơn trong cấu trúc đánh giá của item, Item-Based thường hoạt động tốt hơn User-Based trong các hệ thống có quy mô lớn, như Amazon hoặc các nền tảng streaming.

Trong nhóm dựa trên mô hình, Matrix Factorization (MF) được xem là cuộc cách mạng của hệ thống gợi ý hiện đại. Đây là mô hình đã dẫn đến chiến thắng của đội BellKor trong cuộc thi Netflix Prize năm 2009. MF phân rã ma trận đánh giá thành hai không gian tiềm ẩn mô tả đặc trưng ẩn của người dùng và phim, cho phép mô hình dự đoán ngay cả khi dữ liệu đánh giá rất thưa. Các biến thể quan trọng của MF như Probabilistic Matrix Factorization (PMF) hay SVD++ tiếp tục cải thiện khả năng tổng

quát hoá bằng cách mô hình hóa thêm các tín hiệu implicit như lịch sử xem, hành vi tương tác không có đánh giá, hoặc bổ sung thành phần xác suất để tăng tính ổn định. SVD++ đặc biệt thành công trong dữ liệu implicit, vốn là dạng dữ liệu phổ biến trong hệ thống thực tế, nơi người dùng xem phim nhưng không để lại đánh giá.

Ngoài MF, lĩnh vực CF kinh điển còn bao gồm các mô hình như k-Nearest Neighbors (kNN), nơi hệ thống tìm các người dùng hoặc phim gần nhất theo khoảng cách vector trong không gian đặc trưng. Dù kNN đơn giản và thường được dùng làm baseline so sánh, nó vẫn có vai trò quan trọng trong việc dựng hình trực quan về cấu trúc dữ liệu và trong các hệ thống quy mô nhỏ.

2.4. Vấn đề cold start

Một trong những thách thức cơ bản và lâu đời nhất của hệ thống gợi ý là vấn đề cold start, xảy ra khi hệ thống phải đưa ra gợi ý trong khi thông tin ban đầu không đầy đủ hoặc hoàn toàn vắng mặt. Bản chất của hệ thống gợi ý dựa trên dữ liệu lịch sử đồng nghĩa rằng nếu người dùng hoặc phim chưa có đủ tương tác, mô hình sẽ rất khó học được đặc trưng đại diện. Do đó, cold start có thể chia thành ba dạng chính: cold start người dùng, cold start sản phẩm (phim) và cold start hệ thống. Mặc dù mỗi dạng có biểu hiện khác nhau, chúng đều bắt nguồn từ cùng một nguyên nhân: thiếu dữ liệu để mô hình hóa.

Đối với cold start người dùng, hệ thống không có hoặc có rất ít thông tin về sở thích của một người dùng mới. Người dùng chưa thực hiện bất kỳ đánh giá nào hoặc chỉ tương tác ở mức tối thiểu, khiến các mô hình dựa trên cộng tác, đặc biệt là Collaborative Filtering truyền thống, không thể tìm được hàng xóm hoặc không thể suy ra vector đặc trưng ẩn của người dùng. Điều này thường dẫn đến việc hệ thống phải dựa vào các gợi ý phổ biến hoặc gợi ý ngẫu nhiên, làm giảm đáng kể tính cá nhân hóa trong trải nghiệm người dùng.

Trong khi đó, cold start sản phẩm (phim) xảy ra khi một tựa phim mới được thêm vào hệ thống nhưng chưa có đánh giá từ người dùng. Các mô hình dựa trên cộng tác không thể học được vector đặc trưng ẩn của phim mới, vì chúng cần dữ liệu đánh giá để cập nhật tham số. Điều này dẫn đến việc các phim mới thường bị “chìm”, khó được

gợi ý cho người dùng cho đến khi có đủ dữ liệu tương tác. Trong các nền tảng streaming, điều này tạo ra vòng lặp tiêu cực: phim mới không được gợi ý $\rightarrow$ ít người xem $\rightarrow$ lại tiếp tục thiếu dữ liệu.

Một dạng khác ít được nhắc tới nhưng vẫn quan trọng là cold start hệ thống, khi một nền tảng mới được xây dựng và chưa có dữ liệu người dùng lẫn phim. Lúc này, hệ thống buộc phải sử dụng các chiến lược nhập dữ liệu ban đầu như khảo sát người dùng, dựa vào metadata từ cơ sở dữ liệu ngoài, hoặc áp dụng các mô hình không cần dữ liệu lịch sử.

Vấn đề cold start làm bộc lộ sự hạn chế cơ bản của các mô hình Collaborative Filtering và cả Matrix Factorization, vì chúng đều dựa trên giả định tồn tại một lượng đủ lớn dữ liệu tương tác có cấu trúc. Trong khi MF có thể khái quát tốt trên dữ liệu sparse, nó hoàn toàn không thể xử lý trường hợp không có đánh giá nào để cập nhật vector người dùng hoặc item. Nhiều biến thể như SVD++ tận dụng thêm implicit feedback, giúp giảm bớt khó khăn nhưng vẫn không thể giải quyết cold start hoàn toàn.

Để vượt qua thách thức này, các hệ thống gợi ý thường kết hợp thêm thông tin ngoài, đặc biệt là metadata của phim hoặc đặc điểm hồ sơ người dùng. Lúc này, mô hình dựa trên nội dung (Content-Based Filtering) trở nên quan trọng vì nó cho phép hệ thống xây dựng hồ sơ người dùng từ những thông tin phi tương tác như thể loại yêu thích hoặc diễn viên ưa thích. Ngoài ra, các mô hình lai (hybrid models) và cơ chế embedding dựa trên mô tả văn bản giúp biểu diễn phim mới ngay cả khi chưa có đánh giá.

2.5. Các metric đánh giá

Việc đánh giá chất lượng mô hình gợi ý không chỉ đơn thuần là đo mức độ chính xác của dự đoán, mà còn phải phản ánh khả năng mô hình đưa ra danh sách phim có giá trị đối với người dùng. Do bài toán gợi ý có hai hướng tiếp cận — dự đoán điểm số và xếp hạng top-N — các metric cũng được phân chia tương ứng.

a) Nhóm metric đánh giá dự đoán điểm số (Rating Prediction)

Nhóm này xuất hiện sớm nhất trong lịch sử hệ thống gợi ý, khi mục tiêu chủ yếu là dự đoán chính xác điểm đánh giá mà người dùng sẽ cho một bộ phim.

- RMSE (Root Mean Squared Error): Đây là metric được dùng rộng rãi trong các cuộc thi như Netflix Prize. RMSE phạt nặng các sai số lớn, do đó nhấn mạnh việc mô hình không được dự đoán chênh lệch quá xa so với đánh giá thật. Điều này khiến RMSE nhạy cảm với outlier, nhưng lại phù hợp khi yêu cầu độ chính xác tuyệt đối.

- MAE (Mean Absolute Error): MAE tính sai số trung bình một cách trực tiếp, không bình phương sai lệch như RMSE, nên ổn định hơn. Trong nhiều trường hợp, MAE phản ánh chất lượng mô hình một cách thực tế hơn, đặc biệt khi dữ liệu đánh giá phân bố không đều.

Hai metric này phù hợp cho bài toán dự đoán điểm số, nhưng không đánh giá được chất lượng danh sách gợi ý, vì người dùng quan tâm đến phim nào được đề xuất, không phải điểm số chính xác đến mức nào.

b) Nhóm metric đánh giá top-N recommendation (Ranking Metrics)

Trong hầu hết hệ thống gợi ý thực tế (Netflix, YouTube, Spotify), mục tiêu chính là tạo ra một danh sách đề xuất. Do đó, các metric xếp hạng trở nên quan trọng hơn.

- Precision@K: Đo xem trong top-K gợi ý có bao nhiêu phim thật sự liên quan. Precision nhấn mạnh chất lượng danh sách: càng nhiều phim "đúng" trong top-K càng tốt.

- Recall@K: Phản ánh khả năng bao phủ: trong tất cả phim mà người dùng thực sự quan tâm, mô hình thu lại được bao nhiêu phim trong top-K. Precision chú trọng tính chính xác, trong khi Recall chú trọng độ bao phủ — hai metric này thường được xem xét cùng nhau.

- MAP (Mean Average Precision): Một metric nhạy với thứ tự: phim đúng càng đứng cao trong danh sách thì điểm càng lớn. MAP giúp đánh giá xem mô hình có thực sự đặt những phim phù hợp lên đầu danh sách hay không.

- NDCG (Normalized Discounted Cumulative Gain): Một trong những metric quan trọng nhất hiện nay. NDCG phạt giảm điểm theo vị trí, nghĩa là item đúng ở vị trí đầu

có giá trị cao hơn item đứng ở cuối. Điều này mô phỏng đúng hành vi người dùng: hiếm ai kéo xuống tận cuối danh sách đề xuất.

CHƯƠNG 3: GIẢI PHÁP

3.1. Giới thiệu dataset

a) Bộ dữ liệu Movielens

MovieLens là một trong những bộ dữ liệu kinh điển và phổ biến nhất trong nghiên cứu về hệ gợi ý, đặc biệt đối với các phương pháp gợi ý dựa trên lọc cộng tác (Collaborative Filtering). Bộ dữ liệu này được cung cấp bởi GroupLens Research – một nhóm nghiên cứu của Đại học Minnesota, với mục tiêu hỗ trợ cộng đồng học thuật trong việc đánh giá và so sánh các thuật toán gợi ý. MovieLens được xây dựng từ hệ thống gợi ý phim trực tuyến MovieLens.org, trong đó người dùng đánh giá các bộ phim theo thang điểm từ 0.5 đến 5.

Bộ dữ liệu MovieLens có nhiều phiên bản khác nhau về kích thước và mức độ chi tiết, từ các bản nhỏ như MovieLens 100K, 1M cho đến các bản lớn hơn như 20M, 25M và Latest Datasets được cập nhật định kỳ. Mỗi phiên bản đều bao gồm tối thiểu ba thành phần chính:

- Ratings: Lịch sử đánh giá của người dùng cho các bộ phim, kèm timestamp.
- Movies: Thông tin cơ bản về phim (tên phim, năm phát hành, thể loại).
- Tags (nếu có): Các thẻ gán mô tả nội dung phim do người dùng tạo ra.

Trong khuôn khổ đề tài này, phiên bản MovieLens 20M được lựa chọn, với khoảng 20 triệu lượt đánh giá, bao gồm:

- 20.000.263 ratings
- 138.000 tag applications
- 27.278 movies
- 138.493 users

Lý do chọn phiên bản 20M thay vì 100K hay 1M là vì:

- Quy mô đủ lớn để mô phỏng bối cảnh thực tế:

Một hệ gợi ý trong thực tế thường phải xử lý tập dữ liệu rất lớn và thưa (sparse). MovieLens 20M cung cấp số lượng tương tác đủ để đánh giá hiệu quả của các mô hình học máy, đặc biệt là các mô hình dùng embedding hoặc matrix factorization.

- Thông tin phong phú và đa dạng:


Ngoài rating, bộ dữ liệu còn có tag của người dùng và metadata về phim, tạo điều kiện thử nghiệm nhiều phương pháp gợi ý (Lọc cộng tác, Gợi ý dựa trên nội dung (content-based), Hybrid models)

Tương thích với metadata từ IMDb:

- Một lợi thế quan trọng của phiên bản MovieLens 20M là việc cung cấp mã định danh IMDb và TMDb cho mỗi bộ phim. Điều này cho phép mở rộng thông tin phim bằng cách đồng bộ với cơ sở dữ liệu IMDb – một nguồn dữ liệu phim phong phú bao gồm: Nội dung tóm tắt, Đạo diễn, biên kịch, Diễn viên, Các thuộc tính kỹ thuật (thời lượng, thể loại chi tiết), Đánh giá IMDb vote count, IMDb score

b) Phân tích, thống kê tổng quát về dữ liệu:

- Phân bổ điểm đánh giá của người xem:




Hình 3.1: Biểu đồ phân bố điểm đánh giá của người xem

Biểu đồ phân phối đánh giá trong MovieLens cho thấy người dùng có xu hướng chấm điểm cao hơn thấp. Các mức 3.0, 4.0 và 5.0 chiếm phần lớn tổng số lượt đánh giá, trong đó 4.0 là mức phổ biến nhất, vượt xa các mức còn lại. Ngược lại, những đánh giá thấp như 0.5, 1.0 hay 1.5 xuất hiện rất ít, điều này phản ánh thói quen thường gặp của người dùng: họ hiếm khi chấm điểm cực thấp trừ khi phim thật sự tệ hoặc họ rất không hài lòng. Việc điểm 5.0 ít hơn 4.0 cũng gợi ý rằng người dùng vẫn có sự dè dặt nhất định khi trao mức điểm tối đa.

Đối với hệ gợi ý, đặc điểm phân phối lệch về phía điểm cao này khiến dữ liệu trở nên mất cân bằng một cách tự nhiên. Khi phần lớn đánh giá đều tích cực, mô hình có thể gặp khó khăn trong việc phân biệt đâu là phim người dùng thực sự thích và đâu là phim họ chỉ đánh giá ở mức trung bình khá. Điều này khiến việc chuẩn hóa dữ liệu hoặc làm nổi bật chênh lệch tương đối giữa các rating trở nên quan trọng, giúp mô hình học được sở thích tinh tế hơn thay vì chỉ dựa vào giá trị điểm số tuyệt đối.


- Phân bố lượt đánh giá theo phim:



Hình 3.2: Biểu đồ phân bố lượt đánh giá theo phim

Biểu đồ cho thấy phân phối số lượt đánh giá trên mỗi bộ phim trải dài theo dạng “đuôi dài”, với số lượng phim có ít đánh giá áp đảo hoàn toàn số phim được đánh giá nhiều. Nhờ trục logarit, ta mới nhìn rõ được mức độ chênh lệch: phần lớn phim chỉ nhận được dưới 100 lượt đánh giá, trong khi chỉ có một nhóm rất nhỏ phim nổi bật thu hút đến hàng chục nghìn lượt. Sự mất cân đối lớn này phản ánh tính chất phổ biến của dữ liệu phim—rất nhiều tác phẩm kén người xem hoặc ít được chú ý tồn tại song song với một số ít tác phẩm nổi tiếng được đánh giá dày đặc.

- Phân bố lượt đánh giá theo người xem:




Hình 3.3: Biểu đồ phân bố lượt đánh giá theo người xem

Biểu đồ cho thấy phần lớn người dùng chỉ thực hiện một số lượng đánh giá rất khiêm tốn, và số lượng người dùng giảm nhanh khi số đánh giá tăng lên. Trục log giúp làm rõ sự khác biệt này: có đến hàng chục nghìn người dùng chỉ đánh giá vài chục phim, trong khi số người đánh giá trên một nghìn phim đã giảm xuống còn vài trăm, và những người cho vài nghìn đánh giá chỉ xuất hiện với số lượng rất ít. Một vài điểm nằm rải rác ở mức 6.000–9.000 đánh giá thể hiện những “siêu người dùng” cực kỳ tích cực, nhưng họ hoàn toàn là ngoại lệ.

Đây là một đặc trưng quen thuộc của các bộ dữ liệu gợi ý, nơi đa số người dùng tương tác rất ít, tạo nên hiện tượng “người dùng thừa thớt”. Điều này gây ra thách thức cho mô hình vì với quá ít dữ liệu, việc hiểu sở thích của phần lớn người dùng trở nên khó khăn hơn rất nhiều so với nhóm nhỏ người dùng tích cực. Để tránh việc mô hình chỉ học theo số ít “người dùng năng suất cao”, các chiến lược như làm mượt dữ liệu, ưu tiên tương tác gần đây hoặc dùng thông tin bổ trợ thường được sử dụng để giảm bớt tác động của sự mất cân đối này.

- Biểu đồ 15 thể loại phim phổ biến nhất:



Hình 3.4: Biểu đồ 15 thể loại phim phổ biến nhất


Biểu đồ cho thấy sự áp đảo rõ rệt của hai thể loại **Drama** và **Comedy**, mỗi thể loại có số lượng phim vượt trội so với phần còn lại. Drama đặc biệt nổi bật khi số lượng phim lên đến hơn mười ba nghìn, gần gấp đôi nhiều thể loại phía dưới. Các thể loại như Thriller, Romance, Action và Crime cũng xuất hiện với tần suất đáng kể, tạo nên một nhóm thể loại trung gian có mức phổ biến tương đối đồng đều. Từ Documentary trở xuống, số lượng phim giảm dần, đặc biệt là các thể loại như War, Children hay Musical—những thể loại vốn phục vụ thị trường hẹp hơn và không được sản xuất nhiều bằng.

- Tương quan giữa lượng rating và điểm rating của người xem:

Trước hết, ta thấy rằng khi số lượng đánh giá còn rất ít, điểm trung bình của người dùng dao động cực kỳ rộng — từ dưới 1 cho tới gần 5. Điều này là tự nhiên: với chỉ vài rating, điểm trung bình rất dễ thay đổi và mang nhiều tính ngẫu nhiên. Tuy nhiên, khi số rating tăng lên, phân bố bắt đầu “thu hẹp” và hội tụ về khoảng 3.0–4.0. Điều này phản ánh một hiện tượng quen thuộc: người dùng càng đánh giá nhiều thì

điểm trung bình của họ càng ổn định hơn và bộc lộ xu hướng đánh giá thật sự của họ, thay vì là kết quả của vài rating đơn lẻ.

Ở nhóm người dùng rất tích cực (vài nghìn rating), điểm trung bình thường nằm trong khoảng 3 đến 4, hiếm khi chạm những cực trị quá cao hoặc quá thấp. Điều này cho thấy rằng người dùng thường có xu hướng cho điểm khá “lành tính” khi xem nhiều phim; họ ít khi nghiêng hẳn về kiểu đánh giá khắt khe hoặc dễ dãi tuyệt đối.



Hình 3.5: Mối tương quan giữa số lượng đánh giá và điểm đánh giá trung bình

Tổng thể, biểu đồ không cho thấy mối tương quan tuyến tính rõ rệt giữa số lượng rating và mức độ “dễ hay khó tính”, nhưng nó làm rõ một đặc điểm: điểm trung bình càng ổn định khi người dùng càng hoạt động nhiều. Đây là điều quan trọng trong bối cảnh gợi ý, bởi những người dùng ít tương tác tạo ra dữ liệu rất nhiễu, trong khi người dùng hoạt động mạnh giúp mô hình học được sở thích có tính nhất quán hơn.

3.2. Cách xử lý cold start

a) Phương pháp Item Content-based

Trong bài toán cold start, đặc biệt là item cold-start, hệ thống phải đưa ra gợi ý cho những item hoàn toàn chưa có bất kỳ đánh giá hay tương tác nào từ người dùng. Điều này khiến các phương pháp collaborative filtering truyền thống trở nên kém hiệu quả, bởi chúng phụ thuộc trực tiếp vào lịch sử rating để tính độ tương đồng. Trái lại, phương pháp Item Content-based chỉ khai thác nội dung mô tả bản thân item, nên có khả năng hoạt động độc lập với dữ liệu tương tác và do đó phù hợp tự nhiên với vấn đề cold start.

Trong tập MovieLens, mỗi bộ phim đều có các đặc trưng nội dung như:

- Thể loại (genres)
- Mô tả phim (plot/overview)
- Diễn viên, đạo diễn, từ khóa (tags)
- Năm sản xuất, ngôn ngữ...

Dựa trên các thuộc tính này, mỗi phim có thể được biểu diễn bằng một vector nội dung. Khi cần gợi ý cho một phim mới, hệ thống chỉ cần so sánh vector nội dung của phim đó với các phim hiện có để tìm ra các phim tương tự nhất. Nhờ đó, item mới có thể được đưa vào hệ thống ngay lập tức mà không cần chờ dữ liệu rating.

Phương pháp item content-based được chọn vì ba lý do chính:

- Giải quyết trực tiếp vấn đề cold start: không phụ thuộc thông tin người dùng hay lịch sử đánh giá.
- Ổn định và dễ mở rộng: bất kỳ thông tin nội dung bổ sung nào (mô tả, diễn viên...) đều có thể dùng để cải thiện mô hình.
- Dễ giải thích: có thể nêu rõ lý do phim A được gợi ý vì có nội dung giống phim B theo các thuộc tính cụ thể.

Nhược điểm của cách tiếp cận này là gợi ý đôi khi kém đa dạng do hệ thống chỉ xoay quanh nội dung tương tự, nhưng với mục tiêu giải quyết cold start thì content-based vẫn là lựa chọn tối ưu nhất.

b) Mã hóa nội dung với TF-IDF

Để áp dụng phương pháp Item Content-based, hệ thống cần biểu diễn mỗi bộ phim dưới dạng một vector đặc trưng nội dung. Trong đề tài này, ngoài dữ liệu MovieLens, tôi kết hợp thêm với metadata từ IMDb, thu được khoảng 6.000 bản ghi có cấu trúc:

```
{
  "Title": "Young Aphrodites",
  "Year": "1963",
  "Rated": "N/A",
  "Released": "01 Dec 1966",
  "Runtime": "88 min",
  "Genre": "Drama, History, Romance",
  "Director": "Nikos Koundouros",
  "Writer": "Longus, Kostas Sfikas, Theokritos",
  "Actors": "Eleni Prokopiou, Takis Emmanuel, Kleopatra Rota",
  "Plot": "200 BC. During a merciless drought, the brute nature of man and the delicate essence of woman become inextricably intertwined, as the omnipotence of the carnal instinct demands the total surrender of the flesh.",
  "Language": "Greek",
  "Country": "Greece"
}
```

Hình 3.6: Mã nguồn mã hóa nội dung với TF-IDF

Từ các cột này, tôi xây dựng một trường văn bản tổng hợp rồi mã hóa bằng TF-IDF (Term Frequency – Inverse Document Frequency) để thu được vector nội dung cho từng phim.

Bước 1: Xây dựng trường văn bản tổng hợp từ metadata

Thay vì chỉ dùng riêng lẻ từng cột (genres, plot, actors, ...), toàn bộ metadata của mỗi phim được gộp lại thành một chuỗi văn bản duy nhất. Cách làm này giúp TF-IDF xử lý tất cả thông tin nội dung trong một không gian đặc trưng thống nhất.

- Chuẩn hóa chuỗi (hàm norm): Với các trường dạng danh sách (thể loại, diễn viên, đạo diễn, tác giả kịch bản, quốc gia), mỗi phần tử được chuẩn hóa bằng cách:

- + Chuyển về chữ thường (lower())
- + Loại bỏ khoảng trắng dư ở đầu/cuối (strip())

+ Thay chuỗi khoảng trắng hoặc dấu gạch nối bằng dấu gạch dưới
(`re.sub(r"[\s\-]+", "_", t)`)

- Gắn tiền tố để phân biệt loại thông tin: Sau khi chuẩn hóa, mỗi giá trị được gắn thêm một tiền tố (prefix) thể hiện trường mà nó đến từ:

- + `g_` cho genres (thể loại),
- + `a_` cho actors (diễn viên),
- + `d_` cho directors (đạo diễn),
- + `w_` cho writers (biên kịch),
- + `c_` cho country (quốc gia).

Cách gắn prefix này có hai lợi ích: Giữ được ngữ cảnh của token và Cho phép mô hình TF-IDF học được tầm quan trọng khác nhau của thông tin từ từng trường, dù vẫn chỉ là bag-of-words.

- Kết hợp với title, plot và năm sản xuất: Ngoài các trường dạng danh sách, dữ liệu còn có title, plot, year.

Trong hàm, tiêu đề và plot được đưa về chữ thường rồi nối thẳng vào chuỗi văn bản. Năm sản xuất nếu hợp lệ (toàn bộ là chữ số) được chuyển thành token dạng `year_YYYY`, ví dụ `year_2011`.

- Chuỗi văn bản cuối cùng cho mỗi phim: Toàn bộ các thành phần trên được nối lại bằng dấu cách, tạo thành một câu văn bản tổng hợp. Chuỗi này được lưu vào cột text của DataFrame và là đầu vào duy nhất cho mô hình TF-IDF. Nhờ cách thiết kế này, mỗi vector TF-IDF không chỉ phản ánh ngôn ngữ trong mô tả phim, mà còn mã hóa thêm thông tin thể loại, diễn viên, đạo diễn, biên kịch, quốc gia và năm sản xuất, tất cả trong cùng một không gian đặc trưng.

Bước 2: Huấn luyện mô hình TF-IDF

Sau khi tạo trường văn bản tổng hợp cho mỗi phim, mô hình TF-IDF được huấn luyện bằng `TfidfVectorizer` để biến đổi toàn bộ dữ liệu thành ma trận đặc trưng sparse. Mô hình học từ vựng (vocabulary) gồm các token xuất hiện trong metadata phim, đồng

thời tính trọng số TF-IDF phản ánh mức độ quan trọng của mỗi token đối với từng phim.

Cấu hình TF-IDF được thiết kế nhằm đạt được sự cân bằng giữa độ giàu nội dung, kích thước mô hình, và tốc độ xử lý. Sau khi huấn luyện bằng `fit_transform`, ta thu được ma trận TF-IDF kích thước (`số_phim` $\times$ `số_đặc_trung`), trong đó mỗi hàng là một vector biểu diễn nội dung của phim.

Tham số	Giá trị	Ý nghĩa	Tác dụng trong bài toán
max_features	50,000	Giới hạn số lượng đặc trưng tối đa trong từ vựng	Giữ lại các token quan trọng nhất, giảm kích thước mô hình và chi phí lưu trữ
ngram_range	(1, 2)	Sử dụng unigram và bigram	Bắt được cả từ đơn và cụm từ; giúp tăng khả năng phân biệt nội dung phim
min_df	2	Token phải xuất hiện ít nhất trong 2 phim	Loại bỏ từ hiếm (noise), tăng độ ổn định của vector TF-IDF

Bảng 3.1: Cấu hình TF-IDF

c) Mã hóa kết hợp với SBERT

SBERT và lý do lựa chọn:

Sentence-BERT (SBERT) là một mô hình biểu diễn ngữ nghĩa dựa trên kiến trúc BERT, được tối ưu hóa đặc biệt cho bài toán semantic similarity và sentence embedding. Khác với BERT gốc vốn được thiết kế cho các tác vụ phân loại, SBERT sử dụng kiến trúc Siamese/Triplet, cho phép ánh xạ những đoạn văn bản có ý nghĩa tương tự vào các vector gần nhau trong không gian embedding. Điều này giúp SBERT trở thành một trong những mô hình mạnh nhất hiện nay để biểu diễn các đoạn văn bản như mô tả phim.

Việc lựa chọn SBERT cho hệ gợi ý trong đề tài có ba lý do quan trọng:

- Khả năng hiểu ngữ nghĩa sâu: SBERT không chỉ xem xét sự giống nhau về từ vựng như TF-IDF, mà còn hiểu được ngữ nghĩa và ngữ cảnh

- Phù hợp với bài toán cold start: Đối với phim mới chưa có tương tác hay đánh giá, mô tả (plot) và tiêu đề (title) luôn là thông tin sẵn có. SBERT có thể mã hóa trực

tiếp các văn bản này thành embedding chất lượng cao, cho phép hệ thống xác định phim tương tự mà không cần rating

- Tính đồng nhất và ổn định: Embedding của SBERT là vector dense kích thước cố định (thường 768 chiều), dễ chuẩn hóa và sử dụng trong các phép tính độ tương đồng như cosine similarity. Điều này giúp mô hình gợi ý ổn định, ít bị ảnh hưởng bởi độ thưa dữ liệu như TF-IDF.

Nhờ những ưu điểm trên, SBERT cung cấp một biểu diễn ngữ nghĩa sâu hơn, linh hoạt hơn, và phù hợp cho các hệ gợi ý hiện đại – đặc biệt khi nguồn dữ liệu phim thường bao gồm nhiều mô tả văn bản dài

Phương pháp mã hóa kết hợp TF-IDF metadata + SBERT:

Trong đề tài này, thay vì sử dụng SBERT một cách độc lập, tôi áp dụng một chiến lược mã hóa kết hợp (hybrid embedding), nhằm tận dụng ưu điểm của cả hai nguồn thông tin:

- Metadata của phim (genres, actors, directors, writers, country, year)
- Văn bản mô tả nội dung (title + plot)

Hai loại thông tin này bổ trợ cho nhau:

- Metadata có tính cấu trúc và phân loại rất cao (vd: thể loại, quốc gia, diễn viên)
- Mô tả phim lại mang tính ngữ nghĩa tự nhiên, thường phản ánh chủ đề, bối cảnh và diễn biến câu chuyện.

Bước 1: Mã hóa metadata bằng TF-IDF + giảm chiều bằng SVD

Metadata dạng danh sách (thể loại, diễn viên...) được chuyển thành “cụm token đặc trưng” như:

- g_action, g_comedy,
- a_robert_downey_jr,
- d_christopher_nolan,
- c_united_states,

- year_2011.

Sau đó, chúng được mã hóa bằng TF-IDF, cho phép mô hình học được mức độ quan trọng của từng đặc trưng metadata trong não đồ phim.

Do TF-IDF tạo ra vector có số chiều lớn, phương pháp giảm chiều SVD được áp dụng để nén vector metadata về 256 chiều.

Mục đích của bước này là loại bỏ nhiễu, giữ lại các thành phần quan trọng nhất, tạo embedding gọn nhẹ, dễ kết hợp với SBERT.

Bước 2: Mã hóa title + plot bằng SBERT

Toàn bộ tiêu đề và phần mô tả (plot) được ghép thành một đoạn văn bản và đưa vào mô hình SBERT. Kết quả là một embedding ngữ nghĩa dense (thường 768 chiều), phản ánh nội dung câu chuyện, chủ đề, và bối cảnh phim. Embedding SBERT sau đó được chuẩn hóa để đảm bảo ổn định trong tính toán độ tương đồng.

Bước 3: Hợp nhất hai nguồn embedding

Sau khi có:

- Vector SBERT (ngữ nghĩa)
- Vector metadata TF-IDF đã giảm chiều (đặc trưng cấu trúc)

Hai vector được kết hợp bằng phương pháp **weighted concatenation** – ghép vector có trọng số:

- Trọng số SBERT: 0.7
- Trọng số metadata: 0.3

Tỷ lệ này được chọn theo trực giác và thực nghiệm vì văn bản mô tả thường phản ánh nội dung sâu sắc hơn metadata, nhưng metadata vẫn mang giá trị phân loại mạnh (thể loại, diễn viên, quốc gia...).

Sau khi ghép, toàn bộ vector được chuẩn hóa lần cuối để đưa về cùng thang độ dài và tối ưu cho tính toán cosine similarity.

d) So sánh kết quả

3.3. Mô hình đề xuất

a) Mô hình SVD (Singular Value Decomposition)

SVD trong hệ gợi ý thực chất là một dạng *Matrix Factorization* được tối ưu hóa trực tiếp trên các rating quan sát được. Mục tiêu là xấp xỉ ma trận đánh giá R bằng tích của hai ma trận người dùng và sản phẩm trong không gian các nhân tố tiềm ẩn:

$$\hat{r}_{ui} = \mu + b_u + b_i + p_u^\top q_i$$

Trong đó:

- μ : giá trị rating trung bình toàn hệ.
- b_u, b_i : bias của người dùng và phim.
- $p_u \in R^k$: vector đặc trưng (latent vector) của người dùng u .
- $q_i \in R^k$: vector đặc trưng của phim i .

Mục tiêu huấn luyện là giảm thiểu sai số bình phương có điều chuẩn:

$$\min_{p_u, q_i, b_u, b_i} \sum_{(u,i) \in K} (r_{ui} - \hat{r}_{ui})^2 + \lambda(\|p_u\|^2 + \|q_i\|^2 + b_u^2 + b_i^2)$$

Với K là tập các cặp đánh giá quan sát được. Tối ưu thường dùng *Stochastic Gradient Descent (SGD)* hoặc *ALS*.

Ý nghĩa: SVD nắm bắt các đặc trưng tiềm ẩn của người dùng (sở thích thể loại, diễn viên, phong cách phim) và phim (mức phổ biến, mức khó tính) để tạo dự đoán tốt hơn so với phương pháp dựa trên giá trị trung bình thuần túy.

Áp dụng vào Movielens:

Mô hình SVD được huấn luyện trên tập dữ liệu MovieLens 20M với cấu hình số chiều tiềm ẩn cố định và tham số điều chuẩn được tối ưu hóa bằng phương pháp SGD. Sau khi hội tụ, mô hình đạt được các chỉ số lỗi như sau:

- **RMSE:** 0.7864

- **MAE:** 0.5981

Giá trị RMSE ở mức khoảng 0.78 cho thấy mô hình có khả năng dự đoán tương đối chính xác so với mặt bằng các phương pháp factorization truyền thống trên tập dữ liệu lớn và thưa như MovieLens 20M. Chỉ số MAE thấp hơn 0.6 cũng phản ánh sai lệch trung bình giữa dự đoán và đánh giá thực tế là nhỏ, thể hiện tính ổn định của mô hình.

b) Mô hình SVD++

SVD++ mở rộng SVD bằng cách khai thác thêm tương tác ngầm (implicit feedback). Nếu người dùng đã xem phim, dù không rating, điều này vẫn mang ý nghĩa rằng họ quan tâm đến phim đó.

SVD++ bổ sung thêm một thành phần dựa trên tập các phim người dùng đã tương tác $N(u)$:

$$\hat{r}_{ui} = \mu + b_u + b_i + q_i^\top \left(p_u + \frac{1}{\sqrt{|N(u)|}} \sum_{j \in N(u)} y_j \right)$$

Trong đó:

- p_u : vector biểu diễn người dùng từ đánh giá tường minh.
- y_j : vector đóng góp từ implicit feedback của item j .
- $N(u)$: tập các phim mà người dùng u đã xem hoặc tương tác.

Hàm mất mát:

$$\min \sum_{(u,i) \in K} (r_{ui} - \hat{r}_{ui})^2 + \lambda (\|p_u\|^2 + \|q_i\|^2 + \sum_{j \in N(u)} \|y_j\|^2 + b_u^2 + b_i^2)$$

Ý nghĩa:

- Thành phần $\frac{1}{\sqrt{|N(u)|}} \sum y_j$ giúp mô hình nhận biết sở thích từ các phim người dùng từng xem, kể cả không đánh giá.
- SVD++ đặc biệt hiệu quả trong dữ liệu thưa — ví dụ, MovieLens có rất nhiều người dùng đánh giá rất ít phim.

c) So sánh mô hình và kết quả huấn luyện

Tiêu chí	SVD	SVD++
Loại dữ liệu	Chỉ dùng rating tường minh	Dùng cả rating và implicit interactions
Độ chính xác	Tốt	Tốt hơn, đặc biệt khi dữ liệu thưa
Độ phức tạp	Thấp hơn	Cao hơn nhiều (tính toán với $N(u)$)
Ứng dụng	Hệ gợi ý cơ bản	Hệ gợi ý nâng cao, cá nhân hóa mạnh

Bảng 3.2: So sánh mô hình và kết quả huấn luyện

SVD cung cấp baseline mạnh, dễ huấn luyện, phù hợp để đánh giá hiệu quả MF, SVD++ khai thác triệt để lịch sử tương tác người dùng, cho kết quả vượt trội, đặc biệt ở các người dùng ít rating.

Kết quả huấn luyện và đánh giá trên cùng 1 tập 5M ratings:

Do chi phí huấn luyện của mô hình SVD++ lớn hơn đáng kể so với SVD, đặc biệt trên tập MovieLens 20M, thí nghiệm được thực hiện trên một tập rút gọn có kích thước xấp xỉ 5 triệu lượt đánh giá. Kết quả thu được như sau:

Mô hình	RMSE	MAE
SVD	0.8687	0.6673
SVD++	0.8451	0.6444

Bảng 3.3: Kết quả huấn luyện và đánh giá trên cùng 1 tập 5M rating

Kết quả cho thấy SVD++ consistently đạt độ chính xác cao hơn SVD ở cả hai thước đo RMSE và MAE. Mức giảm RMSE khoảng **0.0236** và giảm MAE khoảng **0.0229** chứng minh rằng việc khai thác thêm tương tác ngầm (implicit feedback) mang lại lợi ích rõ rệt, ngay cả khi dữ liệu chưa quá thưa.

Mặc dù lợi thế của SVD++ là rõ ràng, mô hình phải đánh đổi bằng thời gian huấn luyện tăng mạnh, do mỗi cập nhật tham số của người dùng phải tính đến toàn bộ tập item mà họ từng tương tác. Điều này lý giải vì sao thí nghiệm chỉ được thực hiện trên tập 5M thay vì 20M.

KẾT LUẬN

Kết quả đạt được:

Trong quá trình thực hiện đề tài, nhóm đã triển khai và đánh giá nhiều hướng tiếp cận khác nhau cho hệ gợi ý phim dựa trên bộ dữ liệu MovieLens, tập trung vào việc giải quyết bài toán cold start và cải thiện chất lượng gợi ý. Trước hết, nhóm tiến hành nghiên cứu hướng tiếp cận Item Content-based nhằm tận dụng thông tin mô tả của phim để xây dựng hệ gợi ý trong trường hợp dữ liệu tương tác còn hạn chế. Hai phương pháp biểu diễn đặc trưng nội dung được thử nghiệm gồm TF-IDF thuần và TF-IDF kết hợp với SBERT. Đối với TF-IDF thuần, mô hình bước đầu cho phép xác định mức độ tương đồng giữa các phim dựa trên các đặc trưng từ vựng, mang lại khả năng gợi ý chấp nhận được đối với các trường hợp phim có mô tả rõ ràng, tuy nhiên vẫn còn hạn chế trong việc nắm bắt ngữ nghĩa sâu và khó đạt hiệu quả cao đối với những phim có nội dung mô tả ngắn hoặc nghèo thông tin.

Hạn chế của đề tài:

Mặc dù đề tài đã đạt được một số kết quả nhất định, quá trình nghiên cứu vẫn tồn tại một số hạn chế. Trước hết, phạm vi thử nghiệm về phương pháp biểu diễn nội dung còn tương đối hẹp. Nhóm chủ yếu tập trung vào TF-IDF và kết hợp TF-IDF với SBERT, trong khi nhiều phương pháp mới hơn như Doc2Vec, các mô hình embedding dựa trên Transformer tối ưu cho văn bản dài, hoặc các mô hình đa phương thức (kết hợp hình ảnh poster, metadata mở rộng) chưa được triển khai. Điều này khiến khả năng so sánh toàn diện giữa các hướng tiếp cận còn hạn chế và kết luận về chất lượng xử lý bài toán cold start mới chỉ dừng lại ở một số phương pháp cơ bản và bán hiện đại.

Bên cạnh đó, đối với nhóm mô hình Collaborative Filtering, việc nghiên cứu mới chỉ dừng ở hai mô hình kinh điển là SVD và SVD++, chưa mở rộng sang các phương pháp tiên tiến hơn như Neural Collaborative Filtering (NCF), LightFM, AutoEncoder-based CF hoặc các dạng hybrid model sử dụng cả nội dung lẫn tương tác. Điều này phần nào giới hạn khả năng đánh giá mức độ cải thiện khi áp dụng các mô hình học sâu hoặc mô hình lai, vốn đang là xu hướng chủ đạo trong hệ gợi ý hiện đại.

Hướng phát triển trong tương lai:

Trong giai đoạn tiếp theo, đề tài có thể mở rộng theo hướng nghiên cứu các phương pháp gợi ý dựa trên phân tích thể loại phim (genres-based). Thay vì chỉ khai thác trực tiếp thông tin nội dung dưới dạng văn bản, việc sử dụng các đặc trưng thể loại để hình thành các cụm phim có tính chất tương đồng có thể giúp hệ gợi ý hoạt động hiệu quả hơn trong những trường hợp dữ liệu mô tả hạn chế hoặc không đồng nhất. Phân cụm phim dựa trên genres cho phép xây dựng cấu trúc không gian nội dung rõ ràng hơn, từ đó tạo nền tảng cho các thuật toán gợi ý khai thác đặc trưng nhóm thay vì chỉ xem xét từng phim độc lập.

Trên cơ sở phân cụm, hệ thống có thể định hướng gợi ý theo nguyên tắc lựa chọn các phim nằm trong cụm gần nhất với sở thích của người dùng, được xác định từ lịch sử tương tác hoặc hồ sơ đặc trưng của họ. Đồng thời, để tăng tính đa dạng và tránh hiện tượng “bong bóng lọc”, hệ gợi ý cũng có thể mở rộng phạm vi tìm kiếm sang các cụm lân cận, từ đó tạo ra tập gợi ý cân bằng hơn giữa độ phù hợp và tính khám phá. Cách tiếp cận này không chỉ khai thác được cấu trúc thể loại sẵn có mà còn giúp hệ gợi ý thích ứng tốt hơn với người dùng mới hoặc người dùng có sở thích không quá rõ ràng.

TÀI LIỆU THAM KHẢO

- [1] F. Maxwell Harper & J. Konstan, *"The MovieLens Datasets: History and Context"*, ACM Transactions on Interactive Intelligent Systems (TIIS), 2016.
- [2] J. Herlocker, J. Konstan, A. Borchers & J. Riedl, *"An Algorithmic Framework for Performing Collaborative Filtering"*, Proceedings of SIGIR, 1999.
- [3] G. Adomavicius & A. Tuzhilin, *"Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions"*, IEEE Transactions on Knowledge and Data Engineering (TKDE), 2005.
- [4] M. Pazzani & D. Billsus, *"Content-Based Recommendation Systems"*, The Adaptive Web, Springer, 2007.
- [5] Y. Koren, R. Bell & C. Volinsky, *"Matrix Factorization Techniques for Recommender Systems"*, IEEE Computer, 2009.
- [6] Y. Koren, *"Factorization Meets the Neighborhood: A Multifaceted Collaborative Filtering Model"*, Proceedings of KDD, 2008. (Nguồn gốc thuật toán SVD++)
- [7] S. Funk, *"Netflix Update: Try This at Home"* (Technical Report), 2006. (Giới thiệu SVD cho hệ gợi ý)
- [8] R. Salakhutdinov & A. Mnih, *"Probabilistic Matrix Factorization"*, NIPS, 2008.
- [9] F. Ricci, L. Rokach, B. Shapira, *"Recommender Systems Handbook"*, Springer, 2015. (Tổng quan CF, CBF, hybrid models)
- [10] C. Desrosiers & G. Karypis, *"A Comprehensive Survey of Neighborhood-Based Recommendation Methods"*, In: Recommender Systems Handbook, Springer, 2011.