

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HƯNG YÊN



ĐỒ ÁN 3

ỨNG DỤNG MÔ HÌNH CHỦ ĐỀ (TOPIC MODELING) ĐỂ PHÂN LOẠI CHỦ ĐỀ CHO GỢI Ý

NGÀNH: KHOA HỌC MÁY TÍNH

SINH VIÊN: HOÀNG VĂN TÀI

LỚP: 12422TN

MÃ SINH VIÊN: 10122319

NGƯỜI HƯỚNG DẪN: PGS. TS. NGUYỄN VĂN HẬU

HƯNG YÊN – 2025

NHẬN XÉT

Nhận xét của giáo viên hướng dẫn

[illegible]

GIÁO VIÊN HƯỚNG DẪN

LỜI CAM ĐOAN

Em xin cam đoan đồ án “Ứng dụng mô hình topic modeling để phân loại chủ đề cho gợi ý” là kết quả thực hiện của bản thân em dưới sự hướng dẫn của thầy Nguyễn Văn Hậu.

Những phân sử dụng tài liệu tham khảo trong đồ án đã được nêu rõ trong phần tài liệu tham khảo. Các kết quả trình bày trong đồ án và chương trình xây dựng được hoàn toàn là kết quả do bản thân em thực hiện.

Nếu vi phạm lời cam đoan này, em xin chịu hoàn toàn trách nhiệm trước khoa và nhà trường.

Hưng Yên, ngày ... tháng...năm...

Sinh viên

Hoàng Văn Tài

LỜI CẢM ƠN

Để có thể hoàn thành đồ án này, lời đầu tiên em xin phép gửi lời cảm ơn tới bộ môn Khoa học máy tính, Khoa Công nghệ thông tin – Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã tạo điều kiện thuận lợi cho em thực hiện đồ án môn học này.

Đặc biệt em xin chân thành cảm ơn thầy Nguyễn Văn Hậu đã rất tận tình hướng dẫn, chỉ bảo em trong suốt thời gian thực hiện đồ án vừa qua.

Em cũng xin chân thành cảm ơn tất cả các Thầy, các Cô trong Trường đã tận tình giảng dạy, trang bị cho em những kiến thức cần thiết, quý báu để giúp em thực hiện được đồ án này.

Mặc dù em đã có cố gắng, nhưng với trình độ còn hạn chế, trong quá trình thực hiện đề tài không tránh khỏi những thiếu sót. Em hy vọng sẽ nhận được những ý kiến nhận xét, góp ý của các Thầy cô về những kết quả triển khai trong đồ án.

Em xin trân trọng cảm ơn!

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt	Cụm từ tiếng anh	Diễn giải

MỤC LỤC ẢNH

Hình 2.1: Sơ đồ kết nối văn bản với từ vựng	15
Hình 2.2: Sơ đồ kết nối văn bản tới các từ thông qua trung gian là các topics ẩn....	16
Hình 2.3: Đồ thị của quá trình sinh trong LDA	18
Hình 2.4.....	20
Hình 3.1: Bộ dữ liệu amazon_book_review	21
Hình 3.2: Kiểm tra dữ liệu	22
Hình 3.3: Kết quả sau khi chuẩn hóa tên cột	23
Hình 3.4: Phân bố điểm đánh giá của người dùng.....	23
Hình 3.5: Mỗi quan hệ giữa điểm đánh giá và mức độ hữu ích.....	24
Hình 3.6: Mỗi quan hệ giữa giá sách và mức đánh giá của người dùng.....	25
Hình 3.7: Phân bố số lượng đánh giá của mỗi người dùng.....	26
Hình 3.8: Kết quả ma trận Bag-of-words.....	27
Hình 3.9: Đánh giá bằng 2 chỉ số.....	28
Hình 3.10: Hiển thị các chủ đề.....	30
Hình 3.11: phân phối của topic	31
Hình 3.12: Số topic tìm được trong BERTopic	32
Hình 3.13: Hiển thị các 1 số chủ đề BERTopic	32

MỤC LỤC

NHẬN XÉT	2
LỜI CAM ĐOAN	3
LỜI CẢM ƠN	4
DANH MỤC TỪ VIẾT TẮT.....	5
MỤC LỤC ẢNH	6
CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI.....	9
1.1 Lý do chọn đề tài	9
1.2 Mục tiêu của đề tài	9
1.2.1 Mục tiêu tổng quát	9
1.2.2 Mục tiêu cụ thể.....	9
1.3 Giới hạn và phạm vi của đề tài.....	10
1.3.1 Đối tượng nghiên cứu	10
1.3.2 Phạm vi nghiên cứu.....	10
1.4 Nội dung thực hiện	10
1.5 Phương pháp tiếp cận	11
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	12
2.1 Giới thiệu về hệ thống gợi ý (Recommender System).....	12
2.2 Các phương pháp gợi ý phổ biến.....	12
2.2.1 Gợi ý dựa trên nội dung (Content-based Filtering)	12
2.2.2 Gợi ý cộng tác (Collaborative Filtering – CF).....	12
2.2.3 Gợi ý lai (Hybrid Recommendation)	12
2.3 Mô hình topic modeling	13

2.3.1	Phân bố Dirichlet tiềm ẩn cho mô hình chủ đề.....	13
2.3.2	Phân tích ngữ nghĩa tiềm ẩn (LSA)	19
CHƯƠNG 3: ÁP DỤNG MÔ HÌNH.....		21
3.1	Thu thập dữ liệu	21
3.1.1	Trình bày dữ liệu bài toán.....	21
3.1.2	Tiền xử lý dữ liệu.....	21
3.2	Trực quan hóa dữ liệu.....	23
3.3	Áp dụng mô hình.....	26
3.3.1	Mô hình LDA(Latent Dirichlet Allocation).....	26
3.3.2	Mô hình BERTopic.....	31
3.3.3	So Sánh LDA và BERTopic	33
TÀI LIỆU THAM KHẢO.....		36

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI

1.1 Lý do chọn đề tài

Trong thời đại bùng nổ thông tin hiện nay, lượng dữ liệu văn bản được tạo ra hằng ngày từ các nguồn như mạng xã hội, báo chí, diễn đàn, và trang thương mại điện tử là vô cùng lớn. Việc tự động phân loại, trích xuất và gợi ý nội dung phù hợp với người dùng trở thành một thách thức quan trọng. Topic Modeling (mô hình chủ đề) là một hướng tiếp cận mạnh mẽ trong xử lý ngôn ngữ tự nhiên (NLP), giúp máy tính hiểu được cấu trúc ngữ nghĩa ẩn trong tập văn bản, từ đó phát hiện ra các chủ đề tiềm ẩn mà không cần gán nhãn thủ công.

Đề tài “Ứng dụng mô hình Topic Modeling để phân loại chủ đề cho gợi ý” được lựa chọn nhằm:

- Giúp hệ thống gợi ý nội dung (recommendation system) hoạt động thông minh hơn dựa trên các chủ đề thực chất của văn bản.
- Kết hợp giữa xử lý ngôn ngữ tự nhiên (NLP) và máy học không giám sát (unsupervised learning) để áp dụng trong thực tiễn như gợi ý bài viết, sản phẩm, hoặc tin tức theo chủ đề quan tâm.

1.2 Mục tiêu của đề tài

1.2.1 Mục tiêu tổng quát

Xây dựng một mô hình có khả năng phân tích và phân loại chủ đề tự động trong tập dữ liệu văn bản, từ đó ứng dụng kết quả để đưa ra gợi ý nội dung theo chủ đề cho người dùng.

1.2.2 Mục tiêu cụ thể

- Tìm hiểu các mô hình Topic Modeling phổ biến như LDA (Latent Dirichlet Allocation), NMF (Non-negative Matrix Factorization).
- Tiền xử lý dữ liệu văn bản tiếng Việt hoặc tiếng Anh: làm sạch, tách từ, loại bỏ stopwords.
- Xây dựng và huấn luyện mô hình phân tích chủ đề trên tập dữ liệu thu thập

được.

- Đánh giá chất lượng mô hình thông qua các chỉ số như Coherence Score hoặc Perplexity.
- Ứng dụng kết quả phân loại chủ đề để gợi ý nội dung tương tự (ví dụ: bài viết, sản phẩm, tin tức cùng chủ đề).
- Trình bày kết quả dưới dạng trực quan (biểu đồ, dashboard hoặc giao diện web).

1.3 Giới hạn và phạm vi của đề tài

1.3.1 Đối tượng nghiên cứu

- Các thuật toán và mô hình phân tích chủ đề văn bản như LDA, NMF, LSI.
- Ứng dụng mô hình Topic Modeling trong bài toán gợi ý nội dung theo chủ đề (content-based recommendation).
- Dữ liệu nghiên cứu có thể là tập văn bản thu thập từ báo điện tử, diễn đàn, hoặc bình luận người dùng.

1.3.2 Phạm vi nghiên cứu

Đề tài tập trung vào một loại dữ liệu văn bản duy nhất (ví dụ: tin tức, mô tả sản phẩm hoặc bài đăng mạng xã hội). Chỉ triển khai mô hình ở mức demo / thử nghiệm, chưa mở rộng thành hệ thống gợi ý hoàn chỉnh cho người dùng thực. Không tập trung vào các mô hình học sâu (Deep Learning) nâng cao như BERT hay GPT, mà chủ yếu khai thác mô hình thống kê cổ điển (LDA, NMF) để phân loại chủ đề. Dữ liệu có thể được giới hạn trong vài nghìn văn bản để đảm bảo khả năng xử lý trong thời gian cho phép.

1.4 Nội dung thực hiện

- Tìm hiểu cơ sở lý thuyết về Topic Modeling
- Tìm hiểu các bước tiền xử lý dữ liệu văn bản
- Thu thập và chuẩn bị dữ liệu
- Xây dựng mô hình Topic Modeling
- Phân loại và gợi ý theo chủ đề
- Đánh giá và phân tích kết quả

1.5 Phương pháp tiếp cận

Nghiên cứu cơ sở lý thuyết về xử lý ngôn ngữ tự nhiên (NLP):

- Tìm hiểu các bước xử lý văn bản trước khi đưa vào mô hình: làm sạch dữ liệu, chuẩn hóa, tách từ, loại bỏ stopwords, biểu diễn văn bản bằng TF-IDF hoặc Bag-of-Words.
- Nắm vững nguyên lý của các mô hình phân tích chủ đề như: LDA (Latent Dirichlet Allocation): mô hình xác suất sinh chủ đề dựa trên phân phối Dirichlet.
- NMF (Non-negative Matrix Factorization): mô hình phân rã ma trận phi âm để phát hiện chủ đề ẩn.
- Phân tích ưu nhược điểm của từng mô hình: LDA phù hợp với dữ liệu lớn, nhưng đòi hỏi tinh chỉnh tham số. NMF có tốc độ nhanh hơn, dễ triển khai, nhưng không mang ý nghĩa xác suất.
- Lựa chọn mô hình phù hợp: Đề tài ưu tiên LDA vì khả năng biểu diễn tốt ý nghĩa ngữ nghĩa ẩn của văn bản, phù hợp với bài toán gợi ý theo chủ đề.

Thu thập dữ liệu thực tế: Lấy dữ liệu văn bản từ các nguồn công khai như báo điện tử, diễn đàn, hoặc tập dữ liệu chuẩn (20 Newsgroups). Mỗi văn bản có thể chứa nhiều chủ đề, giúp mô hình học được phân phối chủ đề phong phú.

Tiền xử lý dữ liệu: Loại bỏ ký tự đặc biệt, dấu câu, số, ký hiệu. Chuẩn hóa chữ thường, tách từ, loại bỏ từ dừng. Biểu diễn văn bản dưới dạng vector từ điển (TF-IDF hoặc CountVectorizer).

Huấn luyện mô hình Topic Modeling: Sử dụng thư viện gensim hoặc scikit-learn để huấn luyện mô hình LDA/NMF. Thử nghiệm nhiều giá trị số chủ đề (k) để chọn mô hình tốt nhất dựa trên Coherence Score. Phân loại và gợi ý chủ đề: Gán mỗi văn bản vào chủ đề chiếm ưu thế nhất. Tính độ tương đồng giữa các văn bản bằng cosine similarity để gợi ý nội dung tương tự.

Đánh giá kết quả: Đánh giá độ mạch lạc của chủ đề và tính phù hợp của gợi ý.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1 Giới thiệu về hệ thống gợi ý (Recommender System)

Hệ thống gợi ý (RS – Recommender System) là các mô hình hoặc thuật toán giúp dự đoán mức độ quan tâm của người dùng đối với các sản phẩm hoặc nội dung chưa từng tương tác trước đó. Mục tiêu chính là cá nhân hóa trải nghiệm người dùng, đồng thời tăng tỉ lệ tương tác và doanh thu cho nền tảng. Trong lĩnh vực thời trang, hệ thống gợi ý đóng vai trò then chốt trong việc giúp người dùng tìm kiếm sản phẩm phù hợp với gu thẩm mỹ, nhu cầu, và ngữ cảnh (mùa, sự kiện, phong cách, v.v.).

2.2 Các phương pháp gợi ý phổ biến

2.2.1 Gợi ý dựa trên nội dung (Content-based Filtering)

Phương pháp này dựa vào đặc trưng của sản phẩm và sở thích của người dùng trong quá khứ.

Ví dụ: Nếu người dùng thích “áo sơ mi trắng”, hệ thống sẽ gợi ý các sản phẩm có đặc trưng tương tự (chất liệu cotton, màu sáng, phong cách basic).

Đặc trưng của sản phẩm có thể được mô tả bằng:

- Thuộc tính thủ công: màu sắc, kiểu dáng, thương hiệu, giới tính.
- Đặc trưng trích xuất tự động: embedding từ mô hình học sâu (ví dụ: CNN cho ảnh, BERT cho mô tả văn bản).

2.2.2 Gợi ý cộng tác (Collaborative Filtering – CF)

Dựa vào hành vi tương tác của người dùng (mua hàng, đánh giá, click, lưu sản phẩm).

Các kỹ thuật chính:

- User-based CF: tìm người dùng tương tự.
- Item-based CF: tìm sản phẩm tương tự.
- Matrix Factorization: phân rã ma trận người dùng – sản phẩm thành embedding ẩn.

Nhược điểm: khó hoạt động tốt với item mới (cold start) hoặc dữ liệu thưa.

2.2.3 Gợi ý lai (Hybrid Recommendation)

Kết hợp nhiều phương pháp (Content-based + Collaborative + Knowledge-based) nhằm tận dụng ưu điểm và khắc phục nhược điểm từng loại. Đối với thời trang, hybrid

model thường kết hợp thông tin hình ảnh, mô tả văn bản, và phản hồi người dùng để tạo gợi ý chính xác và tự nhiên hơn.

2.3 Mô hình topic modeling

Topic Modeling là một kỹ thuật xử lý ngôn ngữ tự nhiên giúp khám phá các chủ đề hoặc chủ điểm ẩn trong các tập dữ liệu văn bản lớn bằng cách phân tích các mẫu từ và nhóm các tài liệu tương tự lại với nhau. Các phương pháp như Phân bố Dirichlet Ngầm (LDA) giúp sắp xếp văn bản phi cấu trúc, chẳng hạn như bài viết hoặc bài đăng trên mạng xã hội, giúp việc hiểu văn bản trở nên dễ dàng hơn. Đọc bài viết này, bạn sẽ hiểu rõ cách thức hoạt động của mô hình hóa chủ đề, các ứng dụng thực tế của nó, và cách nó có thể tiết kiệm thời gian, cải thiện phân tích dữ liệu và khám phá các xu hướng có giá trị trong dữ liệu văn bản, biến nó thành một công cụ mạnh mẽ cho bất kỳ ai làm việc với khối lượng thông tin lớn.

2.3.1 Phân bố Dirichlet tiềm ẩn cho mô hình chủ đề

Có nhiều phương pháp để lấy chủ đề từ văn bản, chẳng hạn như – Tần suất Thuật ngữ và Tần suất Văn bản Nghịch đảo. Các kỹ thuật Phân tích Ma trận Không Âm. Phân bố Dirichlet Tiềm ẩn là kỹ thuật mô hình hóa chủ đề phổ biến nhất và trong bài viết này, chúng ta sẽ thảo luận về kỹ thuật này.

LDA giả định rằng các tài liệu được tạo ra từ nhiều chủ đề khác nhau. Các chủ đề này sau đó tạo ra các từ dựa trên phân phối xác suất của chúng. Với một tập dữ liệu tài liệu, LDA sẽ truy ngược và cố gắng tìm ra chủ đề nào sẽ tạo ra các tài liệu đó ngay từ đầu.

LDA là một kỹ thuật phân tích ma trận. Trong không gian vector, bất kỳ kho ngữ liệu (tập hợp tài liệu) nào cũng có thể được biểu diễn dưới dạng ma trận thuật ngữ tài liệu. Ma trận sau đây thể hiện kho ngữ liệu gồm N tài liệu D1, D2, D3 ... Dn và kích thước từ vựng của M từ W1, W2 .. Wn. Giá trị của ô i,j cho biết tần suất xuất hiện của từ Wj trong Tài liệu Di.

	W1	W2	W3	Wn
D1	0	2	1	3
D2	1	4	0	0
D3	0	2	3	1
Dn	1	1	3	0

LDA chuyển đổi Ma trận Tài liệu-Thuật ngữ này thành hai ma trận chiều thấp hơn – M1 và M2. M1 là ma trận chủ đề tài liệu và M2 là ma trận chủ đề-thuật ngữ với chiều tương ứng là (N, K) và (K, M) , trong đó N là số lượng tài liệu, K là số lượng chủ đề và M là kích thước từ vựng.

	K1	K2	K3	K
D1	1	0	0	1
D2	1	1	0	0
D3	1	0	0	1
Dn	1	0	1	0

	W1	W2	W3	Wm
K1	0	1	1	1
K2	1	1	1	0
K3	1	0	0	1
K	1	1	0	0

Lưu ý rằng hai ma trận này đã cung cấp phân phối chủ đề từ và chủ đề tài liệu. Tuy nhiên, phân phối này cần được cải thiện, đó là mục tiêu chính của LDA. LDA sử dụng các kỹ thuật lấy mẫu để cải thiện các ma trận này.

Nó lặp lại từng từ "w" cho mỗi tài liệu "d" và cố gắng điều chỉnh chủ đề hiện tại – gán từ bằng một phép gán mới. Một chủ đề mới "k" được gán cho từ "w" với xác suất P là tích của hai xác suất $p1$ và $p2$. Với mỗi chủ đề, hai xác suất $p1$ và $p2$ được tính toán. $P1 - p(\text{chủ đề } t / \text{tài liệu } d) = \text{tỷ lệ các từ trong tài liệu } d \text{ hiện đang được gán cho chủ đề } t$. $P2 - p(\text{từ } w / \text{chủ đề } t) = \text{tỷ lệ các phép gán cho chủ đề } t \text{ trên tất cả các tài liệu bắt nguồn từ từ } w \text{ này}$.


Việc gán chủ đề - từ hiện tại được cập nhật với một chủ đề mới với xác suất là tích của $p1$ và $p2$. Trong bước này, mô hình giả định rằng tất cả các phép gán từ - chủ đề hiện có, ngoại trừ từ hiện tại, đều đúng.

Về cơ bản, đây là xác suất mà chủ đề t tạo ra từ w , do đó, việc điều chỉnh chủ đề của từ hiện tại với xác suất mới là hợp lý. Sau một số lần lặp lại, trạng thái ổn định đạt được khi phân phối chủ đề và thuật ngữ chủ đề của tài liệu khá tốt. Đây chính là điểm hội tụ của LDA.

a) LDA giảm thiểu khối lượng tính toán

Giả định rằng chúng ta có 1000 từ có tần suất xuất hiện nhiều nhất trong văn bản và chúng ta có 1000 văn bản. Giả sử mỗi văn bản có 500 từ xuất hiện bên trong chúng.

Làm thế nào để chúng ta có thể hiểu được các văn bản này thuộc về những nhóm nào? Một cách đơn giản là kết nối mỗi văn bản với một từ bằng 1 thread dựa trên sự xuất hiện của từ đó trong văn bản như sơ đồ bên dưới.




Hình 2.1: Sơ đồ kết nối văn bản với từ vựng.

Thông qua việc thống kê tần suất xuất hiện của các từ quan trọng trong một văn bản ta nhận thấy rằng có một số văn bản sẽ có một tập hợp các từ gần như nhau. Do đó chúng sẽ liên quan với nhau về một chủ đề nào đó. Nhưng để làm như vậy chúng ta cần có $\text{num_words} * \text{num_documents} = 500 * 1000 = 500000$ threads cho nó. Số lượng này tạo ra một chi phí tính toán rất lớn. Chính vì thế một cách đơn giản và tốn kém ít chi phí hơn đó là tìm cách giảm số lượng các kết nối giữa documents và words bằng cách tạo ra những topics trung gian nhóm các từ liên quan vào chung 1 nhóm và kết nối thông qua các nhóm này.

b) Làm thế nào để giảm chiều dữ liệu

Chúng ta có thể giải quyết vấn đề này bằng cách thêm một layer nhân tố ẩn có số units tương ứng với số lượng các topics mà chúng ta xác định sẽ có trong mô hình. Giả định chúng ta biết 10 topics có thể xuất hiện trong toàn bộ các văn bản. Những topics này có tính ẩn tức là chúng là tưởng tượng và không thể định nghĩa chính xác topics và mục đích chính khi sử dụng những topics này làm trung gian là giảm số lượng threads kết nối đến documents và từ đó giảm chi phí tính toán. Sau đó để tìm ra phân phối của văn bản theo các từ chứa trong nó, chúng ta sẽ kết nối các từ đến topic mà nó thuộc về và kết nối các topics đến các văn bản dựa trên loại topics mà mỗi văn bản chứa.

Nhưng vậy mỗi văn bản sẽ có khoảng 10 topics và mỗi topic sẽ có 500 từ. Số lượng threads lúc này sẽ là 20000 threads bao gồm 10000 threads kết nối giữa 1000 văn bản đến 10 topics và 10000 threads kết nối 10 topics đến 1000 từ vựng. Như chúng ta có thể hình dung ở hình dưới:



Hình 2.2: Sơ đồ kết nối văn bản tới các từ thông qua trung gian là các topics ẩn

c) Lý thuyết về model LDA

Các định nghĩa

Một số định nghĩa mà chúng ta sẽ sử dụng trong mô hình LDA:

- Từ (word): Là đơn vị cơ bản nhất của LDA. Một từ được xác định bởi một chỉ số index trong từ điển có giá trị từ 1 đến V . Một từ thứ i được biểu diễn dưới dạng one-hot véc tơ sao cho phần tử thứ i của véc tơ bằng 1 và các phần tử còn lại bằng 0.
- Văn bản (document): là một tập hợp của từ được kí hiệu bởi d . Mỗi một véc tơ đại diện cho 1 từ trong câu.
- Bộ văn bản (corpus): Là tập hợp của văn bản kí hiệu bởi C .
- Topic ẩn (latent topic): Là những chủ đề ẩn được xác định dựa trên phân phối của các từ và làm trung gian biểu diễn các văn bản theo topic. Số lượng topic được xác định trước và kí hiệu là K .

Chúng ta sẽ tìm ra một mô hình xác suất cho hàm ước lượng hợp lý tối đa của bộ văn bản sẽ có xác suất lớn nhất và các văn bản có nội dung gần nhau sẽ có mức độ tương quan lớn.

Latent Dirichlet Allocation (LDA) là mô hình thuộc lớp mô hình sinh xác suất (generative probabilistic model) của một bộ văn bản. Ý tưởng cơ bản của mô hình đó là mỗi một văn bản được biểu diễn bởi một hỗn hợp ngẫu nhiên của các topics ẩn, mỗi một topic được đặc tả bởi phân phối của nhóm các từ.


Các tham số của mô hình

- α là tham số của phân phối tiên nghiệm Dirichlet của topic đối với mỗi văn bản.
- β là tham số của phân phối tiên nghiệm Dirichlet của topic đối với mỗi từ.
- θ_i là phân phối của topic đối với văn bản thứ i .
- ϕ_k là phân phối của từ đối với topic thứ k .
- Z_{ij} là topic của từ thứ j đối với văn bản thứ i . Là một số nguyên có giá trị trong khoảng $[1, K]$.
- w_{ij} là index trong vocabulary của từ thứ i thuộc văn bản thứ j . Giá trị là một số nguyên trong khoảng $[1, V]$.

Trong mô hình LDA biến duy nhất mà chúng ta quan sát được là các từ w_{ij} , các biến còn lại đều là những nhân tố ẩn được sinh ra từ các phân phối xác định. Trong đó quan trọng nhất là một phân phối tiên nghiệm Dirichlet được sử dụng để mô hình hóa phân phối của các cặp topic-word. Phân phối của một topic qua các từ thường có skew lớn (phân phối dạng nhọn, đuôi mỏng) để xác suất tập trung vào một nhóm nhỏ các từ. K kí hiệu số lượng topic và $\phi_1, \dots, \phi_K$ là những véc tơ V chiều (V là kích thước của vocabulary) lưu các tham số phân phối Dirichlet của các topic theo từ.

Ta cũng có thể coi rằng θ và ϕ tương tự như những ma trận được tạo ra từ phép phân tích suy biến từ ma trận document-word ở thuật toán LSA. Theo đó mỗi dòng của θ tương ứng với văn bản và mỗi cột tương ứng với topic; và ϕ bao gồm các dòng tương ứng topic và các cột tương ứng với các từ.

d) Quá trình sinh



Hình 2.3: Đồ thị của quá trình sinh trong LDA

Như vậy ta có thể thấy có 2 quá trình lặp lại liên tục trong LDA là quá trình lựa chọn topic và quá trình lựa chọn từ. Các tham số được khởi tạo tiến trình ban đầu là α và β . Từ đó tính toán được phân phối hỗn hợp của topic θ và phân phối của từ theo topic w . Phân phối xác suất của văn bản được tạo ra dưới dạng trộn lẫn ngẫu nhiên các topics, trong đó mỗi topic được xác lập bởi phân phối trên toàn bộ các từ. LDA giả định một tiến trình sinh cho bộ văn bản D bao gồm M văn bản như sau:

- Với mỗi một văn bản lựa chọn độ dài văn bản $N \sim \text{Poisson}$
- Lựa chọn ma trận $\theta \sim \text{Dir}(\alpha)$. Sao cho tham số θ_i chính là phân phối topic của văn bản thứ i . Tham số α thường là một véc tơ thưa k chiều với đa số các thành phần bằng 0. Mỗi chiều của α đặc trưng cho 1 topic.
- Lựa chọn $\phi \sim \text{Dir}(\beta)$ đại diện cho phân phối của từ theo topic. Tương tự như α , β cũng là một véc tơ thưa k chiều mà mỗi chiều của nó đặc trưng cho 1 topic. Các tham số của phân phối được lựa chọn là véc tơ thưa nhằm mục đích để mỗi một topic chỉ được giải thích bởi một nhóm nhỏ các từ thuộc về topic đó.

Lưu ý rằng multinomial ở đây là những multinomial với 1 phép thử duy nhất nên nó tương đương với phân phối categorical.

Việc đầu tiên là chúng ta giả định số lượng topics ẩn là đã biết và bằng k , và do đó k cũng sẽ quy định số chiều của phân phối Dirichlet. Thứ 2, chúng ta xác định xác suất của từ được tham số hóa bằng một ma trận $\beta \in \mathbb{R}^{k \times V}$ với mỗi phần tử β_{ij} đặc trưng cho phân phối xác suất của từ thứ j cho chủ đề i hay $\beta_{ij} = p(w_j = 1 \mid z_i = 1)$. Sau đó

chúng ta sẽ cố định các tham số này. Khi đó ta sẽ tính được hàm mật độ xác suất của các topics đối với mỗi văn bản khi đã biết tham số α theo phân phối Dirichlet:

$$f(\theta; \alpha) = \frac{(\Gamma(\sum_{i=1}^K \alpha_i))}{(\prod_{i=1}^K \Gamma(\alpha_i))} \prod_{i=1}^K \theta_i^{\alpha_i-1} \quad (*)$$

Khi đó phân phối xác suất chung của hỗn hợp topic θ với tập N topic z và tập N từ w tại các α, β đã biết chính là:

$$p(\theta, z, w | \alpha, \beta) = p(\theta | \alpha) \prod_{i=1}^N p(z_n | \theta) p(w_n | z_n, \beta) \quad (*)$$

Thành phần $p(\theta | \alpha)$ chính là phân phối xác suất hỗn hợp topic tương ứng với văn bản khi đã biết trước tham số phân phối Dirichlet α . Về còn lại $\prod_{i=1}^N p(z_n | \theta) p(w_n | z_n, \beta)$ chính là phân phối xác suất khi đã biết trước phân phối hỗn hợp topic θ và tham số phân phối Dirichlet β .

Nếu lấy xác suất biên của một văn bản bằng cách tích phân theo θ và lấy tổng toàn bộ các z ta sẽ được:

$$p(w | \alpha, \beta) = \int p(\theta | \alpha) \prod_{i=1}^N \sum_{z_n} p(z_n | \theta) p(w_n | z_n, \beta) d\theta \quad (*)$$


Và cuối cùng, xác suất của toàn bộ tập dữ liệu (văn bản) $\mathcal{D}$ dựa trên xác suất biên từ mỗi văn bản:

$$p(\mathcal{D} | \alpha, \beta) = \prod_{d=1}^M \int p(\theta_d | \alpha) \prod_{i=1}^N \sum_{z_n} p(z_n | \theta) p(w_n | z_n, \beta) d\theta_d \quad (*)$$

2.3.2 Phân tích ngữ nghĩa tiềm ẩn (LSA)

Phân tích Ngữ nghĩa Tiềm ẩn (LSA) là một phương pháp được sử dụng để tìm kiếm ý nghĩa ẩn trong văn bản. Phương pháp này xem xét cách các từ xuất hiện trong các tài liệu khác nhau và khám phá các mẫu hình sử dụng của chúng. Thay vì chỉ đếm tần suất xuất hiện của các từ, LSA cố gắng hiểu ngữ cảnh và mối quan hệ giữa các từ. Phương pháp này hoạt động bằng cách chuyển đổi văn bản thành một bảng lớn về số

lượng từ, sau đó sử dụng toán học để thu nhỏ bảng đó, chỉ giữ lại những phần quan trọng nhất. Điều này giúp máy tính nhóm các từ và tài liệu tương tự lại với nhau dựa trên ý nghĩa chứ không chỉ dựa trên các từ chính xác.



Hình 2.4

CHƯƠNG 3: ỨNG DỤNG MÔ HÌNH

3.1 Thu thập dữ liệu

3.1.1 Trình bày dữ liệu bài toán

Dữ liệu được thu thập từ kaggle

<https://www.kaggle.com/datasets/mohamedbakhmet/amazon-books-reviews> bộ

dataset có tên: amazon_book_review

... (3000000, 10)

	Id	Title	Price	User_id	profileName	review/helpfulness	review/score	review/time	review/summary	review/text
0	1882931173	Its Only Art If Its Well Hung!	NaN	AVCGYZL8FQQTD	Jim of Oz "jim-of-oz"	7/7	4.0	940636800	Nice collection of Julie Strain images	This is only for Julie Strain fans. It's a col...
1	0826414346	Dr. Seuss: American Icon	NaN	A30TK6U7DNS82R	Kevin Killian	10/10	5.0	1095724800	Really Enjoyed It	I don't care much for Dr. Seuss but after read...
2	0826414346	Dr. Seuss: American Icon	NaN	A3UH4UZ4RSVO82	John Granger	10/11	5.0	1078790400	Essential for every personal and Public Library	If people become the books they read and if "t...
3	0826414346	Dr. Seuss: American Icon	NaN	A2MVUWT453QH61	Roy E. Perry "amateur philosopher"	7/7	4.0	1090713600	Philip Nel gives silly Seuss a serious treatment	Theodore Seuss Geisel (1904-1991), aka "D...
4	0826414346	Dr. Seuss: American Icon	NaN	A22X4XUPKF66MR	D. H. Richards "ninthwavestore"	3/3	4.0	1107993600	Good academic overview	Philip Nel - Dr. Seuss: American IconThis is b...

Hình 3.1: Bộ dữ liệu amazon_book_review

- Dữ liệu gồm 3.000.000 bản ghi và gồm 10 cột gồm:
 - Id: Mã sản phẩm trên amazon dùng để định danh sách được review
 - Title: Tên sách tương ứng với ID
 - Price: Giá sách
 - User_id: Mã người dùng
 - Profile_name: Tên hiển thị
 - Review/helpfulness: Định danh x/y, x số người thấy hữu ích, y tổng số người đánh giá review đó
 - Review/score: Số sao đánh giá
 - Review/time: Thời gian review, lưu dưới dạng
 - Review/text: Nội dung đầy đủ của văn bản

3.1.2 Tiền xử lý dữ liệu

- kiểm tra dữ liệu khuyết thiếu

```
print(df.info())  
  
print(df.describe())  
  
print(df.dtypes)
```

Hình 3.2: Kiểm tra dữ liệu

Trong quá trình tiền xử lý dữ liệu, nhận thấy bộ dữ liệu đã được chuẩn hóa và làm sạch rất tốt từ trước. Các giá trị bị thiếu, trùng lặp hoặc ngoại lệ hầu như không xuất hiện, đồng thời các thuộc tính cũng đã được định dạng đúng kiểu dữ liệu. Vì vậy, tôi không cần thực hiện thêm các bước xử lý như loại bỏ nhiễu, chuẩn hoá dữ liệu hay mã hoá lại biến. Điều này giúp rút ngắn thời gian tiền xử lý và cho phép tập trung trực tiếp vào các bước phân tích và xây dựng mô hình.

b) Xóa dữ liệu thiếu và không quan trọng

Các cột như: profileName, review/time, review/helpfulness, Price không ảnh hưởng đến kết quả mô hình nên loại bỏ để giảm thiểu dữ liệu, Tránh nhiễu và đơn giản hóa mô hình Các thuộc tính không liên quan có thể: Gây nhiễu trong phân tích Làm mô hình học các đặc trưng không cần thiết Việc chọn lọc cột giúp: Dữ liệu rõ ràng hơn Kết quả topic có tính diễn giải cao

c) Chuẩn hóa định dạng tên cột

Việc chuẩn hóa tên thuộc tính giúp đảm bảo tính nhất quán trong quá trình tiền xử lý dữ liệu, giảm nguy cơ lỗi khi thao tác trên DataFrame và tạo điều kiện thuận lợi cho việc xây dựng pipeline xử lý văn bản và hệ thống gợi ý.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3000000 entries, 0 to 2999999
Data columns (total 10 columns):
#   Column      Dtype
---  -
0   Id           object
1   Title        object
2   Price        float64
3   user_id      object
4   profileName  object
5   helpfulness  object
6   rating       float64
7   review_time  int64
8   summary      object
9   review_text  object
dtypes: float64(2), int64(1), object(7)
memory usage: 228.9+ MB
```


Hình 3.3: Kết quả sau khi chuẩn hóa tên cột

d) Chuyển cột helpfulness từ dạng chuỗi “x/y” sang một giá trị số thể hiện mức độ hữu ích của review.

Chuẩn hóa dữ liệu cho Machine Learning ML không xử lý tốt chuỗi dạng “x/y” Tỷ lệ số giúp: Dễ học Dễ so sánh giữa các review. Nâng cao chất lượng mô hình Review có helpfulness cao → đáng tin cậy hơn Có thể dùng làm: Trọng số cho topic modeling Ưu tiên review chất lượng trong recommendation. Thuộc tính helpfulness được chuyển đổi từ dạng chuỗi sang tỷ lệ số nhằm phản ánh mức độ hữu ích của mỗi đánh giá. Việc chuẩn hóa này giúp dữ liệu phù hợp hơn cho các bước phân tích và xây dựng mô hình gợi ý.

3.2 Trực quan hóa dữ liệu

a) Trực quan hóa phân bố điểm đánh giá (rating) của người dùng




Hình 3.4: Phân bố điểm đánh giá của người dùng

Phân tích hành vi người dùng Quan sát xu hướng: Người dùng đánh giá cao hay thấp? Có thiên lệch về rating 4–5 sao không? Phát hiện mất cân bằng dữ liệu (Data Imbalance) Dataset Amazon thường có: Nhiều review 4–5 sao Ít review 1–2 sao Điều này ảnh hưởng đến: Recommendation System Sentiment analysis Đánh trọng số rating

Phân tích phân bố điểm đánh giá cho thấy sự mất cân bằng giữa các mức rating, trong đó các đánh giá tích cực chiếm tỷ lệ lớn. Nhận xét này đóng vai trò quan trọng trong việc lựa chọn và điều chỉnh các phương pháp xây dựng hệ thống gợi ý.

b) Phân tích mối quan hệ giữa điểm đánh giá (rating) và mức độ hữu ích của review (helpfulness ratio).




Hình 3.5: Mối quan hệ giữa điểm đánh giá và mức độ hữu ích

Phân tích chất lượng review Biểu đồ cho phép quan sát: Review có rating cao có thực sự hữu ích hơn không? Review rating thấp nhưng helpfulness cao → review phê bình chi tiết. Hỗ trợ thiết kế trọng số cho mô hình Nếu review có helpfulness cao tập trung ở: Rating cao → ưu tiên review tích cực Rating trung bình → thông tin cân bằng, giàu nội dung. Có thể dùng helpfulness_ratio làm trọng số cho topic modeling hoặc recommendation. Phát hiện xu hướng và ngoại lệ. Các điểm: Rating thấp nhưng helpfulness cao → review đáng chú ý Rating cao nhưng helpfulness thấp → review ngắn, ít thông tin

Phân tích mối tương quan giữa rating và helpfulness ratio cho thấy rằng các đánh giá có nội dung chi tiết và mang tính phản biện thường nhận được mức độ hữu ích cao, ngay cả khi điểm đánh giá không ở mức tối đa.

c) Mối quan hệ giữa giá sách và mức đánh giá của người dùng




Hình 3.6: Mối quan hệ giữa giá sách và mức đánh giá của người dùng

Phân tích mối quan hệ giữa giá và mức độ hài lòng Biểu đồ giúp trả lời các câu hỏi: Sách đắt hơn có được đánh giá cao hơn không? Giá có ảnh hưởng trực tiếp đến cảm nhận của người đọc không? Phát hiện xu hướng và ngoại lệ Các điểm: Giá cao nhưng rating thấp → kỳ vọng cao nhưng không hài lòng Giá thấp nhưng rating cao → sách giá trị tốt Những ngoại lệ này có thể cung cấp insight quan trọng cho hệ thống gợi ý. Hỗ trợ thiết kế Recommendation System Nếu không có mối tương quan rõ ràng: Rating nên được ưu tiên hơn giá Nếu có xu hướng: Có thể tích hợp Price như một yếu tố phụ trong recommendation (filter hoặc ranking).

Phân tích mối quan hệ giữa giá sách và điểm đánh giá cho thấy yếu tố giá không phải là yếu tố quyết định chính đến mức độ hài lòng của người dùng, qua đó khẳng định vai trò quan trọng của nội dung và chất lượng sách trong hệ thống gợi ý.

d) Phân tích phân bố số lượng đánh giá mà mỗi người dùng



Hình 3.7: Phân bố số lượng đánh giá của mỗi người dùng

Phát hiện hiện tượng Long-tail Đa số người dùng: Chỉ viết rất ít review Một số ít người dùng: Viết rất nhiều review Đây là đặc trưng phổ biến của các hệ thống trực tuyến. Ảnh hưởng đến Recommendation System Dữ liệu người dùng không đồng đều Gây ra: Cold-start user (người dùng mới, ít dữ liệu) Bias về người dùng hoạt động nhiều. Cơ sở cho các quyết định xử lý tiếp theo Từ biểu đồ có thể: Lọc người dùng quá ít review Áp dụng regularization Kết hợp content-based recommendation để giảm cold-start

Phân tích mức độ hoạt động của người dùng cho thấy sự mất cân bằng rõ rệt trong dữ liệu, đặt ra thách thức cho các phương pháp collaborative filtering truyền thống và nhấn mạnh sự cần thiết của các phương pháp lai (hybrid recommendation).

3.3 Áp dụng mô hình

3.3.1 Mô hình LDA(Latent Dirichlet Allocation)

a) Gộp nội dung review (summary + review_text)

Mục đích: Kết hợp tiêu đề review (summary) và nội dung review (review_text) thành một văn bản hoàn chỉnh. Tăng lượng thông tin ngữ nghĩa cho mỗi tài liệu.

Ý nghĩa trong nghiên cứu: Summary thường ngắn gọn, súc tích Review text chi tiết hơn → Gộp lại giúp mô hình topic học chủ đề tốt hơn.

b) Lấy mẫu dữ liệu (Sampling)

Mục đích: Lấy 50.000 review ngẫu nhiên từ tập dữ liệu lớn. Lý do cần sampling: Dataset Amazon Books có hàng triệu review LDA với Bag-of-Words rất tốn RAM

& thời gian Sampling giúp: Huấn luyện nhanh hơn Phù hợp với Colab / máy cá nhân
`random.seed(42)`: Đảm bảo kết quả có thể tái lập (reproducibility).

c) Tiền xử lý văn bản (Text Preprocessing)

Các bước: `lower()` → đưa về chữ thường Regex → loại bỏ: Số Ký tự đặc biệt Dấu câu, Mục đích: Giảm nhiễu Chuẩn hóa văn bản Phù hợp cho LDA truyền thống

d) Biểu diễn văn bản bằng Bag-of-Words

Ý nghĩa các tham số: `stop_words='english'` → Loại bỏ từ dừng (the, is, and...) `max_df=0.6` → Loại từ xuất hiện ở >60% tài liệu (từ quá chung) `min_df=30` → Chỉ giữ từ xuất hiện ít nhất 30 lần (loại từ hiếm) `max_features=30000` → Giới hạn số từ vựng để giảm chiều dữ liệu `gram_range=(1,2)` → Sử dụng unigram + bigram → Bắt được cụm từ như “science fiction”

Kích thước ma trận Bag-of-Words: (50000, 13957)

Hình 3.8: Kết quả ma trận Bag-of-words


e) Đánh giá mô hình LDA theo số lượng chủ đề (Number of Topics)

Mục tiêu của thí nghiệm này là **xác định số lượng chủ đề (k) phù hợp** cho mô hình Latent Dirichlet Allocation (LDA) khi áp dụng trên tập dữ liệu review sách. Việc lựa chọn k ảnh hưởng trực tiếp đến khả năng biểu diễn ngữ nghĩa và độ diễn giải của mô hình.

`k_values = [5, 10, 15, 20, 30]` Mô hình LDA được huấn luyện với các giá trị k khác nhau, đại diện cho các mức độ chi tiết của không gian chủ đề: k nhỏ: chủ đề tổng quát, dễ diễn giải nhưng thiếu chi tiết k lớn: chủ đề chi tiết hơn nhưng dễ bị trùng lặp hoặc nhiễu

huấn luyện mô hình các tham số `n_components = k`: số lượng chủ đề cần học `max_iter = 15`: số vòng lặp tối đa của thuật toán EM `learning_method = 'batch'`: Sử dụng toàn bộ tập dữ liệu trong mỗi vòng lặp Phù hợp với bài toán đánh giá mô hình và dữ liệu có kích thước trung bình `random_state = 42`: đảm bảo khả năng tái lập kết quả `n_jobs = -1`: tận dụng toàn bộ CPU để tăng tốc huấn luyện

Đánh giá mô hình Sau khi huấn luyện



Hình 3.9: Đánh giá bằng 2 chỉ số

- Perplexity Đo lường khả năng mô hình dự đoán dữ liệu văn bản Được hiểu là mức độ “bối rối” của mô hình Giá trị càng thấp → mô hình càng tốt Perplexity được sử dụng rộng rãi trong các bài toán Topic Modeling để đánh giá chất lượng mô hình.
- Log-likelihood Đo mức độ phù hợp của mô hình với dữ liệu huấn luyện Giá trị càng cao (ít âm hơn) → mô hình càng phù hợp Log-likelihood phản ánh khả năng mô hình giải thích dữ liệu quan sát.
- Quy trình đánh giá Với mỗi giá trị k, mô hình LDA được: Huấn luyện trên cùng một tập dữ liệu Bag-of-Words Đánh giá bằng Perplexity và Log-likelihood Lưu lại kết quả để so sánh giữa các mô hình Việc sử dụng cùng tập dữ liệu và cùng cấu hình huấn luyện giúp đảm bảo tính công bằng trong so sánh.
- Ý nghĩa thực nghiệm Khi k tăng: Perplexity thường giảm do mô hình có nhiều tham số hơn Log-likelihood tăng do mô hình fit tốt hơn Tuy nhiên, k quá lớn có thể: Gây overfitting Sinh ra các topic trùng lặp hoặc khó diễn giải Do đó, số topic được lựa chọn là giá trị cân bằng giữa chất lượng thống kê và khả năng diễn giải ngữ nghĩa.

Kết quả thực nghiệm cho thấy khi số lượng chủ đề tăng, mô hình LDA đạt được perplexity thấp hơn và log-likelihood cao hơn. Tuy nhiên, sự cải thiện dần trở nên không đáng kể khi k vượt quá một ngưỡng nhất định. Dựa trên cả hai chỉ số đánh giá

và khả năng diễn giải các chủ đề, nghiên cứu lựa chọn giá trị k phù hợp cho mô hình LDA trong các thí nghiệm tiếp theo.

f) Trích xuất và diễn giải các chủ đề từ mô hình LDA

Sau khi xác định số lượng chủ đề phù hợp ($k = 15$), bước tiếp theo là huấn luyện mô hình LDA cuối cùng và diễn giải ý nghĩa của từng chủ đề thông qua các từ khóa đại diện. Điều này giúp đánh giá tính ngữ nghĩa và khả năng diễn giải của mô hình topic modeling.

Lấy danh sách đặc trưng từ Bag-of-Words `feature_names` là danh sách toàn bộ: Từ đơn (unigram) Cụm từ 2 từ (bigram) được sinh ra từ mô hình `CountVectorizer`. Mỗi cột trong ma trận Bag-of-Words tương ứng với một từ / cụm từ trong danh sách này. Hàm trích xuất từ khóa đại diện cho mỗi topic Hàm này được xây dựng nhằm hiển thị các từ khóa quan trọng nhất của từng chủ đề, giúp người nghiên cứu hiểu và đặt tên cho topic.

Huấn luyện mô hình LDA cuối cùng Giá trị k được chọn dựa trên: Perplexity Log-likelihood Khả năng diễn giải chủ đề Cấu hình giống thí nghiệm trước để đảm bảo tính nhất quán Mô hình này được dùng cho: Phân tích nội dung Gán topic cho review Ứng dụng trong recommendation system

Mô hình LDA cuối cùng với 15 chủ đề được huấn luyện và mỗi chủ đề được diễn giải thông qua các từ khóa có trọng số cao nhất. Kết quả cho thấy các chủ đề có tính ngữ nghĩa rõ ràng và phản ánh các nhóm nội dung khác nhau trong tập dữ liệu đánh giá sách.

```
=== Topic 0 ===
like, read, really, good, just, dont, think, know, people, reading, didnt, did, im, thought, want

=== Topic 1 ===
war, history, american, world, time, people, america, years, historical, life, country, political, great, century, men

=== Topic 2 ===
god, christian, bible, church, faith, jesus, read, philosophy, life, religion, religious, lewis, christianity, christ, gods

=== Topic 3 ===
love, women, novel, woman, jane, young, family, characters, men, life, mr, man, little, austen, marriage

=== Topic 4 ===
great, buy, bought, good, books, just, copy, cover, time, new, money, like, pictures, old, little

=== Topic 5 ===
world, human, life, story, society, novel, lord, people, reader, hobbit, fantasy, evil, nature, man, rings

=== Topic 6 ===
people, life, way, make, work, does, need, like, think, real, just, business, right, things, change

=== Topic 7 ===
science, time, author, like, work, fiction, read, authors, fact, does, point, written, think, writing, just

=== Topic 8 ===
characters, story, novel, read, plot, character, like, just, time, writing, end, books, series, good, pages

=== Topic 9 ===
story, life, love, family, man, old, mother, young, father, home, new, little, children, girl, boy
```

Hình 3.10: Hiển thị các chủ đề

g) Phân phối chủ đề của một văn bản cụ thể

Mục tiêu của bước này là minh họa cách mô hình LDA gán các chủ đề cho một review cụ thể, từ đó kiểm tra: Tính nhất quán ngữ nghĩa của mô hình Khả năng biểu diễn một văn bản dưới dạng phân phối xác suất trên không gian chủ đề

Lựa chọn văn bản phân tích `doc_id` là chỉ số của review được chọn trong tập dữ liệu Việc chọn một review cụ thể giúp: Trực quan hóa kết quả mô hình Đánh giá chất lượng topic modeling ở mức độ từng văn bản

Biểu diễn văn bản dưới dạng Bag-of-Words X là ma trận Bag-of-Words đã được vector hóa `doc_vector` là vector đặc trưng của review thứ `doc_id` Vector này phản ánh: Số lần xuất hiện của từng từ trong từ điển

```

Phân phối topic của review 1000:

Topic 0: 0.1445
Topic 1: 0.0333
Topic 2: 0.0005
Topic 3: 0.1313
Topic 4: 0.0714
Topic 5: 0.0005
Topic 6: 0.0005
Topic 7: 0.0005
Topic 8: 0.0005
Topic 9: 0.0005
Topic 10: 0.3661
Topic 11: 0.2487
Topic 12: 0.0005
Topic 13: 0.0005
Topic 14: 0.0005

Nội dung review:
So Jean Hill is no John Dean Just some thoughts on Jean Hill and her book.1

```

Hình 3.11: phân phối của topic

Mỗi review được biểu diễn dưới dạng phân phối xác suất trên các chủ đề học được từ mô hình LDA. Kết quả cho thấy review được đặc trưng bởi một số chủ đề chính với xác suất cao, phản ánh đúng nội dung ngữ nghĩa của văn bản.

3.3.2 Mô hình BERTopic

a) Khởi tạo mô hình

Giải thích các tham số

- `language="english"` Sử dụng mô hình embedding và tiền xử lý tối ưu cho tiếng Anh Bao gồm: Tokenization Stopwords Sentence embedding phù hợp
- `calculate_probabilities=True` Yêu cầu BERTopic tính xác suất phân phối topic cho từng văn bản Kết quả: Mỗi review được biểu diễn bằng vector xác suất trên các topic Tương tự phân phối topic trong LDA, nhưng: Dựa trên embedding ngữ nghĩa Không dựa trên Bag-of-Words
- `verbose=True` Hiển thị log trong quá trình huấn luyện: Thời gian embedding Clustering Số lượng topic được tạo Hữu ích cho: Theo dõi tiến trình Debug

Huấn luyện mô hình BERTopic

- Quá trình bên trong BERTopic BERTopic thực hiện chuỗi bước sau:
- Sentence Embedding Chuyển mỗi review thành vector ngữ nghĩa Sử dụng mô hình transformer (ví dụ: MiniLM)
- Dimensionality Reduction Áp dụng UMAP để giảm chiều embedding Giữ cấu trúc ngữ nghĩa cục bộ

- Clustering Sử dụng HDBSCAN để nhóm các review Không cần chỉ định trước số topic
- Topic Representation Áp dụng c-TF-IDF để trích xuất từ khóa đại diện cho mỗi topic

```
usr/local/lib/python3.12/dist-packages/hdbscan/robust_single_linkage.py:175: SyntaxWarning: invalid escape sequence '\{'  
$max \{ core_k(a), core_k(b), 1/\alpha d(a,b) \}$.  
2025-12-03 01:41:55,524 - BERTopic - Embedding - Transforming documents to embeddings.  
modules.json: 100% ████████████████████████████████████████ 349/349 [00:00<00:00, 24.0kB/s]  
  
config_sentence_transformers.json: 100% ████████████████████████████████████████ 116/116 [00:00<00:00, 11.6kB/s]  
  
README.md: █ 10.5k/? [00:00<00:00, 1.06MB/s]  
  
sentence_bert_config.json: 100% ████████████████████████████████████████ 53.0/53.0 [00:00<00:00, 6.05kB/s]  
  
config.json: 100% ████████████████████████████████████████ 612/612 [00:00<00:00, 64.5kB/s]  
  
model.safetensors: 100% ████████████████████████████████████████ 90.9M/90.9M [00:34<00:00, 3.57MB/s]  
  
tokenizer_config.json: 100% ████████████████████████████████████████ 350/350 [00:00<00:00, 40.5kB/s]  
  
vocab.txt: █ 232k/? [00:00<00:00, 13.6MB/s]  
  
tokenizer.json: █ 466k/? [00:00<00:00, 23.5MB/s]  
  
special_tokens_map.json: 100% ████████████████████████████████████████ 112/112 [00:00<00:00, 12.8kB/s]  
  
config.json: 100% ████████████████████████████████████████ 190/190 [00:00<00:00, 16.4kB/s]  
  
Batches: 100% ████████████████████████████████████████ 589/589 [00:40<00:00, 98.47it/s]  
  
2025-12-03 01:43:15,657 - BERTopic - Embedding - Completed ✓  
2025-12-03 01:43:15,658 - BERTopic - Dimensionality - Fitting the dimensionality reduction algorithm  
2025-12-03 01:44:04,661 - BERTopic - Dimensionality - Completed ✓  
2025-12-03 01:44:04,663 - BERTopic - Cluster - Start clustering the reduced embeddings  
2025-12-03 01:44:38,711 - BERTopic - Cluster - Completed ✓  
2025-12-03 01:44:38,728 - BERTopic - Representation - Fine-tuning topics using representation models.  
2025-12-03 01:44:41,668 - BERTopic - Representation - Completed ✓  
Số topic BERTopic tìm được: 215
```

Hình 3.12: Số topic tìm được trong BERTopic

b) **Hiển thị và diễn giải các chủ đề từ mô hình BERTopic**

Sau khi huấn luyện mô hình BERTopic, bước tiếp theo là phân tích và diễn giải các chủ đề được phát hiện thông qua các từ khóa đại diện. Điều này giúp đánh giá: Tính ngữ nghĩa của các chủ đề Mức độ phù hợp của mô hình đối với dữ liệu review sách Lựa chọn các chủ đề để hiển thị Vòng lặp hiển thị 5 chủ đề đầu tiên Việc giới hạn số topic giúp: Trình bày gọn gàng trong báo cáo Minh họa kết quả tiêu biểu của mô hình Trong phân tích đầy đủ, toàn bộ các topic có thể được đánh giá và gán nhãn.

```

==== BERTopic Topic 0 ====
[['game', np.float64(0.010373686421414155)), ('team', np.float64(0.009040416822478477)), ('games', np.float64(0.007200733227048788)), ('he', np.float64(0.007084773667351757)), ('pla

==== BERTopic Topic 1 ====
[['key', np.float64(0.01411375776460857)), ('clipper', np.float64(0.012708668095749483)), ('chip', np.float64(0.0119728021452251)), ('encryption', np.float64(0.0115208112024564601))

==== BERTopic Topic 2 ====
[['ites', np.float64(0.5133871509282852)), ('cheek', np.float64(0.47842385582618663)), ('yep', np.float64(0.3557234332217785)), ('huh', np.float64(0.31984937774405785)), ('ken', np.

==== BERTopic Topic 3 ====
[['israel', np.float64(0.01903722274195005)), ('israeli', np.float64(0.014414114334141796)), ('jews', np.float64(0.011370576168762724)), ('arab', np.float64(0.01084567987145778)), (

==== BERTopic Topic 4 ====
[['monitor', np.float64(0.02214724181956514)), ('card', np.float64(0.02192395468676334)), ('video', np.float64(0.0164778483264981)), ('drivers', np.float64(0.01294757352019489)),

```

Hình 3.13: Hiển thị các 1 số chủ đề BERTopic

Các chủ đề được sinh ra bởi BERTopic được diễn giải thông qua các từ khóa đại diện có trọng số cao, cho phép đánh giá trực quan tính ngữ nghĩa và phục vụ cho việc gán nhãn chủ đề trong hệ thống gợi ý.

3.3.3 So Sánh LDA và BERTopic

Đánh giá chất lượng chủ đề bằng Topic Coherence

	LDA	BERTopic
Coherence	0.4898329535417038	0.45328569151795456

Bên cạnh các chỉ số thống kê như *perplexity* hay *log-likelihood*, nghiên cứu sử dụng Topic Coherence để đánh giá tính nhất quán ngữ nghĩa của các chủ đề. Chỉ số coherence phản ánh mức độ các từ trong cùng một chủ đề có đồng xuất hiện và liên quan ngữ nghĩa với nhau hay không, từ đó đánh giá khả năng diễn giải của mô hình. Mặc dù BERTopic dựa trên embedding cho khả năng biểu diễn ngữ nghĩa tốt hơn, chỉ số coherence dựa trên đồng xuất hiện từ có thể chưa phản ánh đầy đủ chất lượng của các chủ đề sinh ra. Do đó, việc kết hợp cả đánh giá định lượng và phân tích định tính là cần thiết

KẾT LUẬN

Những kết quả đạt được Trong phạm vi của đồ án, nghiên cứu đã xây dựng và đánh giá thành công một quy trình Topic Modeling trên dữ liệu đánh giá sách Amazon, phục vụ cho bài toán phân tích nội dung và hệ thống gợi ý. Cụ thể, các kết quả chính đạt được bao gồm: Thu thập và tiền xử lý tập dữ liệu review sách Amazon với quy mô lớn, bao gồm làm sạch dữ liệu, loại bỏ giá trị thiếu, chuẩn hóa văn bản và trích xuất đặc trưng. Áp dụng mô hình Latent Dirichlet Allocation (LDA) để trích xuất các chủ đề tiềm ẩn từ nội dung review, đồng thời đánh giá mô hình thông qua các chỉ số perplexity, log-likelihood và topic coherence. Áp dụng mô hình BERTopic, một phương pháp topic modeling hiện đại dựa trên biểu diễn ngữ nghĩa bằng transformer, cho phép tự động xác định số lượng chủ đề và trích xuất các topic mang tính ngữ nghĩa cao. Thực hiện so sánh định lượng giữa LDA và BERTopic bằng chỉ số coherence (c_v), đồng thời phân tích định tính thông qua các từ khóa đại diện của từng chủ đề. Biểu diễn mỗi review dưới dạng phân phối xác suất trên các chủ đề, tạo nền tảng cho việc xây dựng hồ sơ người dùng và ứng dụng trong hệ thống gợi ý dựa trên nội dung. Kết quả thực nghiệm cho thấy cả hai mô hình đều có khả năng trích xuất các chủ đề có ý nghĩa từ dữ liệu review, trong đó LDA thể hiện ưu thế về tính nhất quán thống kê, còn BERTopic thể hiện ưu thế về khả năng nắm bắt ngữ nghĩa sâu.

Những hạn chế của nghiên cứu Bên cạnh các kết quả đạt được, nghiên cứu vẫn tồn tại một số hạn chế: Mô hình LDA phụ thuộc mạnh vào Bag-of-Words, do đó chưa khai thác được đầy đủ ngữ nghĩa sâu và mối quan hệ ngữ cảnh giữa các từ. BERTopic sử dụng mô hình embedding mặc định và chưa được fine-tune trên miền dữ liệu sách, điều này có thể ảnh hưởng đến chất lượng biểu diễn ngữ nghĩa. Việc đánh giá chất lượng topic chủ yếu dựa trên chỉ số coherence và phân tích từ khóa, chưa có đánh giá định tính từ chuyên gia hoặc người dùng thực tế. Hệ thống gợi ý mới dừng lại ở mức phân tích nội dung và trích xuất chủ đề, chưa triển khai đầy đủ một pipeline recommendation hoàn chỉnh kết hợp với dữ liệu hành vi người dùng. Chưa tích hợp

rõ ràng cấu trúc taxonomy phân cấp của thể loại sách để tổ chức và diễn giải các chủ đề một cách hệ thống.

Hướng phát triển trong tương lai Từ các hạn chế trên, nghiên cứu có thể được mở rộng và phát triển theo các hướng sau: Tích hợp taxonomy phân cấp của sách (genre – subgenre) vào kết quả topic modeling nhằm tạo ra các chủ đề có cấu trúc và dễ diễn giải hơn. Xây dựng hệ thống gợi ý lai (hybrid recommendation system) bằng cách kết hợp topic distribution với collaborative filtering và metadata của sách. Áp dụng các mô hình ngôn ngữ lớn (LLMs) để: Tự động đặt tên chủ đề Gộp hoặc phân cấp các topic Sinh mô tả ngữ nghĩa cho từng chủ đề Fine-tune mô hình embedding trong BERTopic trên tập dữ liệu sách để cải thiện chất lượng chủ đề. Thực hiện đánh giá thực nghiệm với người dùng hoặc thông qua các chỉ số recommendation (Precision@K, Recall@K, NDCG). Mở rộng nghiên cứu sang các miền dữ liệu khác như phim, âm nhạc hoặc bài báo để đánh giá khả năng tổng quát hóa của phương pháp.

Nghiên cứu đã chứng minh tính khả thi của việc áp dụng topic modeling, cả truyền thống và hiện đại, trong việc khai thác nội dung đánh giá sách. Các kết quả đạt được không chỉ có ý nghĩa về mặt học thuật mà còn đặt nền tảng cho việc xây dựng các hệ thống gợi ý thông minh, có khả năng diễn giải và mở rộng trong tương lai.

TÀI LIỆU THAM KHẢO

- [1]. N. V. Hậu, P. M. Chuẩn, và N. V. Quyết , “Giáo trình Học máy cơ bản”, Nhà xuất bản Khoa học và Kỹ thuật, 2022.
- [2]. Khoa CNTT – Đại học SPKT Hưng Yên, “*Quy trình hướng dẫn đồ án 3*”, 2021.
- [3]. <https://www.kaggle.com/datasets/mohamedbakhet/amazon-books-reviews>