

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HÙNG YÊN



ĐỒ ÁN 3

**SO SÁNH 4 CHIẾN LƯỢC COLD-START (POPULAR/
CONTENT-BASED/ MF/ TAXONOMY-AWARE) TRÊN DỮ LIỆU
MOVIELENS**

NGÀNH: KHOA HỌC MÁY TÍNH
KHOA: CÔNG NGHỆ THÔNG TIN

SINH VIÊN: **TRẦN HỒNG LĨNH**

MÃ LỚP: **12422TN**

MÃ SINH VIÊN: **12522060**

HƯỚNG DẪN: **PGS. TS. NGUYỄN VĂN HẬU**

HUNG YÊN – 2025

NHẬN XÉT

Nhận xét của giảng viên hướng dẫn:

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

GIẢNG VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

LỜI CAM ĐOAN

Tôi xin cam đoan đề án “So sánh 4 chiến lược cold-start (popular/content-based/ MF/ taxonomy-aware) trên dữ liệu MovieLens” là kết quả thực hiện của bản thân.

Những phần sử dụng tài liệu tham khảo trong bài tìm hiểu đã được nêu rõ trong phần tài liệu tham khảo.

Nếu vi phạm lời cam đoan này, tôi xin chịu hoàn toàn trách nhiệm trước khoa và nhà trường.

Hưng Yên, ngày

... tháng...năm...

Sinh viên

.....

LỜI CẢM ƠN

Để có thể hoàn thành đồ án này, lời đầu tiên tôi xin phép gửi lời cảm ơn tới Khoa Công nghệ thông tin – Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã tạo điều kiện thuận lợi cho tôi thực hiện phần trình bày về “So sánh 4 chiến lược cold-start (popular/ content-based/ MF/ taxonomy-aware) trên dữ liệu MovieLens”.

Đặc biệt tôi xin chân thành cảm ơn thầy Nguyễn Văn Hậu đã gợi ý, chỉ dẫn tôi trong đồ án này.

Tôi cũng xin chân thành cảm ơn tất cả các Thầy, các Cô trong Trường đã tận tình giảng dạy, trang bị cho tôi những kiến thức cần thiết, quý báu để giúp tôi thực hiện .

Tôi xin trân trọng cảm ơn!

MỤC LỤC

NHẬN XÉT.....	2
LỜI CAM ĐOAN.....	3
LỜI CẢM ƠN.....	4
DANH MỤC BẢNG.....	7
DANH MỤC HÌNH ẢNH.....	8
CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI.....	9
1.1 Lý do chọn đề tài.....	9
1.2 Mục tiêu đề tài.....	9
1.2.1 Mục tiêu tổng quát.....	9
1.2.2 Mục tiêu cụ thể.....	10
1.3 Giới hạn và phạm vi của đề tài.....	11
1.3.1 Đối tượng nghiên cứu.....	11
1.3.2 Phạm vi nghiên cứu.....	11
1.4 Phương pháp tiếp cận.....	11
1.5 Nội dung thực hiện.....	12
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	13
2.1 Popular-based.....	13
2.2 Content-based.....	13
2.2.1 Item profiles.....	13
2.2.2 Hàm mất mát.....	14
2.3 Matrix Factorization.....	15
2.3.1 Khái niệm.....	15
2.3.2 Hàm mất mát.....	17
2.3.3 Tối ưu hàm mất mát.....	17
2.4 Taxonomy-aware.....	18
2.5 Các chỉ số đánh giá.....	19
2.5.1 Precision@K.....	19
2.5.2 Recall@K.....	19
2.5.3 NDCG@K.....	20
2.6 Kết chương.....	20

CHƯƠNG 3: XÂY DỰNG MÔ HÌNH HỌC MÁY.....	22
3.1 Thu thập dữ liệu.....	22
3.1.1 Dữ liệu về Movies.....	22
3.1.2 Dữ liệu về Ratings.....	23
3.1.3 Dữ liệu về Tags.....	24
3.1.4 Dữ liệu về Links.....	24
3.1.5 Dữ liệu về genome_scores.....	25
3.1.6 Dữ liệu về genome_tags.....	25
3.2 Phân tích dữ liệu.....	26
3.3 Các chiến lược cold-start.....	32
3.3.1 Popular Recommender System.....	32
3.3.2 Content based Recommender System.....	33
3.3.3 Matrix Factorization.....	34
3.3.4 Taxonomy-aware (2 cấp).....	34
3.4 Kết chương.....	35
CHƯƠNG 4: ĐÁNH GIÁ KẾT QUẢ.....	36
4.1 Tổng hợp kết quả so sánh bốn mô hình.....	36
4.2 Kết chương.....	37
KẾT LUẬN.....	38
TÀI LIỆU THAM KHẢO.....	39

DANH MỤC BẢNG

Bảng 3. 1 Dữ liệu movies (5 bản ghi)	22
Bảng 3. 2 Dữ liệu sau khi chuyển đổi	23
Bảng 3. 3 Dữ liệu Ratings (5 bản ghi)	23
Bảng 3. 4 Dữ liệu tags (5 bản ghi)	24
Bảng 3. 5 Dữ liệu link (5 bản ghi)	24
Bảng 3. 6 Dữ liệu genome_scores (5 bản ghi)	25
Bảng 3. 7 Dữ liệu genome_tag (5 bản ghi)	25
Bảng 3. 8 Tổng quan dữ liệu	26
Bảng 3. 9 Top 10 movies có popular cao nhất	32
Bảng 3. 10 Kết quả đánh giá phương pháp Popular	33
Bảng 3. 11 Kết quả đánh giá phương pháp Content-based	33
Bảng 3. 12 Kết quả phương pháp MF	34
Bảng 3. 13 Kết quả phương pháp Taxonomy-aware	35
Bảng 4. 1 Tổng hợp chỉ số các phương pháp.....	36

DANH MỤC HÌNH ẢNH

Hình 2. 1 Item feature vector	14
Hình 2. 2 Phân tách bất kỳ matrix	16
Hình 2. 3 Tổng quát phân tích một ma trận	16
Hình 3. 1 Phân phối điểm đánh giá (Rating Distribution)	26
Hình 3. 2 Phân phối số lượng phim người dùng đánh giá	27
Hình 3. 3 Phân phối số lượng người dùng đã đánh giá mỗi phim	28
Hình 3. 4 Top 10 bộ phim được đánh giá nhiều nhất	29
Hình 3. 5 Thể loại phim phổ biến	29
Hình 3. 6 Điểm trung bình theo thể loại phim	30
Hình 3. 7 Độ liên quan giữa phim và tag	31
Hình 3. 8 Cây 2 cấp genres	34

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI

1.1 Lý do chọn đề tài

Trong thời đại bùng nổ dữ liệu và công nghệ số hiện nay, các nền tảng trực tuyến như Netflix, Spotify hay Shopee đều phải đối mặt với một thách thức lớn: làm sao để hiểu rõ người dùng mới và đưa ra những gợi ý phù hợp ngay cả khi chưa có đủ dữ liệu về họ. Đây chính là vấn đề “**cold-start**” trong hệ thống gợi ý – một trong những vấn đề quan trọng và phổ biến nhất trong lĩnh vực **Recommender System**.

Các hệ thống gợi ý đóng vai trò then chốt trong việc nâng cao trải nghiệm người dùng và thúc đẩy tương tác. Chúng giúp người dùng nhanh chóng tìm được sản phẩm, phim hay bài hát mà họ yêu thích, đồng thời cũng giúp doanh nghiệp tăng doanh thu và giữ chân khách hàng. Tuy nhiên, khi xuất hiện người dùng hoặc sản phẩm mới, hệ thống thường thiếu thông tin để gợi ý chính xác – từ đó làm giảm chất lượng khuyến nghị.

Xuất phát từ những kiến thức đã học trong học phần **Data Mining** và các học phần khác, tôi muốn nghiên cứu và so sánh hiệu quả của bốn chiến lược cold-start phổ biến gồm:

- **Popular-based** (gợi ý theo mức độ phổ biến)
- **Content-based** (gợi ý dựa trên nội dung)
- **Matrix Factorization** (phân rã ma trận)
- **Taxonomy-aware** (gợi ý có nhận thức theo phân cấp thể loại)

Dữ liệu **MovieLens** được lựa chọn vì đây là bộ dữ liệu chuẩn, có cấu trúc rõ ràng và được sử dụng rộng rãi trong các nghiên cứu về hệ thống gợi ý. Mục tiêu của đề tài là đánh giá và so sánh hiệu suất của từng chiến lược cold-start thông qua các chỉ số như **Precision@K** và **NDCG**, từ đó đưa ra nhận xét và đề xuất hướng cải thiện cho các hệ thống gợi ý trong bối cảnh cold-start.

1.2 Mục tiêu đề tài

1.2.1 Mục tiêu tổng quát

Mục tiêu tổng quát của đề tài là nghiên cứu, xây dựng và so sánh hiệu quả của bốn chiến lược gợi ý cold-start bao gồm: Popular-based, Content-based, Matrix

Factorization (MF) và Taxonomy-aware, trên bộ dữ liệu MovieLens.

Đề tài hướng đến việc đánh giá khả năng gợi ý phim cho người dùng mới hoặc sản phẩm mới khi thông tin lịch sử đánh giá còn hạn chế, đồng thời tìm ra chiến lược phù hợp và hiệu quả nhất trong từng tình huống cold-start khác nhau.

1.2.2 Mục tiêu cụ thể

Một số mục tiêu cụ thể của đề tài:

Thu thập phân tích và xử lý dữ liệu

- Dữ liệu được lấy từ bộ MovieLens của GroupLens
[MovieLens | GroupLens](#)
- Bộ dữ liệu bao gồm các file chính như: ratings.csv, movies.csv, và tags.csv, chứa các thông tin về người dùng, phim, điểm đánh giá và thể loại.
- Thực hiện tiền xử lý: loại bỏ giá trị thiếu, hợp nhất các bảng dữ liệu, tách phần train/test để phục vụ đánh giá mô hình.

Xây dựng và huấn luyện các mô hình gợi ý

- Triển khai 4 chiến lược cold-start:
 - Popular-based: gợi ý theo độ phổ biến của phim.
 - Content-based: gợi ý dựa trên đặc trưng nội dung (TF-IDF, cosine similarity giữa các phim).
 - Matrix Factorization: sử dụng kỹ thuật phân rã ma trận để dự đoán xếp hạng ẩn.
 - Taxonomy-aware: mở rộng content-based bằng cách khai thác cấu trúc phân cấp (taxonomy) của thể loại phim.
- Tối ưu các tham số và đảm bảo mô hình có khả năng gợi ý cho người dùng mới.

Đánh giá và so sánh hiệu suất giữa các chiến lược

- Sử dụng các chỉ số đánh giá phổ biến: Precision@K, NDCG
- So sánh hiệu suất giữa các mô hình trong các kịch bản cold-start khác nhau (người dùng mới, phim mới).
- Phân tích trade-off giữa độ chính xác và độ đa dạng của từng chiến lược.

1.3 Giới hạn và phạm vi của đề tài

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu:

- Hệ thống gợi ý phim và các chiến lược (cold-start) trong Recommender System.

Khách thể nghiên cứu:

- Người dùng mới hoặc phim mới trong hệ thống gợi ý (chưa có đủ dữ liệu lịch sử dùng).
- Quy trình huấn luyện và đánh giá các chiến lược cold-start trong bài toán gợi ý phim.
- Bộ dữ liệu MovieLens, bao gồm thông tin người dùng, phim, thể loại và đánh giá.

1.3.2 Phạm vi nghiên cứu

Phạm vi dữ liệu:

- Sử dụng bộ dữ liệu MovieLens do GroupLens Research cung cấp.

Phạm vi mô hình:

- Popular-based: Gợi ý dựa trên độ phổ biến toàn cục.
- Content-based: Gợi ý dựa trên nội dung phim và đặc trưng TF-IDF.
- Matrix Factorization (MF): Phân rã ma trận người dùng–phim để suy luận ẩn.
- Taxonomy-aware: Gợi ý có nhận thức phân cấp, dựa vào cây thể loại 2 cấp.

Phạm vi thời gian:

- Từ 10/2025 đến 11/2025

1.4 Phương pháp tiếp cận

Để thực hiện đề tài “So sánh 4 chiến lược cold-start (Popular / Content-Based / MF / Taxonomy-Aware) trên dữ liệu MovieLens”, tôi sử dụng phương pháp tiếp cận theo hướng khai phá dữ liệu và học máy (Machine Learning), gồm các bước chính sau:

Thu thập và tiền xử lý dữ liệu

- Sử dụng bộ dữ liệu MovieLens.

- Làm sạch dữ liệu: loại bỏ giá trị trống, chuyển đổi định dạng, tách train/test theo người dùng mới.

Trích xuất và biểu diễn đặc trưng

- Với Content-based: tạo ma trận TF-IDF cho thể loại phim.
- Với MF: xây dựng ma trận người dùng–phim và thực hiện phân rã SVD hoặc ALS.
- Với Taxonomy-aware: xây dựng cây thể loại hai cấp và mã hóa thành vector phân cấp.

Xây dựng và huấn luyện mô hình

- Triển khai lần lượt 4 chiến lược.
- Huấn luyện, tinh chỉnh và lưu lại mô hình cho từng phương pháp.

Đánh giá và so sánh kết quả

- Tính toán các chỉ số Precision@K, NDCG cho từng mô hình.
- So sánh kết quả để xác định chiến lược tối ưu trong từng kịch bản cold-start.

1.5 Nội dung thực hiện

Đề tài gồm 4 chương:

- Chương 1: Tổng quan về đề tài
Trình bày lý do chọn đề tài, mục tiêu, phạm vi và phương pháp tiếp cận.
- Chương 2: Cơ sở lý thuyết
Giới thiệu tổng quan về hệ thống gợi ý, vấn đề cold-start, các phương pháp Popular-based, Content-based, Matrix Factorization, Taxonomy-aware và các chỉ số đánh giá như Precision@K, NDCG.
- Chương 3: Xây dựng và huấn luyện mô hình
Trình bày chi tiết quá trình tiền xử lý dữ liệu, thiết kế và triển khai bốn chiến lược cold-start, cùng quy trình đánh giá và so sánh kết quả.
- Chương 4: Thực nghiệm và đánh giá kết quả
Tổng hợp, trực quan hóa và phân tích kết quả so sánh; rút ra nhận xét, ưu – nhược điểm của từng phương pháp và đề xuất hướng phát triển trong tương lai.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1 Popular-based

Popular-based recommender (gợi ý dựa trên độ phổ biến) là hệ gợi ý không cá nhân hóa (non-personalized): nó gợi ý cho mọi người dùng cùng một danh sách các item “phổ biến nhất”.

Nguyên lý cơ bản: các item được nhiều người tương tác (xem, mua, đánh giá, click, v.v.) thì có khả năng được gợi ý cao hơn.

Mặc dù đơn giản, nếu không được thiết kế khéo có thể dẫn đến bias (ưu tiên các item nổi bật, làm tăng “vòng lặp giàu-thịnh”) - một số bài nghiên cứu gọi vấn đề này là *popularity bias*.

- Scoring item theo độ phổ biến đơn giản.

$$\text{score}(i) = \text{count}(i)$$

Với $\text{count}(i)$: số lượt tương tác (rating, click, view, mua...) mà item i nhận được trong tập huấn luyện.

Khi đã có score cho tất cả item, hệ gợi ý xếp hạng theo score giảm dần và chọn top-N.

- Sử dụng trung bình (Mean) nếu có rating

$$\text{mean_rating}(i) = \frac{1}{|U_i|} \sum_{u \in U_i} r_{u,i}$$

U_i : tập người dùng đã đánh giá item i .

2.2 Content-based

Content-based systems: là đánh giá đặc tính của items được recommended.

Ví dụ: một user xem rất nhiều các bộ phim về cảnh sát hình sự, vậy thì gợi ý một bộ phim trong cơ sở dữ liệu có chung đặc tính hình sự tới user này, ví dụ phim Người phán xử. Cách tiếp cận này yêu cầu việc sắp xếp các items vào từng nhóm hoặc đi tìm các đặc trưng của từng item.

2.2.1 Item profiles

Trong các hệ thống content-based, tức dựa trên nội dung của mỗi item, chúng ta cần xây dựng một bộ hồ sơ (profile) cho mỗi item. Profile này được biểu diễn dưới dạng toán học là một feature vector. Trong những trường hợp đơn giản, feature vector được trực tiếp trích xuất từ item. Ví dụ, xem xét các features của một bài hát mà có thể được sử dụng trong các Recommendation Systems:

- *Ca sĩ*. Cùng là bài *Thành phố buồn* nhưng có người thích bản của Đan Nguyên, có người lại thích bản của Đàm Vĩnh Hưng.
- *Nhạc sĩ sáng tác*. Cùng là nhạc trẻ nhưng có người thích Phan Mạnh Quỳnh, người khác lại thích MTP.
- *Năm sáng tác*. Một số người thích nhạc xưa cũ hơn nhạc hiện đại.
- *Thể loại*. Điều này thì chắc rồi, Quan họ và Bolero sẽ có thể thu hút những nhóm người khác nhau.

	A	B	C	D	E	F	item's feature vectors
Mưa nửa đêm	5	5	0	0	1	?	$\mathbf{x}_1 = [0.99, 0.02]$
Cỏ úa	5	?	?	0	?	?	$\mathbf{x}_2 = [0.91, 0.11]$
Vùng lá me bay	?	4	1	?	?	1	$\mathbf{x}_3 = [0.95, 0.05]$
Con cò bé bé	1	1	4	4	4	?	$\mathbf{x}_4 = [0.01, 0.99]$
Em yêu trường em	1	0	5	?	?	?	$\mathbf{x}_5 = [0.03, 0.98]$
User's models	θ_1	θ_2	θ_3	θ_4	θ_5	θ_6	← need to optimize

Hình 2. 1 Item feature vector

2.2.2 Hàm mất mát

Giả sử rằng số users là N , số items là M , utility matrix được mô tả bởi ma trận Y . Thành phần ở hàng thứ m , cột thứ n của Y là mức độ quan tâm (ở đây là số sao đã rate) của user thứ n lên sản phẩm thứ m mà hệ thống đã thu thập được. Ma trận Y bị khuyết rất nhiều thành phần tương ứng với các giá trị mà hệ thống cần dự đoán. Thêm nữa, gọi R là ma trận rated or not thể hiện việc một user đã rated một item hay chưa. Cụ thể, r_{ij} bằng 1 nếu item thứ i đã được rated bởi user thứ j , bằng 0 trong trường hợp ngược lại.

Mô hình tuyến tính:

Giả sử rằng ta có thể tìm được một mô hình cho mỗi user, minh họa bởi vector cột hệ số w_i và bias b_n sao cho mức độ quan tâm của một user tới một item có thể tính được bằng một hàm tuyến tính:

$$y_{mn} = x_m w_n + b_n \quad (1)$$

x_m là một vector hàng, w_n là một vector cột

Xét một user thứ n bất kỳ, nếu ta coi training set là tập hợp các thành phần đã được điền của y_n , ta có thể xây dựng hàm mất mát tương tự như Ridge Regression như sau:

$$\mathcal{L}_n = \frac{1}{2} \sum_{m: r_{mn}=1} (x_m w_n + b_n - y_{mn})^2 + \frac{\lambda}{2} \|w_n\|_2^2$$

Trong đó, thành phần thứ hai là regularization term và λ là một tham số dương. Chú ý rằng regularization thường không được áp dụng lên bias b_n .

$$\mathcal{L}_n = \frac{1}{2s_n} \sum_{m: r_{mn}=1} (x_m w_n + b_n - y_{mn})^2 + \frac{\lambda}{2s_n} \|w_n\|_2^2$$

Trong đó s_n là số lượng các items mà user thứ n đã rated

$$s_n = \sum_{m=1}^M r_{mn},$$

Khi đó, biểu thức hàm mất mát của mô hình cho *user* thứ n được viết gọn thành:

$$\mathcal{L}_n = \frac{1}{2s_n} \|\hat{\mathbf{X}}_n \mathbf{w}_n + b_n \mathbf{e}_n - \hat{\mathbf{y}}_n\|_2^2 + \frac{\lambda}{2s_n} \|\mathbf{w}_n\|_2^2$$


trong đó, $\mathbf{e}_n$ là vector cột chứa s_n phần tử 1.

2.3 Matrix Factorization

2.3.1 Khái niệm

Matrix Factorization là một hướng tiếp cận khác của Collaborative Filtering, còn gọi là Matrix Decomposition, nghĩa là gợi ý bằng "*kỹ thuật phân rã ma trận*".

Kỹ thuật phân rã ma trận là phương pháp chia một ma trận lớn X thành hai ma trận có kích thước nhỏ hơn là W và H , sao cho ta có thể xây dựng lại X từ hai ma trận nhỏ hơn này càng chính xác càng tốt, nghĩa là $X \sim W H^T$.



Hình 2. 2 Phân tách bất kỳ matrix

ý tưởng chính của Matrix Factorization là đặt items và users vào trong cùng một không gian thuộc tính ẩn. Trong đó, $W \in R^{|U| \times K}$ là một ma trận mà mỗi dòng u là một vector bao gồm K nhân tố tiềm ẩn (latent factors) mô tả user u và $H \in R^{|I| \times K}$ là một ma trận mà mỗi dòng i là một vector bao gồm K nhân tố tiềm ẩn mô tả cho item i . Sẽ có x là một vector của item profile.

Một vector w tương ứng với mỗi user sao cho ratings đã biết của user đó cho item (y) xấp xỉ với:


$$y \approx xw$$

Mở rộng với Y là *utility matrix*, giả sử đã được điền hết giá trị, ta có:

$$Y \approx \begin{bmatrix} \mathbf{x}_1 \mathbf{w}_1 & \mathbf{x}_1 \mathbf{w}_2 & \dots & \mathbf{x}_1 \mathbf{w}_N \\ \mathbf{x}_2 \mathbf{w}_1 & \mathbf{x}_2 \mathbf{w}_2 & \dots & \mathbf{x}_2 \mathbf{w}_N \\ \dots & \dots & \ddots & \dots \\ \mathbf{x}_M \mathbf{w}_1 & \mathbf{x}_M \mathbf{w}_2 & \dots & \mathbf{x}_M \mathbf{w}_N \end{bmatrix} = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \dots \\ \mathbf{x}_M \end{bmatrix} \begin{bmatrix} \mathbf{w}_1 & \mathbf{w}_2 & \dots & \mathbf{w}_N \end{bmatrix} = \mathbf{XW}$$

với M, N lần lượt là số users và số items.

K được chọn thường nhỏ hơn rất nhiều so với M và N , và cả hai ma trận X và W đều phải có bậc (rank) không được vượt quá K .



Hình 2. 3 Tổng quát phân tích một ma trận

2.3.2 Hàm mất mát

Hàm mất mát không có cả bias và biến tối ưu cho X và W :

$$L_{(x,w)} = \frac{1}{2s} \sum_{n=1}^N \sum_{m:r_{mn}} (y_{mn} - x_m w_n)^2 + \frac{\lambda}{2} (\|X\|_F^2 + \|W\|_F^2)$$

Trong đó, $r_{mn} = 1$ nếu item thứ m đã được đánh giá bởi user thứ n , $\|O\|$ là căn bậc hai của tổng bình phương tất cả các phần tử của ma trận, s là toàn bộ số ratings đã có. Thành phần thứ nhất chính là trung bình sai số của mô hình. Thành phần thứ hai trong hàm mất mát phía, có tác dụng giúp tránh overfitting.

Chúng ta sẽ tối ưu X và W bằng cách cố định từng ma trận và tối ưu ma trận còn lại cho tới khi hội tụ.

2.3.3 Tối ưu hàm mất mát

Khi cố định X , việc tối ưu W chính là bài toán tối ưu của *Content-based Filtering*:

$$L_{(w)} = \frac{1}{2s} \sum_{n=1}^N \sum_{m:r_{mn}} (y_{mn} - x_m w_n)^2 + \frac{\lambda}{2} \|W\|_F^2$$

Ngược lại, khi cố định W , việc tối ưu X được đưa về tối ưu hàm:

$$L_{(x)} = \frac{1}{2s} \sum_{n=1}^N \sum_{m:r_{mn}} (y_{mn} - x_m w_n)^2 + \frac{\lambda}{2} \|X\|_F^2$$

Sẽ được tối ưu bằng Gradient Descent. Bài toán tối ưu W có thể được tách thành N bài toán nhỏ (N là số lượng users), mỗi bài toán tương ứng với việc đi tối ưu một cột của ma trận W .

$$L_{(w_n)} = \frac{1}{2s} \sum_{m:r_{mn}} (y_{mn} - x_m w_n)^2 + \frac{\lambda}{2} \|w_n\|_2^2$$

Và đạo hàm của nó là:

$$\frac{\partial L(w_n)}{\partial w_n} = -\frac{1}{s} \hat{X}_n^T (\hat{y}_n - \hat{X}_n w_n) + \lambda w_n$$

Công thức cập nhật cho các cột của W là:

$$w_n = w_n - \eta \left(\frac{1}{s} \hat{X}_n^T (\hat{y}_n - \hat{X}_n w_n) + \lambda w_n \right)$$

Đặt W_m là ma trận được tạo bằng các cột của W tương ứng với các users đã đánh giá items đó và sử dụng *submatrix* Y tương ứng là y_m . Công thức trên sẽ trở thành:

$$L(x_n) = \frac{1}{2s} \|\hat{y}^m - x_m \hat{W}_n\|_2^2 + \frac{\lambda}{2} \|x_m\|_2^2$$

Công thức cập nhật cho mỗi hàng của X là:


$$x_n = x_n - \eta \left(\frac{1}{s} (\hat{y}^m - x_m \hat{W}_m) \hat{W}_n^T + \lambda w_m \right)$$


Sau khi cố định X , tính W và ngược lại, cố định W và tính X cho đến khi các ma trận này hội tụ, ta sẽ thu được ma trận X và W cần tìm. Từ đó, dự đoán các giá trị ratings chưa biết.

2.4 Taxonomy-aware

Taxonomy-aware Recommender System (TARS) là một hướng mở rộng của hệ gợi ý truyền thống, trong đó hệ thống khai thác thông tin phân cấp (taxonomy) giữa các item (hoặc thể loại) để nâng cao chất lượng gợi ý.

Taxonomy có thể hiểu là cấu trúc phân cấp (hierarchical structure) mô tả mối quan hệ cha - con giữa các danh mục (categories) hoặc đặc tính (attributes) của sản phẩm, phim, sách,... Ví dụ như hình:





Trong cấu trúc này, “Superhero” là một nhánh con của “Action”, còn “Action” lại thuộc nhóm “Fiction”. Việc mô hình nhận thức được mối quan hệ này giúp lan truyền sở thích của người dùng giữa các nhóm thể loại có liên quan — ví dụ, nếu người dùng thích “Superhero”, thì khả năng cao họ cũng thích “Action”.

Các mô hình gợi ý truyền thống như Collaborative Filtering hoặc Matrix Factorization chỉ dựa vào lịch sử tương tác trực tiếp giữa người dùng và sản phẩm, mà không hiểu ngữ nghĩa hoặc quan hệ phân cấp giữa các item.

Taxonomy-aware Recommender System khắc phục hạn chế này bằng cách:

- Nhúng (embed) mỗi node trong cây taxonomy (thể loại cha, con) vào cùng không gian vector.
- Lan truyền thông tin từ node cha sang node con (và ngược lại), nhằm giúp mô hình hiểu được quan hệ giữa các thể loại liên quan.
- Kết hợp embedding của taxonomy với embedding của người dùng hoặc item trong quá trình dự đoán.

Nhờ đó, hệ thống có thể:

- Gợi ý item mới có cùng nhóm thể loại.
- Cải thiện khả năng gợi ý trong bài toán cold-start (item mới hoặc user mới).
- Tăng tính đa dạng (diversity) và bao phủ (coverage) của kết quả gợi ý.

2.5 Các chỉ số đánh giá

2.5.1 *Precision@K*

Chỉ số precision@K đo lường số lượng mục được truy xuất có liên quan. Chỉ số này không nhận biết thứ hạng và do đó chỉ xem xét số lượng kết quả có liên quan chứ không phải thứ tự của chúng.

Có thể tính precision@K bằng cách chia số lượng mục có liên quan trong kết quả K hàng đầu cho K.

$$Precision@K = \frac{TP}{TP + FP} = \frac{TP}{K} = \frac{\text{Number of relevant items in } K}{\text{Total number of items in } K}$$

2.5.2 Recall@K

Chỉ số recall@K đo lường số lượng mục liên quan đã được truy xuất thành công từ toàn bộ tập dữ liệu. Chỉ số này không nhận biết thứ hạng và do đó chỉ xem xét số lượng kết quả có liên quan chứ không phải thứ tự của chúng. Bạn có thể tính toán recall@K bằng cách chia số lượng mục có liên quan trong kết quả K hàng đầu cho tổng số mục có liên quan trong toàn bộ tập dữ liệu.

$$Recall@K = \frac{TP}{TP + FN} = \frac{\text{Number of relevant items in } K}{\text{Total number of relevant items}}$$

2.5.3 NDCG@K

Normalized Discounted Cumulative Gain (NDCG) là thước đo mức độ tốt của một danh sách được xếp hạng. Ý tưởng là nếu các mục có liên quan được sắp xếp từ phù hợp nhất đến ít liên quan nhất thì điểm NDCG sẽ được tối đa hóa nếu các mục có liên quan nhất được đề xuất ở đầu danh sách.

$$NDCG@K = \frac{DCG@K}{IDCG@K}$$

DCG@K tính toán như sau:

$$DCG@K = \sum_{k=1}^K \frac{rel_i}{\log_2(i+1)}$$

Bạn có thể chia lợi nhuận tích lũy chiết khấu cho mức tăng của danh sách được xếp hạng lý tưởng, trong đó tất cả các mục được sắp xếp hoàn hảo dựa trên mức độ liên quan. Kết quả là, bạn nhận được một chỉ số chuẩn hóa (0 đến 1) cho thấy xếp hạng của bạn so với kết quả lý tưởng cho một danh sách nhất định như thế nào.

2.6 Kết chương

Trong chương 2, báo cáo đã trình bày cơ sở lý thuyết về các phương pháp gợi ý và chỉ số đánh giá mô hình, làm nền tảng cho quá trình xây dựng và triển khai hệ thống gợi ý trong các chương tiếp theo.

Cụ thể:

- Popular-based giới thiệu phương pháp gợi ý dựa trên độ phổ biến của các item, thường được sử dụng trong các hệ thống đơn giản hoặc giai đoạn khởi đầu, khi chưa có đủ dữ liệu người dùng.
- Content-based trình bày cách gợi ý dựa trên nội dung, trong đó mô hình phân tích đặc trưng của item và sở thích của người dùng để tìm ra các sản phẩm có nội dung tương tự.
- Matrix Factorization mô tả kỹ thuật phân rã ma trận — một hướng tiếp cận quan trọng của Collaborative Filtering, cho phép biểu diễn người dùng và sản phẩm trong cùng không gian đặc trưng tiềm ẩn nhằm dự đoán các giá trị rating chưa biết.
- Taxonomy-aware mở rộng mô hình gợi ý truyền thống bằng cách tích hợp thông tin phân cấp (taxonomy) giữa các item, giúp mô hình hiểu được mối quan hệ ngữ nghĩa và cải thiện khả năng gợi ý trong các tình huống cold-start.
- Các chỉ số đánh giá trình bày các thước đo phổ biến như Precision@K, Recall@K và NDCG@K, được sử dụng để đánh giá độ chính xác, khả năng bao phủ và mức độ hợp lý của danh sách gợi ý.

Tổng hợp lại, chương này đã xây dựng nền tảng lý thuyết vững chắc cho việc thiết kế và đánh giá mô hình gợi ý. Các kiến thức về phương pháp, mô hình và chỉ số đánh giá trong chương 2 sẽ được ứng dụng và triển khai cụ thể trong chương 3, nhằm hiện thực hóa hệ thống gợi ý của đề tài.

CHƯƠNG 3: XÂY DỰNG MÔ HÌNH HỌC MÁY

3.1 Thu thập dữ liệu

Bài toán: So sánh 4 chiến lược cold-start trên bộ dữ liệu MovieLens.

Dữ liệu: [Starter: MovieLens 20M Dataset 144a8ee2-e](#)

Dữ liệu sách này bao gồm 6 file csv thể hiện về movies, ratings, tags, links, genome_scores và genome_tags.

3.1.1 Dữ liệu về Movies

Đối với dữ liệu về Users bao gồm 27278 bản ghi và có các trường sau:

movieId : id bộ phim.

title: Tên bộ phim.

genres: thể loại phim

Bảng 3. 1 Dữ liệu movies (5 bản ghi)

movieId	title	genres
1	Toy Story (1995)	Adventure Animation Children Comedy Fantasy
2	Jumanji (1995)	Adventure Children Fantasy
3	Grumpier Old Men (1995)	Comedy Romance
4	Waiting to Exhale (1995)	Comedy Drama Romance
5	Father of the Bride Part II (1995)	Comedy

Bộ dữ liệu không có giá trị null, phân tách thông tin năm ra mắt từ cột title thành cột year và ép kiểu số, chuyển cột genres thành list các thể loại.

Dữ liệu sau khi chuyển đổi như sau:

Bảng 3. 2 Dữ liệu sau khi chuyển đổi

movieId	title	genres	year
1	Toy Story	[Adventure, Animation, Children, Comedy, Fantasy]	1995
2	Jumanji	[Adventure, Children, Fantasy]	1995
3	Grumpier Old Men	[Comedy, Romance]	1995
4	Waiting to Exhale	[Comedy, Drama, Romance]	1995

3.1.2 Dữ liệu về Ratings

Đối với dữ liệu về Ratings bao gồm 20000263 bản ghi và có 3 trường sau:

userId: id người dùng.

movieId: id bộ phim.

rating: rating của phim

Bảng 3. 3 Dữ liệu Ratings (5 bản ghi)

userId	movieId	rating
1	2	3.5
1	29	3.5
1	32	3.5
1	47	3.5
1	50	3.5

3.1.3 Dữ liệu về Tags

Bộ dữ liệu về tags trong MovieLens chính là nguồn thông tin ngữ nghĩa (semantic) giúp ta hiểu thêm về ý nghĩa phim ngoài các thể loại (genres).

Đối với dữ liệu về Tags bao gồm 465564 bản ghi và có 3 trường sau:

userId: id người dùng.

movieId: id bộ phim.

tag: nguồn ngữ nghĩa để hiểu về thể loại phim

Bảng 3. 4 Dữ liệu tags (5 bản ghi)

userId	movieId	tag
18	4141	Mark Waters
65	208	dark hero
65	353	dark hero
65	521	noir thriller

3.1.4 Dữ liệu về Links

Dữ liệu links là cầu nối (mapping) giữa tập MovieLens và các cơ sở dữ liệu phim lớn khác — đặc biệt là IMDb và TMDb.

Đối với dữ liệu về Links bao gồm 465564 bản ghi và có 3 trường sau:

movieId: id bộ phim.

imdbId: id của bộ dữ liệu IMDb

tmdbId: id của bộ dữ liệu TMDb

Bảng 3. 5 Dữ liệu link (5 bản ghi)

movieId	imdbId	tmdbId
1	114709	862.0
2	113497	8844.0
3	113228	15602.0
4	114885	31357.0
5	113041	11862.0

3.1.5 Dữ liệu về genome_scores

Dữ liệu genome_scores là nền tảng của “Genome Tag Recommender System”, giúp hệ thống hiểu sâu hơn về ý nghĩa nội dung (semantic meaning) của từng phim.

Đối với dữ liệu về genome_scores bao gồm 11709768 bản ghi và có 3 trường sau:

movieId: id bộ phim.

tagId: id của bộ dữ liệu IMDb

relevance: mức độ liên quan của một thẻ (tag) cụ thể đối với một bộ phim nhất định, với giá trị từ 0 đến 1.

Bảng 3. 6 Dữ liệu genome_scores (5 bản ghi)

movieId	tagId	relevance
1	1	0.02500
1	2	0.02500
1	3	0.05775
1	4	0.09675
1	5	0.14675

Ép kiểu dữ liệu cho bộ data này thành int32 và float32 cho giảm dữ liệu bộ nhớ lưu trữ.

3.1.6 Dữ liệu về genome_tags

Dữ liệu genome_tags là từ điển (vocabulary) của toàn bộ 1.128 tag ngữ nghĩa (semantic tags) mà nhóm nghiên cứu MovieLens đã xây dựng.

Đối với dữ liệu về genome_tags bao gồm 1128 bản ghi và có 2 trường sau:

tagId: id tag cho thể loại phim.

tag: tag ngữ nghĩa mà nhóm nghiên cứu xây dựng.

Bảng 3. 7 Dữ liệu genome_tag (5 bản ghi)

tagId	tag
1	007
2	007 (series)
3	18th century
4	1920s
5	1930s

3.2 Phân tích dữ liệu

Tổng quan về dữ liệu so sánh này có:

Bảng 3. 8 Tổng quan dữ liệu


Users	138493
Movies	27259
Ratings	20000263
Rating avg	3.53

Bộ dữ liệu có quy mô lớn (với hơn 20 triệu lượt đánh giá), thích hợp để huấn luyện và đánh giá các mô hình gợi ý.

Số lượng người dùng và phim đều đủ lớn, phản ánh môi trường thực tế: nhiều người dùng, nhiều sản phẩm, tương tác dày đặc.

Điểm đánh giá trung bình khoảng 3.53/5, cho thấy người dùng có xu hướng đánh giá tích cực hơn tiêu cực (không quá khắt khe).

a) Phân phối điểm đánh giá




Hình 3. 1 Phân phối điểm đánh giá (Rating Distribution)

Nhận xét:

- Người dùng có xu hướng đánh giá tích cực, ít khi cho điểm quá thấp, điều này dẫn đến phân phối lệch về bên phải (right-skewed).
- Phản ánh thực tế: người dùng chỉ đánh giá những phim mình quan tâm hoặc tương đối hài lòng, các phim quá tệ thì bị bỏ qua ngay từ đầu nên ít xuất hiện trong dữ liệu rating.

b) Phân phối số lượng phim người dùng đánh giá




Hình 3. 2 Phân phối số lượng phim người dùng đánh giá

Trung bình mỗi người dùng đánh giá khoảng 114 bộ phim, khoảng 20 đến 40 nghìn người dùng có lượng đánh nhiều bộ phim hơn (khoảng trên dưới 1000 bộ) cho thấy bộ dữ liệu khá đồng đều.

Nhận xét:

- Việc nhiều người dùng đánh nhiều phim là lợi thế cho: Matrix Factorization (MF), Collaborative Filtering (CF) nói chung vì mô hình có nhiều dữ liệu để học embedding người dùng.
- Tuy nhiên vẫn tồn tại một lượng lớn user “ít tương tác”.

c) Phân phối số lượng người dùng đánh giá mỗi phim




Hình 3. 3 Phân phối số lượng người dùng đã đánh giá mỗi phim

Trung bình mỗi bộ phim được đánh giá bởi gần 1000 người dùng. Một vài lượng ít được xem và đánh giá vượt trội hơn hẳn khoảng trên dưới 10000 người dùng.

Nhận xét:

- Đa số phim có số lượt đánh giá vừa phải (quanh mức trung bình ~1000 users/phim).
- Một số phim nổi bật (blockbuster, kinh điển) được rất nhiều người xem và đánh giá (có thể >10000 rating).
- Những phim cực kỳ nổi bật này đóng vai trò quan trọng trong Popular based, thường làm ảnh hưởng lớn lên các mô hình collaborative (vì chúng xuất hiện trong nhiều vector tương tác).

d) Top 10 bộ phim được đánh giá nhiều nhất




Hình 3. 4 Top 10 bộ phim được đánh giá nhiều nhất

Biểu đồ này thường là biểu đồ cột (bar chart) hiển thị 10 bộ phim có số lượt rating cao nhất.

Nhận xét:

- Những phim này đều là các phim rất nổi tiếng, kinh điển, thường được nhiều người xem.
- Đây là cơ sở cho chiến lược Popular-based.
- Danh sách gợi ý rất an toàn nhưng thiếu tính đa dạng.

e) Thể loại phim phổ biến




Hình 3. 5 Thể loại phim phổ biến

Xu hướng người xem thích xem những thể loại phim bi kịch xung đột và kịch tính (drama) và những thể loại phim hài kịch vui nhộn, gây cười (comedy) và những thể loại phim khác được phân bổ khá đồng đều.

Nhận xét:

- Drama và Comedy là hai thể loại được thống kê được nhiều người xem, đây là những thể loại “dễ xem” đại chúng
- Các thể loại khác như: Action, Thriller, Romance, Crime... có số lượng khá đồng đều, không bị quá chênh lệch.
- Dữ liệu không bị lệch quá nhiều về một thể loại duy nhất.
- Các mô hình dựa trên genres (Content-based, Taxonomy-aware) có nền tảng phong phú để học.

f) Điểm đánh giá trung bình theo thể loại




Hình 3. 6 Điểm trung bình theo thể loại phim

Xu hướng người xem nhiều cũng quyết định một phần nào đó về điểm trung bình theo thể loại, những thể loại được xem nhiều hơn có điểm đánh giá cao hơn những thể loại còn lại (tức $> 3.5/5$).

Nhận xét:

- Thể loại vừa phổ biến vừa có average rating cao là “vùng vàng” cho hệ gợi ý:
- Nếu gợi ý các phim thuộc những thể loại này, xác suất user hài lòng sẽ cao hơn.
- Thiết kế chiến lược Content-based / Taxonomy-aware,
- Có thể ưu tiên tăng trọng số/score cho các thể loại có average rating cao.

g) Độ liên quan (relevance) giữa phim và tag



Hình 3. 7 Độ liên quan giữa phim và tag

Biểu đồ này thường trực quan hóa từ bộ `genome_scores` – nơi mỗi cặp (`movieId`, `tagId`) có một giá trị `relevance` từ 0 đến 1.

Mỗi tag (ví dụ: “007”, “time travel”, “based on novel”, “dark comedy”, ...) được gán một mức `relevance` cho từng bộ phim.

Nhận xét:

- Phần lớn các cặp (phim, tag) có `relevance` nhỏ (gần 0), chỉ một số ít tag thực sự “đặc trưng” cho từng phim với `relevance` cao (gần 1).
- Tag là nguồn thông tin ngữ nghĩa mạnh, nhưng khá “thừa”
- Nếu khai thác tốt, ta có thể mô tả nội dung phim chi tiết hơn hẳn so với chỉ dựa vào genres.
- Là tiền đề để Mở rộng Content-based/TARS từ genres sang tag ngữ nghĩa.
- Xây dựng vector đặc trưng phim giàu ngữ nghĩa (high-dimensional semantic vector).

3.3 Các chiến lược cold-start

3.3.1 Popular Recommender System

Phương pháp thực hiện Popular Recommender System có rất nhiều cách thực hiện và đơn giản, có thể gợi ý theo số lượng những bộ phim được xem nhiều nhất, rating cao nhất,... tùy theo cột có mức độ quan tâm mà bạn thiết lập để gợi ý.

Phương pháp này thực chất không phải một mô hình mà nó chỉ là một thuật toán đơn giản hoặc phức tạp phụ thuộc vào cái bạn thiết lập, miễn đầu ra là danh sách k bộ phim được gợi ý.

Phương pháp này mục đích sẽ gợi ý cho tất cả các người dùng đặc biệt là những người dùng mới chưa có lịch sử hoạt động.

Các bước thực hiện như sau:

- Merge 2 bộ dữ liệu ratings và movies theo movieId
- Chia bộ dữ liệu thành train và test (80% train và 20% test, test tập người dùng mới)
- Tính độ phổ biến phim (trung bình rating mỗi phim)

Sau khi thực hiện thu được top 10 bộ phim để gợi ý cho bất kỳ người dùng mới nào:

Bảng 3. 9 Top 10 movies có popular cao nhất

title	mean	count
Shawshank Redemption, The	4.448969	50734
Godfather, The	4.363499	33150
Usual Suspects, The	4.333529	37598
Schindler's List	4.310110	40131
Godfather: Part II, The	4.278481	21804
Seven Samurai (Shichinin no samurai)	4.269521	9285
Rear Window	4.268150	13953
Band of Brothers	4.260407	3435
Casablanca	4.257825	19457

Đánh giá trên tập test với những người dùng mới (K=10) thu được kết quả:

Bảng 3. 10 Kết quả đánh giá phương pháp Popular

Precision@10	0.0812
Recall@10	0.0483
NDCG@10	0.0940

3.3.2 Content based Recommender System

Phương pháp Content based sử dụng TF – IDF để xử lý, biểu thị nội dung phim (thể hiện tần suất xuất hiện)

Giả định: Nếu người dùng thích một phim A họ sẽ có xu hướng thích các phim có nội dung tương tự.

Đặc trưng (features) sử dụng: genres sẽ được xử lý bằng TF – IDF và vector hóa thành dạng multi-hot / TF-IDF vector.

Các bước thực hiện như sau:

- Chuẩn hóa genres (tách chuỗi trong trường genres và vector hóa nó bằng TF-IDF).
- Xây dựng ma trận tương đồng giữa các phim (cosine, giá trị 1 là giống nhau, 0 là không liên quan).
- Khi gợi ý một danh sách phim cho một người dùng, dựa vào các phim user đã đánh giá trước đó, lựa chọn phim có điểm đặc trưng là cao nhất làm đại diện.
- Tính vector đặc trưng của user gợi ý bằng cách tổng hợp thông tin các phim đại diện (điểm cao nhất này)
- Tính độ tương đồng giữa user profile và gợi ý top phim có độ tương đồng cao nhất.

Đánh giá trên tập test với những người dùng mới (K=10, 100000 user) thu được kết quả:

Bảng 3. 11 Kết quả đánh giá phương pháp Content-based

Precision@10	0.0056
Recall@10	0.0026
NDCG@10	0.0060

3.3.3 Matrix Factorization

Sử dụng SVD (Singular Value Decomposition) trong surprise

Các bước thực hiện như sau:

- Tạo reader cho surprise khoảng dữ liệu rating (scale từ 0 đến 5)
- Tạo dataset cho surprise từ data ratings với 3 trường ([‘userId’, ‘movieId’, ‘rating’])

- Chia bộ dữ liệu thành trainset và testset (tỷ lệ 8/2)
- Các thông số SVD: $n_factor=100$, $lr_all=0.005$, $reg_all=0.02$
- Tạo set phim user xem trong trainset (đối với 500 user), tạo hàm gợi ý


Kết quả khi thực hiện trên testset như sau:

Bảng 3. 12 Kết quả phương pháp MF

Precision@10	0.1237
Recall@10	0.0815
NDCG@10	0.1422

3.3.4 Taxonomy-aware (2 cấp)

Dựa vào các thể loại phim (genres) tôi xây dựng một cây 2 cấp như hình sau:



Hình 3. 8 Cây 2 cấp genres

Các bước thực hiện như sau:

- Tạo một dataframe 2 cấp genres như hình trên với các trường movieId, title, parent (cấp 1), genres (cấp 2).
- Lưu trữ và đánh idx cho genres (cấp 2)
- Lưu trữ và đánh idx cho parents (cấp 1)
- Chuyển đổi vector (multi-hot) cho genres (cấp 2)
- Tạo hàm chuẩn hóa cho mid
- Tạo profile user theo genres (dùng các phim user ratings ≥ 3.5 để nhấn mạnh yêu thích).
- Tạo hàm tính relevance score với công thức

$$\text{Relevance score} = \alpha * \text{cosine}(\text{profile user, movies}) + (1-\alpha) * \text{pop_norm}$$
- Tạo hàm gợi ý cho taxonomy_aware (thiết lập $\alpha=0.7$)

Kết quả khi thực hiện trên testset (K=10, trên 500 user) như sau:

Bảng 3. 13 Kết quả phương pháp Taxonomy-aware

Precision@10	0.0153
Recall@10	0.0090
NDCG@10	0.0163

3.4 Kết chương

Trong chương 3, bốn chiến lược cold-start gồm popular-based, content-based, matrix factorization và taxonomy-aware đã được triển khai và đánh giá trên bộ dữ liệu MovieLens 20M.

Quy trình gồm các bước:

- Chuẩn hóa và xử lý dữ liệu
- Xây dựng mô hình cho từng chiến lược
- Thiết kế cơ chế gợi ý cho từng user
- Đánh giá mô hình theo Precision@K, Recall@K và NDCG@K

Kết quả cho thấy:

- Popular-based: đơn giản, dễ áp dụng và hoạt động tốt trong trường hợp người dùng hoàn toàn mới.
- Content-based: dựa trên TF-IDF của genres, tuy hợp lý nhưng hiệu quả thấp hơn (có thể do đặc trưng nội dung hạn chế chỉ 23 genres).
- Matrix Factorization: mạnh trong trường hợp gợi ý truyền thống.
- Taxonomy-aware: tận dụng cấu trúc phân cấp kết hợp cosine similarity

CHƯƠNG 4: ĐÁNH GIÁ KẾT QUẢ

4.1 Tổng hợp kết quả so sánh bốn mô hình

Sau khi huấn luyện và đánh giá bốn chiến lược trên tập kiểm tra (500 người cold-start), kết quả trung bình thu được như sau:

Bảng 4. 1 Tổng hợp chỉ số các phương pháp

Phương pháp	Precision@10	Recall@10	NDCG@10
Popular-based	0.0812	0.0483	0.0940
Content-based	0.0057	0.0025	0.0056
Matrix Factorization	0.1237	0.0815	0.1422
Taxonomy-aware	0.0153	0.0090	0.0163

Nhận xét

- Matrix Factorization (MF) có precision cao nhất (0.1237), cho thấy mô hình chọn được các phim phù hợp nhất với sở thích người dùng cold-start.
- Taxonomy-aware có kết quả tốt hơn content-based thuần, cho thấy việc khai thác cấu trúc phân cấp thể loại giúp cải thiện chất lượng gợi ý.
- Content-based có hiệu quả thấp do chỉ dựa trên độ tương đồng nội dung, không tận dụng hành vi người dùng khác.
- Popular baseline đạt kết quả khá do thiên lệch về các item phổ biến, nhưng không cá nhân hóa.

4.2 Kết chương

Chương này đã tổng hợp và đánh giá toàn diện bốn chiến lược cold-start dựa trên các chỉ số quan trọng.

Kết quả cho thấy:

- Taxonomy-aware là phương pháp tốt nhất cho cold-start người dùng.
- MF vẫn mạnh nhưng không phù hợp khi dữ liệu user ít.
- Content-based bằng TF-IDF genres cần bổ sung thông tin nội dung nâng cao (tags, keywords, embedding).
- Popular-based hoạt động ổn định nhưng thiếu cá nhân hóa.

KẾT LUẬN

Kết quả đạt được

- Xây dựng xong bốn chiến lược cold-start gồm: Popular-based, Content-based, MF và Taxonomy-aware.
- Hoàn thiện quy trình tiền xử lý dữ liệu, xây dựng đặc trưng mô hình.
- Thiết kế cơ chế gợi ý cho người dùng mới thông qua các phương pháp dựa trên nội dung và phân cấp thể loại
- Đánh giá hiệu suất mô hình bằng các chỉ số đánh giá phổ biến: Precision@K, Recall@K và NDCG@K.
- Xác định mô hình hiệu quả trong các chiến lược cold-start.
- So sánh ưu điểm nhược điểm từng chiến lược từ chỉ số đánh giá.
- Tổng hợp cái nhìn toàn diện.

Hạn chế đề tài

- Đặc trưng nội dung còn đơn giản, chỉ sử dụng genres, chưa khai thác các đặc trưng sâu khác như tóm tắt phim, đạo diễn,...
- Content-based chỉ dựa trên TF-IDF của thể loại, nên khả năng phân biệt phim còn thấp → dẫn đến precision/recall rất thấp.
- Matrix Factorization chưa được tối ưu cho cold-start, không kết hợp thêm thông tin nội dung để làm giàu embedding user mới.
- Taxonomy chỉ xây dựng ở 2 cấp, chưa khai thác đầy đủ cấu trúc phân cấp phong phú hơn.
- Tính toán chủ yếu chạy trên môi trường notebook, chưa triển khai thành hệ thống gợi ý hoàn chỉnh hay API ứng dụng thực tế.

Hướng phát triển

- Mở rộng đặc trưng nội dung
- Xây dựng Hybrid Recommender System
- Mở rộng thử Taxonomy-aware
- Triển khai hệ thống thực tế

TÀI LIỆU THAM KHẢO

- Algolia. (2023, 7 31). *Popular models and techniques for recommender systems*. Retrieved from <https://www.algolia.com/blog/ai/the-anatomy-of-high-performance-recommender-systems-part-iv>
- Tiep, V. H. (2017, 5 17). *Content-based Recommendation Systems*. Retrieved from <https://machinelearningcoban.com/2017/05/17/contentbasedrecommendersys/>
- Zonoozi, A. (2025, 1 31). *What Is Matrix Factorization?* Retrieved from <https://builtin.com/articles/matrix-factorization>