

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HƯNG YÊN



ĐỒ ÁN 3
NGHIÊN CỨU ẢNH HƯỞNG MÙA VỤ
LÊN DANH MỤC

NGÀNH: KHOA HỌC MÁY TÍNH
CHUYÊN NGÀNH: TRÍ TUỆ NHÂN TẠO VÀ KHOA HỌC DỮ LIỆU

SINH VIÊN: NGUYỄN ĐÌNH PHÚ
MÃ LỚP: 12422TN
MÃ SINH VIÊN: 10122291
HƯỚNG DẪN: PGS. TS. NGUYỄN VĂN HẬU

HƯNG YÊN – 2025

NHẬN XÉT

Nhận xét của giảng viên hướng dẫn:

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

GIẢNG VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

LỜI CAM ĐOAN

Em xin cam đoan đồ án “Nghiên cứu ảnh hưởng mùa vụ lên danh mục” là kết quả thực hiện của bản thân em dưới sự hướng dẫn của thầy Nguyễn Văn Hậu

Những phần sử dụng tài liệu tham khảo trong đồ án đã được nêu rõ trong phần tài liệu tham khảo. Các kết quả trình bày trong đồ án và chương trình xây dựng được hoàn toàn là kết quả do bản thân em thực hiện.

Nếu vi phạm lời cam đoan này, em xin chịu hoàn toàn trách nhiệm trước khoa và nhà trường.

Hung Yên, ngày 4 tháng 10 năm 2025

Sinh viên

Nguyễn Đình Phú

LỜI CẢM ƠN

Để có thể hoàn thành đồ án này, lời đầu tiên em xin phép gửi lời cảm ơn tới bộ môn Khoa học máy tính, Khoa Công nghệ thông tin – Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã tạo điều kiện thuận lợi cho em thực hiện đồ án này.

Đặc biệt em xin chân thành cảm ơn thầy Nguyễn Văn Hậu đã rất tận tình hướng dẫn, chỉ bảo em trong suốt thời gian thực hiện đồ án vừa qua.

Em cũng xin chân thành cảm ơn tất cả các Thầy, các Cô trong Trường đã tận tình giảng dạy, trang bị cho em những kiến thức cần thiết, quý báu để giúp em thực hiện được đồ án này.

Mặc dù em đã có cố gắng, nhưng với trình độ còn hạn chế, trong quá trình thực hiện đề tài không tránh khỏi những thiếu sót. Em hi vọng sẽ nhận được những ý kiến nhận xét, góp ý của các Thầy giáo, Cô giáo về những kết quả triển khai trong đồ án.

Em xin trân trọng cảm ơn!

MỤC LỤC

DANH MỤC CÁC THUẬT NGỮ.....	8
DANH MỤC CÁC BẢNG.....	11
CHƯƠNG 1: TỔNG QUAN VÀ LÝ DO CHỌN ĐỀ TÀI.....	12
1.1 Giới thiệu chung về hệ gợi ý	12
1.1.1 Khái niệm và vai trò	12
1.1.2 Các phương pháp cơ bản.....	12
1.1.3 Thách thức trong hệ gợi ý hiện đại.....	13
1.2 Ảnh hưởng của mùa vụ lên danh mục sản phẩm trong hệ gợi ý	14
1.2.1 Tại sao “mùa vụ / thời gian” là vấn đề quan trọng ?	14
1.2.2 Phát biểu bài toán cụ thể.....	14
1.2.3 Mục tiêu và ý nghĩa.....	15
1.3 Tổng quan các hướng tiếp cận liên quan.....	15
1.3.1 Hệ gợi ý dựa trên yếu tố thời gian.....	15
1.3.2 Nhận diện sản phẩm mùa vụ.....	15
1.3.3 Tích hợp mùa vụ vào mô hình gợi ý.....	16
CHƯƠNG 2: DỮ LIỆU, MÔ HÌNH VÀ PHƯƠNG PHÁP ĐỀ XUẤT.....	17
2.1 Bộ dữ liệu	17
2.1.1 Quy mô và cấu trúc dữ liệu.....	17
2.1.2 Đặc thù học thuật của bộ dữ liệu.....	18
2.2 Phát biểu bài toán và mô hình hóa dưới dạng đồ thị	19
2.3 Chiến lược thu nhỏ dữ liệu và làm sạch đồ thị.....	19
2.3.1 Lấy mẫu người dùng (User-centric Random Sampling)	19
2.3.2 Lọc lặp dựa trên ngưỡng tương tác (Iterative k-core Filtering).....	20
2.4 Mô hình hóa yếu tố thời gian và mùa vụ trong trọng số cạnh.....	20
2.5 Xây dựng ma trận kề chuẩn hóa và Graph Laplacian.....	21
2.6 Kiến trúc LightGCN trên đồ thị có trọng số mùa vụ.....	22

2.6.1 Khởi tạo embedding	22
2.6.2 Lan truyền đồ thị (Graph Propagation).....	22
2.6.3 Tổng hợp đa tầng (Layer Aggregation).....	23
2.6.4 Hàm dự đoán	23
2.7 Hàm mục tiêu và chiến lược tối ưu.....	24
2.7.1 Bài toán xếp hạng ngầm và BPR Loss	24
2.7.2 Regularization.....	24
2.7.3 Negative Sampling trên GPU	24
2.8 Quy trình huấn luyện và thiết lập siêu tham số	25
2.9 Mô hình Heuristic hiện đại có xét yếu tố thời gian	26
2.9.1 Mô hình Popularity có suy giảm thời gian	26
2.9.2 Mô hình đồng xuất hiện Item-Item (Co-occurrence-based CF)	27
2.9.3 Kết hợp Co-occurrence và Popularity	28
2.9.4 Thiết lập so sánh theo ngữ cảnh thời gian.....	28
2.9.5 Vai trò của Modern Heuristic trong đồ án.....	29
CHƯƠNG 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ	30
3.1 Thiết lập thực nghiệm.....	30
3.1.1 Chiến lược chia tập theo thời gian (Temporal Split).....	30
3.1.2 Giao thức đánh giá Top-K.....	30
3.2 Các độ đo đánh giá (Evaluation Metrics).....	31
3.2.1 Recall@K.....	31
3.2.2 Precision@K.....	32
3.2.3 NDCG@K (Normalized Discounted Cumulative Gain).....	32
3.2.4 MAP@K (Mean Average Precision).....	33
3.2.5 HitRate@K.....	33
3.3 Kết quả và phân tích mô hình Seasonal LightGCN.....	34
3.3.1 Phân tích theo Recall và Precision	34
3.3.2 Phân tích theo NDCG và MAP.....	35
3.3.3 Phân tích theo HitRate.....	35

3.4 Kết quả mô hình Heuristic hiện đại có xét thời gian.....	36
3.4.1 Tác động của cửa sổ thời gian và hàm suy giảm.....	36
3.4.2 Vai trò của Heuristic trong phân tích khoa học.....	36
KẾT LUẬN.....	38
TÀI LIỆU THAM KHẢO.....	41

DANH MỤC CÁC THUẬT NGỮ

Thuật ngữ	Viết tắt	Giải thích
Recommender System	RS	Hệ thống gợi ý, mục tiêu là dự đoán và xếp hạng các item mà người dùng có khả năng quan tâm.
Collaborative Filtering	CF	Phương pháp gợi ý dựa trên hành vi của nhiều người dùng thay vì nội dung item.
Implicit Feedback		Dữ liệu phản hồi gián tiếp (click, mua hàng, xem), không có rating tường minh.
Graph Neural Network	GNN	Mô hình học sâu trên dữ liệu dạng đồ thị.
LightGCN		Mô hình GNN tối giản cho bài toán recommendation, chỉ giữ lại lan truyền embedding tuyến tính.
Seasonal Effect		Hiện tượng hành vi người dùng thay đổi theo thời gian, mùa vụ, xu hướng.
Temporal Dynamics		Động lực thời gian trong dữ liệu tương tác người-vật phẩm.
Heuristic Method		Phương pháp dựa trên luật kinh nghiệm, không học tham số.

Co-occurrence		Đồng xuất hiện: hai item được mua/xem cùng trong một phiên hoặc giỏ hàng.
Popularity-based Ranking		Gợi ý dựa trên độ phổ biến (tần suất xuất hiện).
Time Decay		Cơ chế giảm trọng số của dữ liệu cũ theo hàm thời gian.
Representation Learning		Học biểu diễn vector ẩn của user và item.
Top-K Recommendation		Bài toán xếp hạng K item tốt nhất cho mỗi người dùng.
Recall@K		Tỷ lệ item đúng được truy hồi trong top-K.
Precision@K		Tỷ lệ item đúng trong danh sách K gợi ý.
NDCG@K		Thước đo xếp hạng có xét vị trí, dựa trên Discounted Cumulative Gain.
MAP@K		Mean Average Precision, trung bình độ chính xác tích lũy.
HitRate@K	HR@K	Xác suất ít nhất một item đúng xuất hiện trong top-K.
BPR		Bayesian Personalized Ranking, hàm loss cho implicit feedback.

Đồ án 3: Nghiên cứu ảnh hưởng mùa vụ lên danh mục

Long-tail Distribution		Phân bố đuôi dài của item, số ít rất phổ biến, số nhiều rất hiếm.
Sparsity		Độ thưa của ma trận user-item.
Temporal Split		Chia train/test theo trục thời gian.
Ranking-based Evaluation		Đánh giá dựa trên thứ hạng thay vì sai số dự đoán.
Cold-start		Vấn đề thiếu dữ liệu cho user/item mới.
Modern Heuristic		Tổ hợp luật đồng xuất hiện + xu hướng + thời gian suy giảm.
Seasonal Modeling		Mô hình hóa yếu tố mùa vụ trong recommendation.

DANH MỤC CÁC BẢNG

Bảng 1.1 Các phương pháp phổ biến xây dựng hệ gợi ý.....	13
Bảng 2.1 Bối cảnh huấn luyện.....	28
Bảng 3.1 Kết quả và phân tích mô hình Seasonal LightGCN.....	34
Bảng 3.2 Kết quả mô hình Heuristic	36

CHƯƠNG 1: TỔNG QUAN VÀ LÝ DO CHỌN ĐỀ TÀI

1.1 Giới thiệu chung về hệ gợi ý

1.1.1 Khái niệm và vai trò

Hệ gợi ý (**Recommendation System - RecSys**) là một nhánh quan trọng trong lĩnh vực trí tuệ nhân tạo, được xây dựng nhằm dự đoán nhu cầu và sở thích của người dùng, từ đó đề xuất các sản phẩm hoặc dịch vụ phù hợp. Với sự bùng nổ dữ liệu trong thương mại điện tử, mạng xã hội và các nền tảng nội dung số, hệ gợi ý trở thành công cụ thiết yếu giúp giảm tải tình trạng "quá tải thông tin" đồng thời tăng tính cá nhân hóa trong trải nghiệm người dùng.

Trong thương mại điện tử như Amazon, Shopee hay các nền tảng giải trí như Netflix, Spotify, RecSys đóng vai trò cốt lõi trong việc tăng tỷ lệ nhấn chọn (CTR), tỷ lệ chuyển đổi (Conversion Rate), gia tăng doanh thu và giữ chân khách hàng. Chính vì vậy, nghiên cứu cải thiện hiệu năng của hệ gợi ý luôn là chủ đề được quan tâm rộng rãi trong cả học thuật lẫn thực tiễn.

1.1.2 Các phương pháp cơ bản

Có ba lớp phương pháp phổ biến (có thể kết hợp) để xây dựng hệ gợi ý:

Phương pháp	Ý tưởng chính	Ưu điểm	Hạn chế
Collaborative Filtering	Dùng thông tin tương tác người dùng - mục (rating, click, mua, xem) để tìm người dùng tương đồng hoặc mục tương đồng	Không cần hiểu rõ đặc trưng mục; dễ áp dụng	Vấn đề cold-start (người dùng/mục mới), dữ liệu thưa (sparse), hiệu suất khi tập lớn
Content-based	Dùng đặc trưng của	Giải quyết phân	Phụ thuộc vào

	mục (thông tin mô tả, từ khóa, đặc trưng nội dung) để so sánh	nào cold-start mục, có giải thích được vì sao gợi ý	chất lượng đặc trưng mục, khả năng mở rộng khi dữ liệu lớn
Hybrid	Kết hợp hai hoặc nhiều phương pháp để tận dụng ưu điểm, giảm nhược điểm	Linh hoạt, hiệu năng cao hơn trong nhiều trường hợp thực tế	Cấu trúc phức tạp hơn, cần thiết kế hợp lý để cân bằng các thành phần

Bảng 1.1 Các phương pháp phổ biến xây dựng hệ gợi ý

Ví dụ, Netflix sử dụng mô hình Hybrid, kết hợp dự đoán dựa vào người dùng tương đồng và các đặc trưng nội dung phim.

Ngoài ra, trong các hệ gợi ý động (“dynamic recommender systems”), yếu tố thời gian được đưa vào để bắt kịp sự thay đổi sở thích người dùng theo thời gian.

1.1.3 Thách thức trong hệ gợi ý hiện đại

- Dữ liệu thiếu (**sparse data**), đặc biệt khi có nhiều mục hoặc người dùng mới
- **Cold-start** (người dùng mới, sản phẩm mới)
- Khả năng mở rộng (**scalability**) khi hệ có rất nhiều người dùng và mục
- Tính động/dao động theo thời gian (**temporal dynamics**), tức là sở thích người dùng và mức độ phổ biến mục có thể thay đổi theo thời gian
- Đa bối cảnh (**context-aware**), tức là gợi ý có thể phụ thuộc vào ngữ cảnh (thời gian, địa điểm, thiết bị, mùa, sự kiện)
- Cân bằng giữa “lợi ích ngắn hạn” (gợi ý những gì người dùng dễ click mua) và “khám phá / đa dạng hóa” (giới thiệu mục mới, tránh lặp lại)
- Công bằng (**fairness**), minh bạch, giải thích (**explainability**) của gợi ý

Nhiều nghiên cứu gần đây cũng xem xét yếu tố thời gian, ảnh hưởng thời gian đến việc gợi ý - ví dụ hệ gợi ý thời gian (**time-aware recommender systems**) hoặc hệ gợi ý động (**dynamic RS**)

1.2 Ảnh hưởng của mùa vụ lên danh mục sản phẩm trong hệ gợi ý

1.2.1 Tại sao “mùa vụ / thời gian” là vấn đề quan trọng ?

Trong thực tế, hành vi mua hàng của người dùng phụ thuộc rất nhiều vào mùa vụ (ví dụ: mùa hè cần quạt, mùa đông cần áo lạnh, các dịp lễ như Tết, Giáng sinh cần những món đồ trang trí hoặc vật phẩm thương mua trong dịp đó, v.v.).

Nếu hệ gợi ý không xét đến mùa vụ, nó có thể gợi ý sản phẩm không phù hợp vào thời điểm hiện tại (ví dụ gợi ý áo khoác mùa đông vào mùa hè), khiến trải nghiệm người dùng giảm.

Mục tiêu của đề tài là: làm thế nào để hệ gợi ý “**nhạy**” với mùa vụ, tức là khi mùa vụ thay đổi, danh mục sản phẩm gợi ý cũng thay đổi cho phù hợp, tăng hiệu quả (tỷ lệ mua, doanh thu) hơn so với hệ gợi ý thông thường.

1.2.2 Phát biểu bài toán cụ thể

Đề tài tập trung giải quyết hai vấn đề chính:

1. **Mô hình hóa ảnh hưởng mùa vụ lên danh mục sản phẩm:** Xác định và học được mối quan hệ giữa mùa và sản phẩm qua embedding mùa vụ.
2. **Xây dựng mô hình gợi ý nhạy theo mùa:** Tích hợp đặc trưng mùa vụ vào quá trình dự đoán độ phù hợp của từng sản phẩm đối với người dùng, sao cho hệ gợi ý thay đổi theo mùa hiện tại.

Nói cách khác, bài toán không chỉ yêu cầu dự đoán sản phẩm “phù hợp với sở thích” mà còn yêu cầu dự đoán sản phẩm “phù hợp với thời điểm”.

1.2.3 Mục tiêu và ý nghĩa

- Nâng cao độ chính xác của hệ gợi ý nhờ phản ánh được chu kỳ tiêu dùng theo mùa.
- Đem lại trải nghiệm gợi ý thực tế hơn, tránh đề xuất sản phẩm không phù hợp thời điểm.
- Ứng dụng rộng rãi trong thương mại điện tử, siêu thị, thời trang và bán lẻ.
- Tạo nền tảng nghiên cứu cho các mô hình recommendation có yếu tố thời gian và ngữ cảnh.

1.3 Tổng quan các hướng tiếp cận liên quan

1.3.1 Hệ gợi ý dựa trên yếu tố thời gian

Nhiều nghiên cứu chỉ ra rằng sở thích người dùng thay đổi theo thời gian và hệ gợi ý cần học được những thay đổi này. Các hướng tiếp cận chính gồm:

- **Time-aware Recommender Systems:** mô hình hóa thời gian như một đặc trưng quan trọng.
- **Dynamic Recommender Systems:** học sự thay đổi liên tục trong sở thích người dùng.
- **Mô hình chuỗi (RNN/Transformer):** xử lý các phiên mua hàng theo thứ tự thời gian.

1.3.2 Nhận diện sản phẩm mùa vụ

Nhiều nghiên cứu tìm cách xác định mức độ “mùa vụ” của sản phẩm để cải thiện gợi ý. Những hướng đi phổ biến:

- Tính trọng số mùa vụ (seasonality weight).
- Dùng Bayesian inference để ước lượng độ mùa vụ theo thời gian.
- Dùng mô hình phân loại đa phương thức (multimodal) để phát hiện sản phẩm mùa vụ.

1.3.3 Tích hợp mùa vụ vào mô hình gợi ý

Một số chiến lược kết hợp mùa vụ với mô hình recommendation gồm:

- **Feature-based:** Đưa thời gian/mùa vụ vào làm một đặc trưng (feature) đầu vào cho các mô hình.

- **Time-splitting:** Chia dữ liệu theo thời gian và học mô hình riêng cho từng mùa.

- **Graph-based Weighting (Hướng tiếp cận của đề tài):** Mô hình hóa dữ liệu dưới dạng đồ thị người dùng - sản phẩm (User-Item Graph). Yếu tố mùa vụ và thời gian được tích hợp trực tiếp vào trọng số của các cạnh (edge weights) trong đồ thị. Các tương tác gần thời điểm hiện tại hoặc đúng mùa sẽ có trọng số lớn hơn, giúp quá trình truyền tin (message passing) trong mạng GNN ưu tiên các thông tin này.

Đề tài này lựa chọn cách tiếp cận Graph Neural Network (LightGCN) kết hợp với cơ chế Seasonal Edge Weighting, phù hợp với dữ liệu giao dịch thưa và quy mô lớn của bộ dữ liệu thực nghiệm.

CHƯƠNG 2: DỮ LIỆU, MÔ HÌNH VÀ PHƯƠNG PHÁP ĐỀ XUẤT

2.1 Bộ dữ liệu

Các thực nghiệm trong đồ án được thực hiện trên bộ dữ liệu công khai H&M Personalized Fashion Recommendations, được phát hành trong khuôn khổ cuộc thi của Kaggle: <https://www.kaggle.com/competitions/h-and-m-personalized-fashion-recommendations>

Bộ dữ liệu này ghi lại toàn bộ lịch sử giao dịch mua sắm của chuỗi bán lẻ thời trang H&M trong giai đoạn từ tháng 09/2018 đến tháng 09/2020, bao gồm hàng chục triệu tương tác giữa khách hàng và sản phẩm. Đây là một trong những bộ dữ liệu chuẩn (benchmark) lớn nhất cho bài toán Implicit Feedback Recommendation trong lĩnh vực thương mại điện tử thời trang.

2.1.1 Quy mô và cấu trúc dữ liệu

Tập dữ liệu giao dịch (**transactions_train.csv**) có các đặc trưng chính:

Số người dùng (customers): ~1,37 triệu

Số sản phẩm (articles): ~105 nghìn

Số giao dịch: ~31 triệu

Khoảng thời gian: 2 năm (weekly seasonal cycles rõ rệt)

Dạng phản hồi: **Implicit feedback** (chỉ biết mua / không mua, không có rating)

Mỗi bản ghi giao dịch có dạng bộ ba: (u,i,t) trong đó:

u là mã khách hàng (customer_id),

i là mã sản phẩm (article_id),

t là thời điểm mua (t_{dat}).

Dữ liệu thể hiện đặc tính:

Cực kỳ thưa (high sparsity):

$$\text{Sparsity} = 1 - \frac{|\mathcal{E}|}{|\mathcal{U}| \times |\mathcal{I}|} \approx 99.999\%$$

Phân phối long-tail: số ít sản phẩm rất phổ biến, phần lớn sản phẩm có rất ít lượt mua.

Tính mùa vụ rõ rệt: chu kỳ tuần, tháng, mùa (Summer, Winter, Holiday sales), rất phù hợp để nghiên cứu temporal dynamics và seasonal effect.

2.1.2 Đặc thù học thuật của bộ dữ liệu

Bộ H&M hội tụ đầy đủ các thách thức điển hình của hệ gợi ý hiện đại:

1. **Implicit Feedback Only:** Không tồn tại đánh giá tường minh (explicit rating), do đó bài toán trở thành học xếp hạng (ranking) thay vì hồi quy.
2. **Concept Drift theo thời gian:** Sở thích người dùng thay đổi theo mùa (season), xu hướng (trend), và vòng đời sản phẩm (product life-cycle).
3. **Cấu trúc đồ thị lưỡng phân quy mô lớn:** Người dùng và sản phẩm tạo thành một bipartite graph với hàng chục triệu cạnh, là môi trường lý tưởng cho các mô hình Graph Neural Network.

Chính các đặc điểm này làm cho bộ dữ liệu H&M trở thành nền tảng phù hợp để kiểm chứng mô hình Seasonal LightGCN được đề xuất.

2.2 Phát biểu bài toán và mô hình hóa dưới dạng đồ thị

Bài toán đặt ra trong đề tài là xây dựng một hệ thống gợi ý sản phẩm (Recommender System) cho dữ liệu giao dịch theo thời gian, trong đó mỗi bản ghi có dạng:

$$(u, i, t), \quad u \in \mathcal{U}, i \in \mathcal{I}, t \in \mathbb{T}$$

với u là người dùng (User), i là sản phẩm (Item), và t là thời điểm phát sinh giao dịch. Dữ liệu thuộc dạng Implicit Feedback, tức chỉ quan sát được hành vi mua, không có đánh giá mức độ hài lòng.

$$G = (\mathcal{V}, \mathcal{E}), \quad \mathcal{V} = \mathcal{U} \cup \mathcal{I}$$

Một cạnh $(u, i) \in \mathcal{E}$ tồn tại nếu người dùng u đã từng tương tác với sản phẩm i . Mục tiêu của mô hình là học ánh xạ:

$$f: (\mathcal{U}, \mathcal{I}) \rightarrow \mathbb{R}$$

sao cho điểm số $f(u, i)$ phản ánh mức độ phù hợp để xếp hạng (ranking) các sản phẩm cho từng người dùng.

Khác với các mô hình đồ thị tĩnh truyền thống, đề tài này đưa yếu tố thời gian và mùa vụ (seasonality) trực tiếp vào cấu trúc đồ thị thông qua việc gán trọng số động cho các cạnh, biến đồ thị thành một Weighted Temporal Graph.

2.3 Chiến lược thu nhỏ dữ liệu và làm sạch đồ thị

Dữ liệu giao dịch của H&M có quy mô rất lớn, số lượng người dùng và sản phẩm lên tới hàng trăm nghìn, dẫn đến đồ thị lưỡng phân có hàng triệu cạnh và độ thưa cao. Để đảm bảo tính khả thi tính toán và ổn định của quá trình lan truyền trên đồ thị, một chiến lược tiền xử lý gồm hai bước chính được áp dụng.

2.3.1 Lấy mẫu người dùng (User-centric Random Sampling)

Từ tập người dùng gốc $\mathcal{U}$, một tập con $\mathcal{U}' \subset \mathcal{U}$ có kích thước cố định N được chọn ngẫu nhiên không hoàn lại:

$$\mathcal{U}' \sim \text{Uniform}(\mathcal{U}, N)$$

Chỉ các giao dịch liên quan đến $\mathcal{U}'$ mới được giữ lại. Cách tiếp cận này giúp:

- Giảm bậc tự do của đồ thị.
- Bảo toàn phân phối thống kê toàn cục.
- Tạo điều kiện so sánh công bằng giữa các kịch bản thí nghiệm.

2.3.2 Lọc lặp dựa trên ngưỡng tương tác (Iterative k-core Filtering)

Sau khi lấy mẫu, đồ thị có thể chứa nhiều nút bậc thấp gây nhiễu cho quá trình Graph Convolution. Do đó, ta áp dụng bộ lọc k-core với $k=5$ theo cách lặp:

$$\deg(u) \geq k, \quad \deg(i) \geq k$$

Quá trình loại bỏ user và item có số tương tác nhỏ hơn k được lặp lại cho đến khi đồ thị hội tụ. Kết quả là một đồ thị con dày đặc hơn, trong đó mọi nút đều có đủ số lân cận để quá trình lan truyền embedding có ý nghĩa thống kê.

2.4 Mô hình hóa yếu tố thời gian và mùa vụ trong trọng số cạnh

Trong đồ thị truyền thống, mỗi cạnh (u, i) chỉ mang giá trị nhị phân. Tuy nhiên, trong thực tế hành vi tiêu dùng chịu ảnh hưởng mạnh bởi:

- Độ mới (Recency).
- Chu kỳ mùa vụ (Seasonality theo tháng).

Do đó, đề tài định nghĩa trọng số cạnh w_{ui} là tích của hai thành phần:

$$w_{ui} = \underbrace{\frac{1}{1 + \lambda \cdot \Delta t_{ui}}}_{\text{Time Decay}} \times \underbrace{\gamma \cdot \mathbb{I}(\text{month}(t_{ui}) = \text{month}(t_{\text{test}})) + 1 \cdot \mathbb{I}(\text{otherwise})}_{\text{Seasonal Boost}}$$

Trong đó:

- Δt_{ui} là số ngày từ thời điểm giao dịch đến mốc đánh giá.
- λ là hệ số suy giảm theo thời gian.
- $\gamma > 1$ là hệ số khuếch đại mùa vụ.
- Hàm chỉ báo $\mathbb{I}(\cdot)$ xác định giao dịch có thuộc cùng tháng với tập kiểm tra hay không.

Cơ chế này biến đồ thị ban đầu thành một Seasonally Reweighted Graph, trong đó các cạnh phản ánh mức độ liên quan động của hành vi trong bối cảnh thời gian hiện tại.

2.5 Xây dựng ma trận kề chuẩn hóa và Graph Laplacian

Từ đồ thị lưỡng phân có trọng số mùa vụ $G = (\mathcal{U} \cup \mathcal{I}, \mathcal{E}, W)$ ta xây dựng ma trận kề có trọng số:

$$A = \begin{bmatrix} 0 & W \\ W^T & 0 \end{bmatrix} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times (|\mathcal{U}|+|\mathcal{I}|)}$$

trong đó $W_{ui} = w_{ui}$ là trọng số cạnh giữa user u và item i .

Để đảm bảo tính ổn định số học và tránh hiện tượng bùng nổ embedding khi lan truyền qua nhiều lớp, ma trận kề được chuẩn hóa theo dạng Laplacian đối xứng:

$$\tilde{A} = D^{-1/2} A D^{-1/2}$$

với D là ma trận đường chéo bậc nút:

$$D_{vv} = \sum_k A_{vk}$$

Phép chuẩn hóa này có hai ý nghĩa:

1. Về mặt toán học, nó tương đương với việc chuẩn hóa năng lượng phổ của toán tử lan truyền, giúp quá trình nhân ma trận lặp không gây mất ổn định.
2. Về mặt ngữ nghĩa, nó cân bằng ảnh hưởng của các nút có bậc lớn (popular items) và các nút ít tương tác, tránh việc embedding bị chi phối quá mạnh bởi các hub.

Ma trận $\tilde{A}$ chính là toán tử lan truyền (Propagation Operator) được sử dụng trong các lớp của LightGCN.

2.6 Kiến trúc LightGCN trên đồ thị có trọng số mùa vụ

2.6.1 Khởi tạo embedding

Mỗi user u và item i được gán một vector embedding ban đầu:

$$\mathbf{e}_u^{(0)}, \mathbf{e}_i^{(0)} \in \mathbb{R}^d$$

Các vector này được khởi tạo ngẫu nhiên theo phân phối chuẩn. Gộp lại thành ma trận embedding toàn cục:

$$\mathbf{E}^{(0)} = \begin{bmatrix} \mathbf{E}_U^{(0)} \\ \mathbf{E}_I^{(0)} \end{bmatrix} \in \mathbb{R}^{(|\mathcal{U}|+|\mathcal{I}|) \times d}$$

2.6.2 Lan truyền đồ thị (Graph Propagation)

Khác với GCN cổ điển, LightGCN loại bỏ các phép biến đổi tuyến tính và hàm kích hoạt phi tuyến, chỉ giữ lại cơ chế lan truyền thuần túy:

$$\mathbf{E}^{(l+1)} = \tilde{\mathbf{A}} \mathbf{E}^{(l)}, \quad l = 0, 1, \dots, L-1$$

Do $\tilde{A}$ đã được gán trọng số mùa vụ, nên mỗi bước lan truyền thực chất là một phép tổng có trọng số, trong đó:

- Các tương tác mới (recency cao) và đúng mùa (seasonal boost) có hệ số truyền lớn.

- Các tương tác cũ, lệch mùa bị suy giảm ảnh hưởng.

Như vậy, embedding của người dùng tại các lớp cao sẽ bị kéo về phía các sản phẩm mang tính thời vụ hiện tại.

2.6.3 Tổng hợp đa tầng (Layer Aggregation)

Embedding cuối cùng của mỗi nút được lấy trung bình qua tất cả các tầng:

$$E = \frac{1}{L+1} \sum_{l=0}^L E^{(l)}$$

Cơ chế này cho phép kết hợp:

- Thông tin bậc thấp (sở thích dài hạn, global preference).
- Thông tin bậc cao (sở thích ngắn hạn, xu hướng theo mùa).

Sau khi tách lại:

$$E = \begin{bmatrix} E_U \\ E_I \end{bmatrix}$$

ta thu được embedding cuối cùng cho user và item.

2.6.4 Hàm dự đoán

Điểm phù hợp giữa user u và item i được tính bằng tích vô hướng:

$$\hat{y}_{ui} = \mathbf{e}_u^T \mathbf{e}_i$$

2.7 Hàm mục tiêu và chiến lược tối ưu

2.7.1 Bài toán xếp hạng ngầm và BPR Loss

Do dữ liệu thuộc dạng implicit feedback, mục tiêu không phải dự đoán giá trị tuyệt đối mà là học thứ hạng tương đối. Với mỗi bộ ba (u, i, j) , trong đó:

- i là sản phẩm đã mua (positive item),
- j là sản phẩm chưa mua (negative item),

mô hình tối ưu hóa hàm Bayesian Personalized Ranking:

$$\mathcal{L}_{\text{BPR}} = - \sum_{(u,i,j)} \log \sigma(\hat{y}_{ui} - \hat{y}_{uj})$$

Trong đó $\sigma(\cdot)$ là hàm sigmoid. Hàm loss khuyến khích:

$$\hat{y}_{ui} > \hat{y}_{uj}$$

với biên càng lớn càng tốt.

2.7.2 Regularization

Để tránh overfitting, một hạng tử chuẩn hóa L2 được thêm vào:

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda (\|\mathbf{e}_u\|^2 + \|\mathbf{e}_i\|^2 + \|\mathbf{e}_j\|^2)$$

2.7.3 Negative Sampling trên GPU

Thay vì sinh mẫu âm trên CPU, đề tài thực hiện sampling trực tiếp trong không gian chỉ số trên GPU:

$$j \sim \text{Uniform}(\mathcal{J})$$

Cách làm này loại bỏ chi phí truyền dữ liệu CPU-GPU và cho phép mỗi mini-batch sinh hàng nghìn mẫu âm trong thời gian hằng số, giúp tốc độ huấn luyện tăng đáng kể.

2.8 Quy trình huấn luyện và thiết lập siêu tham số

Toàn bộ quá trình huấn luyện được thực hiện theo mini-batch stochastic optimization:

1. Lấy một batch các cặp (u, i) từ tập huấn luyện.
2. Sinh ngẫu nhiên các item âm j .
3. Tính embedding thông qua LightGCN với toán tử lan truyền $\tilde{A}$.
4. Tối ưu hàm BPR Loss bằng Adam:

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$$

với η là learning rate.

Các siêu tham số chính:

Kích thước embedding: $d = 64$

Số lớp lan truyền: $L = 3$

Batch size: 2048, Optimizer: Adam, Learning rate: 0.001

Hệ số suy giảm thời gian λ và hệ số khuếch đại mùa vụ γ .

Hai mô hình được huấn luyện song song:

1. Baseline LightGCN: $\tilde{A}$ xây dựng từ trọng số đồng nhất.
2. Seasonal LightGCN: $\tilde{A}$ xây dựng từ trọng số suy giảm thời gian và khuếch đại mùa vụ.

Sự khác biệt duy nhất nằm ở cấu trúc trọng số của đồ thị, giúp đánh giá thuần túy ảnh hưởng của yếu tố mùa vụ lên chất lượng biểu diễn embedding và hiệu quả gợi ý.

2.9 Mô hình Heuristic hiện đại có xét yếu tố thời gian

Nhằm kiểm chứng rằng cải thiện hiệu năng của mô hình đề xuất không chỉ đến từ việc đưa thông tin thời gian vào dữ liệu mà thực sự đến từ cơ chế học biểu diễn trên đồ thị, tiến hành xây dựng một tập các mô hình so sánh (baseline) thuộc nhóm heuristic hiện đại có xét yếu tố thời gian. Các mô hình này không sử dụng học sâu (deep learning), mà dựa trên các nguyên lý thống kê và khai phá luật kết hợp, vốn được sử dụng rộng rãi trong các hệ gợi ý công nghiệp quy mô lớn.

Cụ thể, triển khai một khung so sánh dựa trên sự kết hợp giữa:

1. Item Popularity có suy giảm theo thời gian (Time-decayed Popularity)
2. Item-Item Co-occurrence (Market Basket Analysis / Item-based Collaborative Filtering)
3. Cửa sổ thời gian ngắn hạn và dài hạn (Short-term vs Long-term Context)

Mục tiêu là mô phỏng các hệ gợi ý dựa trên xu hướng (trend-aware recommender) và so sánh trực tiếp giữa bối cảnh tĩnh (non-seasonal) và bối cảnh động (seasonal).

2.9.1 Mô hình Popularity có suy giảm thời gian

Với mỗi sản phẩm i , điểm phổ biến được xác định bởi tổng trọng số các lần xuất hiện trong tập huấn luyện:

$$s_i = \sum_{t \in \mathcal{T}_i} \frac{1}{(\Delta t + 1)^\alpha}$$

Trong đó:

$\mathcal{T}_i$ là tập các thời điểm mà sản phẩm i được mua.

$\Delta t = t_{\max} - t$ là số ngày chênh lệch giữa thời điểm mua và thời điểm hiện tại.

α là hệ số suy giảm theo lũy thừa (power-law decay).

Hai cấu hình được sử dụng:

1. Non-seasonal: $\alpha = 0$

$$s_i = \sum_{t \in \mathcal{T}_i} 1$$

tương đương với Popularity tĩnh truyền thống.

2. Seasonal: $\alpha = 0.7$

Ưu tiên mạnh các giao dịch gần hiện tại, mô phỏng xu hướng ngắn hạn.

Cách tiếp cận này tương đương với các mô hình recency-biased popularity thường dùng trong hệ thống gợi ý tin tức, thương mại điện tử và streaming media.

2.9.2 Mô hình đồng xuất hiện Item-Item (Co-occurrence-based CF)

Dựa trên giả thuyết: “Các sản phẩm thường được mua cùng nhau trong cùng một phiên (basket) có xu hướng liên quan ngữ nghĩa và chức năng.”

Từ dữ liệu giao dịch, mỗi giỏ hàng B_u^t của người dùng u tại thời điểm t được xem là một tập sản phẩm. Ma trận đồng xuất hiện được xây dựng như sau:

$$C_{ij} = \sum_{(u,t)} \mathbb{I}(i \in B_u^t \wedge j \in B_u^t)$$

Trong đó C_{ij} là số lần sản phẩm i và j cùng xuất hiện trong một giỏ hàng.

Với mỗi sản phẩm, chỉ giữ lại Top-N láng giềng có giá trị C_{ij} lớn nhất nhằm giảm nhiễu.

Mô hình dự đoán dựa trên sản phẩm mua gần nhất i_u^{last} , sau đó đề xuất các sản phẩm j có $C_{i_u^{last}, j}$ lớn nhất.

Đây chính là dạng Item-based Collaborative Filtering không học embedding, thường được dùng làm baseline mạnh trong các bài toán recommendation quy mô lớn.

2.9.3 Kết hợp Co-occurrence và Popularity

Danh sách gợi ý Top-K cho mỗi người dùng được xây dựng theo hai tầng:

1. Tầng cá nhân hóa (Personalized Layer): Lấy các sản phẩm đồng xuất hiện mạnh nhất với sản phẩm mua gần nhất của người dùng.
2. Tầng xu hướng toàn cục (Trend-aware Filling): Nếu số lượng gợi ý chưa đủ K, bổ sung bằng các sản phẩm có Popularity cao nhất theo mô hình suy giảm thời gian.

Cách kết hợp này phản ánh kiến trúc phổ biến trong các hệ recommender thực tế: “Personalized signal first, global trend as back-off.”

2.9.4 Thiết lập so sánh theo ngữ cảnh thời gian

Hai bối cảnh huấn luyện được thiết lập:

Kịch bản	Cửa sổ dữ liệu	Ý nghĩa
Non-seasonal (Global)	52 tuần	Sở thích dài hạn, quy luật tĩnh
Seasonal (Local)	5 tuần	Xu hướng ngắn hạn, mùa vụ

Bảng 2.1 Bối cảnh huấn luyện

Qua đó, cùng một thuật toán heuristic được chạy trong hai chế độ:

- Static Long-term Model: Không xét suy giảm thời gian, học quy luật toàn cục.

- Dynamic Short-term Model: Có suy giảm thời gian mạnh, tập trung vào mùa hiện tại.

2.9.5 Vai trò của Modern Heuristic trong đồ án

Khung so sánh này đóng vai trò then chốt về mặt phương pháp luận:

1. Chứng minh rằng: Chỉ riêng việc đưa yếu tố thời gian và cửa sổ ngắn hạn cũng đã giúp cải thiện Recall và NDCG.
2. Tạo nền tảng để lập luận rằng: Mô hình Seasonal LightGCN không chỉ kế thừa lợi ích của time-aware heuristic, mà còn vượt trội nhờ khả năng học biểu diễn ẩn (latent representation) và lan truyền tín hiệu trên đồ thị.

Nói cách khác, phân heuristic hiện đại này giúp tách bạch hai nguồn cải thiện:

- Temporal Effect (mùa vụ, xu hướng)
- Graph Representation Learning Effect (LightGCN)

Từ đó khẳng định đóng góp khoa học cốt lõi của đề tài nằm ở việc kết hợp hai yếu tố này trong một khung đồ thị học sâu thống nhất.

CHƯƠNG 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ

3.1 Thiết lập thực nghiệm

3.1.1 Chiến lược chia tập theo thời gian (Temporal Split)

Khác với chia ngẫu nhiên, trong hệ gợi ý thực tế cần tuân thủ trục thời gian để tránh rò rỉ thông tin tương lai (data leakage). Do đó, dữ liệu được chia theo nguyên tắc:

- Tập huấn luyện: các giao dịch trước thời điểm T_{test} .
- Tập kiểm tra: các giao dịch trong cửa sổ $[T_{\text{test}}, T_{\text{test}} + \Delta]$.

Cụ thể:

$$\mathcal{D}_{\text{train}} = \{(u, i, t) \mid t < T_{\text{test}}\}$$

$$\mathcal{D}_{\text{test}} = \{(u, i, t) \mid t \geq T_{\text{test}}\}$$

Trong đó $\Delta = 1$ tuần, mô phỏng bài toán next-item recommendation trong ngữ cảnh ngắn hạn.

3.1.2 Giao thức đánh giá Top-K

Với mỗi người dùng u , mô hình sinh ra một danh sách gợi ý:

$$\widehat{\mathcal{J}}_u^K = \{i_1, i_2, \dots, i_K\}$$

trong đó $K = 12$ theo cấu hình thí nghiệm. Tập sản phẩm thực sự được mua trong giai đoạn test là:

$$\mathcal{J}_u^{\text{test}}$$

Bài toán trở thành đánh giá chất lượng của một danh sách xếp hạng (ranking list) trong bối cảnh implicit top-K recommendation.

3.2 Các độ đo đánh giá (Evaluation Metrics)

Trong bài toán gợi ý với phản hồi ẩn (Implicit Feedback Recommendation), mục tiêu không phải là dự đoán chính xác giá trị tuyệt đối của một đánh giá, mà là xếp hạng đúng các sản phẩm liên quan lên đầu danh sách gợi ý. Do đó, các độ đo được sử dụng đều thuộc nhóm ranking-based metrics, đánh giá chất lượng thứ hạng của Top-K đề xuất.

Với mỗi người dùng u , ký hiệu:

$\mathcal{I}_u^{\text{test}}$: tập các sản phẩm mà người dùng u thực sự mua trong tập kiểm tra.

$\hat{\mathcal{I}}_u^K = (i_1, i_2, \dots, i_K)$: danh sách K sản phẩm được mô hình gợi ý theo thứ tự giảm dần của điểm số dự đoán.

3.2.1 Recall@K

Recall@K đo lường tỷ lệ các sản phẩm liên quan được mô hình thu hồi trong Top-K:

$$\text{Recall@K}(u) = \frac{|\mathcal{I}_u^{\text{test}} \cap \hat{\mathcal{I}}_u^K|}{|\mathcal{I}_u^{\text{test}}|}$$

Giá trị Recall@K trung bình trên toàn bộ tập người dùng:

$$\text{Recall@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \text{Recall@K}(u)$$

Về mặt ý nghĩa, Recall phản ánh khả năng bao phủ sở thích thực của người dùng. Trong hệ gợi ý, Recall cao đồng nghĩa với việc hệ thống không bỏ sót các sản phẩm mà người dùng có khả năng mua trong tương lai gần. Tuy nhiên, Recall không xét đến thứ tự xếp hạng trong Top-K.

3.2.2 Precision@K

Precision@K đo lường tỷ lệ các gợi ý đúng trong danh sách Top-K:

$$\text{Precision@K}(u) = \frac{|\mathcal{I}_u^{\text{test}} \cap \hat{\mathcal{I}}_u^K|}{K}$$

Giá trị Precision@K trung bình trên toàn bộ tập người dùng:

$$\text{Precision@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \text{Precision@K}(u)$$

Precision phản ánh độ tinh khiết (purity) của danh sách gợi ý: trong K sản phẩm được đề xuất, bao nhiêu sản phẩm thực sự hữu ích. Chỉ số này đặc biệt quan trọng trong các hệ thống thương mại điện tử, nơi không gian hiển thị có hạn (ví dụ: 12 sản phẩm trên một trang).

3.2.3 NDCG@K (Normalized Discounted Cumulative Gain)

NDCG là độ đo xếp hạng có xét đến vị trí, gán trọng số cao hơn cho các mục liên quan xuất hiện ở đầu danh sách:

$$\text{DCG@K}(u) = \sum_{i=1}^K \frac{\text{rel}_i}{\log_2(i+1)}$$

trong đó: $\text{rel}_i = 1$ nếu sản phẩm ở vị trí i thuộc $\mathcal{I}_u^{\text{test}}$, ngược lại bằng 0.

Giá trị lý tưởng:

$$\text{IDCG@K}(u) = \sum_{i=1}^{\min(K, |\mathcal{I}_u^{\text{test}}|)} \frac{1}{\log_2(i+1)}$$

Chuẩn hóa về khoảng $[0, 1]$:

$$\text{NDCG@K}(u) = \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}$$

Giá trị NDCG@K trung bình trên toàn bộ tập người dùng:

$$\text{NDCG@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \text{NDCG@K}(u)$$

NDCG phản ánh chất lượng thứ hạng, đánh giá việc gợi ý đúng ở vị trí sớm hay muộn. Trong bối cảnh recommendation, NDCG cao đồng nghĩa với việc các sản phẩm phù hợp được đẩy lên đầu danh sách.

3.2.4 MAP@K (Mean Average Precision)

Average Precision (AP) cho mỗi người dùng u :

$$\text{AP@K}(u) = \frac{1}{|\mathcal{J}_u^{\text{test}}|} \sum_{i=1}^K \text{Precision@i}(u) \cdot \text{rel}_i$$

trong đó $\text{Precision@i}(u)$ là độ chính xác tại vị trí cắt i , và rel_i là biến chỉ thị (1 nếu đúng, 0 nếu sai).

Mean Average Precision (MAP) trên toàn bộ tập người dùng:

$$\text{MAP@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \text{AP@K}(u)$$

MAP đánh giá toàn bộ đường cong Precision-Recall của danh sách xếp hạng, do đó phản ánh chất lượng tổng thể của thứ tự gợi ý chứ không chỉ ở một vị trí cắt cố định.

3.2.5 HitRate@K

HitRate@K đo xác suất danh sách gợi ý chứa ít nhất một sản phẩm đúng:

$$\text{HitRate@K}(u) = \begin{cases} 1, & \text{nếu } |\mathcal{J}_u^{\text{test}} \cap \hat{\mathcal{J}}_u^K| > 0 \\ 0, & \text{ngược lại} \end{cases}$$

Giá trị HitRate@K trung bình trên toàn bộ tập người dùng:

$$\text{HitRate@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \text{HitRate@K}(u)$$

Đây là độ đo mang ý nghĩa khả năng “đánh trúng” ít nhất một nhu cầu của người dùng trong Top-K, thường được sử dụng trong các hệ thống gợi ý sản phẩm mới hoặc gợi ý lần đầu.

3.3 Kết quả và phân tích mô hình Seasonal LightGCN

Metric	Baseline	Seasonal	Gain
Recall@12	0.01288	0.01349	+4.71%
Precision@12	0.00306	0.00335	+9.66%
NDCG@12	0.00747	0.00890	+19.02%
MAP@12	0.00351	0.00479	+36.19%
HitRate@12	0.03397	0.03647	+7.36%

Bảng 3.1 Kết quả và phân tích mô hình Seasonal LightGCN

3.3.1 Phân tích theo Recall và Precision

Mức tăng Recall@12 đạt 4.71% cho thấy mô hình Seasonal LightGCN có khả năng thu hồi được nhiều sản phẩm liên quan hơn trong tập gợi ý, phản ánh việc khai thác thông tin thời gian giúp mô hình nắm bắt tốt hơn các sở thích ngắn hạn của người dùng.

Đáng chú ý hơn, Precision@12 tăng tới 9.66%, cho thấy không chỉ số lượng sản phẩm đúng tăng lên, mà tỷ lệ chính xác trong danh sách gợi ý cũng được cải

thiện rõ rệt. Điều này chứng tỏ cơ chế seasonal re-weighting trong đồ thị đã giúp các embedding người dùng dịch chuyển gần hơn tới các sản phẩm “đúng mùa”, làm tăng độ tập trung của các đề xuất.

3.3.2 Phân tích theo NDCG và MAP

NDCG@12 tăng 19.02% và MAP@12 tăng tới 36.19%, là hai cải thiện có ý nghĩa nhất về mặt học thuật.

NDCG@12 phản ánh chất lượng thứ hạng: việc tăng gần 20% cho thấy các sản phẩm liên quan không chỉ xuất hiện trong Top-12 mà còn được đẩy lên các vị trí đầu danh sách, nơi có xác suất được người dùng chú ý và tương tác cao nhất.

MAP@12 đo chất lượng xếp hạng toàn cục trên toàn bộ danh sách, do đó mức tăng hơn 36% cho thấy cấu trúc thứ tự của toàn bộ Top-K đã được tối ưu đáng kể khi đưa yếu tố mùa vụ vào trọng số cạnh.

Từ góc độ hình học của không gian embedding, kết quả này hàm ý rằng seasonal weighting đã làm thay đổi phổ Laplacian của đồ thị, qua đó điều chỉnh quỹ đạo lan truyền (propagation path) trong LightGCN, khiến các vector biểu diễn của người dùng hội tụ mạnh hơn về các cụm sản phẩm phù hợp với bối cảnh thời gian hiện tại.

3.3.3 Phân tích theo HitRate

HitRate@12 tăng 7.36% cho thấy xác suất “đánh trúng ít nhất một nhu cầu thực” của người dùng trong mỗi danh sách gợi ý cũng được cải thiện. Điều này đặc biệt quan trọng trong các hệ thống gợi ý thương mại điện tử, nơi chỉ cần một sản phẩm đúng cũng có thể dẫn tới hành vi mua hàng.

Tổng hợp các chỉ số, có thể kết luận rằng: Việc đưa thông tin mùa vụ vào ma trận kề của đồ thị giúp LightGCN học được biểu diễn không gian ẩn mang tính

động theo thời gian, từ đó cải thiện đồng thời khả năng bao phủ (Recall), độ chính xác (Precision), và chất lượng xếp hạng (NDCG, MAP).

3.4 Kết quả mô hình Heuristic hiện đại có xét thời gian

Metric	Non-seasonal	Seasonal	Gain
Recall@12	0.01997	0.02981	+49.27%
NDCG@12	0.01401	0.01905	+36.00%

Bảng 3.2 Kết quả mô hình Heuristic

3.4.1 Tác động của cửa sổ thời gian và hàm suy giảm

Khi chuyển từ mô hình sử dụng dữ liệu dài hạn (52 tuần, không decay) sang mô hình ngắn hạn (5 tuần, power-law decay với $\alpha=0.7$), cả Recall và NDCG đều tăng mạnh:

Recall@12 tăng gần 50% cho thấy việc tập trung vào các giao dịch gần hiện tại giúp mô hình bắt kịp xu hướng mùa vụ (seasonal trend) tốt hơn rất nhiều so với việc học quy luật tĩnh.

NDCG@12 tăng 36% chứng tỏ các sản phẩm “đúng mùa” không chỉ được gợi ý nhiều hơn mà còn được xếp ở vị trí cao hơn.

Điều này khẳng định rằng seasonal effect là một hiện tượng thực, mạnh và có thể đo lường được, ngay cả khi sử dụng các mô hình heuristic không có học sâu.

3.4.2 Vai trò của Heuristic trong phân tích khoa học

Mô hình heuristic đóng vai trò như một “đối chứng” (control group), giúp xác định rằng:

- Phần cải thiện hiệu năng không chỉ đến từ kiến trúc GNN phức tạp,
- Mà bản thân thông tin thời gian và mùa vụ đã mang giá trị dự báo rất lớn.

Tuy nhiên, các heuristic này chỉ khai thác quan hệ cục bộ (co-occurrence bậc 1) và không học được cấu trúc biểu diễn không gian ẩn, do đó bị giới hạn về khả năng tổng quát hóa và cá nhân hóa sâu.

KẾT LUẬN

Đồ án đã đề xuất và khảo sát một hướng tiếp cận tích hợp yếu tố mùa vụ (seasonality) vào mô hình gợi ý dựa trên đồ thị, cụ thể là kiến trúc LightGCN, nhằm nâng cao chất lượng hệ thống gợi ý trong bối cảnh dữ liệu tương tác người dùng-sản phẩm mang tính động theo thời gian.

Trên phương diện lý thuyết, đồ án đã làm rõ ba luận điểm cốt lõi:

Thứ nhất, hành vi tiêu dùng trong lĩnh vực thời trang thể hiện tính chu kỳ rõ rệt, chịu ảnh hưởng mạnh bởi các yếu tố thời gian như mùa trong năm, xu hướng ngắn hạn và hiệu ứng gần đây (recency effect). Do đó, việc mô hình hóa dữ liệu dưới giả định tĩnh là chưa đủ để phản ánh đầy đủ động lực ẩn của sở thích người dùng.

Thứ hai, việc tái trọng số hóa đồ thị tương tác theo yếu tố mùa vụ cho phép đưa thông tin thời gian trực tiếp vào cấu trúc Laplacian của đồ thị. Điều này làm thay đổi cơ chế lan truyền thông tin trong LightGCN, từ đó dẫn đến sự điều chỉnh hình học của không gian embedding người dùng và sản phẩm theo bối cảnh thời gian.

Thứ ba, so với các phương pháp heuristic có xét thời gian, mô hình Seasonal LightGCN không chỉ khai thác được hiệu ứng gần (short-term trend) mà còn học được các tín hiệu cộng tác bậc cao (high-order collaborative signals), nhờ khả năng biểu diễn trong không gian ẩn và cơ chế truyền thông tin đa lớp của mạng nơ-ron đồ thị.

Về mặt thực nghiệm, các kết quả trên bộ dữ liệu thời trang cho thấy mô hình đề xuất đạt được cải thiện nhất quán trên nhiều độ đo đánh giá chuẩn như Recall@K, Precision@K, NDCG@K, MAP@K và HitRate@K so với mô hình

LightGCN cơ sở. Đặc biệt, mức tăng đáng kể của các chỉ số NDCG và MAP khẳng định rằng việc tích hợp thông tin mùa vụ không chỉ làm tăng số lượng dự đoán đúng mà còn cải thiện chất lượng sắp hạng, tức là đưa các sản phẩm phù hợp lên các vị trí đầu danh sách gợi ý.

Từ các kết quả trên, có thể rút ra kết luận tổng quát rằng:

Việc kết hợp mô hình học biểu diễn trên đồ thị với thông tin động theo thời gian, thông qua cơ chế seasonal re-weighting, là một hướng tiếp cận hiệu quả và có cơ sở lý thuyết vững chắc để nâng cao chất lượng hệ thống gợi ý trong các miền dữ liệu mang tính chu kỳ.

Hạn chế của đồ án:

Mặc dù đạt được các kết quả khả quan, đồ án vẫn tồn tại một số hạn chế:

1. Thông tin thời gian mới chỉ được mô hình hóa ở mức rời rạc (theo tuần hoặc theo mùa), chưa xét đến động lực liên tục (continuous-time dynamics).
2. Trọng số mùa vụ được thiết kế thủ công hoặc dựa trên thống kê, chưa được học một cách hoàn toàn tự động trong quá trình tối ưu.
3. Mô hình mới chỉ được đánh giá trên một tập dữ liệu thuộc lĩnh vực thời trang, do đó khả năng tổng quát hóa sang các miền khác (âm nhạc, video, tin tức) cần được kiểm chứng thêm.

Hướng phát triển trong tương lai:

Dựa trên những kết quả đạt được, một số hướng cho đồ án tiếp theo có thể được đề xuất như sau:

1. Thứ nhất, mở rộng sang mô hình đồ thị động (Dynamic Graph Neural Networks), trong đó cấu trúc đồ thị và embedding được cập nhật liên tục

theo dòng thời gian, cho phép nắm bắt sự tiến hóa của sở thích người dùng một cách mượt và chính xác hơn.

2. Thứ hai, kết hợp các mô hình học chuỗi thời gian hiện đại như Temporal Transformer hoặc Time-aware Attention Mechanism vào LightGCN, nhằm học trực tiếp hàm trọng số theo thời gian thay vì thiết kế thủ công.
3. Thứ ba, nghiên cứu tích hợp thêm các ngữ cảnh khác ngoài thời gian, chẳng hạn như vị trí địa lý, thời tiết, hoặc sự kiện xã hội, để xây dựng mô hình gợi ý theo ngữ cảnh đa chiều (context-aware recommender systems).

Cuối cùng, việc triển khai và đánh giá mô hình trong môi trường thực tế (online testing) sẽ là bước quan trọng để kiểm chứng tính hiệu quả và khả năng ứng dụng của phương pháp trong các hệ thống gợi ý quy mô lớn.

TÀI LIỆU THAM KHẢO

- [1] He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020). LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2020), 639-648.
- [2] Rendle, S., Freudenthaler, C., Gantner, Z., & Schmidt-Thieme, L. (2009). BPR: Bayesian Personalized Ranking from Implicit Feedback. Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI 2009), 452-461.
- [3] Koren, Y. (2009). Collaborative Filtering with Temporal Dynamics. Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD 2009), 447-456.
- [4] Hidasi, B., Karatzoglou, A., Baltrunas, L., & Tikk, D. (2016). Session-based Recommendations with Recurrent Neural Networks. Proceedings of the 4th International Conference on Learning Representations (ICLR 2016).
- [5] Wu, S., Tang, Y., Zhu, Y., Wang, L., Xie, X., & Tan, T. (2019). Session-based Recommendation with Graph Neural Networks. Proceedings of the 33rd AAAI Conference on Artificial Intelligence (AAAI 2019), 346-353.