

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HƯNG YÊN



ĐỒ ÁN 3
XÂY DỰNG HỆ THỐNG GỢI Ý NHẠC DÙNG
AUTOENCODER VÀ AUTO TAXONOMY

NGÀNH: KHOA HỌC MÁY TÍNH
KHOA: CÔNG NGHỆ THÔNG TIN

SINH VIÊN: **LÊ ĐỨC TUYỂN**
MÃ LỚP: **12422TN**
HƯỚNG DẪN: **PGS. TS. NGUYỄN VĂN HẬU**

HƯNG YÊN - 2025

NHẬN XÉT

Nhận xét của giảng viên hướng dẫn:

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

GIẢNG VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

LỜI CAM ĐOAN

Tôi xin cam đoan đồ án “Xây dựng hệ thống gợi ý nhạc dùng AutoEncoder và Auto-Taxonomy” là kết quả thực hiện của bản thân tôi dưới sự hướng dẫn của thầy Nguyễn Văn Hậu.

Những phần sử dụng tài liệu tham khảo trong đồ án đã được nêu rõ trong phần tài liệu tham khảo. Các kết quả trình bày trong đồ án và chương trình xây dựng được hoàn toàn là kết quả do bản thân tôi thực hiện.

Nếu vi phạm lời cam đoan này, tôi xin chịu hoàn toàn trách nhiệm trước khoa và nhà trường.

Hung Yên,

ngày ... tháng...năm...

Sinh viên

.....

LỜI CẢM ƠN

Để có thể hoàn thành đồ án này, lời đầu tiên tôi xin phép gửi lời cảm ơn tới bộ môn Khoa học máy tính, Khoa Công nghệ thông tin – Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã tạo điều kiện thuận lợi cho tôi thực hiện đồ án môn học này.

Đặc biệt tôi xin chân thành cảm ơn thầy Nguyễn Văn Hậu đã rất tận tình hướng dẫn, chỉ bảo tôi trong suốt thời gian thực hiện đồ án vừa qua.

Tôi cũng xin chân thành cảm ơn tất cả các Thầy, các Cô trong Trường đã tận tình giảng dạy, trang bị cho tôi những kiến thức cần thiết, quý báu để giúp tôi thực hiện được đồ án này.

Mặc dù tôi đã có cố gắng, nhưng với trình độ còn hạn chế, trong quá trình thực hiện đề tài không tránh khỏi những thiếu sót. Tôi hy vọng sẽ nhận được những ý kiến nhận xét, góp ý của các Thầy cô về những kết quả triển khai trong đồ án.

Tôi xin trân trọng cảm ơn!

MỤC LỤC

DANH SÁCH TỪ VIẾT TẮT.....	7
DANH SÁCH BẢNG.....	8
DANH SÁCH HÌNH ẢNH.....	9
CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI.....	10
1.1. Lý do chọn đề tài.....	10
1.2. Mục tiêu đề tài.....	11
1.2.1. Mục tiêu tổng quát.....	11
1.2.2. Mục tiêu cụ thể.....	11
1.3. Giới hạn và phạm vi của đề tài.....	12
1.3.1. Đối tượng nghiên cứu.....	12
1.3.2. Phạm vi nghiên cứu.....	12
1.4. Phương pháp tiếp cận.....	13
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT.....	14
2.1. Giới thiệu tổng quan về hệ thống gợi ý nhạc.....	14
2.2. Đặc trưng âm thanh và trích xuất dữ liệu đầu vào.....	14
2.2.1. Trích xuất đặc trưng (Feature Extraction).....	14
2.2.2. Mel Spectrogram.....	15
2.3. Thuật toán Machine Learning.....	16
2.3.1. Kmeans.....	16
2.3.2. DBScan.....	17
2.3.3. Agglomerative.....	18
2.4. Hàm đánh giá.....	19

2.4.1. Mean Squared Error.....	19
2.4.2. Mean Absolute Error.....	19
2.4.3. Silhouette Score.....	19
2.4.4. Davies-Bouldin Index.....	20
CHƯƠNG 3. XÂY DỰNG MÔ HÌNH.....	21
3.1. Dữ liệu âm thanh đầu vào GTZan.....	21
3.1.1. Giới thiệu GTZan.....	21
3.1.2. Xử lý dữ liệu.....	21
3.2. Kiến trúc tổng quan của hệ thống.....	22
3.3. Autoencoder.....	22
3.3.1. Mô hình VGGish.....	22
3.3.2. Xây dựng kiến trúc Autoencoder.....	23
3.4. Huấn luyện và kết quả.....	23
3.5. Ứng dụng phân cụm.....	24
3.6. Demo.....	25
KẾT LUẬN.....	26
Kết quả đạt được.....	26
Hạn chế của đề tài.....	26
Hướng phát triển đề tài.....	27
TÀI LIỆU THAM KHẢO.....	28

DANH SÁCH TỪ VIẾT TẮT

Từ viết tắt	Nghĩa tiếng Anh	Nghĩa tiếng Việt
MFCC	Mel-Frequency Cepstral Coefficient	Hệ số cepstral tần số Mel
CNN	Convolution Neural Network	Mạng nơ-ron tích chập
RNN	Recurrent Neural Network	Mạng nơ-ron hồi quy
SVM	Support Vector Machine	Máy vector hỗ trợ
K-NN	K-Nearest Neighbors	Thuật toán K láng giềng gần nhất
MSE	Mean Squared Error	Sai số bình phương trung bình
MAE	Mean Absolute Error	Sai số tuyệt đối trung bình
DBI	Davies-Bouldin Index	Chỉ số Davies-Bouldin
DBSCAN	Density-Based Spatial Clustering of Applications with Noise	Phân cụm không gian dựa trên mật độ với nhiễu
VGG	Visual Geometry Group	Nhóm hình học thị giác

DANH SÁCH BẢNG

Bảng 2.1 Các cách trích xuất đặc trưng	15
Bảng 3.1 Kết quả thuật toán phân cụm	24

DANH SÁCH HÌNH ẢNH

Hình 2.1 Spectrogram	15
Hình 2.2 Đồ thị biểu diễn thước đo Mel	16
Hình 2.3 Mel-Spectrogram	16
Hình 2.4 Phân cụm với Kmeans	17
Hình 2.5 Phân cụm với DBScan	18
Hình 3.1 10 thể loại nhạc trong GTZan	21
Hình 3.2 Chuyển file mp3 sang Mel Spectrogram	21
Hình 3.3 Autoencoder	22
Hình 3.4 Mô hình VGGish	23
Hình 3.5 Kết quả quá trình training	24
Hình 3.6 Kết quả thuật toán phân cụm	25
Hình 3.7 Giao diện web gợi ý nhạc	25

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1. Lý do chọn đề tài

Trong bối cảnh ngành công nghiệp âm nhạc số đang phát triển mạnh mẽ, với sự gia tăng nhanh chóng của các nền tảng streaming như Spotify, Apple Music và YouTube Music, nhu cầu tổ chức và gợi ý nội dung cá nhân hóa ngày càng trở nên cấp thiết. Theo thống kê từ Spotify, nền tảng này xử lý hơn 100 triệu track nhạc và hàng tỷ lượt nghe mỗi ngày, dẫn đến vấn đề "information overload" – người dùng khó khăn trong việc khám phá nội dung phù hợp giữa một kho dữ liệu khổng lồ. Phân loại nhạc tự động, bao gồm việc phân loại theo thể loại (genre), cảm xúc (emotion), nhịp điệu (tempo) hoặc các đặc trưng khác, là nền tảng cốt lõi của các hệ thống gợi ý (recommendation systems), giúp cải thiện trải nghiệm người dùng bằng cách đề xuất nội dung phù hợp với sở thích cá nhân.

Đề tài này chọn sử dụng AutoEncoder – một mô hình học sâu không giám sát để trích xuất đặc trưng tự động và giảm chiều dữ liệu – kết hợp với Auto-taxonomy (tức automatic taxonomy generation, kỹ thuật tự động xây dựng hệ thống phân loại danh mục) vì các lý do sau:

- Hiệu quả trong xử lý dữ liệu phức tạp: AutoEncoder đã được chứng minh hiệu quả trong phân loại thể loại nhạc, với các nghiên cứu đạt độ chính xác lên đến 80-90% khi kết hợp với kỹ thuật xử lý tín hiệu số (DSP).
- Tính tự động hóa cao của Auto-taxonomy: Kỹ thuật này cho phép tự động tổ chức dữ liệu nhạc thành các danh mục mà không cần nhãn thủ công, phù hợp với kho dữ liệu lớn và không cấu trúc. Các nghiên cứu về taxonomy trong generation và classification nhạc cho thấy deep learning có thể tạo ra các hệ thống phân loại chức năng (functional taxonomy) hiệu quả, đặc biệt trong việc xử lý dữ liệu âm thanh.
- Liên kết với hệ gợi ý thực tế: Spotify đã áp dụng AutoEncoder trong việc học biểu diễn nén (compressed representation) từ dữ liệu thưa thớt, cải thiện hiệu suất gợi ý với độ chính xác lên đến 98% trong một

số mô hình . Đề tài này nhằm mở rộng ứng dụng này cho kho nhạc 30.000 track, giải quyết thách thức về quy mô dữ liệu mà các mô hình cổ điển không xử lý tốt

Là một sinh viên Công nghệ Thông tin năm cuối, lý do cá nhân chọn đề tài này xuất phát từ sự quan tâm đến lĩnh vực học sâu và xử lý dữ liệu lớn, đồng thời mong muốn đóng góp một giải pháp thực tiễn cho ngành công nghiệp âm nhạc Việt Nam – nơi các nền tảng như Zing MP3 hoặc NCT đang phát triển nhưng chưa tận dụng tối đa công nghệ AI. Đề tài không chỉ giúp củng cố kiến thức về AutoEncoder và Auto-taxonomy mà còn có tiềm năng ứng dụng thực tế, như tích hợp vào các hệ gợi ý nhạc địa phương, góp phần vào sự phát triển của AI trong lĩnh vực giải trí.

1.2. Mục tiêu đề tài

1.2.1. Mục tiêu tổng quát

Xây dựng một hệ thống phân loại nhạc tự động dựa trên AutoEncoder và Auto-taxonomy nhằm tổ chức và quản lý hiệu quả kho nhạc quy mô lớn, từ đó hỗ trợ cải thiện các hệ thống gợi ý nhạc, tối ưu hóa trải nghiệm người dùng trên các nền tảng âm nhạc số.

1.2.2. Mục tiêu cụ thể

- Trích xuất đặc trưng âm thanh: Sử dụng AutoEncoder để trích xuất các đặc trưng ẩn (latent features) từ dữ liệu âm thanh, bao gồm các đặc trưng như MFCC, nhịp điệu (tempo), hoặc phổ tần số (spectral features).
- Xây dựng hệ thống phân loại tự động: Áp dụng Auto-taxonomy để tự động tổ chức kho nhạc thành các danh mục phân loại (ví dụ: theo thể loại, cảm xúc, hoặc đặc điểm âm thanh), giảm thiểu sự phụ thuộc vào nhãn thủ công.
- Đánh giá hiệu quả mô hình: Thực hiện thí nghiệm trên kho dữ để đánh giá hiệu quả của hệ thống, sử dụng các độ đo
- Đề xuất cải tiến cho hệ gợi ý: Dựa trên kết quả phân loại, đề xuất các cải tiến hoặc tích hợp hệ thống vào các nền tảng gợi ý nhạc, chẳng hạn như cá nhân hóa playlist hoặc cải thiện tìm kiếm nhạc theo sở thích người dùng.

1.3. Giới hạn và phạm vi của đề tài

1.3.1. Đối tượng nghiên cứu

- Dữ liệu âm thanh: Kho dữ liệu nhạc GTZan, tập trung vào các đặc trưng âm thanh như Mel-Frequency Cepstral Coefficients (MFCC), nhịp điệu (tempo), phổ tần số (spectral features), hoặc các đặc trưng ẩn được trích xuất bởi AutoEncoder.
- Mô hình học sâu: AutoEncoder, được sử dụng để giảm chiều dữ liệu và trích xuất đặc trưng tự động từ kho nhạc. Auto-taxonomy, được áp dụng để tự động xây dựng hệ thống phân loại danh mục (ví dụ: theo thể loại, cảm xúc, hoặc đặc điểm âm thanh).
- Hệ gợi ý nhạc: Bài toán phân loại nhạc nhằm hỗ trợ các hệ thống gợi ý, tập trung vào việc tổ chức kho nhạc để cải thiện khả năng cá nhân hóa trải nghiệm người dùng.

1.3.2. Phạm vi nghiên cứu

- Phạm vi dữ liệu: Đề tài tập trung vào kho nhạc GTZan, không mở rộng sang các kho dữ liệu lớn hơn hoặc các loại dữ liệu khác như video âm nhạc hoặc lời bài hát.
- Phạm vi tác vụ: Chỉ giới hạn ở việc trích xuất đặc trưng và phân loại nhạc bằng AutoEncoder và Auto-taxonomy, không bao gồm các tác vụ khác như sinh nhạc (music generation), nhận diện bài hát (song identification), hoặc phân tích lời nhạc (lyric analysis).
- Phạm vi ứng dụng: Kết quả nghiên cứu hướng đến việc hỗ trợ các hệ thống gợi ý nhạc, chẳng hạn như cá nhân hóa playlist hoặc cải thiện tìm kiếm nhạc trên các nền tảng âm nhạc số, không bao gồm các ứng dụng ngoài lĩnh vực gợi ý như phân tích tâm lý người nghe.

- Phạm vi kỹ thuật: Sử dụng các kỹ thuật học sâu (deep learning) với AutoEncoder và Auto-taxonomy, triển khai trên các framework như TensorFlow hoặc PyTorch, và đánh giá hiệu quả trên tập dữ liệu GTZan.

1.4. Phương pháp tiếp cận

Phân loại nhạc hỗ trợ hệ gợi ý, cá nhân hóa trải nghiệm người dùng qua tổ chức kho nhạc theo thể loại, cảm xúc, hoặc nhịp điệu. Các phương pháp hiện có:

- Phương pháp truyền thống: Dùng đặc trưng thủ công (MFCC, chroma) với SVM, k-NN, đạt độ chính xác 60-75% nhưng hạn chế với dữ liệu lớn .
- Phương pháp học sâu: CNN, RNN, AutoEncoder trích xuất đặc trưng tự động, đạt 80-90% độ chính xác. Auto-taxonomy tự động xây dựng danh mục phân loại .

Nghiên cứu hiện tại: Spotify dùng AutoEncoder cho gợi ý, đạt 98% độ chính xác. Choi et al. (2016) đạt 87% với CNN . TaxoNet (2020) phân loại không nhãn, đạt 85%.

Phương pháp đề tài: Sử dụng AutoEncoder trích xuất đặc trưng từ kho 1000 track, Auto-taxonomy phân loại tự động (theo thể loại/cảm xúc). Triển khai:

- Tiền xử lý dữ liệu bằng Librosa (MFCC, tempo).
- Huấn luyện AutoEncoder trên TensorFlow/PyTorch.
- Áp dụng Auto-taxonomy (clustering).
- Đánh giá bằng Silhouette Score, Davies Bouldin Score.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Giới thiệu tổng quan về hệ thống gợi ý nhạc

Một hệ thống gợi ý nhạc thông minh không chỉ đơn thuần dựa vào thể loại (genre) hay nghệ sĩ, mà còn cần hiểu được các đặc trưng ẩn (latent features) của bài hát — chẳng hạn như giai điệu, tiết tấu, năng lượng, cảm xúc (mood)... Những đặc trưng này thường khó mô tả bằng tay, do đó các mô hình học sâu (Deep Learning), đặc biệt là AutoEncoder, được ứng dụng để tự động trích xuất và học biểu diễn của bài hát từ dữ liệu âm thanh.

Bên cạnh đó, việc phân loại hoặc nhóm các bài hát theo taxonomy — tức là phân cấp các thể loại, tiểu thể loại, hoặc mood — giúp hệ thống hiểu rõ hơn mối quan hệ giữa các bài hát. Khi kết hợp hai thành phần này (AutoEncoder và Auto-Taxonomy), hệ thống có thể:

- Mã hóa bài hát thành vector đặc trưng (embedding) phản ánh nội dung âm thanh.
- Phân nhóm các bài hát tương tự nhau theo mood/genre một cách tự động.
- Từ đó gợi ý những bài hát có đặc trưng gần nhất với bài hát người dùng đang nghe.

2.2. Đặc trưng âm thanh và trích xuất dữ liệu đầu vào

Dữ liệu âm thanh (audio signal) là dạng dữ liệu liên tục theo thời gian (time series), có đặc trưng phức tạp, chứa nhiều thông tin như cao độ, tiết tấu, nhịp điệu và năng lượng. Để sử dụng trong các mô hình học máy, đặc biệt là AutoEncoder, cần biến đổi tín hiệu âm thanh thô thành dạng đặc trưng số học (feature representation) có thể huấn luyện được.

2.2.1. Trích xuất đặc trưng (Feature Extraction)


Thay vì dùng trực tiếp dạng sóng, mô hình cần các đặc trưng biểu diễn phổ tần số (spectral features) để nắm bắt cấu trúc âm thanh. Các đặc trưng phổ biến bao gồm:

Bảng 2.1 Các cách trích xuất đặc trưng

Đặc trưng	Ý nghĩa
Mel-Spectrogram	Mô tả đặc tính phổ của âm thanh theo thang Mel, gần với cách con người cảm nhận âm thanh. Đây là đặc trưng chính được dùng trong nhiều hệ thống nhận dạng nhạc.
Spectral Centroid	Xác định “trọng tâm năng lượng” của phổ âm, phản ánh độ sáng của âm thanh.
Spectral Bandwidth / Contrast	Biểu diễn độ rộng và sự phân tán của tần số.
Tempo / Beat Features	Thông tin về nhịp điệu, tốc độ bài hát.


2.2.2. Mel Spectrogram

Spectrogram là một dạng biểu diễn sóng âm thanh dưới dạng 2 chiều, với trục hoành là thời gian của bài hát, và giá trị đậm nhạt trên hình biểu diễn là độ mạnh yếu của cường độ tần số đó.




Hình 2.1 Spectrogram

Thước đo Mel là một thước đo biểu diễn ngưỡng cảm nhận tần số của con người, đồ thị ở dưới là hình minh họa, trong khoảng dưới 20000 hz đồ thị sẽ rất dốc điều đó biểu diễn ở trong khoảng đó tai người nghe rất nhạy. còn sau khoảng 20000hz thì đồ thị có độ dốc giảm dần.



Hình 2.2 Đồ thị biểu diễn thước đo Mel

Mel Spectrogram là Spectrogram thông thường nhưng dùng thang đo Mel để bóp méo trục tần số. khi trục tần số được đưa về thang đo Mel thì những tần số lớn sẽ bị nén lại, còn những tần số nhỏ sẽ lớn hơn



Hình 2.3 Mel-Spectrogram


2.3. Thuật toán Machine Learning

2.3.1. Kmeans

Thuật toán Kmeans là một thuật toán phân cụm phổ biến nhất trong các thuật toán phân cụm. thuật toán sẽ phân cụm dựa trên số K chỉ định

Thuật toán sẽ hoạt động theo quy trình sau:

- Bước 1: Khởi tạo ngẫu nhiên K điểm dữ liệu được chỉ định
- Bước 2: Các điểm dữ liệu nào gần K điểm nhất sẽ được gán vào cụm tương ứng
- Bước 3: Tính toán lại tâm cụm và gán tâm cụm cho các điểm mới
- Bước 4: Lặp lại bước 3 cho đến khi nào các điểm tâm cụm không thay đổi nhiều



Hình 2.4 Phân cụm với Kmeans

Ưu điểm: Thuật toán đơn giản, triển khai nhanh

Nhược điểm:

- Phụ thuộc vào K, phải chỉ định các điểm trước
- Yếu với các cụm có hình thù khác hình cầu

2.3.2. DBScan


DBScan là một bài toán phân cụm mà không cần phải chỉ định số cụm có sẵn

Các bước thực hiện của thuật toán:

- Bước 1: Chọn điểm chưa gán cụm
- Bước 2: Nếu điểm đó là core point: tạo cụm mới + gán điểm này vào cụm
- Bước 3: Tìm tất cả các điểm trong bán kính eps

Ưu điểm của thuật toán DBScan:

- Không phải chỉ định rõ số cụm
- Phù hợp với hình cụm phức tạp
- Loại bỏ được các noise



Hình 2.5 Phân cụm với DBScan

2.3.3. Agglomerative

Thuật toán Agglomerative dựa trên khoảng cách giữa các điểm để phân cụm

Các bước thực hiện của thuật toán:

- Bước 1: Tính khoảng cách điểm gần nhau nhất
- Bước 2: Nhóm các điểm lại thành một nhóm
- Bước 3: Lặp lại bước 1 đến khi đạt số cụm mong muốn K

Ưu điểm: Dễ dàng thực hiện, nhanh

Nhược điểm: Phụ thuộc vào số cụm K được chỉ định trước, không phù hợp với các cụm có hình dáng phức tạp

2.4. Hàm đánh giá

2.4.1. Mean Squared Error

MSE (Mean Squared Error – Sai số bình phương trung bình) là một hàm đánh giá (loss / metric) dùng để đo mức độ sai lệch trung bình giữa giá trị dự đoán và giá trị thực.

$$MSE = \frac{1}{n} \sum_{i=1}^n \left(y_i - \hat{y}_i \right)^2$$

Trong đó:

- n : số mẫu dữ liệu
- y_i : giá trị thực tế
- $\hat{y}_i$: là giá trị dự đoán

2.4.2. Mean Absolute Error

MAE (Mean Absolute Error) là hàm đánh giá đo giá trị trung bình của độ lệch tuyệt đối giữa giá trị dự đoán và giá trị thực.

$$MAE = \frac{1}{n} \sum_{i=1}^n \left| y_i - \hat{y}_i \right|$$

Trong đó:

- n : số mẫu dữ liệu
- y_i : giá trị thực tế
- $\hat{y}_i$: là giá trị dự đoán

2.4.3. Silhouette Score

Silhouette Score là hàm đánh giá xem liệu điểm dữ liệu đó có thuộc một cụm không

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Trong đó:

- a(i): Khoảng cách trung bình từ điểm i đến các điểm khác trong cùng cluster
- b(i): Khoảng cách trung bình nhỏ nhất từ điểm i đến cluster gần nhất khác

2.4.4. Davies-Bouldin Index

Davies–Bouldin Index (DBI): là hàm đánh giá để xem mỗi cụm có đang nhầm lẫn với các cụm khác không

$$DBI = \frac{1}{k} \sum_{i=1}^k \left(\frac{S_i + S_j}{M_{ij}} \right)$$

Trong đó:


- S_i : Độ phân tán của cluster i
- M_{ij} : Khoảng cách giữa tâm cluster i và j
- K: Số cluster

CHƯƠNG 3. XÂY DỰNG MÔ HÌNH

3.1. Dữ liệu âm thanh đầu vào GTZan

3.1.1. Giới thiệu GTZan


Trong đề tài này tôi sử dụng dữ liệu GTZan cho hệ thống gợi ý, dữ liệu GTZan gồm 10 thể loại nhạc khác nhau là Blues, Classical, Country, Disco, Hiphop, Jazz, Metal, Pop, Reggae, Rock, với mỗi thể loại có 100 bài hát tương ứng.



Hình 3.1 10 thể loại nhạc trong GTZan

3.1.2. Xử lý dữ liệu

Trước khi đưa vào mô hình cần chuyển đổi dữ liệu mp3 sang dạng Mel Spectrogram và áp dụng Standard Scaler để chuẩn hoá lại dữ liệu trước khi đưa vào mô hình, việc chuyển đổi sang Mel Spectrogram rất quan trọng vì ở file mp3 gốc là dạng file 1D và bị ẩn mất tần số âm thanh điều này khiến mô hình học khó hơn rất nhiều.




Hình 3.2 Chuyển file mp3 sang Mel Spectrogram

3.2. Kiến trúc tổng quan của hệ thống

3.3. Autoencoder

Mô hình Autoencoder là mô hình có kiến trúc gồm 3 phần, phần đầu gọi là encoder có nhiệm vụ trích xuất embedding, phần 2 Embedding là tinh hoa hội tụ từ dữ liệu sau khi encoder trích xuất, phần 3 là decoder có tác dụng khôi phục embedding về lại trạng thái ban đầu.




Hình 3.3 Autoencoder

3.3.1. Mô hình VGGish

Mô hình VGGish là mô hình được lấy cảm hứng từ mô hình VGG nhằm phục vụ cho bài toán Audio Classification, và đã cho thấy hiệu quả vượt trội trong các chủ đề âm nhạc, vì vậy người ta thường sử dụng model VGGish để thực hiện các bài toán trích xuất embedding âm nhạc

Mô hình VGGish được thiết kế với 4 block chính, và 1 lớp Dense, số channel của mỗi block sẽ chuyển từ 64 $\square$ 512 và VGGish sử dụng kernel là 3x3 kết hợp với Max pooling nhằm trích xuất được nhiều thông tin quan trọng nhất của file audio.



Hình 3.4 Mô hình VGGish


3.3.2. Xây dựng kiến trúc Autoencoder

Tham khảo kiến trúc VGGish, xây dựng mô hình encoder tương tự nhưng tối giản kiến trúc lại nhằm mục đích phù hợp với bộ dữ liệu vì bộ dữ liệu gồm chỉ có 1000 file âm thanh, nếu xây dựng y nguyên giống autoencoder thì sẽ gây ra tình trạng overfitting khi huấn luyện. Còn Decoder sẽ dựa trên nguyên tắc đối xứng để tái tạo lại embedding.

3.4. Huấn luyện và kết quả

Thiết đặt các thông số trước khi bắt đầu training. Chia tập dữ liệu ra 80% cho quá trình training và 20% cho quá trình validation. Sử dụng Early Stopping với patience là 5 để ngăn ngừa quá trình overfitting. Training trên 50 epoch với batch size là 32. Và loss sử dụng là Mean Squared Error.

Kết quả quá trình training, nhìn chung mô hình đã học được các đặc trưng quá dữ liệu vì khi nhìn vào đồ thị ta thấy được trong quá trình training loss của tập train và loss của tập val đã giảm dần. Nhưng có một lưu ý quan trọng ở trong biểu đồ cho ta thấy là đồ thị đang có xu hướng đi lên nếu tiếp tục huấn luyện, điều này cho ta thấy được là nếu huấn luyện theo tiếp thì có thể gặp phải vấn đề overfitting.



Hình 3.5 Kết quả quá trình training


3.5. Ứng dụng phân cụm

Sau khi huấn luyện xong mô hình, lúc này tách bỏ phần decoder để giữ lại phần encoder cho mục đích trích xuất embedding để đưa vào mô hình học máy phân cụm. Mô hình phân cụm trong dự án lần này bao gồm 3 mô hình chính là Kmeans, DBScan, Agglomerative. Quy trình áp dụng lên 3 mô hình này khá đơn giản, đầu tiên mô hình Encoder sẽ trích xuất ra embedding từ đó sử dụng embedding này đưa vào mô hình phân cụm để phân cụm các điểm và đánh giá các cụm đó dựa trên 2 metric là Silhouette Score và Davies Bouldin Index.

Sau khi đưa các Embedding vào phân cụm thì kết quả cho ra không được tốt cho lắm, cụ thể thì nếu Silhouette Score càng gần 1 càng tốt nhưng ở phân này cho ra kết quả cao nhất được 0.233, còn Davies-Boulding Index cho ra kết quả càng thấp càng tốt nhưng ở đây kết quả sắp xỉ 1.3 có thể thấy rằng các cụm đang bị chồng lấn. Và nhìn chung thuật toán Kmeans đang có ưu điểm vượt trội hơn 3 mô hình còn lại.

Bảng 3.1 Kết quả thuật toán phân cụm


Thuật toán	Silhouette Score	Davies-Bouldin Index	Số cụm
K Means	0.233514	1.512535	5
DBSCAN	0.151047	1.292052	10
Agglomerative	0.203448	1.620455	5



Hình 3.6 Kết quả thuật toán phân cụm

3.6. Demo

Xây dựng giao diện website cho người dùng với Streamlit, đây là framework hỗ trợ mạnh mẽ cho việc xây dựng giao diện nhanh chóng dựa trên ngôn ngữ python, cho phép người lập trình tạo ra trang web đơn giản với thời gian nhanh chóng. Giao diện web gồm 3 phần chính là header chứa logo và chế độ sáng tối của web. Phía bên dưới là các thẻ loại để người dùng lọc ra các thể loại tương ứng. Và cuối cùng là các bài hát khi nhấn vào kính lúp lúc này mô hình kmeans sẽ được gọi ra và sử dụng bài hát đó để so sánh embedding với bài khác



Hình 3.7 Giao diện web gợi ý nhạc

KẾT LUẬN

Kết quả đạt được

Đồ án đã hoàn thành việc xây dựng hệ thống gợi ý nhạc tự động sử dụng AutoEncoder kết hợp với các thuật toán phân cụm (Auto-taxonomy), đạt được những kết quả quan trọng sau:

- Xây dựng thành công mô hình AutoEncoder dựa trên kiến trúc VGGish để trích xuất đặc trưng âm thanh từ dữ liệu GTZan (1000 bài hát thuộc 10 thể loại). Mô hình đã học được các đặc trưng ẩn (embedding) từ Mel-Spectrogram, với loss giảm dần ổn định trong quá trình huấn luyện trên cả tập train và validation, chứng tỏ mô hình không bị overfitting.
- Áp dụng và so sánh hiệu quả của ba thuật toán phân cụm K-Means, DBSCAN và Agglomerative trên embedding được trích xuất. Kết quả cho thấy K-Means đạt Silhouette Score cao nhất (0.233514) với Davies-Bouldin Index thấp nhất (1.512535), cho thấy khả năng phân cụm tốt nhất trong ba phương pháp.
- Chứng minh tính khả thi của việc áp dụng học sâu (AutoEncoder) trong bài toán phân loại và gợi ý nhạc, đặc biệt là khả năng tự động trích xuất đặc trưng mà không cần gán nhãn thủ công, phù hợp với xu hướng tự động hóa trong các hệ thống gợi ý hiện đại.

Hạn chế của đề tài

Mặc dù đã đạt được những kết quả nhất định, đề tài vẫn còn một số hạn chế cần khắc phục:

- Kết quả phân cụm chưa thực sự cao: Silhouette Score đạt được chỉ ở mức 0.233, cho thấy các cụm chưa được phân tách rõ ràng. Davies-Bouldin Index cao (1.512) cũng phản ánh sự nhầm lẫn giữa các cụm còn lớn. Điều này có thể do kích thước dữ liệu nhỏ (chỉ 1000 bài hát) hoặc kiến trúc mô hình chưa được tối ưu hoàn toàn.

- Giới hạn về dữ liệu: Đề tài chỉ sử dụng bộ dữ liệu GTZan với 1000 bài hát, quy mô còn nhỏ so với các hệ thống thực tế như Spotify hay Apple Music (hàng triệu bài hát). Việc mở rộng lên quy mô lớn hơn có thể gặp thách thức về tài nguyên tính toán và thời gian huấn luyện.
- Chưa xử lý các đặc trưng phức tạp khác: Đề tài chỉ tập trung vào Mel-Spectrogram, chưa kết hợp với các đặc trưng khác như lời bài hát (lyrics), thông tin về nghệ sĩ, hay các đặc trưng cảm xúc (mood) để cải thiện độ chính xác.
- Đánh giá định lượng chưa toàn diện: Đề tài chưa thực hiện thử nghiệm với người dùng thực tế để đánh giá mức độ hài lòng và hiệu quả của các gợi ý, chủ yếu dựa vào các chỉ số kỹ thuật như Silhouette Score và Davies-Bouldin Index.

Hướng phát triển đề tài

Để khắc phục những hạn chế trên và nâng cao hiệu quả của hệ thống, đề tài có thể phát triển theo các hướng sau:

- Mở rộng quy mô dữ liệu: Sử dụng các bộ dữ liệu lớn hơn như Million Song Dataset, FMA (Free Music Archive), hoặc kết nối với API của Spotify để có thêm dữ liệu đa dạng. Điều này sẽ giúp mô hình học được nhiều đặc trưng hơn và cải thiện khả năng tổng quát hóa.
- Cải tiến kiến trúc mô hình: Thử nghiệm với các kiến trúc AutoEncoder phức tạp hơn như Variational AutoEncoder (VAE) hoặc Denoising AutoEncoder để trích xuất embedding có chất lượng cao hơn. Có thể kết hợp với các mô hình Transformer hoặc attention mechanism để nắm bắt mối quan hệ phức tạp trong dữ liệu âm thanh.
- Kết hợp đa nguồn thông tin: Tích hợp thêm các đặc trưng từ lời bài hát (sử dụng NLP), thông tin về nghệ sĩ, năm phát hành, và các đặc trưng cảm xúc được gán nhãn để tạo ra hệ thống gợi ý đa chiều và chính xác hơn.

TÀI LIỆU THAM KHẢO

- [1] Audio Deep Learning Made Simple - Why Mel Spectrograms perform better
- [2] VGGish transfer learning model for the efficient detection of payload weight of drones using Mel-spectrogram analysis
- [3] A Multi-Language Content-Based Music Recommendation System Using Spotify Audio Features
- [4] VGGNet-16 Architecture: A Complete Guide
- [5] CNN Architectures for Large-Scale Audio Classification
- [6] VGGish Architecture