

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HÙNG YÊN



ĐỒ ÁN 3
ỨNG DỤNG META - LEARNING FEW - SHOT CHO
DOMAIN SÁCH THIẾU DỮ LIỆU

NGÀNH: KHOA HỌC MÁY TÍNH
CHUYÊN NGÀNH: TRÍ TUỆ NHÂN TẠO VÀ KHOA HỌC DỮ LIỆU

SINH VIÊN: NGUYỄN TRUNG HIẾU
MÃ LỚP: 12422TN
HƯỚNG DẪN: PGS. TS. NGUYỄN VĂN HẬU

HÙNG YÊN – 2026

NHẬN XÉT

Nhận xét của giáo viên hướng dẫn

[illegible]

GIÁO VIÊN HƯỚNG DẪN

Nguyễn Văn Hậu

LỜI CAM ĐOAN

Tôi xin cam đoan đề án “Ứng dụng meta-learning few-shot cho domain sách thiếu dữ liệu” là kết quả thực hiện của bản thân tôi dưới sự hướng dẫn của thầy Nguyễn Văn Hậu.

Những phần sử dụng tài liệu tham khảo trong đề án này đã được nêu rõ trong phần tài liệu tham khảo. Các kết quả trình bày trong đề án này hoàn toàn là kết quả do bản thân thực hiện.

Nếu vi phạm lời cam đoan này, tôi xin chịu hoàn toàn trách nhiệm trước khoa và nhà trường.

Hung Yên, ngày 22 tháng 1 năm 2026

Sinh viên

Nguyễn Trung Hiếu

LỜI CẢM ƠN

Để có thể hoàn thành đồ án này, lời đầu tiên tôi xin phép gửi lời cảm ơn tới Khoa Công nghệ thông tin – Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã tạo điều kiện thuận lợi cho tôi thực hiện đồ án môn học này.

Đặc biệt tôi xin chân thành cảm ơn thầy Nguyễn Văn Hậu đã rất tận tình hướng dẫn, chỉ bảo trong suốt thời gian thực hiện đồ án vừa qua.

Tôi cũng xin chân thành cảm ơn tất cả các Thầy, các Cô trong Trường đã tận tình giảng dạy, trang bị cho tôi những kiến thức cần thiết, quý báu để giúp tôi thực hiện được đồ án này.

Mặc dù tôi đã có cố gắng, nhưng với trình độ còn hạn chế, trong quá trình thực hiện đề tài không tránh khỏi những thiếu sót. Tôi hi vọng sẽ nhận được những ý kiến nhận xét, góp ý của các Thầy giáo, Cô giáo về những kết quả triển khai trong đồ án.

Tôi xin trân trọng cảm ơn!

MỤC LỤC

MỤC LỤC	1
DANH MỤC CÁC THUẬT NGỮ.....	4
DANH MỤC ẢNH.....	5
DANH MỤC BẢNG	6
CHƯƠNG 1: TỔNG QUAN VỀ HỆ GỢI Ý	7
1.1 Giới thiệu về hệ gợi ý	7
1.1.1 Hệ gợi ý	7
1.1.2 Tầm quan trọng của hệ gợi ý trong domain sách.....	7
1.2 Ý nghĩa của bài toán	8
1.2.1 Giải quyết vấn đề dữ liệu thưa thớt.....	8
1.2.2 Cải thiện trải nghiệm người dùng	8
1.2.3 Ứng dụng thực tiễn.....	8
1.3 Các cách tiếp cận giải quyết bài toán.....	9
1.3.1 Phương pháp truyền thống	9
1.3.2 Phương pháp hiện đại.....	9
1.3.3 Meta-learning few-shot như giải pháp tiềm năng.....	10
1.4 Tình hình nghiên cứu hiện tại.....	10
1.4.1 Tổng quan các nghiên cứu	10
1.4.2 Những nhóm nghiên cứu/nhà khoa học nổi bật.....	11
1.4.3 Kết quả và hạn chế	11
1.4.4 Mục tiêu nghiên cứu.....	11
1.5 Kết luận.....	12
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT	13
2.1 Giới thiệu về Meta-learning Few-shot	13
2.1.1 Khái niệm Meta-learning	13

2.1.2 Few-shot Learning.....	13
2.1.3 Ứng dụng trong hệ gợi ý	13
2.2 Mô hình Meta-learning Few-shot.....	13
2.2.1 Tổng quan về MAML và FOMAML.....	14
2.2.2 Tổng quan về Reptile	14
2.2.3 Cấu trúc mô hình	15
2.3 Các bước của thuật toán	16
2.3.1 Giai đoạn Meta-training	16
2.3.2 Giai đoạn Meta-testing	17
2.3.3 Tích hợp vào hệ gợi ý.....	17
2.4 Kỹ thuật xử lý dữ liệu thừa thớt	17
2.4.1 Tăng cường dữ liệu.....	17
2.4.2 Biểu diễn đặc trưng	18
2.4.3 Xử lý cold-start.....	18
2.5 Hàm đánh giá.....	18
2.5.1 Hàm mất mát.....	18
2.5.2 Chỉ số đánh giá	19
2.6 So sánh tổng quan các mô hình.....	20
2.7 Kết chương.....	21
CHƯƠNG 3: XÂY DỰNG MÔ HÌNH	22
3.1 Thu thập dữ liệu.....	22
3.1.1 Trình bày dữ liệu bài toán	22
3.1.2 Tiền xử lý dữ liệu	23
3.2 Trực quan hóa dữ liệu.....	24
3.3 Huấn luyện mô hình	26
3.3.1 Mô hình MAML	26

3.3.2 Mô hình FOMAML.....	26
3.3.3 Mô hình Reptile.....	27
3.3.4 So sánh giữa các mô hình.....	27
3.4 Demo hệ thống gợi ý sách.....	29
3.5 Kết chương	30
KẾT LUẬN.....	31
TÀI LIỆU THAM KHẢO	32

DANH MỤC CÁC THUẬT NGỮ

STT	Từ viết tắt	Cụm từ tiếng Anh	Diễn giải
1	MAML	Model-Agnostic Meta-Learning	Meta-learning độc lập với mô hình
2	FOMAML	First-Order Model-Agnostic Meta-Learning	Meta-learning bậc nhất (xấp xỉ MAML)
3	Reptile	Reptile	Thuật toán meta-learning dựa trên cập nhật tham số trực tiếp
4	BPR	Bayesian Personalized Ranking	Xếp hạng cá nhân hóa Bayes
5	NDCG@K	Normalized Discounted Cumulative Gain at K	Lợi ích tích lũy giảm giá chuẩn hóa tại top-K
6	Recall@K	Recall at K	Tỷ lệ thu hồi tại top-K

DANH MỤC ẢNH

Hình 3. 1 Biểu đồ phân phối xếp hạng của rating.....	24
Hình 3. 2 Biểu đồ các thể loại sách phổ biến nhất.....	25
Hình 3. 3 Website demo gợi ý sách theo thể loại cho người dùng.....	29

DANH MỤC BẢNG

Bảng 2. 1 So sánh tổng quan các mô hình	20
Bảng 3. 1 Bảng mô tả các cột trong file books_rating	22
Bảng 3. 2 Bảng mô tả các cột trong file books_data	22
Bảng 3. 3 Kết quả đánh giá MAML	26
Bảng 3. 4 Kết quả đánh giá FOMAML	26
Bảng 3. 5 Kết quả đánh giá Reptile	27
Bảng 3. 6 So sánh kết quả các mô hình meta-learning	27
Bảng 3. 7 Query BPR loss trên các train tasks phổ biến	28

CHƯƠNG 1: TỔNG QUAN VỀ HỆ GỢI Ý

1.1 Giới thiệu về hệ gợi ý

1.1.1 Hệ gợi ý

Hệ gợi ý (Recommender System) là một lớp các thuật toán hoặc hệ thống được thiết kế để dự đoán và đề xuất các mục (items) mà người dùng có thể quan tâm, dựa trên thông tin về sở thích, hành vi hoặc đặc điểm của họ. Hệ gợi ý được ứng dụng rộng rãi trong nhiều lĩnh vực thực tiễn như thương mại điện tử (Amazon, Lazada), nền tảng nội dung (Netflix, Spotify), mạng xã hội (Facebook, YouTube), và đặc biệt trong các nền tảng liên quan đến sách như Goodreads hoặc các thư viện số. Các hệ thống này sử dụng dữ liệu lịch sử, thông tin ngữ cảnh hoặc đặc trưng nội dung để đưa ra các gợi ý cá nhân hóa, từ đó nâng cao trải nghiệm người dùng và tăng cường tương tác.

- Hệ gợi ý có thể được phân loại thành ba loại chính:
 - Lọc cộng tác (Collaborative Filtering): Dựa trên tương tác giữa người dùng và các mục (ví dụ: lịch sử mua sách, đánh giá sách) để tìm ra các mẫu tương đồng giữa người dùng hoặc các mục.
 - Lọc dựa trên nội dung (Content-based Filtering): Sử dụng các đặc trưng nội tại của các mục (ví dụ: thể loại, tác giả, từ khóa) để đề xuất các mục tương tự với những gì người dùng đã thích trước đó.
 - Phương pháp lai (Hybrid Methods): Kết hợp cả lọc cộng tác và lọc dựa trên nội dung để tận dụng ưu điểm của cả hai, giảm thiểu hạn chế riêng lẻ.

1.1.2 Tầm quan trọng của hệ gợi ý trong domain sách

Trong lĩnh vực sách, hệ gợi ý đóng vai trò quan trọng trong việc giúp người đọc khám phá các cuốn sách phù hợp với sở thích cá nhân, đặc biệt trong bối cảnh số lượng sách ngày càng lớn và đa dạng. Các nền tảng như thư viện số, cửa hàng sách trực tuyến (Amazon Kindle, Google Books) hoặc ứng dụng đọc sách (Wattpad, Goodreads) đều phụ thuộc vào hệ gợi ý để cải thiện trải nghiệm người dùng. Tuy nhiên, domain sách thường gặp phải thách thức lớn về dữ liệu thưa thớt (sparse data), đặc biệt trong các trường hợp:

- Dữ liệu người dùng hạn chế: Nhiều người dùng mới (new users) hoặc người dùng không thường xuyên tương tác (ít đánh giá, ít mua sách) dẫn đến thiếu thông tin về sở thích của họ.

- Dữ liệu sách hạn chế: Các cuốn sách mới hoặc ít phổ biến (long-tail items) thường không có đủ đánh giá hoặc thông tin để đưa vào hệ gợi ý.
- Domain đặc thù: Một số thể loại sách hoặc thị trường ngách (ví dụ: sách học thuật, sách chuyên ngành) có lượng dữ liệu rất hạn chế, khiến các phương pháp gợi ý truyền thống khó đạt hiệu quả cao.

Do đó, việc phát triển một hệ gợi ý hiệu quả trong domain sách, đặc biệt khi dữ liệu thưa thớt, là một bài toán có ý nghĩa thực tiễn và khoa học lớn.

1.2 Ý nghĩa của bài toán

1.2.1 Giải quyết vấn đề dữ liệu thưa thớt

Trong domain sách, vấn đề dữ liệu thưa thớt xuất hiện khi:

- Ma trận người dùng-sách (user-item matrix) có rất ít giá trị được điền (ví dụ: chỉ một số ít người dùng đánh giá hoặc mua một cuốn sách cụ thể).
- Các sách mới hoặc ít phổ biến không có đủ thông tin tương tác để được gợi ý chính xác.
- Người dùng mới không có lịch sử tương tác, dẫn đến khó khăn trong việc cá nhân hóa gợi ý (vấn đề cold-start).

Việc giải quyết bài toán này không chỉ giúp cải thiện độ chính xác của hệ gợi ý mà còn mở rộng khả năng áp dụng cho các domain khác có đặc điểm tương tự (ví dụ: phim ít xem, sản phẩm mới ra mắt).

1.2.2 Cải thiện trải nghiệm người dùng

Hệ gợi ý hiệu quả giúp người đọc tìm thấy các cuốn sách phù hợp với sở thích cá nhân, từ đó:

- Tăng mức độ hài lòng và gắn bó của người dùng với nền tảng.
- Khuyến khích khám phá các thể loại sách mới, đặc biệt là các sách ít phổ biến nhưng có giá trị cao.
- Hỗ trợ người dùng tiết kiệm thời gian trong việc tìm kiếm sách phù hợp.

1.2.3 Ứng dụng thực tiễn

- Thư viện số: Giúp người dùng tìm kiếm sách phù hợp trong các kho lưu trữ số khổng lồ.
- Cửa hàng sách trực tuyến: Tăng doanh số bán hàng bằng cách đề xuất sách phù hợp, giảm tỷ lệ người dùng rời bỏ.

- Nền tảng đọc sách điện tử: Cá nhân hóa trải nghiệm đọc, tăng thời gian sử dụng ứng dụng và mức độ tương tác của người dùng.

1.3 Các cách tiếp cận giải quyết bài toán

1.3.1 Phương pháp truyền thống

- Lọc cộng tác (Collaborative Filtering):
 - Dựa trên ma trận người dùng-sách, sử dụng các kỹ thuật như phân rã ma trận (Matrix Factorization) hoặc phương pháp dựa trên hàng xóm gần nhất (k-Nearest Neighbors).
 - Ưu điểm: Hiệu quả khi có dữ liệu tương tác phong phú.
 - Nhược điểm: Không hoạt động tốt trong trường hợp dữ liệu thưa thớt hoặc cold-start.
- Lọc dựa trên nội dung (Content-based Filtering):
 - Sử dụng đặc trưng của sách như thể loại, tác giả, từ khóa, hoặc nội dung văn bản để đề xuất các sách tương tự.
 - Ưu điểm: Không phụ thuộc vào dữ liệu tương tác của người dùng.
 - Nhược điểm: Khó đề xuất các sách đa dạng, dễ bị giới hạn trong các thể loại quen thuộc với người dùng.
- Phương pháp lai:
 - Kết hợp cả hai phương pháp trên để cải thiện độ chính xác và khắc phục các hạn chế riêng lẻ.

1.3.2 Phương pháp hiện đại

- Mô hình học sâu (Deep Learning):
 - Sử dụng các mạng nơ-ron như Autoencoders, Neural Collaborative Filtering (NCF) hoặc mô hình dựa trên đồ thị (Graph Neural Networks) để học các biểu diễn phức tạp của người dùng và sách.
 - Ưu điểm: Có khả năng khai thác các mẫu dữ liệu phi tuyến tính.
 - Nhược điểm: Yêu cầu lượng dữ liệu lớn để huấn luyện và khó thích nghi với dữ liệu thưa thớt.
- Học tăng cường (Reinforcement Learning):
 - Sử dụng các tác nhân học để tối ưu hóa gợi ý dựa trên phản hồi của người dùng theo thời gian thực.

- Ưu điểm: Linh hoạt, có thể thích nghi với thay đổi sở thích của người dùng.
- Nhược điểm: Phức tạp trong việc triển khai và yêu cầu thời gian huấn luyện dài.
- Meta-learning few-shot:
 - Meta-learning tập trung vào việc huấn luyện mô hình để thích nghi nhanh với các tác vụ mới chỉ với một lượng nhỏ dữ liệu (few-shot learning).
 - Trong domain sách, meta-learning few-shot có thể học từ các tác vụ gợi ý liên quan (ví dụ: các thể loại sách khác) để áp dụng cho domain sách thiếu dữ liệu.
 - Ưu điểm: Hiệu quả trong các tình huống cold-start và dữ liệu thưa thớt.
 - Nhược điểm: Phức tạp trong thiết kế và yêu cầu dữ liệu meta-training đa dạng.

1.3.3 Meta-learning few-shot như giải pháp tiềm năng

Meta-learning few-shot được xem là một giải pháp đầy triển vọng cho bài toán gợi ý trong domain sách thiếu dữ liệu. Bằng cách học cách thích nghi nhanh với các tác vụ mới, meta-learning có thể:

- Xử lý hiệu quả các trường hợp cold-start (người dùng mới, sách mới).
- Tận dụng thông tin từ các domain liên quan để cải thiện gợi ý trong domain mục tiêu.
- Giảm phụ thuộc vào dữ liệu lớn, phù hợp với các nền tảng có lượng tương tác hạn chế.

1.4 Tình hình nghiên cứu hiện tại

1.4.1 Tổng quan các nghiên cứu

- Hệ gợi ý trong domain sách:
 - Các nghiên cứu trước đây tập trung vào sử dụng lọc cộng tác và lọc dựa trên nội dung để gợi ý sách trên các nền tảng như Goodreads, Amazon, hoặc các thư viện số.
 - Một số nghiên cứu gần đây tích hợp thông tin văn bản (mô tả sách, đánh giá) vào mô hình học sâu để cải thiện độ chính xác.
 - Hạn chế: Hầu hết các nghiên cứu giả định có dữ liệu phong phú, ít tập trung vào vấn đề dữ liệu thưa thớt.
- Ứng dụng meta-learning trong hệ gợi ý:
 - Meta-learning đã được áp dụng trong một số lĩnh vực như phân loại hình ảnh, xử lý ngôn ngữ tự nhiên, nhưng ứng dụng trong hệ gợi ý còn khá mới mẻ.

- Một số nghiên cứu gần đây đã thử nghiệm meta-learning trong gợi ý cá nhân hóa, đặc biệt trong các tình huống cold-start.
- Các mô hình như MAML (Model-Agnostic Meta-Learning) hoặc Prototypical Networks đã được thử nghiệm để học cách thích nghi với các domain mới.

1.4.2 Những nhóm nghiên cứu/nhà khoa học nổi bật

- Chelsea Finn và cộng sự: Nghiên cứu về MAML và các biến thể meta-learning, ứng dụng trong nhiều lĩnh vực bao gồm học với ít dữ liệu.
- Hugo Larochelle: Tập trung vào các phương pháp few-shot learning và meta-learning trong học máy.
- Nhóm nghiên cứu tại DeepMind và Google Research: Đã có các công trình về meta-learning và ứng dụng trong các bài toán thực tiễn, bao gồm cả gợi ý.
- Các nghiên cứu tại hội nghị lớn (NeurIPS, ICML, AAAI): Các bài báo gần đây về meta-learning trong hệ gợi ý, tập trung vào cold-start và dữ liệu thưa thớt.

1.4.3 Kết quả và hạn chế

- Kết quả nổi bật:
 - Các mô hình meta-learning few-shot đạt được độ chính xác cao hơn trong các tình huống cold-start so với phương pháp truyền thống (ví dụ: độ chính xác tăng 10-20% trong một số nghiên cứu).
 - Khả năng mở rộng: Meta-learning có thể được áp dụng cho nhiều domain khác nhau, không chỉ giới hạn trong sách.
- Hạn chế:
 - Yêu cầu dữ liệu meta-training đa dạng để đảm bảo mô hình học được các đặc trưng tổng quát.
 - Độ phức tạp tính toán cao, đòi hỏi tài nguyên lớn trong giai đoạn huấn luyện.
 - Khó khăn trong việc đánh giá hiệu quả thực tiễn trên các nền tảng lớn với dữ liệu thực tế.

1.4.4 Mục tiêu nghiên cứu

- Mục tiêu chính:
 - Ứng dụng meta-learning few-shot để xây dựng một hệ gợi ý hiệu quả trong domain sách thiếu dữ liệu, tập trung vào việc giải quyết các vấn đề cold-start và dữ liệu thưa thớt.

- Phát triển mô hình có khả năng thích nghi nhanh với các sách mới hoặc người dùng mới chỉ với một lượng nhỏ dữ liệu.
- Mục tiêu phụ:
 - So sánh hiệu quả của mô hình meta-learning few-shot với các phương pháp truyền thống (lọc cộng tác, lọc dựa trên nội dung) và hiện đại (học sâu, học tăng cường) về độ chính xác, khả năng mở rộng, và tính hiệu quả trong domain sách.
 - Đề xuất các cải tiến cho mô hình meta-learning để tối ưu hóa hiệu suất trong các ứng dụng thực tiễn như thư viện số hoặc cửa hàng sách trực tuyến.

1.5 Kết luận

Trình bày tổng quan về hệ gợi ý, nhấn mạnh vai trò quan trọng của chúng trong việc cá nhân hóa trải nghiệm người dùng, đặc biệt trong domain sách với thách thức dữ liệu thưa thớt. Các phương pháp truyền thống như lọc cộng tác và lọc dựa trên nội dung, dù hiệu quả trong một số trường hợp, vẫn gặp khó khăn khi dữ liệu hạn chế. Trong khi đó, các phương pháp hiện đại như học sâu và học tăng cường đòi hỏi lượng dữ liệu lớn, không phù hợp với các tình huống cold-start. Meta-learning few-shot nổi lên như một giải pháp tiềm năng, với khả năng thích nghi nhanh và hiệu quả trong domain sách thiếu dữ liệu. Các nghiên cứu hiện tại cho thấy meta-learning đã đạt được những kết quả đáng kể, nhưng vẫn còn những thách thức cần giải quyết, như độ phức tạp tính toán và yêu cầu dữ liệu meta-training đa dạng. Những mục tiêu nghiên cứu được đề xuất sẽ là nền tảng để phát triển một hệ gợi ý hiệu quả, mở ra hướng đi mới cho các ứng dụng thực tiễn trong lĩnh vực sách và các domain tương tự. Chương tiếp theo sẽ đi sâu vào chi tiết kỹ thuật của mô hình meta-learning few-shot, bao gồm các bước triển khai, kỹ thuật xử lý dữ liệu, và phương pháp đánh giá.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1 Giới thiệu về Meta-learning Few-shot

2.1.1 Khái niệm Meta-learning

Meta-learning là một phương pháp học máy tập trung vào việc huấn luyện mô hình để thích nghi nhanh chóng với các tác vụ mới chỉ với một lượng nhỏ dữ liệu. Không giống các phương pháp học máy truyền thống yêu cầu dữ liệu lớn để đạt hiệu quả, meta-learning tận dụng các "tác vụ" từ các domain liên quan để học cách tối ưu hóa quá trình học trên dữ liệu mới.

Trong bối cảnh hệ gợi ý, meta-learning giúp mô hình học cách dự đoán sở thích của người dùng hoặc đề xuất sách trong các tình huống thiếu dữ liệu, chẳng hạn như khi có người dùng mới hoặc sách mới.

2.1.2 Few-shot Learning

Few-shot learning là một nhánh của meta-learning, tập trung vào việc học từ một số lượng rất nhỏ ví dụ thường là 1-5 mẫu, được gọi là K-shot. Trong domain sách thiếu dữ liệu, few-shot learning đặc biệt hữu ích vì:

- Nó cho phép mô hình dự đoán sở thích người dùng chỉ dựa trên một vài tương tác (ví dụ: một vài cuốn sách đã đọc hoặc đánh giá).
- Nó hỗ trợ gợi ý các sách ít phổ biến hoặc mới xuất bản, vốn có rất ít thông tin tương tác.

2.1.3 Ứng dụng trong hệ gợi ý

Meta-learning few-shot được áp dụng trong hệ gợi ý để:

- Xử lý cold-start: Tạo gợi ý chính xác cho người dùng mới hoặc sách mới mà không cần dữ liệu lớn.
- Tăng khả năng thích nghi: Học từ các domain liên quan (ví dụ: các thể loại sách khác) để áp dụng cho domain sách thiếu dữ liệu.

2.2 Mô hình Meta-learning Few-shot

Trong nghiên cứu này, chúng ta sẽ tập trung vào mô hình MAML (Model-Agnostic Meta-Learning), một trong những phương pháp meta-learning phổ biến và linh hoạt, có thể áp dụng cho hệ gợi ý. Ngoài ra, các mô hình như Prototypical Networks cũng sẽ được xem xét để so sánh.

2.2.1 Tổng quan về MAML và FOMAML

MAML (Model-Agnostic Meta-Learning) là một thuật toán meta-learning được đề xuất nhằm tìm một tập hợp tham số ban đầu tối ưu cho mô hình sao cho nó có thể thích nghi nhanh với các tác vụ mới chỉ qua vài bước tối ưu (gradient updates). Trong hệ gợi ý, MAML có thể được sử dụng để:

- Huấn luyện mô hình trên nhiều tác vụ gợi ý từ các domain liên quan (ví dụ: các thể loại sách khác nhau).
- Tinh chỉnh mô hình để gợi ý sách trong domain thiếu dữ liệu chỉ với vài mẫu tương tác.

First-Order Model-Agnostic Meta-Learning (FOMAML) là một biến thể hiệu quả về tính toán của thuật toán MAML gốc (Finn et al., 2017). Trong MAML chuẩn, quá trình meta-update yêu cầu tính đạo hàm bậc hai (second-order derivatives) để truyền gradient qua các bước inner adaptation, dẫn đến chi phí bộ nhớ và thời gian tính toán rất lớn, đặc biệt với mô hình có hàng triệu tham số

2.2.2 Tổng quan về Reptile

Reptile là một thuật toán meta-learning first-order cực kỳ đơn giản và hiệu quả về tính toán, được đề xuất như một phương pháp thay thế cho MAML mà không cần tính bất kỳ đạo hàm bậc cao nào hay gradient qua query loss.

- Cách hoạt động của Reptile dựa trên ý tưởng “di chuyển tham số meta về phía tham số đã được adapted trên support set”:
- Bắt đầu từ tham số hiện tại θ .
- Thực hiện inner adaptation trên support set trong k bước (thường 30–32 bước như trong nghiên cứu này) để thu được tham số tạm thời θ' :

$$\theta' = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\text{support}}(\theta) \quad (2.1)$$

(với α là inner learning rate).

- Sau đó cập nhật meta một cách trực tiếp:

$$\theta \leftarrow \theta + \beta(\theta' - \theta)$$

Trong đó

- β là meta learning rate (thường nhỏ, ví dụ 0.001 hoặc 0.0001 khi train dài).

- Cập nhật này tương đương với việc lấy trung bình vector hướng từ θ đến θ' qua nhiều task, giúp tham số meta dần tiến gần đến vùng có khả năng thích nghi nhanh.
- Ưu điểm nổi bật của Reptile:
 - Không cần giữ computation graph qua inner steps hay tính gradient của query loss.
 - Chi phí bộ nhớ và thời gian gần như chỉ bằng huấn luyện thông thường, dễ scale với mô hình lớn và số episode cao.
 - Thực nghiệm cho thấy Reptile đạt hiệu suất gần tương đương hoặc đôi khi vượt MAML/FOMAML trong nhiều bài toán few-shot, đặc biệt khi kết hợp với số lượng episode lớn.

2.2.3 Cấu trúc mô hình

Mô hình chính được sử dụng trong nghiên cứu là TaxonomyRecModel, một mô hình gợi ý dựa trên tích chập điểm (dot-product) được tăng cường bởi biểu diễn phân cấp thể loại sách. Mô hình này được thiết kế để tận dụng thông tin thể loại một cách hiệu quả, giúp cải thiện khả năng chuyển giao kiến thức giữa các domain (thể loại) khác nhau trong meta-learning few-shot.

Các thành phần embedding

- Mô hình bao gồm các tầng embedding riêng biệt:
 - User embedding: Biểu diễn vector cho mỗi người dùng $u \in \mathbb{R}^d$.
 - Book embedding: Biểu diễn vector cơ sở cho mỗi cuốn sách $b \in \mathbb{R}^d$.
 - Parent category embedding: Biểu diễn vector cho thể loại cha (parent category) $p \in \mathbb{R}^d$.
 - Sub-category embedding: Biểu diễn vector cho từng thể loại con (sub-category) $s_i \in \mathbb{R}^d$ (tối đa 10 sub-categories mỗi sách, sử dụng padding index nếu ít hơn).
- Tất cả các embedding được khởi tạo bằng Xavier uniform và được L2-normalize trong quá trình forward.
- Xây dựng biểu diễn item sách
 - Với mỗi sách, biểu diễn item được tính như sau:
 - Mean pooling các sub-categories:

$$\mathbf{m} = \frac{\sum_{s \in \mathcal{S}} s \cdot \mathbb{1}_{s \neq \text{pad}}}{\sum \mathbb{1}_{s \neq \text{pad}}} \quad (2.2)$$

(mask để bỏ qua padding, clamp min=1 để tránh chia zero; sau đó L2-normalize m).

- Ghép nối đặc trưng taxonomy:

$$\text{raw} = [\mathbf{b}; \mathbf{p}; \mathbf{m}] \in \mathbb{R}^{3d} \quad (2.3)$$

- Chiều tuyến tính (nếu sử dụng taxonomy): $\mathbf{i} = \text{norm}(\mathbf{W} \cdot \text{raw} + \text{bias})$ với $\mathbf{W} \in \mathbb{R}^{d \times 3d}$, bias tùy chọn. Nếu tắt taxonomy (use_taxonomy=False), biểu diễn item chỉ là $\mathbf{i} = \mathbf{b}$ (sau normalize).

- Dự đoán preference score

- Điểm tương tác giữa user u và sách i :

$$\hat{r}_{ui} = \mathbf{u}^\top \mathbf{i} \quad (2.4)$$

- Kết quả là scalar, càng cao càng thể hiện sở thích lớn.

Mô hình này đơn giản nhưng hiệu quả nhờ tích hợp trực tiếp thông tin phân cấp thể loại vào biểu diễn item, giúp kiến thức về cấu trúc taxonomy được chia sẻ giữa các task (thể loại) trong quá trình meta-learning. Biến thể không sử dụng taxonomy được triển khai để đánh giá đóng góp riêng của hierarchical taxonomy trong few-shot adaptation.

2.3 Các bước của thuật toán

2.3.1 Giai đoạn Meta-training

- Mục tiêu: Học một tập hợp tham số ban đầu (meta-parameters) cho mô hình sao cho nó có thể thích nghi nhanh với các tác vụ gợi ý mới.
- Thu thập tập tác vụ: Tạo các tác vụ meta-training từ các domain liên quan. Mỗi tác vụ bao gồm:
 - Support set: Một tập nhỏ các ví dụ (K-shot, ví dụ: 5 tương tác giữa người dùng và sách).
 - Query set: Một tập dữ liệu để đánh giá hiệu quả gợi ý sau khi tinh chỉnh.
- Khởi tạo mô hình: Sử dụng một mạng nơ-ron (ví dụ: mạng nơ-ron sâu hoặc mô hình dựa trên đồ thị) với tham số ban đầu θ .
- Inner loop (tối ưu hóa cục bộ): Đối với mỗi tác vụ cập nhật tham số tạm thời θ'_i từ θ bằng một hoặc vài bước gradient descent trên $\mathcal{D}_{support}$

$$\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{T_i}(f_{\theta}) \quad (2.5)$$

trong đó α là inner learning rate, $\mathcal{L}_{T_i}$ là hàm mất mát trên tác vụ T_i , f_θ là mô hình với tham số θ .

- Outer loop (tối ưu hóa meta): Tối ưu θ dựa trên hiệu suất của mô hình sau tinh chỉnh trên $\mathcal{D}_{\text{query}}$ của nhiều tác vụ:

$$\theta \leftarrow \theta - \beta \nabla_\theta \sum_{T_i \sim p(T)} \mathcal{L}_{T_i}(f_{\theta'_i}) \quad (2.6)$$

trong đó β là meta learning rate, $p(T)$ là phân phối các tác vụ.

- Kết quả: Một tập hợp tham số ban đầu θ tối ưu, cho phép mô hình thích nghi nhanh với các tác vụ mới.

2.3.2 Giai đoạn Meta-testing

- Mục tiêu: Tinh chỉnh mô hình trên dữ liệu sách thiếu dữ liệu để đưa ra gợi ý chính xác.
- Thu thập dữ liệu: Lấy một tập dữ liệu nhỏ từ domain sách thiếu dữ liệu (ví dụ: vài đánh giá hoặc tương tác của người dùng với sách).
- Tinh chỉnh mô hình: Sử dụng tham số ban đầu θ từ meta-training, thực hiện vài bước gradient descent trên dữ liệu mới:

$$\theta' = \theta - \alpha \nabla_\theta \mathcal{L}_{\text{new}}(f_\theta) \quad (2.7)$$

- Đưa ra gợi ý: Sử dụng mô hình đã tinh chỉnh để dự đoán sở thích người dùng hoặc đề xuất sách dựa trên đặc trưng sách và dữ liệu tương tác.

2.3.3 Tích hợp vào hệ gợi ý

- Kết hợp đặc trưng:
 - Đặc trưng sách: Sử dụng thông tin nội dung như thể loại, tác giả, từ khóa, hoặc biểu diễn văn bản (text embeddings) từ mô hình như BERT.
 - Đặc trưng người dùng: Sử dụng lịch sử tương tác (nếu có) hoặc thông tin ngữ cảnh (ví dụ: độ tuổi, sở thích chung).
- Đề xuất gợi ý: Mô hình dự đoán xác suất một người dùng sẽ quan tâm đến một cuốn sách cụ thể, sau đó xếp hạng các sách để đưa ra danh sách gợi ý.

2.4 Kỹ thuật xử lý dữ liệu thừa thớt

2.4.1 Tăng cường dữ liệu

- Sử dụng kỹ thuật như tạo dữ liệu tổng hợp (synthetic data) dựa trên các đặc trưng sách (ví dụ: tạo các mẫu tương tác giả định từ thông tin thể loại hoặc tác giả).

- Kết hợp thông tin từ các domain liên quan (ví dụ: sử dụng dữ liệu từ các thể loại sách phổ biến để tăng cường dữ liệu cho thể loại sách hiếm).

2.4.2 Biểu diễn đặc trưng

- Đặc trưng sách: Sử dụng các kỹ thuật như TF-IDF, word embeddings hoặc mô hình ngôn ngữ lớn (BERT) để biểu diễn nội dung sách.
- Đặc trưng người dùng: Tạo các vector người dùng dựa trên lịch sử tương tác hoặc thông tin ngữ cảnh, sử dụng kỹ thuật như one-hot encoding hoặc embeddings.

2.4.3 Xử lý cold-start

- Người dùng mới: Sử dụng thông tin ngữ cảnh hoặc dữ liệu từ các người dùng tương tự để khởi tạo gợi ý.
- Sách mới: Tận dụng đặc trưng nội dung để đưa sách mới vào hệ thống gợi ý.

2.5 Hàm đánh giá

2.5.1 Hàm mất mát

Trong nghiên cứu này, Bayesian Personalized Ranking (BPR) loss được sử dụng làm hàm mất mát chính xuyên suốt cả giai đoạn meta-training và inner adaptation trong meta-testing. BPR loss đặc biệt phù hợp với dữ liệu implicit feedback từ dataset Amazon Books Reviews. Công thức BPR loss:

$$\mathcal{L}_{BPR} = -\frac{1}{|\mathcal{B}|} \sum_{(u, i^+, i^-) \in \mathcal{B}} \log (\sigma(\hat{r}_{ui^+} - \hat{r}_{ui^-})) \quad (2.8)$$

Trong đó:

- u : người dùng
- i^+ : sách mà người dùng u đã tương tác tích cực (positive item)
- i^- : sách negative được sample ngẫu nhiên từ toàn bộ tập sách
- $\hat{r}_{ui^+}$: điểm dự đoán mức độ yêu thích của người dùng u đối với sách positive i^+ (dot-product sau L2-normalize)
- $\hat{r}_{ui^-}$: điểm dự đoán mức độ yêu thích của người dùng u đối với sách negative i^-
- $\sigma(\cdot)$: hàm sigmoid
- $\mathcal{B}$: batch các triplet (u, i^+, i^-)
- Loss này tối ưu trực tiếp mục tiêu ranking bằng cách đẩy score của positive item cao hơn negative item một cách pairwise.

2.5.2 Chỉ số đánh giá

Vì mục tiêu chính là few-shot ranking trên các test task hiếm (rare genres), các chỉ số đánh giá tập trung vào chất lượng thứ hạng gợi ý trong kịch bản nghiêm ngặt (1 positive item + 999 negative items toàn cục):

- Recall@10: Tỷ lệ các positive item nằm trong top-10 gợi ý
- Công thức:

$$\text{Recall@10} = \frac{\text{số positive item nằm trong top 10 gợi ý}}{\text{tổng số positive item (thường = 1 trong mỗi query)}} \quad (2.9)$$

- NDCG@10 (Normalized Discounted Cumulative Gain @10): Đánh giá chất lượng thứ hạng tổng thể, ưu tiên các positive item xuất hiện ở vị trí cao hơn (càng cao vị trí càng được trọng số lớn).
- Công thức:

$$\text{DCG@10} = \sum_{k=1}^{10} \frac{\text{rel}_k}{\log_2(k+1)} \quad (2.10)$$

$$\text{NDCG@10} = \frac{\text{DCG@10}}{\text{IDCG@10}} \quad (2.11)$$

Trong đó:

- k : Vị trí xếp hạng trong top 10.
- rel_k : Độ liên quan của item ở vị trí k .
- $\log_2(k+1)$: Logarit cơ số 2 của $(k+1)$ – yếu tố giảm dần.
- DCG@10 : Tổng gain có discount.
- IDCG@10 : DCG lý tưởng (positive xếp đầu).
- MRR (Mean Reciprocal Rank): Trung bình nghịch đảo của vị trí xếp hạng đầu tiên của positive item.
- Công thức:

$$\text{MRR} = \frac{1}{Q} \sum_{q=1}^Q \frac{1}{\text{rank}_q} \quad (2.11)$$

Trong đó:

- Q : Tổng số query (số lần đánh giá hoặc số mẫu test).
 - q : Chỉ số của từng query cụ thể (từ 1 đến Q).
 - rank_q : Vị trí xếp hạng của positive item đầu tiên trong danh sách gợi ý cho query q .
 - $1 / \text{rank}_q$: Nghịch đảo của vị trí xếp hạng (reciprocal rank).
 - $1 / Q$: Hệ số trung bình (mean) để lấy giá trị trung bình trên toàn bộ tập test.
- Các chỉ số được tính trung bình trên 800 query interactions mỗi test task sau khi thực hiện inner adaptation (150 bước) trên support set 768 mẫu. Kịch bản đánh giá này mô phỏng thực tế cold-start domain: mô hình phải xếp hạng chính xác chỉ với rất ít dữ liệu hỗ trợ từ thể loại hiếm.

2.6 So sánh tổng quan các mô hình

Bảng 2. 1 So sánh tổng quan các mô hình

Tiêu chí	MAML	FOMAML	Reptile
Bản chất	Meta-learning chuẩn	Biến thể xấp xỉ của MAML	Meta-learning dựa trên cập nhật tham số
Ý tưởng cốt lõi	Học cách học để thích nghi nhanh nhất	Giữ tư duy MAML nhưng giảm lược gradient	Học điểm khởi tạo tốt cho nhiều task
Thích nghi trong task	Fine-tune từ $\theta \rightarrow \theta'$ (giữ full graph)	Fine-tune từ $\theta \rightarrow \theta'$ (cắt graph)	Fine-tune từ $\theta \rightarrow \theta'$
Cập nhật meta	Backprop qua toàn bộ inner loop	Backprop rút gọn (bỏ gradient bậc hai)	Di chuyển θ về gần trung bình các θ'
Khả năng học quy luật thích nghi	Rất mạnh	Khá mạnh	Hạn chế
Tổng quát hoá sang task hiếm	Tốt nhất	Tốt	Trung bình

Nhận xét:

- MAML chuẩn mang lại khả năng thích nghi mạnh nhất nhờ sử dụng exact second-order gradient, nhưng chi phí tính toán và bộ nhớ rất cao, không khả thi với dataset lớn như Amazon Books Reviews trong nghiên cứu này.
- FOMAML và Reptile là hai biến thể first-order hiệu quả, được triển khai thực tế trong đề án để khắc phục hạn chế của MAML chuẩn. Cả hai đều có chi phí thấp, dễ scale với số episode lớn và đạt hiệu suất few-shot ranking tốt khi kết hợp hierarchical taxonomy embedding.
- Reptile nổi bật với độ ổn định cao, hội tụ nhanh ở giai đoạn đầu và ít nhạy cảm với hyperparameter, phù hợp cho prototyping và huấn luyện dài.
- FOMAML thường vượt trội hơn Reptile trong các run dài nhờ tận dụng trực tiếp query gradient và scheduler, mang lại Recall@10 và NDCG@10 cao hơn trên các test task hiếm.

2.7 Kết chương

Chương 2 đã trình bày tổng quan lý thuyết và thiết kế mô hình cho bài toán ứng dụng meta-learning few-shot trong hệ gợi ý sách thiếu dữ liệu. Các nội dung chính bao gồm khái niệm meta-learning, few-shot learning, các thuật toán phổ biến (MAML, FOMAML, Reptile), mô hình TaxonomyRecModel tích hợp hierarchical taxonomy embedding, cũng như cách chia task theo parent category và sử dụng BPR loss cho implicit feedback ranking.

Việc kết hợp hierarchical taxonomy giúp mô hình khai thác thông tin phân cấp thể loại sách, tạo nền tảng vững chắc để chuyển giao kiến thức từ các domain phổ biến sang domain hiếm, giải quyết hiệu quả vấn đề cold-start ở mức domain.

CHƯƠNG 3: XÂY DỰNG MÔ HÌNH

3.1 Thu thập dữ liệu

3.1.1 Trình bày dữ liệu bài toán

Sử dụng tập dữ liệu Amazon Books Reviews – một bộ dữ liệu công khai lớn trên Kaggle, chứa thông tin sách và đánh giá người dùng từ Amazon.

- Bộ dữ liệu bao gồm hai file chính:
 - books_data.csv: Thông tin chi tiết về sách (khoảng 2.1 triệu bản ghi ban đầu).
 - Books_rating.csv: Hơn 3 triệu đánh giá từ người dùng, với điểm đánh giá review/score trên thang 1.0–5.0.
- Để phù hợp với implicit feedback trong bài toán gợi ý ranking, chỉ giữ các đánh giá có review/score ≥ 4.0 làm tương tác tích cực (positive interactions). Sau merge trên cột Title, filter và xử lý, thu được hơn 1.3 triệu tương tác tích cực từ khoảng 116.288 cuốn sách unique và hàng trăm nghìn người dùng.

a) File Books_rating.csv (đánh giá):

Bảng 3. 1 Bảng mô tả các cột trong file books_rating

Cột	Mô tả	Kiểu dữ liệu
id	ID của sách	String
Title	Tiêu đề sách	String
Price	Giá sách	Float
User_id	ID của người dùng đánh giá sách	String
profileName	Tên profile của người dùng	String
review/helpfulness	Đánh giá độ hữu ích của review	String
review/score	Điểm đánh giá sách	Float
review/time	Thời gian đánh giá	Timestamp
review/summary	Tóm tắt nội dung review	String

b) File books_data.csv (thông tin sách):

Bảng 3. 2 Bảng mô tả các cột trong file books_data

Cột	Mô tả	Kiểu dữ liệu
Title	Tiêu đề sách	String
description	Mô tả sách	String

authors	Tên tác giả	String
image	Ảnh bìa sách	String
previewLink	Link truy cập preview sách	String
publisher	Tên nhà xuất bản	String
publishedDate	Ngày xuất bản	String
infoLink	Link thông tin chi tiết sách	String
categories	Danh sách thể loại, yếu tố quan trọng để parsing hierarchical taxonomy	String
ratingsCount	Số lượng đánh giá trung bình hoặc tổng rating count	Integer

Bộ dữ liệu Amazon Books Reviews rất phù hợp với đề tài vì có sự mất cân bằng tự nhiên giữa các thể loại phổ biến và hiếm, lý tưởng để đánh giá meta-learning few-shot trong cold-start domain. Thông tin hierarchical categories cũng hỗ trợ tốt việc chia task và tích hợp taxonomy embedding, tăng khả năng chuyển giao kiến thức giữa các thể loại.

3.1.2 Tiền xử lý dữ liệu


Các bước tiền xử lý dữ liệu được thực hiện nhằm làm sạch, chuyển đổi và tổ chức dữ liệu phù hợp với bài toán meta-learning few-shot theo thể loại sách. Quy trình chính bao gồm:

- Load và làm sạch dữ liệu: Đọc hai file Books_rating.csv và books_data.csv. Loại bỏ các bản ghi thiếu giá trị ở các cột quan trọng (User_id, Title, review/score). Chuyển User_id về kiểu string để xử lý nhất quán.
- Lọc implicit positive feedback: Chỉ giữ các đánh giá có review/score ≥ 4.0 làm tương tác tích cực, loại bỏ các đánh giá trung lập hoặc tiêu cực nhằm tập trung vào ranking-based recommendation.
- Merge dữ liệu: Gộp bảng đánh giá với bảng thông tin sách trên cột Title để lấy trường categories (danh sách thể loại) cho mỗi sách.
- Parsing hierarchical categories: Sử dụng ast.literal_eval để chuyển chuỗi JSON categories thành list Python. Làm sạch bằng cách strip và loại bỏ giá trị rỗng.
- Mapping sang hierarchical taxonomy: Xây dựng từ điển mapping thủ công với 12 parent categories chính. Với mỗi sách:

- Gán parent category dựa trên sub-category đầu tiên khớp.
- Lấy danh sách sub-categories khớp, tối đa 10.
- Loại bỏ hoàn toàn các sách có parent category là “Unknown / Others” để đảm bảo chất lượng task.
- Tạo chỉ mục sách: Lấy unique titles với 116.288 sách, tạo mapping book_to_idx và precompute:
 - parent_tensor: tensor chỉ số parent category cho từng sách.
 - subs_tensor: tensor ($\text{num_books} \times 10$) chứa chỉ số sub-categories
- Tạo tasks theo parent category: Nhóm tương tác theo parent, thống kê kích thước task. Chia:
 - Train tasks: 9 thể loại phổ biến.
 - Test tasks: 3 thể loại hiếm (Arts & Culture, Juvenile Nonfiction, Law & Medical).
- Subsampling users: Chọn ngẫu nhiên 100.000 người dùng hoạt động nhất (có nhiều tương tác nhất), giữ toàn bộ positive interactions của họ.

3.2 Trực quan hóa dữ liệu


a) Biểu đồ phân phối xếp hạng của rating



Hình 3. 1 Biểu đồ phân phối xếp hạng của rating

Nhận xét: Phân bố rating rất lệch về phía tích cực: rating 5.0 chiếm tỷ lệ áp đảo, tiếp theo là 4.0, tổng cộng rating ≥ 4.0 chiếm gần 80% dữ liệu. Các mức rating thấp chỉ chiếm khoảng 20%, với 1.0 thấp nhất. Điều này phản ánh hiện tượng positive bias điển hình trong dữ liệu đánh giá Amazon: người dùng thường chỉ đánh giá khi hài lòng cao, dẫn đến ít tương tác tiêu cực hoặc trung lập. Đặc trưng này rất phù hợp để chuyển sang implicit feedback bằng cách lọc rating ≥ 4.0 làm positive interactions, đồng thời nhấn mạnh nhu cầu sử dụng ranking loss thay vì regression trên rating explicit.

b) Biểu đồ thể loại sách phổ biến nhất



Hình 3. 2 Biểu đồ các thể loại sách phổ biến nhất

Nhận xét: Phân bố thể loại sách mất cân bằng mạnh: Fiction chiếm tỷ lệ áp đảo, Juvenile Fiction đứng thứ hai, trong khi các thể loại còn lại chỉ chiếm tỷ lệ nhỏ. Điều này phản ánh đặc trưng long-tail điển hình của domain sách, với một số thể loại phổ biến chiếm đa số dữ liệu và nhiều thể loại ngách hiếm, rất phù hợp để đánh giá meta-learning few-shot trong cold-start domain.

3.3 Huấn luyện mô hình

3.3.1 Mô hình MAML

Quy trình huấn luyện:

- Train tasks: 9 parent categories phổ biến (>40.000 tương tác).
- Mỗi episode: sample ngẫu nhiên support set và query set (768 mẫu mỗi) từ một train task.
- Inner adaptation: nhiều bước Adam với inner_lr = 0.001, sử dụng BPR loss và global negative sampling (giữ full computation graph để tính second-order gradient).
- Meta-update: Adam optimizer với meta_lr = 0.001

Bảng 3. 3 Kết quả đánh giá MAML

Mô hình	Recall@10	NDCG@10	MRR
MAML + Taxonomy	0.3287	0.2008	0.1787
No Taxonomy (baseline)	0.0563	0.0525	0.0557

Nhận xét:

- Sau 5000 episodes, query BPR loss giảm mạnh từ ~0.74 xuống ~0.23 và meta loss hội tụ ổn định quanh 0.25–0.26, chứng minh tham số meta được tối ưu tốt để thích nghi nhanh dù sử dụng exact second-order gradient.
- Exact MAML + Taxonomy đạt Recall@10 = 0.3287 trên test task hiếm (Law & Medical), cải thiện vượt trội so với baseline không taxonomy (chỉ 0.0563), khẳng định mạnh mẽ hiệu quả của hierarchical taxonomy embedding trong chuyển giao kiến thức.
- Tổng thể: MAML thể hiện khả năng few-shot ranking xuất sắc trong cold-start domain, vượt trội hơn các biến thể first-order về chất lượng thích nghi dù chi phí tính toán cao hơn.

3.3.2 Mô hình FOMAML

Bảng 3. 4 Kết quả đánh giá FOMAML

Mô hình	Recall@10	NDCG@10	MRR
FOMAML + Taxonomy	0.2637	0.1430	0.1234
No Taxonomy (baseline)	0.0663	0.0623	0.0653

Nhận xét:

- Sau 5000 episodes, query BPR loss và meta loss hội tụ ổn định quanh 0.65–0.67, cho thấy mô hình đã học được tham số meta tốt để thích nghi nhanh dù chưa đạt mức giảm mạnh như các run dài hơn.
- FOMAML + Taxonomy đạt $\text{Recall}@10 = 0.2637$ trên test task hiếm, cải thiện rõ rệt so với baseline không taxonomy.
- Tổng thể: FOMAML thể hiện khả năng few-shot ranking tốt trong cold-start domain, với hiệu suất ổn định và chi phí tính toán thấp hơn Exact MAML, phù hợp cho huấn luyện thực tế.

3.3.3 Mô hình Reptile

Bảng 3. 5 Kết quả đánh giá Reptile

Mô hình	Recall@10	NDCG@10	MRR
Reptile + Taxonomy	0.2825	0.1545	0.1323
No Taxonomy (baseline)	0.0725	0.0703	0.0738

Nhận xét:

- Sau 5000 episodes, query BPR loss giảm ổn định từ ~ 0.67 xuống ~ 0.58 , cho thấy mô hình hội tụ tốt và tham số meta được tối ưu hiệu quả để thích nghi nhanh.
- Reptile + Taxonomy đạt $\text{Recall}@10 = 0.2825$ trên test task hiếm, cải thiện rõ rệt so với baseline không taxonomy (chỉ 0.0725), khẳng định vai trò quan trọng của hierarchical taxonomy embedding trong chuyển giao kiến thức.

3.3.4 So sánh giữa các mô hình

Bảng 3. 6 So sánh kết quả các mô hình meta-learning

Phương pháp	Taxonomy	Recall@10	NDCG@10	MRR
MAML	Meta + Taxonomy	0.3287	0.2008	0.1787
	No Taxonomy	0.0563	0.0525	0.0557
FOMAML	Meta + Taxonomy	0.2637	0.1430	0.1234
	No Taxonomy	0.0663	0.0623	0.0653
Reptile	Meta + Taxonomy	0.2825	0.1545	0.1323
	No Taxonomy	0.0725	0.0703	0.0738

Nhận xét:

MAML đạt hiệu suất cao nhất trên mọi chỉ số ranking, chứng minh ưu thế vượt trội của second-order gradient trong thích nghi nhanh và chính xác. Reptile vượt FOMAML ở cùng số episode nhờ ổn định cao, hội tụ nhanh và ít nhạy hyperparameter. FOMAML tốt ở run ngắn nhưng có tiềm năng vượt Reptile khi train dài nhờ tận dụng query gradient và scheduler phù hợp.

Hierarchical taxonomy embedding mang lại cải thiện vượt trội gấp 4 đến 6 lần so với baseline không taxonomy, khẳng định vai trò then chốt trong chuyển giao kiến thức giữa domain phổ biến và hiếm. Tổng thể, các phương pháp first-order cân bằng tốt giữa hiệu suất và chi phí tính toán, trong khi MAML phù hợp nhất khi ưu tiên chất lượng tối đa dù tốn tài nguyên hơn.

Bảng 3. 7 Query BPR loss trên các train tasks phổ biến

Train Task	MAML	Reptile	FOMAML
Health & Lifestyle	0.2331	0.6568	0.6902
Religion & Spirituality	0.2525	0.6085	0.6557
Business & Personal	0.2997	0.6216	0.6696
Hobbies & Leisure	0.2609	0.5533	0.6629
Science & Technology	0.2620	0.5685	0.6462
Education & Language	0.2342	0.5546	0.6442
Fiction & Literature	0.2866	0.6807	0.6766
Biography & Memoir	0.2906	0.5818	0.6673

Nhận xét:


MAML đạt query BPR loss thấp nhất trên mọi train task, chứng minh khả năng hội tụ vượt trội và thích nghi sâu nhờ tận dụng exact second-order gradient, giúp mô hình học được quy luật tối ưu hóa chính xác hơn trên các task phổ biến.

Reptile đứng thứ hai với query BPR loss ổn định ở mức trung bình 0.55–0.68, thể hiện tốc độ hội tụ đều, nhanh và độ ổn định cao mà không cần gradient phức tạp.

FOMAML có query BPR loss cao hơn, phản ánh tốc độ hội tụ chậm hơn ở run ngắn do chỉ sử dụng first-order approximation, dù vẫn giảm ổn định qua các episode.

Kết quả khẳng định MAML tối ưu nhất về chất lượng thích nghi trên train tasks phổ biến, tạo nền tảng vững chắc cho few-shot adaptation trên test task hiếm, dù đòi hỏi chi phí tính toán cao hơn đáng kể so với hai biến thể first-order.

3.4 Demo hệ thống gợi ý sách



Hình 3. 3 Website demo gợi ý sách theo thể loại cho người dùng

Website demo được phát triển bằng framework Streamlit, cung cấp giao diện web tương tác đơn giản, trực quan, giúp người dùng trải nghiệm hệ thống gợi ý sách dựa trên mô hình meta-learning (FOMAML, Full MAML, Reptile) kết hợp taxonomy embedding. Các chức năng chính bao gồm:

- Hiển thị thông tin Taxonomy Hierarchy và Task Sizes
- Sidebar chứa hai phần mở rộng (expander):
 - Task Sizes: Bảng hiển thị số lượng interactions theo từng Parent Category (tổng 12 thể loại cha, từ Fiction & Literature với 699,814 interactions đến Law & Medical với 10,862 interactions).

- Taxonomy Hierarchy: Cây phân cấp thể loại (Books $\rightarrow$ Parent $\rightarrow$ Sub-categories), ví dụ Fiction & Literature chứa Fiction, Juvenile Fiction, Poetry, Drama, Comics & Graphic Novels, v.v.
- Chọn Model Meta-Learning. Người dùng chọn một trong ba mô hình đã huấn luyện: FOMAML, Full MAML, Reptile
- Gợi ý sách
- Khi nhấn nút " Gợi Ý Sách", hệ thống:
- Tạo tensor user (lập lại user_id cho tất cả sách).
- Tính score cho toàn bộ sách bằng forward pass của TaxonomyRecModel (kết hợp user_emb, book_emb, parent_emb, mean sub_emb).
- Lấy top-K sách có score cao nhất.
- Hiển thị kết quả dạng grid 3 cột, mỗi sách bao gồm: Ảnh bìa, tiêu đề sách, danh sách categories, điểm score dự đoán (đã normalize).

3.5 Kết chương

Chương 3 đã trình bày chi tiết toàn bộ quá trình thực nghiệm ứng dụng meta-learning few-shot cho hệ gợi ý sách trong domain thiếu dữ liệu trên dataset Amazon Books Reviews. Các nội dung chính bao gồm: thu thập dữ liệu từ hai file chính Books_rating.csv và books_data.csv, tiền xử lý dữ liệu với lọc implicit positive feedback khi review/score ≥ 4.0 , parsing hierarchical categories, mapping taxonomy với 12 parent categories, subsampling 100.000 users hoạt động nhất, trực quan hóa phân bố rating với positive bias mạnh khi 60.2% rating 5.0 và phân bố thể loại khi Fiction chiếm 56.4% thể hiện long-tail rõ nét, cũng như huấn luyện và đánh giá ba mô hình meta-learning MAML, Reptile và FOMAML, tất cả đều kết hợp hierarchical taxonomy embedding trong TaxonomyRecModel.

Kết quả thực nghiệm trên test task hiếm Law & Medical cho thấy MAML đạt hiệu suất cao nhất với Recall@10 = 0.3287, NDCG@10 = 0.2008 và MRR = 0.1787, tiếp theo là Reptile với Recall@10 = 0.2825 và FOMAML với Recall@10 = 0.2637. Việc tích hợp hierarchical taxonomy embedding mang lại cải thiện vượt trội gấp 4 - 6 lần so với baseline không taxonomy trên mọi mô hình, khẳng định vai trò then chốt của thông tin phân cấp thể loại parent và subcategories trong việc chuyển giao kiến thức hiệu quả từ các domain phổ biến sang domain hiếm, giải quyết tốt vấn đề cold-start ở mức domain.

KẾT LUẬN

Kết quả đạt được

Đồ án đã thành công ứng dụng meta-learning few-shot vào xây dựng hệ gợi ý sách trong domain thiếu dữ liệu, đạt được các kết quả chính sau:

- MAML đạt hiệu suất cao nhất trong few-shot ranking trên test task hiếm, với $\text{Recall@10} = 0.3287$, $\text{NDCG@10} = 0.2008$, $\text{MRR} = 0.1787$, chứng minh khả năng thích nghi nhanh và chính xác trong cold-start nghiêm ngặt nhờ exact second-order gradient.
- Reptile và FOMAML cũng đạt kết quả tốt Recall@10 lần lượt 0.2825 và 0.2637, cân bằng hiệu suất với chi phí tính toán thấp hơn, phù hợp triển khai thực tế.
- Việc tích hợp hierarchical taxonomy embedding mang lại cải thiện vượt trội so với baseline không taxonomy trên mọi mô hình, khẳng định vai trò then chốt của thông tin phân cấp thể loại trong chuyển giao kiến thức giữa domain phổ biến và hiếm.
- Xây dựng website demo gợi ý hỗ trợ few-shot thích nghi theo thể loại, cho phép người dùng mới nhận gợi ý cá nhân hóa kèm ảnh bìa sách.

Hạn chế

Các mô hình meta-learning đạt hiệu suất vượt trội so với phương pháp truyền thống trong cold-start domain, nhưng vẫn tồn tại một số hạn chế: số lượng task thực tế còn hạn chế do dữ liệu thưa thớt ở nhiều thể loại ngách, các chỉ số ranking vẫn ở mức trung bình do bản chất dataset sparse, và chi phí tính toán của MAML cao hơn đáng kể so với Reptile/FOMAML.

Hướng phát triển

Để nâng cao hơn nữa hiệu quả hệ thống, một số hướng nghiên cứu tiếp theo có thể thực hiện:

- Kết hợp hybrid giữa MAML và Reptile/FOMAML: sử dụng MAML khởi tạo tham số global, sau đó fine-tune.
- Tích hợp mô hình ngôn ngữ lớn để trích xuất đặc trưng từ mô tả sách, đánh giá người dùng và tiêu đề, cải thiện chất lượng nội dung trong few-shot.
- Mở rộng dataset bằng dữ liệu tiếng Việt từ các nền tảng như Tiki, Fahasa, Waka hoặc sử dụng Amazon Books đầy đủ để tăng số lượng task và độ đa dạng thể loại.

TÀI LIỆU THAM KHẢO

- [1] Bộ data: [Amazon Books Reviews](#)
- [2] Paper: Li, M., Hu, S., Zhu, F., & Zhu, Q. (2024). Few-Shot Learning for Cold-Start Recommendation. In Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024), pages 7185–7195, Torino, Italia. ELRA and ICCL.
- [3] N. V. Hậu, P. M. Chuẩn, và N. V. Quyết, “Giáo trình Học máy cơ bản”, Nhà xuất bản Khoa học và Kỹ thuật, 2022.
- [4] Ziegler, C.-N., McNee, S. M., Konstan, J. A., & Lausen, G. (2005). Book-Crossing Dataset. Available at: <http://www2.informatik.uni-freiburg.de/~cziegler/BX/>
- [5] Finn, C., Abbeel, P., & Levine, S. (2017). Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks. Proceedings of the 34th International Conference on Machine Learning (ICML), Sydney, Australia.
- [6] Zhu, Q., Li, M., Zhu, F., & Hu, S. (2020). Few-Shot Learning for Cold-Start Recommendation. arXiv preprint arXiv:2007.08784.